



数理统计

Elegant $\text{\LaTeX}$ 经典之作

作者: Ethan Deng & Liam Huang

组织: Elegant $\text{\LaTeX}$ Program

时间: April 9, 2022

版本: 4.3

自定义: 信息



不要以为抹消过去，重新来过，即可发生什么改变。——比企谷八幡

目录

第 1 章	第一章基础知识	1
第 2 章	参数估计	14
2.1	3.3 点估计量评价	17
2.2	估计量的大样本性质	20
第 3 章	作业	24
3.1	第一周作业	24
3.2	第二次作业	28
3.2.1	45,3,4,6	28
3.2.2	46,1,2,3	32
3.3	第三次作业	37
3.4	第五周作业	42
3.5	第七周作业	49
3.5.1	3.4	55
第 4 章	纯作业	58
4.1	第一周作业	58
4.2	第二周作业	58
4.3	第三周	59
4.4	第五周作业	60
4.5	第七周作业	61

第1章 第一章基础知识

定义 1.1 (偏度系数 Skewness Coefficient)

设随机变量 X 的均值为 μ , 标准差为 σ , 其总体偏度 γ_1 定义为三阶标准化矩:

$$\gamma_1 = E \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{E[(X - \mu)^3]}{\sigma^3}$$

对于样本 $x_1, x_2, \dots, x_n$, 样本偏度 g_1 定义为:

$$g_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right]^{3/2}}$$

当 $\gamma_1 > 0$ 时, 分布为右偏; 当 $\gamma_1 < 0$ 时, 分布为左偏; 对于对称分布, 若其三阶中心矩存在, 则 $\gamma_1 = 0$ 。

东邪的 tip 1.1

一阶中心矩永远等于 0, 二阶会抹杀正负号无法看见方向此外, 三次方对离均值较远的“尾部”更加敏感。在统计学中, 偏度主要关心的就是那个“尾巴”有多长。三次方能吧远离均值的极端值权重放大, 从而更准确地捕捉到分布的倾斜趋势。

例题 1.1 设某种电子元件的寿命 X 服从指数分布 $\mathcal{E}(\lambda)$, 其概率密度为

$$f(x; \lambda) = \begin{cases} \frac{1}{\lambda} e^{-\frac{x}{\lambda}}, & x > 0; \\ 0, & \text{其他,} \end{cases}$$

其中 $\lambda > 0$ 。求样本 $(X_1, X_2, \dots, X_n)^T$ 的概率分布。

解 依题意有 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \lambda)$, 故所求的概率分布为

$$\prod_{i=1}^n f(x_i; \lambda) = \begin{cases} \frac{1}{\lambda^n} \exp \left(-\frac{1}{\lambda} \sum_{i=1}^n x_i \right), & x_1, x_2, \dots, x_n > 0; \\ 0, & \text{其他.} \end{cases}$$

定义 1.2

设 $(X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本, $f(x; \theta)$ 为总体的概率密度函数 (或分布律)。由于样本中的每个观测值 $X_1, X_2, \dots, X_n$ 相互独立且与总体同分布 (i.i.d.), 则称它们的联合概率密度函数 (或联合分布律) 为该样本的概率分布, 记为:

$$L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

其中, $x_1, x_2, \dots, x_n$ 为样本观测值, θ 为待估参数。

 **笔记** 关于“联合分布连乘积”意义的直观理解: 黑箱摸球实验

为了理解为什么需要将 n 个样本的密度函数相乘, 我们可以设定如下实验场景:

- 场景设定: 假设一个黑箱中的纸条数字服从指数分布 $\mathcal{E}(\lambda)$, 但参数 λ 未知。我们独立抽样得到三张纸条, 数字分别为 $x_1 = 1, x_2 = 2, x_3 = 3$ 。
- 连乘的逻辑:
 - 抽到 1 的可能性由 $f(1; \lambda)$ 决定;
 - 抽到 2 的可能性由 $f(2; \lambda)$ 决定;
 - 抽到 3 的可能性由 $f(3; \lambda)$ 决定。

由于抽样是独立的, 这三个数字“同时出现”的总可能性 (联合密度) 就是它们各自可能性的乘积:

$$L(\lambda) = f(1; \lambda) \times f(2; \lambda) \times f(3; \lambda)$$

• 公式推导的意义：

- 评估证据：如果我们代入不同的 λ (如 $\lambda = 1$ 和 $\lambda = 5$)，连乘积结果更大的那个 λ ，在逻辑上就更像是产生这组数据的“真相”。
- 信息压缩：通过连乘，我们发现所有的样本信息最终都浓缩在了 $\sum x_i$ (样本总和) 中。
- 决策基础：这个连乘得到的“联合分布”式子，是后续进行极大似然估计 (寻找最优参数) 的唯一数学依据。

结论：连乘积不是单纯的数学堆砌，它是将分散的观测数据 (证词) 汇聚成统一逻辑证据 (结案报告) 的过程。

2.1

定义 1.3 (总体、样本与抽样)

设 X 表示研究对象某个指标，其取值分布 F_X (或总体分布) 称为总体。通过观察或试验，从总体中获取部分个体指标取值的过程称为抽样。

把一次抽样结果看成随机向量

$$(X_1, X_2, \dots, X_n)^T,$$

则称其为来自总体 X (或 F_X) 的一个样本；其概率分布称为样本分布。对应的具体取值

$$(x_1, x_2, \dots, x_n)$$

称为样本观察值。其中 n 称为样本大小，也称样本容量。



东邪的 tip 1.2 (概率论里面学的都是总体)

1. 概率论里，通常先给定随机变量 X 的分布，再研究它的性质；
2. 数理统计里，则把研究对象的某个指标记为 X ，把它的分布看作总体分布，再根据样本去反推这个分布中的未知信息。

定义 1.4 (简单随机样本)

若样本 $X_1, X_2, \dots, X_n$ 满足：

- 各分量同分布，即每个 X_i 都与总体 X 有相同分布；
- 各分量相互独立，

则称 $X_1, X_2, \dots, X_n$ 为来自总体 X 的简单随机样本，记作

$$X_1, X_2, \dots, X_n \text{ i.i.d.}$$

若总体分布函数为 $F(x)$ (或概率密度为 $f(x)$)，常记作

$$X_1 \sim F(x) \quad (\text{或 } X_1 \sim f(x)).$$



东邪的 tip 1.3

从 X 中选取具体的 X_1 就是抽样，一次抽样并不意味着只得到一个数；一次抽样可以抽取 n 个个体，从而得到一个容量为 n 的样本

$$X_1, X_2, \dots, X_n.$$

其中每个 X_i 是样本观察值，而整组数据才称为一个样本。

例题 1.2 设总体 $X \sim E(\lambda)$, 其概率密度为

$$f(x; \lambda) = \begin{cases} \frac{1}{\lambda} e^{-x/\lambda}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

若 $X_1, X_2, \dots, X_n$ 为来自该总体的简单随机样本, 则样本分布为

$$\prod_{i=1}^n f(x_i; \lambda) = \begin{cases} \frac{1}{\lambda^n} \exp\left(-\frac{1}{\lambda} \sum_{i=1}^n x_i\right), & x_1, x_2, \dots, x_n > 0, \\ 0, & \text{其他.} \end{cases}$$

 **笔记** 所以这个概率分布就是一次抽样抽到这个样本的概率对吧也就是 100 个观测值概率的乘积; 若总体是连续型, 这里写出的则是联合概率密度, 而不是单点概率。

定义 1.5 (参数、参数空间与分布族)

总体分布中出现的常数称为参数; 若有多个参数, 它们组成的向量称为参数向量; 其值未知时称为未知参数。参数所有可能取值构成的集合称为参数空间, 常记为 Θ 。

若总体概率密度 (或概率函数) 写成

$$f(x; \theta), \quad \theta \in \Theta,$$

则由参数空间中所有可能参数值所对应的一族总体分布

$$\{f(x; \theta) : \theta \in \Theta\}$$

称为总体分布族; 对应的一族样本分布

$$\left\{ \prod_{i=1}^n f(x_i; \theta) : \theta \in \Theta \right\}$$

称为样本分布族。



 **笔记** 在数理统计中, 未知的通常不是样本本身, 而是总体分布中的参数。比如正态总体 $N(\mu, \sigma^2)$ 中未知的是 μ, σ^2 , 指数分布 $E(\lambda)$ 中未知的是 λ , 二项分布 $B(n, p)$ 中未知的是 p 。因此把总体写成

$$f(x; \theta)$$

就是在说明: 分布的形式已知, 但其中参数 θ 的真实取值未知。这样一来, 问题就从“研究一个模糊的总体”转化为“研究未知参数 θ ”。

定义 1.6 (统计模型与参数统计问题)

样本分布族称为统计模型。若总体分布形式已知, 只需对其中未知参数作出推断, 则称这类问题为参数统计问题。



 **笔记** 因此, 统计模型通常由两部分确定: 一是参数空间 Θ , 二是由 Θ 所决定的样本分布族。换言之, 所谓“建立统计模型”, 本质上就是说明样本来自哪一族分布, 以及其中哪些参数是未知的。

定义 1.7 (统计量与抽样分布)

设 $X_1, X_2, \dots, X_n$ 是来自总体的样本。若一个量

$$T = T(X_1, X_2, \dots, X_n)$$

是样本的完全已知函数, 即它只依赖于样本而不含未知参数, 则称 T 为统计量。

代入样本观察值

$$x_1, x_2, \dots, x_n$$

后所得的

$$T(x_1, x_2, \dots, x_n)$$

称为统计量的观测值。

由于样本 $(X_1, X_2, \dots, X_n)$ 是随机向量，统计量作为样本的函数也是随机变量；统计量的概率分布称为它的抽样分布。



定义 1.8 (常见统计量)

由样本构造的常见统计量有：样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

样本方差

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

以及极差

$$R = \max_{1 \leq i \leq n} X_i - \min_{1 \leq i \leq n} X_i.$$

它们都只依赖于样本，因而都是统计量。



2.2

定义 1.9 (顺序统计量)

设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本，将 $X_1, X_2, \dots, X_n$ 按从小到大的顺序排列为

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)},$$

称 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 为 $X_1, X_2, \dots, X_n$ 的顺序统计量；称 $X_{(r)}$ 为第 r 个顺序统计量。

显见 $X_{(1)} = \min_{1 \leq i \leq n} \{X_i\}$ 是样本中的最小值，而 $X_{(n)} = \max_{1 \leq i \leq n} \{X_i\}$ 是最大值。对第 r 个顺序统计量 $X_{(r)}$ 的分布有如下结论。



例题 1.3 灯泡寿命与顺序统计量 为了直观理解这些抽象符号，我们看一个生活中的“灯泡寿命”例子。

1. 什么是 $X_1, X_2, \dots, X_n$? (原始样本)

想象你买了 3 个型号完全一样的灯泡（此时 $n = 3$ ），装在客厅的吊灯里。

- X_1 ：第 1 个灯泡实际亮了多少小时。
- X_2 ：第 2 个灯泡实际亮了多少小时。
- X_3 ：第 3 个灯泡实际亮了多少小时。

当你还没拆封时，它们每个人的寿命都服从厂家给出的分布 $F(x)$ 。比如厂家说“平均寿命 1000 小时”，这就是总体分布。

2. 什么是 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$? (排序后的统计量)

等你把这 3 个灯泡用坏了，你会得到三个具体的数，比如： $X_1 = 1200$ 小时， $X_2 = 800$ 小时， $X_3 = 1050$ 小时。顺序统计量就是把这些数按从小到大重新排队：

- $X_{(1)} = 800$ ：这是第一个坏掉的灯泡寿命（最小值）。
- $X_{(2)} = 1050$ ：这是第二个坏掉的灯泡寿命（中位数）。
- $X_{(3)} = 1200$ ：这是最后一个坏掉的灯泡寿命（最大值）。

3. 公式 (2.2.2) 在说什么 ? (直观推导)

公式 $f_{(r)}(x) = rC_n^r F^{r-1}(x)[1 - F(x)]^{n-r} f(x)$ 看着吓人，其实在讲一个排列组合的故事。假设你想求“第二个灯泡在 $x = 1000$ 小时准时坏掉”的概率密度，这意味着在那一时刻：

- 正好有 1 个灯泡寿命就是 1000（对应 $f(x)$ ）。
- 有 $r - 1$ 个（即 1 个）灯泡比 1000 短，已经先坏了（对应 $F(x)^{r-1}$ ）。
- 有 $n - r$ 个（即 1 个）灯泡比 1000 长，还在亮着（对应 $[1 - F(x)]^{n-r}$ ）。
- rC_n^r （也就是 $\frac{n!}{(r-1)!(n-r)!}$ ）：是因为你并不关心到底是哪一只灯泡先坏，哪一只后坏，所以要算上所有的排列组合情况。

总结

- X_i 是杂乱无章的原始数据（比如班里随机 10 个人的身高）。
- $X_{(r)}$ 是排好序的数据（比如这 10 个人里身高排第 3 的那个人）。

在可靠性工程里，如果你把灯泡串联， $X_{(1)}$ （第一个坏的）就决定了电路什么时候断；如果你是并联备份， $X_{(n)}$ （最后一个坏的）才决定了系统什么时候彻底瘫痪。

定理 1.1 (顺序统计量的分布)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 是相应的顺序统计量，则对 $1 \leq r \leq n$ 有

$$P\{X_{(r)} \leq x\} = rC_n^r \int_0^{F(x)} t^{r-1}(1-t)^{n-r} dt. \quad (2.2.1)$$

若 $F(x)$ 具有概率密度 $f(x)$ ，则 $X_{(r)}$ 也有概率密度

$$f_{(r)}(x) = rC_n^r F^{r-1}(x)[1 - F(x)]^{n-r} f(x). \quad (2.2.2)$$

 **笔记** 顺序统计量与二项分布的关系 这个积分的物理意义来自于一个著名的恒等式。第 r 个顺序统计量 $X_{(r)} \leq x$ 等价于“至少有 r 个样本落在了 x 的左边”。用二项分布来写就是：

$$P\{X_{(r)} \leq x\} = \sum_{k=r}^n C_n^k [F(x)]^k [1 - F(x)]^{n-k}$$

数学家们发现，这个离散的求和公式，竟然可以完美地写成一个连续积分的形式：作业 2.2.3

$$\sum_{k=r}^n C_n^k p^k (1-p)^{n-k} = \frac{n!}{(r-1)!(n-r)!} \int_0^p t^{r-1}(1-t)^{n-r} dt$$

这里 $p = F(x)$ 。所以，这个积分的数学意义就是“累积概率的连续化表达”。

东邪的 tip 1.4 (学习新公式都要把他拆成几个部分)

回忆一下 $F(X) = P(X \leq x)$ ，积分区域其实就是每一个点都要带入自变量位置然后乘上他那个点的微元也就是 dt 再累加。F 上面是 $r-1$ 代表前面的 $r-1$ 个， $n-r$ 代表 r 后面的 $n-r$ 个。 $n-r+1+r-1=n$

东邪的 tip 1.5

有 c 几几自然想到排列组合。上面 P 以求导， $F(x)$ 自然替换 t 的位置就成了下面。**1.** 代数上的等价首先，你要知道 rC_n^r 其实只是多项式系数 (Multinomial Coefficient) 的另一种写法：

$$rC_n^r = r \cdot \frac{n!}{r!(n-r)!} = r \cdot \frac{n!}{r \cdot (r-1)!(n-r)!} = \frac{n!}{(r-1)!1!(n-r)!}$$

这个公式的右边非常直观，它代表把 n 个不同的样本分成了三组：

- 第一组：有 $r - 1$ 个样本，它们都小于 x ；
- 第二组：有 1 个样本，它恰好等于 x （这就是我们要找的第 r 个）；
- 第三组：有 $n - r$ 个样本，它们都大于 x 。

例题 1.4 班级考试成绩与分位数 为了帮你透彻理解这些定义，我们用一个“班级考试成绩”的例子来拆解。假

设一个班级有 n 个学生，他们的分数就是样本 $X_1, X_2, \dots, X_n$ 。

1. 样本中位数 (Sample Median) ——找“最中间”的人

中位数的规则很简单：如果人数是奇数，就取正中间那个；如果是偶数，就取中间两个人的平均分。

- **场景 A：人数为奇数** ($n = 5$)：假设成绩排序后是：60, 70, **75**, 85, 90。这里 $n = 2k + 1 = 5$ ，所以 $k = 2$ 。中位数 $M = X_{(k+1)} = X_{(3)} = 75$ 分。
- **场景 B：人数为偶数** ($n = 6$)：假设成绩排序后是：60, 70, **75, 80**, 85, 90。这里 $n = 2k = 6$ ，所以 $k = 3$ 。中位数 $M = \frac{1}{2}(X_{(3)} + X_{(4)}) = \frac{75+80}{2} = 77.5$ 分。

2. 样本上 α 分位数——找“前 10%”的门槛

“上 α 分位数”其实就是：从高往低数，排在前面那 α 比例的门槛。

- **例子**： $n = 10$ 个人，想找上 $\alpha = 0.2$ 分位数（即前 20% 的分数线）
- 计算索引： $[n(1 - \alpha) + 0.5] = [10(1 - 0.2) + 0.5] = [8.5] = 8$ 。
- 结论：排序后的第 8 个数 $X_{(8)}$ 就是上 0.2 分位数。
- 直观理解：总共 10 个人，第 8、9、10 名是前 30%。第 8 名正好是跨入“前 20%”梯队的那个守门员。

3. 总体分位数 (x_α) ——理想状态的“及格线”

总体分位数是针对整个分布（比如全国所有考生的理想模型）来说的。

- **例子**：假设全国成绩服从 0 到 100 的均匀分布 $U[0, 100]$
- 分布函数 $F(x) = \frac{x}{100}$ （对于 $0 \leq x \leq 100$ ）。
- **求上 $\alpha = 0.1$ 分位数**（即前 10% 的分数线）：根据定义，我们要找 x_α 使得 $F(x_\alpha) \geq 1 - 0.1 = 0.9$ 。
 $\frac{x}{100} = 0.9 \implies x = 90$ 。
- **物理意义**：在理想模型中，只要你考到 90 分，你就超过了 90% 的人，成功挤进前 10%。

4. 为什么定义里要用 $\inf$ (下确界)？

这是为了处理那些“不连续”的情况（比如掷骰子）。

- 假设你想找掷骰子点数的“上 0.5 分位数”（中位数）。点数的分布函数是阶梯状的。当 $x = 3$ 时， $F(3) = 0.5$ ；当 x 稍微大一点点，概率可能就跳上去了。
- **$\inf$ 的作用**：它像一个自动定位装置，即便分布函数在某个地方有断层或平台，它也能帮你精准锁定第一个“达标” ($\geq 1 - \alpha$) 的那个点。

总结

- M (中位数) 是为了看“大众水平”。
- x_α (上分位数) 是为了看“优秀水平”的门槛。
- 样本分位数就是用手头这几个具体的数，去估算那个理想中的“门槛”。

定义 1.10 (分位数与中位数)

对于分布函数 $F(x)$ 以及给定的数 $\alpha \in (0, 1)$ ，定义 x_α 为

$$x_\alpha = \inf\{x : F(x) \geq 1 - \alpha\},$$

称其为该分布的上 α 分位数（或者下 $1 - \alpha$ 分位数）。分布 F 的中位数定义为

$$M_F = \frac{1}{2}(\sup\{x : F(x) \leq 0.5\} + \inf\{x : F(x) \geq 0.5\}).$$

设 $X_1, X_2, \dots, X_n$ 是来自分布函数为 $F(x)$ 之分布的简单随机样本。样本的上 α 分位数定义为 $X_{([n(1-\alpha)+0.5])}$ 。样本中位数定义为

$$M = \begin{cases} X_{(k+1)}, & n = 2k + 1; \\ \frac{1}{2}(X_{(k)} + X_{(k+1)}), & n = 2k, \end{cases}$$

其中 k 为正整数。

由定义有 $F(x_\alpha) \geq 1 - \alpha$ 且 $F(x_\alpha - 0) \leq 1 - \alpha$ ；对于连续型分布，有 $F(x_\alpha) = 1 - \alpha$ 。 $X_{([n(1-\alpha)+0.5])}$ 和

M 分别是与总体量 x_α 和 M_F 对应的统计量。由顺序统计量可以引入经验分布函数的概念。



东邪的 tip 1.6

看到 $\inf$ 也就是下极限，还有 $\sup$ 也就是知道他的出现只是为了解决离散的点或者极限不在集合里面比如 $x \in (0, 1)$ 他没有最大值但是有上界



笔记 指示函数 I 的直观理解 指示函数 (Indicator Function) 是数学中用来表达“逻辑判断”的工具。我们可以把它想象成一个“检测开关”或一个“投票器”。其核心规则只有一条：“满足条件就投 1 票，不满足就投 0 票。”

针对公式中的符号 $I_{[X_i, \infty)}(x)$ ，我们可以将其拆解为以下三个部分：

- x ：是你现在手里拿着的那个“尺子”或观测点（比如 $x = 2$ ）；
- $[X_i, \infty)$ ：是检测的“合格区间”，表示所有大于等于 X_i 的范围；
- I ：是执行检测的程序逻辑。

具体运行逻辑如下：

- 如果你的尺子 x 掉进了区间 $[X_i, \infty)$ 里面（即 $x \geq X_i$ ），那么这个 I 就输出 1；
- 如果你的尺子 x 还不够到 X_i （即 $x < X_i$ ），那么这个 I 就输出 0。

在经验分布函数 $F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{[X_i, \infty)}(x)$ 中，这个 I 就在为每一个样本点 X_i 进行检测：凡是那些“躺在 x 左边”的样本，都会让开关变成 1，从而被计入总数中。

例题 1.5 奶茶店等待时间与经验分布函数 假设你在奶茶店随机观测了 $n = 5$ 个人的等待时间（单位：分钟），排序后为：

$$X_{(1)} = 5, \quad X_{(2)} = 10, \quad X_{(3)} = 12, \quad X_{(4)} = 15, \quad X_{(5)} = 25$$

1. 为什么要用指示函数加和再平均？

我们要计算 $F_5(13)$ ，即等待时间小于 13 分钟的概率。公式为：

$$F_5(13) = \frac{1}{5} \sum_{i=1}^5 I_{[X_i, \infty)}(13)$$

这里的每一项都在投票：

- $X_1 = 5 \leq 13$ ，投 1 票；
- $X_2 = 10 \leq 13$ ，投 1 票；
- $X_3 = 12 \leq 13$ ，投 1 票；
- $X_4 = 15 > 13$ ，投 0 票；
- $X_5 = 25 > 13$ ，投 0 票。

总票数为 3，平均票数为 $3/5 = 0.6$ 。这就是我们利用样本对总体概率的“平均估计”。

2. 现实意义总结

- **估算真相**：在不知道奶茶店排队规律（总体分布）的情况下，0.6 是我们根据现有数据能给出的最合理答案。
- **动态更新**：如果你再多测几个人，分母 n 变大，分子也会更新，这个估计会越来越准。

3. 数学意义总结

经验分布函数将离散的观测转化为一个右连续的阶梯函数。根据格列汶科定理，当 $n \rightarrow \infty$ 时，这种基于“求平均”得来的经验估计，将以概率 1 一致地收敛于真正的自然规律。

定义 1.11 (经验分布函数)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, 对任意实数 x , 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{[X_i, \infty)}(x) = \frac{1}{n} \{X_i : X_i \leq x, i = 1, 2, \dots, n\}^\#, \quad (2.2.6)$$

称函数 $F_n(x)$ 为 $X_1, X_2, \dots, X_n$ 的经验分布函数, 式中 $I_A(x)$ 表示集合 A 的指示函数: 当 $x \in A$ 时, $I_A(x) = 1$, 否则 $I_A(x) = 0$ 。

易见, 经验分布函数也可写成

$$F_n(x) = \begin{cases} 0, & x < X_{(1)}; \\ k/n, & X_{(k)} \leq x < X_{(k+1)}, k = 1, 2, \dots, n-1; \\ 1, & x \geq X_{(n)}. \end{cases} \quad (2.2.7)$$



定理 1.2 (经验分布函数的性质)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F_n(x)$ 为其经验分布函数。则对于任意实数 x , 有

1. $P\{\lim_{n \rightarrow \infty} F_n(x) = F(x)\} = 1$.
2. $\lim_{n \rightarrow \infty} P\left\{\frac{\sqrt{n}(F_n(x) - F(x))}{\sqrt{F(x)[1-F(x)]}} \leq y\right\} = \int_{-\infty}^y \phi(u) du$, 其中 $\phi(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$ 为 $N(0, 1)$ 的概率密度函数。



笔记 公式 (2.2.2) 的构造逻辑 该公式的左侧实际上是对经验分布函数 $F_n(x)$ 进行的标准化 (Standardization) 处理。

1. 统计背景

由于 $nF_n(x)$ 服从二项分布 $B(n, p)$, 其中 $p = F(x)$, 根据二项分布的性质:

- 均值 $E[F_n(x)] = p = F(x)$
- 方差 $Var(F_n(x)) = \frac{p(1-p)}{n} = \frac{F(x)[1-F(x)]}{n}$

2. 构造标准化变量

根据中心极限定理 (CLT), 一个随机变量减去期望再除以其标准差, 当 $n \rightarrow \infty$ 时服从标准正态分布:

$$\frac{F_n(x) - E[F_n(x)]}{\sqrt{Var(F_n(x))}} = \frac{F_n(x) - F(x)}{\sqrt{F(x)[1-F(x)]/n}} = \frac{\sqrt{n}(F_n(x) - F(x))}{\sqrt{F(x)[1-F(x)]}}$$

3. 与高斯分布的联系

等式右侧的 $\int_{-\infty}^y \phi(u) du$ 正是标准正态分布 (高斯分布) 的累积分布函数 $\Phi(y)$ 。这表明经验分布函数的点收敛速度是 $\frac{1}{\sqrt{n}}$ 阶的。

定理 1.3 (格列汶科 (Glivenko) 定理)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F_n(x)$ 为其经验分布函数, 记 $D_n = \sup_{-\infty < x < \infty} |F_n(x) - F(x)|$, 则有

$$P\left\{\lim_{n \rightarrow \infty} D_n = 0\right\} = 1.$$



笔记 $D_n = \sup |F_n(x) - F(x)|$:

这是 $F_n(x)$ 和 $F(x)$ 之间最大的垂直偏差。之所以用 $\sup$ (上确界), 是因为我们要确保在 x 轴的任何一个点上, 两者都要足够接近。

$P\{\lim_{n \rightarrow \infty} D_n = 0\} = 1$:

这意味着这种收敛是“几乎处处收敛”的。无论真实的分布 $F(x)$ 是正态分布、均匀分布还是某种奇怪的分

布, 只要样本量够大, 样本就能百分之百代表总体。

2.3

定义 1.12 (卡方分布, 那个像 x 的就念卡)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$ 。令 $\xi = \sum_{i=1}^n X_i^2$, 则称 ξ 的分布为具有自由度 n 的 χ^2 分布。记作 $\xi \sim \chi^2(n)$ 。



东邪的 tip 1.7 (卡方分布要记的公式)

$$E(Y) = k, \quad \text{Var}(Y) = 2k.$$

 **笔记** 自由度更准确地说, 是指真正能自由变化的独立信息个数。

例如, 若

$$Y = Z_1^2 + \dots + Z_n^2, \quad Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1),$$

则 $Y \sim \chi^2(n)$ 。这是因为这里有 n 个彼此独立的标准正态变量, 所以自由度就是 n 。

但若存在约束, 自由度就会减少。例如在样本方差中,

$$\sum_{i=1}^n (X_i - \bar{X})^2$$

虽然看起来有 n 项, 但由于

$$\sum_{i=1}^n (X_i - \bar{X}) = 0,$$

其中一项实际上可由其余各项决定, 因此真正能自由变化的只有 $n-1$ 个, 故自由度为 $n-1$ 。

东邪的 tip 1.8

卡方是一个具体的值他是由每一次所有的 x_i 的平方和算出来的。从 1 到 10 随机抽五个数。每抽一次都可以算出一个卡方。然后把每抽五次当成一个动作, 抽 100 次这样卡也有分布了他服从的技术自由度为 5 的卡方分布。只要对于一个量或者一个设计求出的值, 只要每一次结果不一样他的值就会有分布。但这里有一个问题 1 到 10 是均匀分布到, 要求正太分布的话可以换成从 100000 个人里面抽五个人记录他们的身高。还要进行标准正态化。

 **笔记 1. 理论定义与背景**

若 n 个随机变量 $X_i \sim N(0, 1)$ 且相互独立, 则其平方和 $\xi = \sum_{i=1}^n X_i^2$ 服从自由度为 n 的卡方分布, 记作 $\xi \sim \chi^2(n)$ 。它是衡量观察值与理论值偏离程度的核心工具。

2. 理论模型与皮尔逊统计量

- 理论原型: $\chi^2 = \sum X_i^2$, 基于理想的标准正态变量。
- 应用工具: 皮尔逊统计量 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 。该公式通过分母 E 进行归一化, 使观测偏差在数学特性上趋近于理想卡方分布。

3. 与样本方差的“桥梁”关系

样本方差 s^2 与卡方分布通过以下标准化公式紧密相连:

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$$

两者本质皆为“平方和”: χ^2 是均值为 0、方差为 1 的理论平方和; 而样本方差是经离差标准化与缩放后的现实平方和。由此, 卡方分布成为了推断总体方差、进行区间估计的数学依据。

定理 1.4

设 $\xi \sim \chi^2(n)$, 则 ξ 的概率密度为

$$f(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}, & x > 0; \\ 0, & x \leq 0. \end{cases} \quad (1.1)$$



伽马函数 (Gamma Function)

伽马函数是阶乘函数在复数域上的扩展, 其积分定义为:

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt \quad (\text{Re}(z) > 0) \quad (1.2)$$

东邪的 tip 1.9

所以分母上 2 的 n 次方上为了和 x 配凑出 x/2 的形式。而陪完了以后积分就是 n/2-1+1= 拉姆达 n/2



笔记 1. 结构拆解: 三位一体

我们可以把这个概率密度函数看作是一个“核心部件”装在一个“标准化外壳”里:

$$f(x) = \underbrace{\frac{1}{2^{n/2} \Gamma(n/2)}}_{\text{归一化常数}} \cdot \underbrace{e^{-x/2}}_{\text{指数衰减项}} \cdot \underbrace{x^{n/2-1}}_{\text{形状调节项}} \quad (1.3)$$

- 形状调节项 ($x^{n/2-1}$): 决定了函数在 $x \rightarrow 0$ 时的形态。若 $n = 2$, 该项为 1, 曲线从纵轴出发; 若 $n > 2$, 它决定了曲线从原点爬升的速度。
- 指数衰减项 ($e^{-x/2}$): 源自正态分布的“基因”, 负责让概率在 x 增大时快速收敛, 防止概率“飘走”。
- 归一化常数: 它的唯一作用是确保曲线下方的总面积 (全概率) 恒等于 1。

定理 1.5 (n 个平方和加 m 个平方和加起来自然是 m+n 个平方和, 就是这两个得独立)

设 $\xi \sim \chi^2(m)$, $\eta \sim \chi^2(n)$, ξ 与 η 相互独立, 则有

$$\xi + \eta \sim \chi^2(m+n).$$



引理 1.1

设 $X_1, X_2, \dots, X_n$ 相互独立, 且

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n.$$

设 $A = (a_{ij})_{n \times n}$ 为一个 $n \times n$ 正交矩阵, 记

$$X = (X_1, X_2, \dots, X_n)^T, \quad Y = AX.$$

则 Y 的各分量 $Y_1, Y_2, \dots, Y_n$ 相互独立, 且

$$Y_i \sim N\left(\sum_{k=1}^n a_{ik} \mu_k, \sigma^2\right), \quad i = 1, 2, \dots, n.$$



1. **独立性保持:** 原始变量 $X_1, \dots, X_n$ 是相互独立的。经过正交矩阵 A 变换后, 新生成的变量 $Y_1, \dots, Y_n$ 依然保持相互独立。
2. **分布形式与方差不变:** 每个 Y_i 依然服从正态分布。最关键的是, 方差 σ^2 保持不变, 只有均值发生了线性变换 (变为 $\sum_{k=1}^n a_{ik} \mu_k$)。

定理 1.6 (柯赫伦 (Cochran) 定理)

设 $X_1, X_2, \dots, X_n$ i.i.d., 且 $X_1 \sim N(0, 1)$, 又设 $A_1, A_2, \dots, A_k$ 为非负定的 $n \times n$ 矩阵, 记

$$X = (X_1, X_2, \dots, X_n)^T, \\ Q_i = X^T A_i X, \quad i = 1, 2, \dots, k.$$

若

$$Q_1 + Q_2 + \dots + Q_k = \sum_{i=1}^n X_i^2,$$

且

$$\text{rank}(A_i) = n_i, \quad i = 1, 2, \dots, k,$$

则 $Q_1, Q_2, \dots, Q_k$ 相互独立且分别有

$$Q_i \sim \chi^2(n_i)$$

的充要条件为

$$n = \sum_{i=1}^k n_i.$$



笔记 [柯赫伦 (Cochran) 定理: 平方和的“拆分艺术”]

- 这个定理 (定理 1.6) 在数理统计中具有奠基性的地位, 它本质上回答了一个核心问题: 什么时候我们可以把一个总平方和拆成几个相互独立的卡方分布?
- **1.** 定理背景假设你有 n 个相互独立且服从标准正态分布 $N(0, 1)$ 的随机变量 $X_1, X_2, \dots, X_n$ 。它们的总平方和 $\sum_{i=1}^n X_i^2$ 本身就是一个自由度为 n 的卡方分布 $\chi^2(n)$ 。
- **2.** 定理的核心逻辑如果你试图将这个总平方和拆解为 k 个二次型之和, 即 $Q_1 + Q_2 + \dots + Q_k = \sum_{i=1}^n X_i^2$, 其中每个 $Q_i = X^T A_i X$, 且 $\text{rank}(A_i) = n_i$ 。
- 定理给出了一个充分必要条件: 当且仅当这些矩阵的秩之和正好等于变量的总个数时, 即 $n = \sum_{i=1}^k n_i$, 这 k 个拆分出来的部分 Q_i 就会具备极好的数学性质:
 - 相互独立: 它们之间互不影响, 没有冗余的信息交叉。
 - 服从卡方分布: 每一个 Q_i 都服从自由度为 n_i 的卡方分布, 即 $Q_i \sim \chi^2(n_i)$ 。

定义 1.13 (t 分布- student 分布)

设随机变量 X, Y 相互独立, $X \sim N(0, 1)$, $Y \sim \chi^2(n)$ 。令

$$\xi = \frac{X}{\sqrt{Y/n}},$$

则 ξ 的分布称为具有自由度 n 的 t 分布, 记作 $\xi \sim t(n)$ 。



1. 为什么要这么构造? (解决“未知方差”的痛点)

在理想状态下, 我们算标准分

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

时, 需要知道总体的标准差 σ 。但在现实的生物统计或实验中, 我们根本不知道真正的 σ 。

- 我们只能用样本标准差 S 来代替 σ 。
- 当你把 σ 换成 S 后, 这个统计量就不再服从正态分布了, 因为它分母上的 S 也是一个带有随机性的变量。
- 于是数学家构造了 $\xi = \frac{X}{\sqrt{Y/n}}$:
 - **分子 X :** 对应标准正态分布 $N(0, 1)$ 。

- **分母 Y/n** : 对应样本方差的分布 (即卡方分布除以自由度)。
- **独立性**: 分子分母相互独立。

这样构造出来的结果, 就是一个专门处理小样本、且总体方差未知情形的分布。

定理 1.7

设 $\xi \sim t(n)$, 则 ξ 的概率密度为

$$f(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < x < \infty.$$



东邪的 tip 1.10 (t 分布密度公式的拆解)

- 咱们得把这个公式拆成核 (**Kernel**) 和归一化常数 (**Coefficient**) 两部分, 用逻辑去“拼”出它。
- **1. 先抓“灵魂”**: 核部分 $\left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$ 。
- 这是决定分布形状的部分。
- 底数 $\left(1 + \frac{x^2}{n}\right)$: 你可以把它看作是正态分布 $e^{-x^2/2}$ 的一种“变体”。当 $n \rightarrow \infty$ 时, 根据重要极限公式 $(1 + 1/n)^n \rightarrow e$, 这个底数最终会变回正态分布。
- 指数 $-\frac{n+1}{2}$: 这里的 n 代表分母里卡方变量的自由度, 1 代表分子里标准正态变量的自由度。两者加起来除以 2, 就是总体的“能量分配”。
- **2. 再配“外壳”**: 系数部分 $\frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)}$ 。
- 这部分的唯一目的就是让全域积分等于 1。
- **Gamma 的位次**: 分子永远是“大的”, 即核里那个指数的正值 $\frac{n+1}{2}$; 分母是“小的”, 即原始自由度的一半 $\frac{n}{2}$ 。
- 常数项 $\sqrt{n\pi}$: $\sqrt{\pi}$ 是正态分布带出来的, $\sqrt{n}$ 是为了抵消核里那个 x^2/n 带来的缩放。

定义 1.14 (费希尔-斯内德克分布 (Fisher-Snedecor distribution).)

设随机变量 X, Y 相互独立, $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$, 令

$$\xi = \frac{X/m}{Y/n},$$

则 ξ 的分布称为具有自由度 m 和 n 的 F 分布, 记作 $\xi \sim F(m, n)$ 。



笔记

1. 它是怎么构造出来的?

你可以把它理解为“比率的比率”。

正如图片中定义的, 如果你有两个相互独立的随机变量 X 和 Y , 它们分别服从自由度为 m 和 n 的卡方分布, 那么它们的“单位贡献比”

$$\xi = \frac{X/m}{Y/n}$$

就服从自由度为 (m, n) 的 F 分布。

2. 它有什么核心作用?

在数学和数据分析实践中, F 分布主要用来干这三件事:

- **比较方差 (方差齐性检验)**: 用来判断两组独立数据的波动程度 (方差) 是否显著不同。如果 F 值很大, 说明分子的波动远大于分母。
- **方差分析 (ANOVA)**: 这是它最出名的舞台。通过比较“组间差异”与“组内差异”的比值, 来判断多个样本均值之间是否存在显著差异。这在你感兴趣的生物统计研究中极其常用。
- **线性回归的显著性检验**: 用来判断你建立的整个回归模型是否真的有效, 还是仅仅是随机噪声凑出来

的。

定理 1.8 (F 的概率密度)

设 $\xi \sim F(m, n)$, 则 ξ 的概率密度为

$$f(x) = \begin{cases} \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} m^{\frac{m}{2}} n^{\frac{n}{2}} x^{\frac{m}{2}-1} (n+mx)^{-\frac{m+n}{2}}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$



定理 1.9 (正态总体样本均值与样本方差的分布定理)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

则

1. $\bar{X} \sim N(\mu, \sigma^2/n)$;
2. $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$;
3. $\bar{X}$ 与 s^2 相互独立。



1. 样本均值的分布

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

说明从正态总体抽样后, 样本均值仍然服从正态分布, 且波动变小到了 σ^2/n 。也就是: 均值的估计越来越稳定。

2. 样本方差的分布

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$$

说明样本方差经过标准化后服从卡方分布。也就是: 方差也有明确的抽样分布, 所以才能做方差估计和区间推断。

3. 样本均值与样本方差相互独立

$$\bar{X} \text{ 与 } s^2 \text{ 相互独立}$$

这是正态总体下非常特殊、非常重要的性质。也就是: 位置信息 (均值) 和离散程度信息 (方差) 彼此分开, 不互相干扰。

第2章 参数估计

例题 2.1 设总体 $X \sim N(\mu, 4)$, 其中 μ 未知, 记 $\theta = \mu$, $\Theta = \mathbb{R}$. 对总体作 4 次观测, 得样本 $X = (X_1, X_2, X_3, X_4)^T$. 若观测值为 $x = (8, 9, 11, 10)^T$, 则:

1. **估计量**: 取样本均值作为 μ 的点估计量, 即 $\hat{\mu}(X) = \bar{X} = \frac{1}{4}(X_1 + X_2 + X_3 + X_4)$.
2. **估计值**: 将样本观测值代入估计量, 得 $\hat{\mu}(x) = \bar{x} = \frac{8+9+11+10}{4} = 9.5$.
3. **置信区间**: 由于 $\bar{X} \sim N(\mu, \frac{4}{4}) = N(\mu, 1)$, 取置信水平 95%, 由 $z_{0.975} = 1.96$, 得 μ 的 95% 置信区间为 $[\bar{X} - 1.96 \frac{2}{\sqrt{4}}, \bar{X} + 1.96 \frac{2}{\sqrt{4}}] = [\bar{X} - 1.96, \bar{X} + 1.96]$. 代入 $\bar{x} = 9.5$, 得 $[9.5 - 1.96, 9.5 + 1.96] = [7.54, 11.46]$. 因此, 本例中估计量为 $\hat{\mu}(X) = \bar{X}$, 估计值为 $\hat{\mu}(x) = 9.5$, 95% 置信区间为 $[7.54, 11.46]$.

定义 2.1 (样本中心矩)

设 $X_1, X_2, \dots, X_n$ i.i.d., 是取自总体 X 的一个样本, 则称 $\hat{\alpha}_k$ 为总体 X 的 k 阶样本原点矩, $\hat{\beta}_k$ 为总体 X 的 k 阶样本中心矩.

笔记

- 二阶样本中心矩: $\hat{\beta}_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, 用来描述样本的离散程度, 也就是数据围绕样本均值的波动大小. 它与样本方差本质上是同一个东西, 只差一个修正系数.
- 三阶样本中心矩: $\hat{\beta}_3 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3$, 用来描述样本分布的偏斜程度. 若它大于 0, 通常表示分布右偏; 若小于 0, 通常表示分布左偏; 若接近 0, 通常表示分布较对称.
- 四阶样本中心矩: $\hat{\beta}_4 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^4$, 用来描述样本分布的峰态, 反映数据分布是更尖、更平, 或者尾部是否更厚.

笔记 $X \sim F_\theta(x)$ 表示随机变量 X 服从一个由参数 θ 决定的分布, 也就是说 X 的分布函数为 $F_\theta(x)$. 其中 θ 取不同的值, 就对应这一族分布中的不同具体分布. $F(x)$ 可以是正态分布可以是均匀分布这个只是抽象的表示.

例题 2.2 设总体均值为 μ , 现不直接估计 μ , 而是要估计参数 $\theta = \mu^2$. 令 $\alpha = \mu$, 则 θ 可写为 $\theta = \theta(\alpha) = \alpha^2$. 又因为 μ 的一个自然估计量是样本均值 $\alpha(X) = \bar{X}$, 故由代入估计法, 将 $\theta(\alpha) = \alpha^2$ 中的 α 用 $\alpha(X) = \bar{X}$ 代替, 得到 θ 的估计量为

$$\theta(\alpha(X)) = (\bar{X})^2.$$

因此, μ^2 的代入估计量为 $\bar{X}^2$.

东邪的 tip 2.1

矩阵就是用来同时解方程的

笔记 上述方法称为矩估计法. 其基本思想是: 若总体分布中含有 k 个未知参数 $\theta = (\theta_1, \theta_2, \dots, \theta_k)^T$, 则选取总体的前 k 个原点矩 $\alpha_1, \alpha_2, \dots, \alpha_k$, 并将它们表示为参数的函数, 即 $\alpha_l = \alpha_l(\theta_1, \theta_2, \dots, \theta_k)$, $l = 1, \dots, k$. 再用相应的样本原点矩 $\frac{1}{n} \sum_{i=1}^n X_i$, $\frac{1}{n} \sum_{i=1}^n X_i^2, \dots, \frac{1}{n} \sum_{i=1}^n X_i^k$ 分别代替总体原点矩, 得到关于 $\theta_1, \theta_2, \dots, \theta_k$ 的方程组

$$\begin{cases} \alpha_1(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i, \\ \alpha_2(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^2, \\ \vdots \\ \alpha_k(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^k. \end{cases}$$

将该方程组的解 $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)^T$ 作为参数 θ 的估计量, 称为矩估计量.

例题 2.3 设总体 $X \sim N(\mu, \sigma^2)$, 其中 μ, σ^2 都未知. 现用矩估计法估计参数 μ 与 σ^2 .

总体的一阶原点矩与二阶原点矩分别为 $E(X) = \mu$ 与 $E(X^2) = \mu^2 + \sigma^2$. 用样本原点矩 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 和

$\frac{1}{n} \sum_{i=1}^n X_i^2$ 分别代替它们，得到方程组

$$\mu = \bar{X}, \quad \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

解得

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2.$$

因此， μ 与 σ^2 的矩估计量分别为 $\bar{X}$ 和 $\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$ 。

定义 2.2 (似然函数 likelihood function, 要求互相独立服从一种类型的分布)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x; \theta)$, $\theta \in \Theta$ 。令

$$L(\theta; x) = L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

为样本 $X = (X_1, \dots, X_n)^T$ 的概率密度 (或概率函数), 视其为 θ 的函数, 称为相应于样本 X 的似然函数; 也称 $L(\theta; X)$ 为相应于样本 X 的似然函数。

东邪的 tip 2.2

似然就是想通过这个函数确定参数的大小

定义 2.3 (MLE 用来确定参数的)

设相应于样本 $X = (X_1, X_2, \dots, X_n)^T$ 的似然函数为 $L(\theta; x)$ 。若 $\hat{\theta}(x) = \hat{\theta}(x_1, x_2, \dots, x_n)$ 满足

$$L(\hat{\theta}(x); x) = \max_{\theta \in \Theta} L(\theta; x),$$

则称 $\hat{\theta}(X)$ 为 θ 的最大似然估计量, 简记为 MLE (Maximum likelihood estimator)。

定理 2.1 (求最大似然估计量的三种常见情形)

设似然函数为 $L(\theta; x)$, 则求最大似然估计量时, 常见有以下三种情形:

- 若 $L(\theta; x)$ 关于 θ 连续可导, 且 Θ 为开区域, 则通常先解似然方程组

$$\frac{\partial L(\theta; x)}{\partial \theta_j} = 0, \quad j = 1, 2, \dots, k,$$

或等价地解对数似然方程组

$$\frac{\partial \ln L(\theta; x)}{\partial \theta_j} = 0, \quad j = 1, 2, \dots, k.$$

- 若 $L(\theta; x)$ 关于 θ 有间断点, 则不能直接用似然方程, 需结合似然函数的具体形式分段讨论, 在定义域内直接比较其大小。
- 若参数 θ 取离散值, 则常通过比较相邻参数值处似然函数的大小, 来确定使 $L(\theta; x)$ 取得最大值的参数。

定理 2.2 (最大似然估计在一一变换下会“跟着变过去”)

设 $X \sim f(x; \theta)$, $\theta \in \Theta$, X 是来自于该分布的一个样本, $\hat{\theta}(X)$ 是 θ 的最大似然估计量。设 $\eta = g(\theta)$ 是由 Θ 到 $\hat{\Theta}$ 上的一一映射, 则 $g(\hat{\theta}(X))$ 是 η 的最大似然估计量。

 **笔记** 可以让整个最大的 θ 可以不止一个

定义 2.4 (M 估计)

设样本为 $X_1, \dots, X_n$, 参数为 θ 。若 $\hat{\theta}$ 是通过最小化

$$\sum_{i=1}^n \rho(X_i, \theta)$$

得到的估计, 其中 ρ 是关于误差的某个对称凸函数, 则称 $\hat{\theta}$ 为参数 θ 的一个 **M** 估计。

等价地, 若 $\hat{\theta}$ 满足估计方程

$$\sum_{i=1}^n \psi(X_i, \theta) = 0,$$

其中 ψ 常可看作某个函数 ρ 的导数, 则由该方程得到的估计也称为 **M** 估计。



东邪的 tip 2.3

很多 **M** 估计就是为了减弱离群点的影响

例题 2.4 设样本为

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 10,$$

现用 **M** 估计来估计位置参数 θ 。

1. 若取

$$\rho(u) = u^2,$$

则对应的 **M** 估计为最小化

$$\sum_{i=1}^3 \rho(x_i - \theta) = (1 - \theta)^2 + (2 - \theta)^2 + (10 - \theta)^2.$$

解得

$$\hat{\theta} = \frac{1 + 2 + 10}{3} = \frac{13}{3}.$$

此时得到的就是样本均值。

2. 若取

$$\rho(u) = |u|,$$

则对应的 **M** 估计为最小化

$$\sum_{i=1}^3 \rho(x_i - \theta) = |1 - \theta| + |2 - \theta| + |10 - \theta|.$$

解得

$$\hat{\theta} = 2.$$

此时得到的就是样本中位数。

这说明: **M** 估计的核心思想是先选定损失函数 ρ , 再令总损失最小; 不同的 ρ 会导出不同的估计量。

定义 2.5 (Bayes 估计)

设样本 $X = (X_1, X_2, \dots, X_n)^T$ 来自条件分布 $f(x | \theta)$, 参数 θ 的先验分布为 $\pi(\theta)$ 。在给定样本 X 后, 由贝叶斯公式, θ 的后验分布为

$$p(\theta | X) = \frac{f(X | \theta) \pi(\theta)}{\int_{\Theta} f(X | \theta) \pi(\theta) d\theta}.$$

对于待估参数函数 $g(\theta)$ ，若以其后验均值

$$\hat{g}(X) = \int_{\Theta} g(\theta) p(\theta | X) d\theta = \frac{\int_{\Theta} g(\theta) f(X | \theta) \pi(\theta) d\theta}{\int_{\Theta} f(X | \theta) \pi(\theta) d\theta}$$

作为点估计，则称 $\hat{g}(X)$ 为 $g(\theta)$ 的 **Bayes** 估计，也称后验均值估计。



东邪的 tip 2.4 ($\propto$ 表示正比于)

(proportional to), $A \propto B$ 即 $A = c \cdot B$ ，其中 c 为与关心变量无关的常数。在贝叶斯推断中，由于

$$p(\mu | \mathbf{X}) = \frac{f(\mathbf{X} | \mu) \cdot \pi(\mu)}{f(\mathbf{X})}$$

分母 $f(\mathbf{X})$ 与 μ 无关，故直接写

$$p(\mu | \mathbf{X}) \propto f(\mathbf{X} | \mu) \cdot \pi(\mu)$$

省去分母使计算更简洁，配方完成后自然归一化。



笔记 三个关键概念：

1. 先验分布 $\pi(\theta)$ ：在看到数据之前，你对 θ 的主观判断。比如你觉得一枚硬币正面概率大概在 0.5 左右，这就是先验。
2. 似然函数 $f(X | \theta)$ ：给定参数 θ ，观测到样本 X 的概率。这是数据给你的信息。
3. 后验分布 $p(\theta | X)$ ：看到数据 X 之后，对 θ 的更新判断：

$$p(\theta | X) = \frac{f(X | \theta) \pi(\theta)}{\int_{\Theta} f(X | \theta) \pi(\theta) d\theta}$$

简单说就是：后验 $\propto$ 似然 $\times$ 先验，分母只是归一化常数让概率加起来等于 1。

东邪的 tip 2.5

然后大公式里面的积分就是归一化常数和条件概率里面分母的累加是一样的这里是积分

例题 2.5 抛硬币的 Bayes 估计 设正面概率 θ 的先验为 $\pi(\theta) \sim \text{Beta}(2, 2)$ ，抛硬币 10 次观测到 7 次正面。由 Beta-Binomial 共轭，后验为

$$\theta | X \sim \text{Beta}(2 + 7, 2 + 3) = \text{Beta}(9, 5),$$

Bayes 估计（后验均值）为 $\hat{\theta} = \frac{9}{14} \approx 0.643$ ，相比频率派 MLE $\hat{\theta}_{\text{MLE}} = 0.7$ ，结果被先验适当拉向 0.5。

2.1 3.3 点估计量评价

定义 2.6 ($g(\theta)$ 的无偏估计量)

设 $\hat{g}(\mathbf{X})$ 是 $g(\theta)$ 的估计量，若对于任意 $\theta \in \Theta$ 都有

$$E_{\theta}(\hat{g}(\mathbf{X})) = g(\theta),$$

则称 $\hat{g}(\mathbf{X})$ 为 $g(\theta)$ 的无偏估计量。



估计量的期望等于真实值，就叫无偏估计

例题 2.6 样本均值是总体均值的无偏估计 设总体均值 μ 未知，取样本 $X_1, X_2, X_3 = 4, 5, 9$ ，样本均值为

$$\bar{X} = \frac{4 + 5 + 9}{3} = 6.$$

若真实总体均值 $\mu = 6$, 则 $E(\bar{X}) = \mu = 6$, 即 $\bar{X}$ 是 μ 的无偏估计。

 **笔记** 无偏性与有效性衡量的是估计方法的好坏, 而非样本本身。对同一批样本, 不同估计量的优劣由以下两个标准评价:

- 无偏性: 估计量的期望等于真实参数, 即无系统误差。
- 有效性: 在所有无偏估计量中, 方差最小, 即估计结果最稳定。

「样本取得好不好」对应的是抽样方法 (如随机抽样、分层抽样), 是独立的概念。

定义 2.7 (有效估计量)

设 $\hat{g}(\mathbf{X})$ 和 $\tilde{g}(\mathbf{X})$ 都是 $g(\theta)$ 的无偏估计量, 若

$$\text{Var}_{\theta}(\tilde{g}(\mathbf{X})) \geq \text{Var}_{\theta}(\hat{g}(\mathbf{X})), \quad \forall \theta \in \Theta,$$

且大于号至少在某个 $\theta \in \Theta$ 成立, 则称 $\hat{g}(\mathbf{X})$ 比 $\tilde{g}(\mathbf{X})$ 有效。比值

$$e = \frac{\text{Var}_{\theta}(\hat{g}(\mathbf{X}))}{\text{Var}_{\theta}(\tilde{g}(\mathbf{X}))}$$

称为 $\tilde{g}(\mathbf{X})$ 相对于 $\hat{g}(\mathbf{X})$ 的效率。



东邪的 tip 2.6

$g(\mathbf{X})$ 就是对 $\mathbf{X}$ 操作算出一个 θ 然后, 看见 Var 就知道他比较稳定性了

例题 2.7 样本均值与样本中位数的有效性比较 设总体 $X \sim N(\mu, 1)$, 取样本量 $n = 5$ 。样本均值 $\bar{X}$ 与样本中位数 m 都是 μ 的无偏估计, 但

$$\text{Var}(\bar{X}) = \frac{1}{5} = 0.2, \quad \text{Var}(m) \approx \frac{\pi}{2 \times 5} \approx 0.314.$$

效率为 $e = \frac{0.2}{0.314} \approx 0.637$, 故 $\bar{X}$ 比 m 更有效。

定义 2.8 (一致最小方差无偏估计量)

设 $\hat{g}(\mathbf{X})$ 是 $g(\theta)$ 的一个无偏估计量, 且 $\text{Var}_{\theta}(\hat{g}(\mathbf{X})) < \infty$ 。若对 $g(\theta)$ 的任意无偏估计量 $g^*(\mathbf{X})$, 都有

$$\text{Var}_{\theta}(\hat{g}(\mathbf{X})) \leq \text{Var}_{\theta}(g^*(\mathbf{X})), \quad \forall \theta \in \Theta,$$

则称 $\hat{g}(\mathbf{X})$ 为 $g(\theta)$ 的一致最小方差无偏估计量, 简记作 UMVUE (Uniformly minimum variance unbiased estimator)。



在所有无偏估计里, 方差最小的那个就叫 UMVUE。

定理 2.3 (UMVUE 的充要条件)

设 $\mathcal{U}$ 非空, 则 $\delta(\mathbf{X}) \in \mathcal{U}$ 为 $g(\theta)$ 的 UMVUE 的充要条件是: 对任意 $\delta_0(\mathbf{X}) \in \mathcal{U}_0$, 有

$$E_{\theta}(\delta(\mathbf{X})\delta_0(\mathbf{X})) = 0, \quad \forall \theta \in \Theta.$$



东邪的 tip 2.7

$\mathcal{U}$ 是所有无偏估计的集合 $\mathcal{U}_0$ 就是期望是 0 的无偏估计的集合

 **笔记** 符号说明:

- $\mathcal{U}$: $g(\theta)$ 的所有无偏估计量构成的集合
- $\mathcal{U}_0$: 所有零无偏估计量的集合, 即满足 $E_{\theta}(\delta_0(\mathbf{X})) = 0$ 的估计量
- $\delta(\mathbf{X})$: 待验证是否为 UMVUE 的候选估计量

定理的本质: $\delta(\mathbf{X})$ 是 UMVUE $\iff$ 它与所有零无偏估计量正交, 即

$$E_{\theta}(\delta(\mathbf{X})\delta_0(\mathbf{X})) = 0, \quad \forall \theta \in \Theta, \forall \delta_0 \in \mathcal{U}_0.$$

直觉上, δ_0 是「纯噪声」(期望为零, 不含有效信息)。 δ 与所有噪声正交, 说明其中没有掺入任何多余成分, 因此方差已达最小。

UMVUE 如果存在, 则在以概率 1 相等的意义下是唯一的, 这就是下面的定理。

定理 2.4 (UMVUE 的唯一性)

设 $\delta(\mathbf{X})$, $\delta'(\mathbf{X})$ 都是 $g(\theta)$ 的 UMVUE, 则

$$P_{\theta}(\delta(\mathbf{X}) = \delta'(\mathbf{X})) = 1, \quad \forall \theta \in \Theta.$$

定义 2.9 (正则条件)

设分布族为 $\{f(x; \theta) : \theta \in \Theta\}$, 其中 θ 为一维未知参数, 所谓正则条件是指:

1. Θ 为开区间;
2. 分布族有共同支撑, 即支撑集 $A = \{x : f(x; \theta) > 0\}$ 与 θ 无关;
3. $\forall x \in A$, $\frac{\partial f(x; \theta)}{\partial \theta}$ 在 Θ 上存在, 且满足 $E_{\theta}\left(\frac{\partial \ln f(x; \theta)}{\partial \theta}\right) = 0, \quad \forall \theta \in \Theta$;
4. Fisher 信息量

$$I(\theta) = E_{\theta}\left[\left(\frac{\partial \ln f(x; \theta)}{\partial \theta}\right)^2\right] = \int_A \left(\frac{\partial \ln f(x; \theta)}{\partial \theta}\right)^2 f(x; \theta) dx > 0, \quad \forall \theta \in \Theta.$$

 **笔记** 正则条件的本质是保证 C-R 下界的推导在数学上成立, 每个条件各自排除一类麻烦:

- 条件 1 (Θ 为开区间): 保证对 θ 求导合法, 排除参数在边界处导数无意义的情况。
- 条件 2 (支撑集与 θ 无关): 排除积分上下限随 θ 变动的情况 (如 $U(0, \theta)$), 从而保证积分与求导可交换顺序。
- 条件 3 (得分函数期望为零): 即 $E_{\theta}\left(\frac{\partial \ln f(x; \theta)}{\partial \theta}\right) = 0$, 是积分与求导交换顺序的直接体现, 也是推导 C-R 下界的关键一步。
- 条件 4 ($I(\theta) > 0$): 保证 Fisher 信息量有限且为正, 使得 C-R 下界 $\frac{1}{I(\theta)}$ 有实际意义。

四个条件合在一起, 确保对数似然函数关于 θ 足够光滑, C-R 不等式方可成立。

 **笔记** [Fisher 信息量] Fisher 信息量 $I(\theta)$ 度量样本 X 中包含的关于参数 θ 的信息量, 定义为

$$I(\theta) = \text{Var}\left(\frac{\partial}{\partial \theta} \ln f(X; \theta)\right).$$

为什么取对数? 取对数是为了归一化:

$$\frac{\partial}{\partial \theta} \ln f = \frac{1}{f} \cdot \frac{\partial f}{\partial \theta},$$

相当于把导数除以 f 本身, 变成相对变化率, 消除量纲影响。

为什么取方差? $S(X; \theta) = \frac{\partial}{\partial \theta} \ln f(X; \theta)$ 仍是随机变量, 方差是描述其平均波动程度最自然的选择。又由 $E[S] = 0$, 故

$$I(\theta) = \text{Var}(S) = E(S^2),$$

方差等于二阶矩, 计算更方便。 $I(\theta)$ 越大, θ 越好估计。

定理 2.5 (Cramér-Rao 不等式)

设总体分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足正则条件 1—4, 待估函数 $g(\theta)$ 有一阶导数 $g'(\theta)$ 。 $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$ 是取自总体的一个样本, $\hat{g}(\mathbf{X}) = \hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的无偏估计量, 且满足

$$\frac{\partial}{\partial \theta} \int_{A^n} \hat{g}(x_1, \dots, x_n) \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n = \int_{A^n} \hat{g}(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \left(\prod_{i=1}^n f(x_i; \theta) \right) dx_1 \cdots dx_n,$$

[需要满足积分顺序可交换] 则有

$$\text{Var}_\theta(\hat{g}(\mathbf{X})) \geq \frac{(g'(\theta))^2}{nI(\theta)}, \quad \forall \theta \in \Theta. \quad (2.1)$$

 **笔记** 该定理给出了任意无偏估计量方差的下界 $\frac{(g'(\theta))^2}{nI(\theta)}$, 称为 **C-R** 下界, 无论构造多么巧妙的无偏估计量, 其方差都不可能低于此值。下界由三部分决定:

1. $(g'(\theta))^2$: 待估函数本身的复杂程度, $g(\theta)$ 变化越剧烈, 下界越大;
2. $I(\theta)$: Fisher 信息量, 反映总体模型本身所含的信息量, $I(\theta)$ 越大, 参数越容易估计准确; $I(\theta)$ 可视为大小为 1 的样本所提供的信息量;
3. n : 样本量越大, 下界越小, 估计越精准; $nI(\theta)$ 称为样本的 **Fisher** 信息量, 反映样本 $(X_1, X_2, \dots, X_n)^T$ 所提供的总信息。

若某无偏估计量的方差恰好等于 C-R 下界, 则它已达到最优, 必为 UMVUE, 无法再改进; 若方差远大于下界, 则说明仍有改进空间。

2.2 估计量的大样本性质

定义 2.10 (相合估计量与强相合估计量)

设 $\hat{g}_n = \hat{g}_n(X_1, X_2, \dots, X_n)$ 为 $g(\theta)$ 的估计量。

若对任意固定的 $\theta \in \Theta$, 对任给的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P_\theta\{|\hat{g}_n - g(\theta)| > \varepsilon\} = 0,$$

则称 $\hat{g}_n$ 为 $g(\theta)$ 的相合估计量, 简记为 $\hat{g}_n \xrightarrow{P} g(\theta)$ 。

若对任何固定的 $\theta \in \Theta$ 都有

$$P_\theta\left\{\lim_{n \rightarrow \infty} \hat{g}_n = g(\theta)\right\} = 1,$$

则称 $\hat{g}_n$ 为 $g(\theta)$ 的强相合估计量, 简记为 $\hat{g}_n \xrightarrow{a.s.} g(\theta)$ 。

强相合估计量必为相合估计量。

- 弱相合 $\Leftrightarrow$ 依概率收敛 ($\xrightarrow{P}$)
- 强相合 $\Leftrightarrow$ 几乎处处收敛 ($\xrightarrow{a.s.}$) almost surely

定理 2.6 (强相合估计量经过连续函数变换后仍然是强相合的。)

设 $G(\theta_1, \theta_2, \dots, \theta_k)$ 在参数空间 $\Theta \subset \mathbf{R}^k$ 上连续, $\hat{T}_{in}$ 为 θ_i 的强相合估计量, $i = 1, 2, \dots, k$, 则 $G(\hat{T}_{1n}, \hat{T}_{2n}, \dots, \hat{T}_{kn})$ 为 $G(\theta_1, \theta_2, \dots, \theta_k)$ 的强相合估计量。

定理 2.7 (矩估计量的强相合性)

设总体有直到 k ($k \geq 2$) 阶的矩 $\alpha_i, i = 1, \dots, k, \beta_j, j = 2, \dots, k$ 。若 $g(\theta)$ 可表示为

$$g(\theta) = G(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_2, \dots, \beta_k)$$

且 G 为连续函数, 记 $\hat{\alpha}_i, \hat{\beta}_j$ 分别为样本原点矩和样本中心矩, 则

$$G(\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_k, \hat{\beta}_2, \dots, \hat{\beta}_k)$$

为 $g(\theta)$ 的强相合估计量。

 **笔记** 矩估计量具有强相合性需满足三个条件: 总体有足够高阶的矩存在; $g(\theta)$ 能写成各阶矩的连续函数; 用样本矩替换总体矩。满足这三条, 矩估计量就是强相合的。

定理 2.8 (最大似然估计量的存在性与相合性)

设分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足:

1. Θ 是有限集;
2. 对于不同的参数值 θ 和 θ' , 所对应的分布不同;
3. $\{f(x; \theta) : \theta \in \Theta\}$ 有共同支撑, 即 $A = \{x : f(x; \theta) > 0\}$ 与 θ 无关。

则对于简单随机样本 $(X_1, X_2, \dots, X_n)^T$, θ 的最大似然估计量 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 存在, 且 $\hat{\theta}_n$ 为 θ 的相合估计量。



笔记 三个条件的直觉如下: Θ 是有限集: θ 的取值范围不能无限大, 保证最大值能取到; 不同参数对应不同分布: 保证参数是“可识别的”, 不然两个不同的 θ 长得一样, 根本无法区分; 共同支撑与 θ 无关: 保证似然函数对 θ 求导时不会出现支撑集随 θ 变化的麻烦, 数学上处理起来干净。

定理 2.9 (MLE 相合性 (Consistency) 定理)

设分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足:

- (1) Θ 为 $\mathbf{R}$ (一维实空间) 中的开集; **开集保证可以对 θ 求导**
- (2) 不同的参数值 θ 和 θ' 所对应的分布不同; **如果不同 θ 分布相同就分不清那个是真实参数**
- (3) $\{f(x; \theta) : \theta \in \Theta\}$ 有共同支撑 A ; **保证似然函数的结构在整个参数空间上一致, 也就是似然方程有意义**
- (4) $f(x; \theta)$ 对 θ 的偏导数 $\frac{\partial f(x; \theta)}{\partial \theta}$ 在 Θ 上存在, 并且当简单随机样本 $(X_1, X_2, \dots, X_n)^T \in A^n$ 时, 似然方程

$$\frac{\partial}{\partial \theta} \prod_{i=1}^n f(X_i; \theta) = 0$$

有唯一解 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$, **保证 MLE 存在且唯一——有唯一解才能保证估计量是良定义的, 才能谈收敛到真实值。**

则 $\hat{\theta}_n \xrightarrow{P} \theta$ ($n \rightarrow \infty$), 即 $\hat{\theta}_n$ 为 θ 的相合估计量。



笔记 本定理说的是: 在一定条件下, MLE 是相合估计量——即样本量 $n \rightarrow \infty$ 时, 最大似然估计量依概率收敛到真实参数值。相合性 (Consistency): 估计量随样本量增大越来越准, 极限上依概率收敛到真实参数值, 即

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (n \rightarrow \infty).$$

直觉就是: 数据越多, 估计越靠谱, 样本无穷大时误差趋于 0。一句话总结: (1)(3)(4) 保证 MLE 能算出来且唯一, (2) 保证算出来的东西有意义。

定义 2.11 (渐近正态性)

若 $g(\theta)$ 的估计 $\hat{g}_n = \hat{g}_n(X_1, X_2, \dots, X_n)$ 满足

$$\sqrt{n}(\hat{g}_n - g(\theta)) \xrightarrow{L} N(0, V(\theta)) \quad (n \rightarrow \infty),$$

则称估计量 $\hat{g}_n$ 是渐近正态的。由上式, 当 n 充分大时, 近似地有

$$\hat{g}_n \sim N\left(g(\theta), \frac{V(\theta)}{n}\right),$$

称该分布为估计量 $\hat{g}_n$ 的渐近分布, $V(\theta)/n$ 称为 $\hat{g}_n$ 的渐近方差。



笔记 本定义说的是: 估计量 $\hat{g}_n$ 的误差经过 $\sqrt{n}$ 放大后, 在大样本下近似服从正态分布。

直觉是: 单个估计误差 $\hat{g}_n - g(\theta)$ 随 n 增大趋于 0, 太小了看不清楚形状, 乘以 $\sqrt{n}$ 把它“放大”到合适的尺度, 这时候形状依分布收敛 ($\xrightarrow{L}$, 即弱收敛) 到正态分布。

实际用途是: 样本量足够大时, 可以直接用 $\hat{g}_n \sim N(g(\theta), V(\theta)/n)$ 来做区间估计和假设检验, 不需要知道

$\hat{g}_n$ 的精确分布。

L 是来自法语“Loi”，意思是“分布/定律”，法国概率学派的传统记号。

定理 2.10 (MLE 渐近正态性)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta)$, $\theta \in \Theta$, 分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足:

- (1) Θ 是开区间; (保证可以对 θ 求导)
- (2) $A = \{x : f(x; \theta) > 0\}$ 与 θ 无关, 即分布族有共同支撑; (保证似然函数结构一致, 对所有 θ 有意义)
- (3) $\forall x \in A$, $f(x; \theta)$ 对 θ 三次可微, 且三阶导数是 θ 的连续函数; (保证可以对似然函数做 Taylor 展开)
- (4) 对积分 $\int_A f(x; \theta) dx$ 可在积分号下对 θ 微分两次; (保证期望和导数可以交换顺序, Fisher 信息量的两个等价公式成立)
- (5) Fisher 信息量 $I(\theta)$ 满足 $0 < I(\theta) < \infty$; (保证渐近方差 $1/I(\theta)$ 有意义且非退化)
- (6) $\forall \theta_0 \in \Theta$, 存在正数 a 和函数 $M(x)$, 使得

$$\left| \frac{\partial^3 \ln f(x; \theta)}{\partial \theta^3} \right| \leq M(x), \quad x \in A, \theta_0 - a < \theta < \theta_0 + a$$

及 $E_{\theta_0}(|M(X)|) < \infty$; (控制 Taylor 展开余项, 保证展开合法)

设 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 为似然方程的根, 并且满足 $\hat{\theta}_n \xrightarrow{P} \theta_0$, 则

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{L} N\left(0, \frac{1}{I(\theta_0)}\right).$$



定理 2.11 (Delta 方法-也就是原来相当于 y=x 现在更普遍)

设 $\hat{\theta}_n$ 为 θ 的估计量, 满足

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{L} N(0, V(\theta)),$$

$h(\theta)$ 在 Θ 上可导, 且 $h'(\theta) \neq 0$, 则

$$\sqrt{n}(h(\hat{\theta}_n) - h(\theta)) \xrightarrow{L} N(0, (h'(\theta))^2 V(\theta)) \quad (n \rightarrow \infty).$$



那导乘外导罢了

推论 2.1 (在正则条件下, MLE 的渐近方差恰好达到 C-R 下界)

在定理 3.4.5 和定理 3.4.6 的条件下, 有

$$\sqrt{n}(h(\hat{\theta}) - h(\theta)) \xrightarrow{L} N\left(0, \frac{[h'(\theta)]^2}{I(\theta)}\right).$$

注意, 上式表明 $h(\theta)$ 的最大似然估计量 $h(\hat{\theta})$ 的渐近方差与 C-R 下界一致。这就是说, 在该推论的正则条件下, 最大似然估计量 $h(\hat{\theta})$ 的渐近方差达到了 C-R 下界, 称这样的估计量为有效估计量。



笔记 [模拟估计方法比较] 三种方法的核心区别在于对总体分布 F 的已知程度:

- 简单模拟法: F 完全已知, 直接从 F 中抽取 k 组样本, 用样本方差估计 $\text{Var}(T)$ 。优点: 最简单直接; 缺点: 要求分布完全已知, 实际中很少满足。
- 参数自助法: F_c 类型已知但参数 c 未知, 先用观测数据估计 $\hat{c}$, 再从 $F_{\hat{c}}$ 中产生 B 组样本, 计算

$$\widehat{\text{MSE}}_{pb}(T) = \frac{1}{B} \sum_{j=1}^B (T^{(j)} - \theta(F_{\hat{c}}))^2.$$

优点: 利用了分布类型的先验信息, 估计更精准; 缺点: 依赖分布类型假设正确。

- 一般自助法 (非参数自助法): F 完全未知, 用经验分布函数 F_n 代替 $F_{\hat{c}}$, 即在 $\{x_1, x_2, \dots, x_n\}$ 中有放回地抽取容量为 n 的样本 B 次, 计算每组样本下 $T^{(j)}$, 再估计方差。优点: 无需任何分布假设, 适用范围最

广；缺点：完全依赖样本，小样本下效果差。

第3章 作业

3.1 第一周作业

 **作业 3** 汽车制造商的生产记录表明了每个班的产品数量（每个班的最大产量是 720 辆汽车）。

668	711	625	701	688	667	694	630	547	703	688	697	703
656	677	700	702	688	691	664	688	679	708	699	667	703

1. 画出茎叶图。
2. 计算样本均值和样本中位数。
3. 均值和中位数间的关系关于数据的形状说明了什么？

解

(1) 使用 R 语言的 `stem()` 函数处理该组生产记录数据。为了使茎叶图的结构更加紧凑并消除不必要的空行，我们将 `scale` 参数调整为 0.5。得到结果如下：

```
> data <- c(668, 711, 625, 701, 688, 667, 694, 630, 547, 703, 688, 697, 703,
+          656, 677, 700, 702, 688, 691, 664, 688, 679, 708, 699, 667, 703)
> stem(data, scale = 0.5)
```

The decimal point is 1 digit(s) to the right of the |

```
54 | 7
56 |
58 |
60 |
62 | 50
64 | 6
66 | 4777879
68 | 88881479
70 | 01233381
```

(2) 利用 R 语言中的 `mean()` 和 `median()` 函数计算样本统计量：

- 样本均值： $\bar{x} \approx 678.6154$
- 样本中位数： $M = 688$

(3) 根据计算结果可知，均值(678.6154) < 中位数(688)。在统计学中，当均值小于中位数时，通常说明数据分布呈现左偏（负偏态）。这反映出生产记录中存在极少数产量显著较低的班次（如 547），这些“长尾”数据拉低了整体的平均水平，使得分布曲线向左延伸。

 **作业 4** 在一项血清胆固醇含量 (mg/L) 的研究中，记录了 20 个成年患者的胆固醇含量：

133	137	148	149	152	167	174	179	189	192
201	209	210	211	218	238	245	248	253	257

试求 (1) 样本均值和样本中位数；(2) 极差、四分位数间距和样本方差。

解 (1) 利用 R 语言中的 `mean()` 和 `median()` 函数计算样本统计量：

- 样本均值： $\bar{x} = 195.5$
- 样本中位数： $M = 196.5$


(2) 利用 R 语言计算该组数据的离散程度指标：

- 极差 (**Range**): $R = \max(x) - \min(x) = 257 - 133 = 124$ 。

- 四分位数间距 (IQR): 通过 $\text{IQR}()$ 函数计算得到 $\text{IQR} = Q_3 - Q_1 = 59.75$ 。
- 样本方差 (Sample Variance): 使用 $\text{var}()$ 函数计算 (采用 $n-1$ 修正):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \approx 1605.842$$

 **作业 5** 用上题中的观测值画出箱线图，并由此说明总体分布的形状。



解 使用 R 语言绘制血清胆固醇含量的箱线图 (见上图)，并结合图形特征对总体分布形状进行分析：

- 对称性分析：从图中可以看出，中位数 (箱体中的黑实线) 位置稍稍偏向箱体的右侧 (靠近上四分位数 Q_3)，且左侧的须线 (whisker) 相对于右侧须线略长。
- 偏态说明：结合上题计算结果，均值 ($\bar{x} = 195.5$) 小于中位数 ($M = 196.5$)。箱线图呈现出左侧间距 (最小值到中位数) 略大于右侧间距 (最大值到中位数) 的特征，这表明总体分布呈现轻微的左偏 (负偏态) 分布。
- 离群值判断：在箱线图的上下须线之外未发现孤立的点，说明在该样本数据中不存在明显的异常值 (离群点)。

page44

 **作业 3** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$ ，其中 μ 是已知数，而 σ^2 是未知的，指出下列各量哪些是统计量，哪些不是统计量，并说明理由：

$$\sum_{i=1}^n X_i, \quad X_1 + 2\mu, \quad \max_{1 \leq i \leq n} \{X_i\}, \quad \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}, \quad \sum_{i=1}^n (X_i - \mu)^2.$$

东邪的 tip 3.1

统计量只能由样本 $X_1, \dots, X_n$ 和已知常数构成

解 是，是，是，不是，是

 **笔记** 统计量就是：拿到一组真实样本数据后，对这些数据做具体运算得到的结果。

例如测得

$$x_1, x_2, \dots, x_n,$$

则相加、取平均、取最大值、排序、求平方和等得到的量，通常都是统计量。

 **作业 4** 某机床加工出的零件的直径服从正态分布 $N(\mu, \sigma^2)$ ， μ, σ^2 未知。为对 μ, σ^2 作出估计，随机选取加工出来的 n 个零件进行测量，得到 n 个数据

$$x_1, x_2, \dots, x_n.$$

试写出该问题的统计模型（即参数空间和样本分布族）。

解 设

$$X_1, X_2, \dots, X_n$$

为随机选取的 n 个零件直径，由题意可知

$$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

其中参数 μ, σ^2 均未知。

因此，该问题的统计模型可写为：

- 参数空间为

$$\Theta = \{(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}.$$

- 样本分布族为：样本 $(X_1, X_2, \dots, X_n)$ 的联合概率密度为

$$f(x_1, x_2, \dots, x_n; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right], \quad (\mu, \sigma^2) \in \Theta.$$

故该问题的统计模型就是由参数空间

$$\Theta = \{(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$$

和样本分布族

$$\left\{P_{\mu, \sigma^2} : (X_1, \dots, X_n) \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2), (\mu, \sigma^2) \in \Theta\right\}$$

所组成的统计模型。

作业 6（柯西分布）设 $X_1, X_2, \dots, X_n$ i.i.d., X_1 服从柯西分布，概率密度为

$$f(x, \sigma) = \frac{1}{\pi\sigma} \frac{1}{1 + (x/\sigma)^2}, \quad -\infty < x < \infty,$$

求

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

的抽样分布。

解 设每个样本的特征函数为

$$\varphi_X(t) = E(e^{itX}).$$

由柯西分布的已知结论，

$$X_i \sim \text{Cauchy}(0, \sigma) \implies \varphi_{X_i}(t) = e^{-\sigma|t|}.$$

由于 $X_1, X_2, \dots, X_n$ 相互独立，故

$$\varphi_{\bar{X}}(t) = E(e^{it\bar{X}}) = E\left(e^{it\frac{1}{n}\sum_{i=1}^n X_i}\right) = \prod_{i=1}^n E\left(e^{i(t/n)X_i}\right).$$

于是

$$\varphi_{\bar{X}}(t) = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right) = \left(e^{-\sigma|t|/n}\right)^n = e^{-\sigma|t|}.$$

东邪的 tip 3.2

independent and identically distributed 相互独立而且同分布所以第二行能写成 n 次方，第一行只是把加号从指数取下来变成了乘法

这正是参数为 σ 的柯西分布的特征函数，因此

$$\bar{X} \sim \text{Cauchy}(0, \sigma).$$

故 $\bar{X}$ 的抽样分布仍为柯西分布，其概率密度为

$$f_{\bar{X}}(x) = \frac{1}{\pi\sigma} \frac{1}{1 + (x/\sigma)^2}, \quad -\infty < x < \infty.$$

东邪的 tip 3.3

题目要求样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

的抽样分布，即确定 $\bar{X}$ 服从什么分布并求出其密度函数。

由于直接由密度求 $\bar{X}$ 的分布需要进行多重卷积，计算较为繁琐，因此转而先求 $\bar{X}$ 的特征函数，再由特征函数来确定其分布。

求得 $\bar{X}$ 的特征函数后，将其与已知分布的特征函数进行比较，识别出 $\bar{X}$ 所服从的分布，进而写出其密度函数，从而得到所求的抽样分布。

page45

作业 1 证明 (2.2.3) 式。

解 设

$$S(p) = \sum_{k=r}^n C_n^k p^k (1-p)^{n-k}.$$

对 p 求导，并利用重点等式

$$kC_n^k = nC_{n-1}^{k-1}, \quad (n-k)C_n^k = nC_{n-1}^k,$$

得

$$\begin{aligned} S'(p) &= \sum_{k=r}^n C_n^k \left[kp^{k-1}(1-p)^{n-k} - (n-k)p^k(1-p)^{n-k-1} \right] \\ &= n \sum_{k=r}^n C_{n-1}^{k-1} p^{k-1} (1-p)^{n-k} - n \sum_{k=r}^n C_{n-1}^k p^k (1-p)^{n-k-1}. \end{aligned}$$

在第一项中令 $j = k - 1$ ，则

$$S'(p) = n \sum_{j=r-1}^{n-1} C_{n-1}^j p^j (1-p)^{n-1-j} - n \sum_{k=r}^{n-1} C_{n-1}^k p^k (1-p)^{n-1-k} = nC_{n-1}^{r-1} p^{r-1} (1-p)^{n-r}.$$

再由

$$nC_{n-1}^{r-1} = rC_n^r$$

可得

$$S'(p) = rC_n^r p^{r-1} (1-p)^{n-r}.$$

两边从 0 到 p 积分，并注意 $S(0) = 0$ ，于是

$$S(p) = rC_n^r \int_0^p t^{r-1} (1-t)^{n-r} dt.$$

故

$$\sum_{k=r}^n C_n^k p^k (1-p)^{n-k} = rC_n^r \int_0^p t^{r-1} (1-t)^{n-r} dt.$$

东邪的 tip 3.4

这个证明一边有积分一边没积分就应该想导是对左边求导然后再从 0 到 p 积分

作业 2 (几何分布) 设总体 X 服从几何分布

$$P\{X = k\} = p(1-p)^{k-1}, \quad k = 1, 2, \dots,$$

$X_1, X_2, \dots, X_n$ 是取自 X 的简单随机样本, 求 $X_{(1)}, X_{(n)}$ 的分布。

解 设

$$q = 1 - p, \quad X_{(1)} = \min\{X_1, \dots, X_n\}, \quad X_{(n)} = \max\{X_1, \dots, X_n\}.$$

由于总体服从几何分布,

$$P(X = k) = pq^{k-1}, \quad k = 1, 2, \dots,$$

故对任意 $m = 1, 2, \dots$, 有

$$P(X > m) = q^m, \quad P(X \leq m) = 1 - q^m.$$

1. 求 $X_{(1)}$ 的分布

由次序统计量的分布公式,

$$P(X_{(1)} > m) = P(X_1 > m, \dots, X_n > m) = (P(X > m))^n = q^{mn},$$

因此

$$P(X_{(1)} \leq m) = 1 - q^{mn}.$$

从而

$$P(X_{(1)} = m) = P(X_{(1)} > m-1) - P(X_{(1)} > m) = q^{(m-1)n} - q^{mn} = (1 - q^n)q^{(m-1)n},$$

其中 $m = 1, 2, \dots$

东邪的 tip 3.5

分布函数所有人都有就是小于等于 m 的概率。分布列只有离散型有就是 $P(X=x)$, 概率密度函数只有连续型有因为只有连续型的分布函数才能求导。最大最小值求的时候不是只有他大于 m 的概率而是他能要求其他元素也满足这个条件。

2. 求 $X_{(n)}$ 的分布

由次序统计量的分布公式,

$$P(X_{(n)} \leq m) = P(X_1 \leq m, \dots, X_n \leq m) = (P(X \leq m))^n = (1 - q^m)^n,$$

因此

$$P(X_{(n)} = m) = P(X_{(n)} \leq m) - P(X_{(n)} \leq m-1) = (1 - q^m)^n - (1 - q^{m-1})^n,$$

其中 $m = 1, 2, \dots$

作业 3 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$, 试分别求出 $X_{(1)}$ 和 $X_{(n)}$ 的概率密度。

3.2 第二次作业

3.2.1 45, 3, 4, 6

作业 3 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$, 试分别求出 $X_{(1)}$ 和 $X_{(n)}$ 的概率密度。

解 已知总体 $X \sim U[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$, 其概率密度函数 $f(x)$ 和分布函数 $F(x)$ 分别为:

$$f(x) = \begin{cases} 1, & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 0, & \text{其他} \end{cases}$$

$$F(x) = \begin{cases} 0, & x < \theta - \frac{1}{2} \\ x - \theta + \frac{1}{2}, & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 1, & x > \theta + \frac{1}{2} \end{cases}$$

3.2.1.0.1 1. 求 $X_{(n)}$ 的概率密度 根据次序统计量的概率密度公式, $X_{(n)}$ 的密度函数为:

$$f_{X_{(n)}}(x) = n[F(x)]^{n-1}f(x)$$

代入得:

$$f_{X_{(n)}}(x) = \begin{cases} n(x - \theta + \frac{1}{2})^{n-1}, & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 0, & \text{其他} \end{cases}$$

3.2.1.0.2 2. 求 $X_{(1)}$ 的概率密度 根据次序统计量的概率密度公式, $X_{(1)}$ 的密度函数为:

$$f_{X_{(1)}}(x) = n[1 - F(x)]^{n-1}f(x)$$

由于当 $\theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2}$ 时:

$$1 - F(x) = 1 - (x - \theta + \frac{1}{2}) = \theta + \frac{1}{2} - x$$

代入得:

$$f_{X_{(1)}}(x) = \begin{cases} n(\theta + \frac{1}{2} - x)^{n-1}, & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 0, & \text{其他} \end{cases}$$

 **作业** 4 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F(x)$ 有概率密度 $f(x)$, 求:

1. $X_{(1)}$ 和 $X_{(n)}$ 的联合分布函数及联合概率密度;
2. $R = X_{(n)} - X_{(1)}$ 的分布函数及概率密度。

东邪的 tip 3.6

大写是虚指小写是真实的数

解 设

$$U = X_{(1)} = \min\{X_1, \dots, X_n\}, \quad V = X_{(n)} = \max\{X_1, \dots, X_n\}.$$

先求联合分布函数

$$F_{U,V}(x, y) = P(U \leq x, V \leq y).$$

由顺序统计量的定义分情况讨论:

- 当 $x > y$ 时, 由于 $U \leq V$ 恒成立,

$$\{U \leq x, V \leq y\} = \{V \leq y\},$$

故

$$F_{U,V}(x, y) = P(V \leq y) = P(X_1 \leq y, \dots, X_n \leq y) = [F(y)]^n.$$

- 当 $x \leq y$ 时,

$$F_{U,V}(x, y) = P(V \leq y) - P(U > x, V \leq y).$$

其中

$$P(V \leq y) = [F(y)]^n,$$

而事件 $\{U > x, V \leq y\}$ 表示所有样本都落在区间 $(x, y]$ 内, 因此

$$P(U > x, V \leq y) = (F(y) - F(x))^n.$$

东邪的 tip 3.7

这里本质决定的是 X 的积分区域

从而

$$F_{U,V}(x, y) = [F(y)]^n - (F(y) - F(x))^n.$$

综上,

$$F_{X_{(1)}, X_{(n)}}(x, y) = \begin{cases} [F(y)]^n - (F(y) - F(x))^n, & x \leq y, \\ [F(y)]^n, & x > y. \end{cases}$$

下面求联合概率密度。对区域 $x < y$, 有

$$f_{X_{(1)}, X_{(n)}}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X_{(1)}, X_{(n)}}(x, y).$$

由

$$F_{X_{(1)}, X_{(n)}}(x, y) = [F(y)]^n - (F(y) - F(x))^n$$

求偏导得

$$f_{X_{(1)}, X_{(n)}}(x, y) = n(n-1)(F(y) - F(x))^{n-2} f(x) f(y), \quad x < y.$$

因此联合概率密度为

$$f_{X_{(1)}, X_{(n)}}(x, y) = \begin{cases} n(n-1)(F(y) - F(x))^{n-2} f(x) f(y), & x < y, \\ 0, & x \geq y. \end{cases}$$

东邪的 tip 3.8 (U 和 V 不是独立的最大值的选取限制最小值)

也就是说, 知道“所有样本都不超过 y ”以后, 最小值落到 x 左边的概率已经变了。

更直观地说, 事件 $V \leq y$ 会限制样本全都待在 $(-\infty, y]$ 里。在这个前提下, 再看 $U \leq x$, 它就不是原来那个无条件概率了。

解 设

$$U = X_{(1)}, \quad V = X_{(n)}, \quad R = V - U, \quad T = U.$$

则

东邪的 tip 3.9

这个 T 的选取是任意可以和 R 凑出来 v 就行当你要把一个随机变量组换成另一个随机变量组, 并且要从“旧变量的密度”推出“新变量的密度”时, 就该想到雅可比行列式, 因为边缘密度总是好求的

$$U = T, \quad V = T + R.$$

故雅可比行列式为

$$J = \left| \frac{\partial(u, v)}{\partial(t, r)} \right| = \begin{vmatrix} 1 & 0 \\ 1 & 1 \end{vmatrix} = 1.$$

于是

$$f_{T,R}(t, r) = f_{U,V}(t, t+r), \quad r > 0.$$

由第一问的结果,

$$f_{U,V}(u, v) = n(n-1)(F(v) - F(u))^{n-2} f(u) f(v), \quad u < v.$$

因此

$$\begin{aligned} f_R(r) &= \int_{-\infty}^{\infty} f_{T,R}(t, r) dt = \int_{-\infty}^{\infty} f_{U,V}(t, t+r) dt \\ &= n(n-1) \int_{-\infty}^{\infty} (F(t+r) - F(t))^{n-2} f(t) f(t+r) dt, \quad r > 0. \end{aligned}$$

并且

$$f_R(r) = 0, \quad r \leq 0.$$

 **作业 5** 从某总体抽取一个容量为 5 的样本：

$$-2.8, -1, 1.5, 2.1, 3.4.$$

写出该样本的经验分布函数并画出它的图形。

解 将样本按从小到大排列为

$$x_{(1)} = -2.8, \quad x_{(2)} = -1, \quad x_{(3)} = 1.5, \quad x_{(4)} = 2.1, \quad x_{(5)} = 3.4.$$

经验分布函数定义为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I\{x_i \leq x\}.$$

这里 $n = 5$ ，所以


$$F_5(x) = \begin{cases} 0, & x < -2.8, \\ \frac{1}{5}, & -2.8 \leq x < -1, \\ \frac{2}{5}, & -1 \leq x < 1.5, \\ \frac{3}{5}, & 1.5 \leq x < 2.1, \\ \frac{4}{5}, & 2.1 \leq x < 3.4, \\ 1, & x \geq 3.4. \end{cases}$$

其图形是一个右连续的阶梯函数，在

$$x = -2.8, -1, 1.5, 2.1, 3.4$$

这五个点处分别向上跳跃 $\frac{1}{5}$ 。

可用下列 TikZ 代码作图：



东邪的 tip 3.10

经验分布函数就是：看样本里有多少比例不超过 x 。图像的纵轴就是累积比例，横轴就是具体的节点。也就是 $F_5(x)$ 图像

 **作业 6** 证明：正态分布 $N(\mu, \sigma^2)$ 的上 α ($0 < \alpha < 1$) 分位数 z_α 与标准正态分布的上 α 分位数 u_α 之间有以下关系：

$$z_\alpha = \mu + \sigma u_\alpha$$

证明 设

$$X \sim N(\mu, \sigma^2), \quad Y = \frac{X - \mu}{\sigma}.$$

则

$$Y \sim N(0, 1).$$

由上 α 分位数的定义, z_α 满足

$$P(X > z_\alpha) = \alpha,$$

而标准正态分布的上 α 分位数 u_α 满足

$$P(Y > u_\alpha) = \alpha.$$

另一方面,

$$P(X > z_\alpha) = P\left(\frac{X - \mu}{\sigma} > \frac{z_\alpha - \mu}{\sigma}\right) = P\left(Y > \frac{z_\alpha - \mu}{\sigma}\right).$$

因此

$$P\left(Y > \frac{z_\alpha - \mu}{\sigma}\right) = \alpha.$$

又因为 u_α 是标准正态分布的上 α 分位数, 即满足

$$P(Y > u_\alpha) = \alpha,$$

故必有

$$\frac{z_\alpha - \mu}{\sigma} = u_\alpha.$$

于是

$$z_\alpha = \mu + \sigma u_\alpha.$$

故证。

3.2.2 46,1,2,3

ection

 **作业** 1 设 $X \sim \chi^2(n)$, 证明:

$$E(X^k) = 2^k \left(\frac{n}{2} + k - 1\right) \left(\frac{n}{2} + k - 2\right) \cdots \frac{n}{2}, \quad k = 1, 2, \dots.$$

特别地, 有 $E(X) = n, \text{Var}(X) = 2n$ 。

证明 由卡方分布的密度函数可知, 若

$$X \sim \chi^2(n),$$

则其概率密度为

$$f(x) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} x^{\frac{n}{2}-1} e^{-x/2}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

因此, X 的 k 阶原点矩为

$$E(X^k) = \int_0^\infty x^k f(x) dx.$$

代入密度函数, 得

$$E(X^k) = \frac{1}{2^{n/2}\Gamma(n/2)} \int_0^\infty x^k x^{\frac{n}{2}-1} e^{-x/2} dx = \frac{1}{2^{n/2}\Gamma(n/2)} \int_0^\infty x^{\frac{n}{2}+k-1} e^{-x/2} dx.$$

利用 Gamma 函数积分公式

$$\int_0^{\infty} x^{a-1} e^{-bx} dx = \frac{\Gamma(a)}{b^a} \quad (a > 0, b > 0),$$

取

$$a = \frac{n}{2} + k, \quad b = \frac{1}{2},$$

可得

$$\int_0^{\infty} x^{\frac{n}{2}+k-1} e^{-x/2} dx = \frac{\Gamma(\frac{n}{2}+k)}{(1/2)^{\frac{n}{2}+k}}.$$

故

$$E(X^k) = \frac{1}{2^{n/2} \Gamma(n/2)} \cdot \frac{\Gamma(\frac{n}{2}+k)}{(1/2)^{\frac{n}{2}+k}} = \frac{2^{\frac{n}{2}+k}}{2^{n/2}} \cdot \frac{\Gamma(\frac{n}{2}+k)}{\Gamma(n/2)} = 2^k \frac{\Gamma(\frac{n}{2}+k)}{\Gamma(n/2)}.$$

再由 Gamma 函数的递推公式

$$\Gamma(z+1) = z\Gamma(z),$$

可得

$$\Gamma\left(\frac{n}{2}+k\right) = \left(\frac{n}{2}+k-1\right) \left(\frac{n}{2}+k-2\right) \cdots \left(\frac{n}{2}\right) \Gamma\left(\frac{n}{2}\right).$$

于是

$$\frac{\Gamma(\frac{n}{2}+k)}{\Gamma(n/2)} = \left(\frac{n}{2}+k-1\right) \left(\frac{n}{2}+k-2\right) \cdots \left(\frac{n}{2}\right).$$

代回上式, 得到

$$E(X^k) = 2^k \left(\frac{n}{2}+k-1\right) \left(\frac{n}{2}+k-2\right) \cdots \left(\frac{n}{2}\right).$$

即

$$E(X^k) = 2^k \frac{\Gamma(\frac{n}{2}+k)}{\Gamma(n/2)} = 2^k \left(\frac{n}{2}+k-1\right) \left(\frac{n}{2}+k-2\right) \cdots \left(\frac{n}{2}\right).$$

故证。

注 由上式可顺便验证卡方分布的期望与方差。

当 $k=1$ 时,

$$E(X) = 2 \cdot \frac{n}{2} = n.$$

当 $k=2$ 时,

$$E(X^2) = 2^2 \left(\frac{n}{2}+1\right) \frac{n}{2} = 4 \cdot \frac{n+2}{2} \cdot \frac{n}{2} = n(n+2) = n^2 + 2n.$$

因此

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = (n^2 + 2n) - n^2 = 2n.$$

东邪的 tip 3.11

K 阶矩只是积分里面的东西变了

作业 2 设 $X \sim t(n)$, 则当 $k < n$ 时, $E(X^k)$ 存在且有

$$E(X^k) = \begin{cases} 0, & \text{当 } k \text{ 为奇数;} \\ n^{\frac{k}{2}} \frac{\Gamma(\frac{k+1}{2}) \Gamma(\frac{n-k}{2})}{\sqrt{\pi} \Gamma(\frac{n}{2})}, & \text{当 } k \text{ 为偶数.} \end{cases}$$

当 $k \geq n$ 时, $E(X^k)$ 是否存在?

东邪的 tip 3.12

证明不存在就想不收敛也就是积分趋紧于无穷

证明 设 $X \sim t(n)$, 其密度函数为

$$f(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad x \in \mathbb{R}.$$

当 $|x| \rightarrow \infty$ 时,

$$\left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}} \sim C|x|^{-(n+1)},$$

其中 $C > 0$ 为常数, 因此

$$|x|^k f(x) \sim C|x|^{k-n-1}.$$

于是 $E(X^k)$ 的存在性可由广义积分

$$\int_A^\infty x^{k-n-1} dx$$

的敛散性来判断。由幂函数积分判别法知,

$$\int_A^\infty x^{k-n-1} dx$$

收敛当且仅当

$$k - n - 1 < -1,$$

即

$$k < n.$$

故当 $k \geq n$ 时, 上述积分发散, 从而

$$E(|X|^k) = \infty.$$

因此 $E(X^k)$ 不存在。

故 $t(n)$ 分布的 k 阶矩存在当且仅当 $k < n$ 。

 **作业 3** 设 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$, X_1, X_2 相互独立, 则 $X_1 + X_2$ 与 X_1/X_2 相互独立。

证明 设

$$U = X_1 + X_2, \quad W = \frac{X_1}{X_1 + X_2}.$$

由于 $X_1 > 0$, $X_2 > 0$, 故

$$u > 0, \quad 0 < w < 1.$$

由反变换可得

$$X_1 = Uw, \quad X_2 = U(1-w).$$

又因为 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 且相互独立, 所以其联合密度为

$$f_{X_1, X_2}(x_1, x_2) = \frac{1}{2^{m/2}\Gamma(m/2)} x_1^{m/2-1} e^{-x_1/2} \cdot \frac{1}{2^{n/2}\Gamma(n/2)} x_2^{n/2-1} e^{-x_2/2}, \quad x_1, x_2 > 0.$$

计算雅可比行列式:

$$J = \frac{\partial(x_1, x_2)}{\partial(u, w)} = \begin{vmatrix} w & u \\ 1-w & -u \end{vmatrix} = -u,$$

故

$$|J| = u.$$

因此

$$\begin{aligned} f_{U,W}(u, w) &= f_{X_1, X_2}(uw, u(1-w)) \cdot |J| \\ &= \frac{1}{2^{m/2}\Gamma(m/2)} (uw)^{m/2-1} e^{-uw/2} \cdot \frac{1}{2^{n/2}\Gamma(n/2)} (u(1-w))^{n/2-1} e^{-u(1-w)/2} \cdot u \\ &= \frac{1}{2^{(m+n)/2}\Gamma(m/2)\Gamma(n/2)} u^{(m+n)/2-1} e^{-u/2} w^{m/2-1} (1-w)^{n/2-1}, \end{aligned}$$

其中 $u > 0, 0 < w < 1$.

可见

$$f_{U,W}(u, w) = g(u)h(w),$$

故 U 与 W 相互独立。

又因为

$$\frac{X_1}{X_2} = \frac{Uw}{U(1-w)} = \frac{w}{1-w},$$

即 $\frac{X_1}{X_2}$ 是 W 的函数，因此 U 与 $\frac{X_1}{X_2}$ 也相互独立。
故

$$X_1 + X_2 \quad \text{与} \quad \frac{X_1}{X_2}$$

相互独立。

 **笔记** 可以把这里的 W 和 V 理解成“同一个量的两种不同表示方法”，就像温度既可以用摄氏度表示，也可以用华氏度表示一样。

例如，若用 C 表示摄氏温度，用 F 表示华氏温度，则

$$F = \frac{9}{5}C + 32, \quad C = \frac{5}{9}(F - 32).$$

因此，知道 C 就能确定 F ，知道 F 也能确定 C 。也就是说， C 与 F 虽然写法不同，但本质上描述的是同一个温度，只是换了一种刻度。

同理，在本题中

$$V = \frac{X_1}{X_2}, \quad W = \frac{X_1}{X_1 + X_2},$$

并且二者满足

$$V = \frac{W}{1-W}, \quad W = \frac{V}{1+V}.$$

所以 V 和 W 也是同一个“比例信息”的两种表达方式。

因此，如果已经证明 U 与 W 独立，那么把 W 换成与它一一对应的 V ，独立性不会改变；这就像若某个随机变量与“摄氏温度”独立，那么它也必然与“华氏温度”独立，因为二者本质上是同一件事的不同写法。

所以，这道题里先证明

$$U = X_1 + X_2 \quad \text{与} \quad W = \frac{X_1}{X_1 + X_2}$$

独立，再推出

$$U \quad \text{与} \quad V = \frac{X_1}{X_2}$$

独立，是完全合理的。

东邪的 tip 3.13

一个 W 对应一个 v ，一个 W 能锁定一个 V 。所以能替换。如果一个 W 对应两个 V 就不行了

 **作业** 设 $F \sim F(m, n)$ ，证明

$$F_{1-\alpha}(m, n) F_{\alpha}(n, m) = 1, \quad \forall \alpha \in (0, 1).$$

解 设随机变量 $X \sim F(m, n)$ 。由 F 分布的性质可知

$$\frac{1}{X} \sim F(n, m).$$

记

$$c = F_{1-\alpha}(m, n),$$

则由分位点定义,

$$P(X \leq c) = 1 - \alpha, \quad P(X > c) = \alpha.$$

于是

$$P\left(\frac{1}{X} < \frac{1}{c}\right) = P(X > c) = \alpha.$$

又因为 $\frac{1}{X} \sim F(n, m)$, 所以按 $F(n, m)$ 分布的 α 分位点定义, 有

$$F_{\alpha}(n, m) = \frac{1}{c} = \frac{1}{F_{1-\alpha}(m, n)}.$$

从而

$$F_{1-\alpha}(m, n) F_{\alpha}(n, m) = 1.$$

证毕。

东邪的 tip 3.14 (遇事不决先列出概率分布也就是 $P(X \leq x)$)

设随机变量 X, Y 相互独立, $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$, 令

$$\xi = \frac{X/m}{Y/n},$$

则 ξ 的分布称为具有自由度 m 和 n 的 F 分布, 记作

$$\xi \sim F(m, n).$$

所以这个 F 分布上面的就是前面的。分子就是后面的

作业 设 $X_1, X_2, \dots, X_n$ 独立, $A_{2 \times n}$ 已知,

$$Y = AX,$$

讨论 Y 与 X 的分布类型是否相同。

解 设

$$X = (X_1, X_2, \dots, X_n)^T, \quad Y = AX,$$

其中 A 为已知的 $2 \times n$ 矩阵。

一般来说, Y 与 X 的分布类型不一定相同。

因为 Y 是 $X_1, \dots, X_n$ 的线性组合, 其分布类型取决于 X_i 的具体分布以及矩阵 A 的形式。线性变换通常会改变随机变量的维数与分布结构, 所以不能笼统地说二者分布类型相同。

但在某些特殊情形下分布类型保持不变。例如当 $X_1, \dots, X_n$ 服从正态分布时, $Y = AX$ 仍服从正态分布, 因此这时 Y 与 X 同属正态型分布。

故结论是:

一般不同; 只有在某些特殊分布族 (如正态分布) 下才可能相同。

作业 5 (χ^2 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$\mathbf{X} = (X_1, \dots, X_n)^T,$$

A 为 n 阶对称方阵。证明:

$$\mathbf{X}^T A \mathbf{X} \sim \chi^2(r)$$

当且仅当 A 为幂等矩阵, 即

$$A^2 = A,$$

并且

$$\text{rank}(A) = r.$$

解 由于 A 为实对称矩阵, 存在正交矩阵 Q , 使

$$Q^T A Q = \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

令 $Y = Q^T X$ 。因为 $X \sim N_n(0, I_n)$ 且 Q 为正交矩阵, 所以

$$Y \sim N_n(0, I_n),$$

故 $Y_1, \dots, Y_n$ 相互独立, 且都服从 $N(0, 1)$ 。于是

$$X^T A X = X^T Q \Lambda Q^T X = Y^T \Lambda Y = \sum_{i=1}^n \lambda_i Y_i^2.$$

若 $A^2 = A$, 则

$$\Lambda^2 = \Lambda,$$

从而 $\lambda_i^2 = \lambda_i$, 故 $\lambda_i = 0$ 或 1 。又因

$$\text{rank}(A) = \text{rank}(\Lambda) = r,$$

故恰有 r 个 $\lambda_i = 1$, 其余为 0 。因此

$$X^T A X = \sum_{i=1}^r Y_i^2 \sim \chi^2(r).$$

反之, 若 $X^T A X \sim \chi^2(r)$, 则其矩母函数为

$$M_{X^T A X}(t) = \prod_{i=1}^n (1 - 2\lambda_i t)^{-1/2} = (1 - 2t)^{-r/2}.$$

由此可知恰有 r 个 $\lambda_i = 1$, 其余 $\lambda_i = 0$ 。于是

$$\Lambda^2 = \Lambda, \quad \text{rank}(\Lambda) = r.$$

再由 $A = Q \Lambda Q^T$, 得

$$A^2 = Q \Lambda^2 Q^T = Q \Lambda Q^T = A, \quad \text{rank}(A) = r.$$

故

$$X^T A X \sim \chi^2(r)$$

当且仅当 A 为幂等矩阵, 且 $\text{rank}(A) = r$ 。

3.3 第三次作业

作业 设 $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, 又设 $X_{n+1} \sim N(\mu, \sigma^2)$, 且与 $X_1, \dots, X_n$ 相互独立。记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

证明

$$T = \sqrt{\frac{n}{n+1}} \frac{\bar{X} - X_{n+1}}{s} \sim t(n-1).$$

解 由正态总体样本性质,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1),$$

且 $\bar{X}$ 与 s^2 相互独立。又因 $X_{n+1} \sim N(\mu, \sigma^2)$, 且与 $X_1, \dots, X_n$ 独立, 故 X_{n+1} 与 $\bar{X}, s^2$ 也独立, 从而

$$\bar{X} - X_{n+1} \sim N\left(0, \frac{\sigma^2}{n} + \sigma^2\right) = N\left(0, \frac{n+1}{n}\sigma^2\right),$$

并且 $\bar{X} - X_{n+1}$ 与 s^2 相互独立。

令

$$Z = \frac{\bar{X} - X_{n+1}}{\sqrt{\frac{n+1}{n}\sigma^2}}, \quad U = \frac{(n-1)s^2}{\sigma^2},$$

则 $Z \sim N(0, 1)$, $U \sim \chi^2(n-1)$, 且 Z 与 U 相互独立, 因此

$$\frac{Z}{\sqrt{U/(n-1)}} \sim t(n-1).$$

又

$$\frac{Z}{\sqrt{U/(n-1)}} = \frac{\frac{\bar{X} - X_{n+1}}{\sqrt{\frac{n+1}{n}\sigma^2}}}{\sqrt{\frac{s^2}{\sigma^2}}} = \sqrt{\frac{n}{n+1}} \frac{\bar{X} - X_{n+1}}{s} = T,$$

故 $T \sim t(n-1)$.

东邪的 tip 3.15

要证明是 t 分布 student 分布。分母得是标准正态分布也就是经过操作以后变成 $N(0, 1)$, 找到 x 找到 y 了还要证明他们两个是独立的。这里用的是定理 1.9。用到了平均值的均值还是 μ 但是方差是原来 σ^2 的 $1/n$ 。然后因为相互独立才有平均值相减方差相加。

 **作业 2.4 第 1 题** 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

求 $\text{Var}(s^2)$ 。

东邪的 tip 3.16

要先让 s^2 乘 $n-1/\sigma^2$ 让他服从卡方分布算完了再把乘的这个再弄掉, $n-1$ 是常数方差求的时候直接平方就行了

解 由于总体 $X_1, \dots, X_n$ 来自正态分布 $N(0, 1)$, 故 $\sigma^2 = 1$ 。由正态总体样本方差的性质,

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1),$$

于是这里有 $(n-1)s^2 \sim \chi^2(n-1)$ 。设 $Y = (n-1)s^2$, 则 $Y \sim \chi^2(n-1)$ 。由卡方分布的性质可知

$$D(Y) = 2(n-1).$$

另一方面,

$$D(Y) = D((n-1)s^2) = (n-1)^2 D(s^2).$$

因此

$$(n-1)^2 D(s^2) = 2(n-1),$$

从而

$$D(s^2) = \frac{2}{n-1}.$$

故

$$\boxed{D(s^2) = \frac{2}{n-1}}.$$

 **作业 2.4 第 2 题** 设 $X_1, \dots, X_m$ i.i.d., $X_1 \sim N(\mu_1, \sigma^2)$; $Y_1, \dots, Y_n$ i.i.d., $Y_1 \sim N(\mu_2, \sigma^2)$, 且这两组随机变量相互独立。记

$$s_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \quad s_2^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

1. 求

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{\sigma^2}$$

的分布;

2. 比较 s_1^2 与

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}$$

的方差。

东邪的 tip 3.17

第一题就用卡方分布相加就是自由度相加对吧。第二题我没什么思路是不是还是要先都转化为卡方分布然后再算二阶矩

解

1. 由正态总体样本方差的性质,

$$\frac{(m-1)s_1^2}{\sigma^2} \sim \chi^2(m-1), \quad \frac{(n-1)s_2^2}{\sigma^2} \sim \chi^2(n-1).$$

又因为两组样本相互独立, 所以这两个卡方变量也相互独立, 因此

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{\sigma^2} \sim \chi^2(m+n-2).$$

2. 由

$$\frac{(m-1)s_1^2}{\sigma^2} \sim \chi^2(m-1), \quad D\left(\frac{(m-1)s_1^2}{\sigma^2}\right) = 2(m-1),$$

得

$$\frac{(m-1)^2}{\sigma^4} D(s_1^2) = 2(m-1), \quad D(s_1^2) = \frac{2\sigma^4}{m-1}.$$

再设

$$W = \frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}.$$

由第 1 问知

$$\frac{(m+n-2)W}{\sigma^2} \sim \chi^2(m+n-2), \quad D\left(\frac{(m+n-2)W}{\sigma^2}\right) = 2(m+n-2),$$

于是

$$\frac{(m+n-2)^2}{\sigma^4} D(W) = 2(m+n-2), \quad D(W) = \frac{2\sigma^4}{m+n-2}.$$

因为 $m+n-2 > m-1$, 所以

$$\frac{2\sigma^4}{m+n-2} < \frac{2\sigma^4}{m-1}.$$

因此

$$D\left(\frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}\right) < D(s_1^2).$$

故

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}$$

的方差更小。

 **作业 2.4 第 3 题** 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$, 求

$$Z = \frac{\sum_{i=1}^{n-1} X_i}{X_n}$$

的分布。

解 设

$$Y = \sum_{i=1}^{n-1} X_i.$$

由于 $X_1, \dots, X_{n-1}$ 相互独立, 且 $X_i \sim N(0, 1)$, 故

$$Y \sim N(0, n-1), \quad X_n \sim N(0, 1).$$

又因为 Y 只与 $X_1, \dots, X_{n-1}$ 有关, 而 X_n 与它们独立, 所以 Y 与 X_n 也相互独立。

于是

$$Z = \frac{Y}{X_n} = \sqrt{n-1} \frac{Y/\sqrt{n-1}}{X_n}.$$

其中

$$\frac{Y}{\sqrt{n-1}} \sim N(0, 1),$$

且 $\frac{Y}{\sqrt{n-1}}$ 与 X_n 相互独立, 因此

$$\frac{Y/\sqrt{n-1}}{X_n}$$

服从标准柯西分布。故

$$\frac{Z}{\sqrt{n-1}} \sim C(0, 1),$$

从而

$$Z \sim C(0, \sqrt{n-1}).$$

所以 Z 的分布为参数为 0 和 $\sqrt{n-1}$ 的柯西分布。

 **作业 1** (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 分别用一阶矩和二阶矩求 λ 的矩估计量。

解 设总体服从泊松分布 $P(\lambda)$ 。

由泊松分布的性质,

$$E(X) = \lambda, \quad E(X^2) = \lambda^2 + \lambda.$$

1. 用一阶矩求矩估计量

由矩估计法, 令样本一阶原点矩等于总体一阶原点矩, 即

$$\bar{X} = E(X) = \lambda.$$

因而 λ 的一阶矩估计量为

$$\hat{\lambda}_1 = \bar{X}.$$

2. 用二阶矩求矩估计量

令样本二阶原点矩等于总体二阶原点矩, 即

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = E(X^2) = \lambda^2 + \lambda.$$

于是 λ 满足方程

$$\lambda^2 + \lambda - \frac{1}{n} \sum_{i=1}^n X_i^2 = 0.$$

解得

$$\hat{\lambda}_2 = \frac{-1 + \sqrt{1 + 4\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right)}}{2}.$$

由于 $\lambda > 0$, 舍去负根。

东邪的 tip 3.18

也就是解方程把应该的期望与方差与实际的期望也就是平均数和方差也就是平方和建立等式然后解方程 x_i 都可以视作已经知道的。

 **作业 2** (二项分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim B(k, p)$, 求 p 的矩估计量。

解 由 $X_1 \sim B(k, p)$ 知

$$E(X) = kp.$$

由矩估计法, 令样本一阶原点矩等于总体一阶原点矩, 即

$$\bar{X} = kp.$$

解得 p 的矩估计量为

$$\hat{p} = \frac{\bar{X}}{k}.$$

东邪的 tip 3.19

有几个参数列几个方程其实 k 是已经知道的就 p 一个未知数

 **作业 3** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的矩估计量。

解 由 $X_1 \sim U(\theta_1, \theta_2)$ 知

$$E(X) = \frac{\theta_1 + \theta_2}{2}, \quad E(X^2) = \frac{\theta_1^2 + \theta_1\theta_2 + \theta_2^2}{3}.$$

由矩估计法, 令样本一阶、二阶原点矩分别等于总体一阶、二阶原点矩, 即

$$\bar{X} = \frac{\theta_1 + \theta_2}{2}, \quad \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\theta_1^2 + \theta_1\theta_2 + \theta_2^2}{3}.$$

记

$$m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2,$$

则

$$\theta_1 + \theta_2 = 2\bar{X}, \quad \theta_1^2 + \theta_1\theta_2 + \theta_2^2 = 3m_2.$$

又因为

$$(\theta_1 + \theta_2)^2 = \theta_1^2 + 2\theta_1\theta_2 + \theta_2^2,$$

故

$$\theta_1\theta_2 = (\theta_1 + \theta_2)^2 - (\theta_1^2 + \theta_1\theta_2 + \theta_2^2) = 4\bar{X}^2 - 3m_2.$$

于是 θ_1, θ_2 是方程

$$t^2 - 2\bar{X}t + (4\bar{X}^2 - 3m_2) = 0$$

的两根, 解得矩估计量

$$\hat{\theta}_1 = \bar{X} - \sqrt{3(m_2 - \bar{X}^2)}, \quad \hat{\theta}_2 = \bar{X} + \sqrt{3(m_2 - \bar{X}^2)}.$$

 **笔记** 用的是二元二次方程的根与系数关系, 也叫韦达定理。

如果

$$t^2 - St + P = 0$$

的两根是 r_1, r_2 , 那么

$$r_1 + r_2 = S, \quad r_1 r_2 = P.$$

 **作业 5** (双边指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x)$,

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x|}{\sigma}\right),$$

求 σ 的矩估计量。

解 由密度函数

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x|}{\sigma}\right)$$

可知该分布关于 0 对称, 且

$$E(X) = 0, \quad E(X^2) = 2\sigma^2.$$

由于 $E(X)$ 不含参数 σ , 故取二阶原点矩作矩估计。令

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = E(X^2) = 2\sigma^2,$$

解得

$$\hat{\sigma} = \sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}.$$

故 σ 的矩估计量为

$$\hat{\sigma} = \sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}.$$

3.4 第五周作业

 **作业 7** 设 $X_1, X_2, \dots, X_n$ i.i.d., 试分别求下列总体中 θ 的最大似然估计量。

2. (韦布尔分布) $f(x; \theta) = \frac{x}{\theta^2} e^{-x^2/\theta^2}$, $x > 0$, $\theta > 0$.

东邪的 tip 3.20

先连乘再去对数, 再求导, 去对数不影响因为是单增的。

解 似然函数为

$$L(\theta) = \prod_{i=1}^n \frac{x_i}{\theta^2} e^{-x_i^2/\theta^2} = \frac{\prod_{i=1}^n x_i}{\theta^{2n}} \exp\left(-\frac{\sum_{i=1}^n x_i^2}{\theta^2}\right)$$

取对数得 $\ln L(\theta) = \sum_{i=1}^n \ln x_i - 2n \ln \theta - \frac{\sum_{i=1}^n x_i^2}{\theta^2}$, 对 θ 求导令其为零得 $-\frac{2n}{\theta} + \frac{2 \sum_{i=1}^n x_i^2}{\theta^3} = 0$, 化简得 $\sum_{i=1}^n x_i^2 = n\theta^2$, 故

$$\hat{\theta} = \sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2}$$

 **作业 8** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U\left(\theta - \frac{1}{2}, \theta + \frac{1}{2}\right)$, 证明任意

$$T \in \left[X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2}\right]$$

都是 θ 的最大似然估计量。

证明 均匀分布的密度函数为

$$f(x; \theta) = \begin{cases} 1 & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 0 & \text{其他} \end{cases}$$

故似然函数为 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$, 当且仅当所有 x_i 均落在 $[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$ 内时 $L(\theta) = 1$, 否则 $L(\theta) = 0$ 。上述条件等价于

$$\theta - \frac{1}{2} \leq x_{(1)} \quad \text{且} \quad x_{(n)} \leq \theta + \frac{1}{2}$$

即 $x_{(n)} - \frac{1}{2} \leq \theta \leq x_{(1)} + \frac{1}{2}$, 故对任意 $T \in [X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2}]$, 均有 $L(T) = 1 = \max_{\theta} L(\theta)$, 即 T 为 θ 的最大似然估计量。

作业 10 (双参数指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x; \alpha, \beta)$,

$$f(x; \alpha, \beta) = \begin{cases} \beta \exp\{-\beta(x - \alpha)\}, & x \geq \alpha, \\ 0, & \text{其他}, \end{cases}$$

其中 $\beta > 0$ 。试求 α, β 的最大似然估计量。

东邪的 tip 3.21

我明白了因为关于 α 是单增的所以压根没有极值点. 其实就是为了让似然函数最大然后找极值点或者最大值

解 似然函数为

$$L(\alpha, \beta) = \prod_{i=1}^n \beta e^{-\beta(x_i - \alpha)} \cdot \mathbf{1}(\alpha \leq x_{(1)}) = \beta^n e^{-\beta \sum_{i=1}^n (x_i - \alpha)} \cdot \mathbf{1}(\alpha \leq x_{(1)})$$

固定 β , 由于 $L(\alpha, \beta) \propto e^{n\beta\alpha}$ 关于 α 单调递增, 故在约束 $\alpha \leq x_{(1)}$ 下最大值在边界处取得, 即 $\hat{\alpha} = X_{(1)}$ 。将 $\hat{\alpha}$ 代入取对数得

$$\ln L(\beta) = n \ln \beta - \beta \sum_{i=1}^n (x_i - x_{(1)})$$

对 β 求导令其为零: $\frac{d \ln L}{d \beta} = \frac{n}{\beta} - \sum_{i=1}^n (x_i - x_{(1)}) = 0$, 解得

$$\hat{\beta} = \frac{n}{\sum_{i=1}^n (X_i - X_{(1)})}$$

作业 11 (截尾几何分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., 为来自截尾几何分布总体 X 的样本:

$$P\{X = k\} = \theta^{k-1}(1 - \theta), \quad k = 1, 2, \dots, r;$$

$$P\{X = r + 1\} = \theta^r.$$

记

$$M = \#\{i : X_i = r + 1, i = 1, 2, \dots, n\},$$

试证明 θ 的 MLE 为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i - n}{\sum_{i=1}^n X_i - M}.$$

东邪的 tip 3.22

代表基数也就后面集合多少个元素关于 $\sum_{x_i \leq r} (x_i - 1) + rM = \sum_{i=1}^n x_i - n$ 的推导: 将求和拆分为

$$\sum_{x_i \leq r} (x_i - 1) = \sum_{i=1}^n (x_i - 1) - \sum_{x_i = r+1} (x_i - 1) = \left(\sum_{i=1}^n x_i - n \right) - rM$$

其中 $\sum_{x_i=r+1}(x_i-1) = (r+1-1) \cdot M = rM$, 故

$$\sum_{x_i \leq r} (x_i - 1) + rM = \sum_{i=1}^n x_i - n - rM + rM = \sum_{i=1}^n x_i - n$$

证明 注意到 k 为 PMF 的哑变量, 写似然函数时将 k 替换为实际观测值 x_i , 似然函数为

$$L(\theta) = \prod_{x_i \leq r} \theta^{x_i-1} (1-\theta) \cdot \prod_{x_i=r+1}^M \theta^r = \theta^{\sum_{x_i \leq r} (x_i-1)} (1-\theta)^{n-M} \cdot \theta^{rM}$$

取对数得

$$\ln L(\theta) = \left[\sum_{x_i \leq r} (x_i - 1) + rM \right] \ln \theta + (n - M) \ln(1 - \theta)$$

注意到 $\sum_{x_i \leq r} (x_i - 1) + rM = \sum_{i=1}^n x_i - n + (r - r)M + rM - rM$, 化简得

$$\sum_{x_i \leq r} (x_i - 1) + rM = \sum_{i=1}^n x_i - n - M(r + 1 - r) + rM = \sum_{i=1}^n x_i - n$$

故

$$\ln L(\theta) = \left(\sum_{i=1}^n x_i - n \right) \ln \theta + (n - M) \ln(1 - \theta)$$

对 θ 求导令其为零:

$$\frac{d \ln L}{d\theta} = \frac{\sum_{i=1}^n x_i - n}{\theta} - \frac{n - M}{1 - \theta} = 0$$

解得

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i - n}{\sum_{i=1}^n X_i - M}$$

 **作业 12** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta_1, \theta_2)$,

$$f(x, \theta_1, \theta_2) = \begin{cases} \frac{\theta_1}{\theta_2} x^{\theta_1-1} \exp\left(-\frac{x^{\theta_1}}{\theta_2}\right), & x \geq 0, \\ 0, & \text{其他,} \end{cases}$$

其中 θ_1 已知, 求 θ_2 的最大似然估计量。

东邪的 tip 3.23

计算要点就是别着急算连乘不好算就先取对数取完对数还是恶性就是求完到再算先把不相关的像全部删除

解 似然函数为

$$L(\theta_2) = \prod_{i=1}^n \frac{\theta_1}{\theta_2} x_i^{\theta_1-1} \exp\left(-\frac{x_i^{\theta_1}}{\theta_2}\right)$$

取对数得

$$\ln L(\theta_2) = n \ln \theta_1 - n \ln \theta_2 + (\theta_1 - 1) \sum_{i=1}^n \ln x_i - \frac{1}{\theta_2} \sum_{i=1}^n x_i^{\theta_1}$$

对 θ_2 求导并令其为零:

$$\frac{d \ln L}{d\theta_2} = -\frac{n}{\theta_2} + \frac{\sum_{i=1}^n x_i^{\theta_1}}{\theta_2^2} = 0$$

解得 θ_2 的最大似然估计量为

$$\hat{\theta}_2 = \frac{1}{n} \sum_{i=1}^n X_i^{\theta_1}$$

 **作业 18** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 其中 σ^2 已知, μ 的先验分布为 $N(\nu, \tau^2)$ 。

1. 求 μ 的后验分布;
2. 求 μ 的后验均值估计。

东邪的 tip 3.24

所以他本质上就是求条件概率, 也就是我认为是 μ , 算的是我认为是 μ , 现在出现的数据是事实, 所以我们要求的是在事实的前提下, 我认为是 μ 的概率:

$$p(\mu|\mathbf{X}) = \frac{f(\mathbf{X}|\mu) \cdot \pi(\mu)}{f(\mathbf{X})} \propto \underbrace{f(\mathbf{X}|\mu)}_{\text{似然}} \cdot \underbrace{\pi(\mu)}_{\text{先验}}$$

这里为什么似然是这个公式, 因为似然是我们每一个 X_i 都按照假设的参数 μ 计算的概率密度乘上的也就是 μ 就是以知条件

解 似然函数为

$$f(\mathbf{X}|\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \propto \exp\left(-\frac{n(\bar{x} - \mu)^2}{2\sigma^2}\right)$$

先验分布为

$$\pi(\mu) \propto \exp\left(-\frac{(\mu - \nu)^2}{2\tau^2}\right)$$

后验分布满足 $p(\mu|\mathbf{X}) \propto f(\mathbf{X}|\mu) \cdot \pi(\mu)$, 将指数部分合并:

$$-\frac{n(\bar{x} - \mu)^2}{2\sigma^2} - \frac{(\mu - \nu)^2}{2\tau^2} = -\frac{1}{2} \left(\frac{n}{\sigma^2} + \frac{1}{\tau^2} \right) \left(\mu - \frac{\frac{n\bar{x}}{\sigma^2} + \frac{\nu}{\tau^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}} \right)^2 + \text{常数}$$

令 $\frac{1}{\tau_1^2} = \frac{n}{\sigma^2} + \frac{1}{\tau^2}$, $\mu_1 = \tau_1^2 \left(\frac{n\bar{x}}{\sigma^2} + \frac{\nu}{\tau^2} \right)$, 则

1. 后验分布为

$$\mu|\mathbf{X} \sim N(\mu_1, \tau_1^2)$$

2. μ 的后验均值估计 (Bayes 估计) 为

$$\hat{\mu} = \mu_1 = \frac{\frac{n}{\sigma^2} \bar{X} + \frac{1}{\tau^2} \nu}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

东邪的 tip 3.25

恒等式其实就是裂项, $\bar{x} - \mu$ 求出来。最后我们要求的就是一个 μ 减一个数的东西, 所以我们可以只看 μ^2 , μ 前面的系数再配方, 最后变成 $\mu - \mu_1$ 。分母 2 旁边那个就是方差

 **笔记** 第一步: 利用恒等式

$$\sum_{i=1}^n (x_i - \mu)^2 = n(\bar{x} - \mu)^2 + \sum_{i=1}^n (x_i - \bar{x})^2$$

右边第二项与 μ 无关, 用 $\propto$ 略去; 前置系数 $\frac{1}{\sqrt{2\pi}\sigma}$ 同理略去, 故

$$f(\mathbf{X}|\mu) \propto \exp\left(-\frac{n(\bar{x} - \mu)^2}{2\sigma^2}\right)$$

第二步: 将两个指数合并后, 对 μ 做代数配方 (无需任何定理, 与高中配方 $ax^2 + bx + c$ 本质相同), 凑成

$$-\frac{n(\bar{x} - \mu)^2}{2\sigma^2} - \frac{(\mu - \nu)^2}{2\tau^2} = -\frac{1}{2\tau_1^2} (\mu - \mu_1)^2 + \text{常数}$$

其中常数项与 μ 无关, 用 $\propto$ 略去。

 **作业 20** (帕雷托 (Pareto) 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, 其中 θ 的先验分布为 Pareto(a, b), 其

概率密度为

$$\pi(\theta) = \frac{ba^b}{\theta^{b+1}}, \quad a < \theta < \infty, a > 0, b > 0.$$

1. 求 θ 的后验分布;
2. 求 θ 的后验均值估计。

解 似然函数为

$$f(\mathbf{X}|\theta) = \prod_{i=1}^n \frac{1}{\theta} \cdot \mathbf{1}(\theta \geq x_{(n)}) = \theta^{-n} \cdot \mathbf{1}(\theta \geq x_{(n)})$$

先验分布为 $\pi(\theta) \propto \theta^{-(b+1)} \cdot \mathbf{1}(\theta > a)$, 后验分布满足

$$p(\theta|\mathbf{X}) \propto \theta^{-n} \cdot \theta^{-(b+1)} \cdot \mathbf{1}(\theta \geq \max(x_{(n)}, a)) = \theta^{-(n+b+1)} \cdot \mathbf{1}(\theta \geq \max(x_{(n)}, a))$$

对比帕累托分布标准形式, 令 $a' = \max(x_{(n)}, a)$, $b' = n + b$, 则

1. 后验分布为

$$\theta|\mathbf{X} \sim \text{Pareto}(\max(x_{(n)}, a), n + b)$$

2. θ 的后验均值估计 (Bayes 估计) 为

$$\hat{\theta} = \frac{(n + b) \max(x_{(n)}, a)}{n + b - 1}$$

定义 3.1 (帕累托分布)

若随机变量 θ 的概率密度函数为

$$\pi(\theta) = \frac{ba^b}{\theta^{b+1}}, \quad \theta > a, a > 0, b > 0$$

则称 θ 服从参数为 (a, b) 的帕累托分布, 记为 $\theta \sim \text{Pareto}(a, b)$ 。其直觉来源于“二八定律”, 是一种重尾分布。 a 、 b 的含义:

- a : 帕累托分布的最小值, θ 只能取 $\theta > a$ 的值
- b : 形状参数, 控制尾巴有多重, b 越小尾巴越重

在本题中 a, b 是先验的已知参数, 就像正态先验里的 ν, τ^2 一样, 是出发前对 θ 的主观判断的量化。帕累托分布 $\text{Pareto}(a', b')$ 的均值公式为

$$E[\theta] = \frac{b'a'}{b' - 1}, \quad b' > 1$$

代入 $a' = \max(x_{(n)}, a)$, $b' = n + b$:

$$\hat{\theta} = \frac{(n + b) \max(x_{(n)}, a)}{n + b - 1}$$



 **笔记** [共轭先验 Conjugate Prior] 定义: 先验和后验属于同一分布族, 参数可以不同。这是数学上可以证明的结论, 实际使用时记住配对直接用。

常用共轭先验配对:

似然	共轭先验
正态 (方差已知)	正态
均匀 $U(0, \theta)$	帕累托
二项	Beta
泊松	Gamma
指数	Gamma

看见什么似然就条件反射想到对应的先验, 这是贝叶斯计算的基本功。看见均匀似然 + 帕累托先验, 直接知道后验还是帕累托, 只需要找新参数就行了。

 **作业 1** (泊松分布) 设 $X \sim P(\lambda)$, 试求样本量为 1 时 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量, 并说明该估计的不合理性。

解 设 $\hat{g}(X)$ 为 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量, 需满足

$$E[\hat{g}(X)] = \sum_{k=0}^{\infty} \hat{g}(k) \cdot \frac{\lambda^k e^{-\lambda}}{k!} = e^{-2\lambda}$$

求期望只是把权重从 X 变成了 $g(X)$ 其他的不变

$$E[h(X)] = \sum_{k=0}^{\infty} h(k) \cdot P(X=k) = \sum_{k=0}^{\infty} h(k) \cdot \frac{\lambda^k e^{-\lambda}}{k!}$$

注意到 $e^{-2\lambda} = e^{-\lambda} \cdot e^{-\lambda}$, 而泊松分布中 $k=0$ 时 $P(X=0) = e^{-\lambda}$, 故令

$$\hat{g}(k) = (-1)^k$$

验证:

$$E[(-1)^X] = \sum_{k=0}^{\infty} (-1)^k \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(-\lambda)^k}{k!} = e^{-\lambda} \cdot e^{-\lambda} = e^{-2\lambda} \checkmark$$

故 $\hat{g}(X) = (-1)^X$ 是 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量。

不合理性: $g(\lambda) = e^{-2\lambda} \in (0, 1)$, 而估计量 $(-1)^X$ 的取值只有 ± 1 , 当 X 为奇数时估计值为 $-1 < 0$, 与 $g(\lambda)$ 的真实范围完全不符, 因此该估计虽无偏但实际意义很差。

 **笔记** $P(X=0)$ 是确定的

东邪的 tip 3.26 (看见阶乘求和的时候就要想 e)

上面 k 次方是为了求 k 次导自动变成第一项 1 也就是 e 永远展开的第一项 $e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}$

 **作业 2** (二项分布) 设 $X \sim B(n, p)$, 证明 $g(p) = \frac{1}{1+p^2}$ 不存在无偏估计量。

解 假设存在 $g(p) = \frac{1}{1+p^2}$ 的无偏估计量 $\hat{g}(X)$, 则需满足

$$E[\hat{g}(X)] = \sum_{k=0}^n \hat{g}(k) \binom{n}{k} p^k (1-p)^{n-k} = \frac{1}{1+p^2}$$

对所有 $p \in (0, 1)$ 成立。但左边展开后是关于 p 的次数不超过 n 的多项式, 而右边 $\frac{1}{1+p^2}$ 不是多项式, 两者不可能恒等, 矛盾。故 $g(p) = \frac{1}{1+p^2}$ 不存在无偏估计量。

东邪的 tip 3.27

分母含参数就不是多项式

 **笔记** [不存在无偏估计量的证明套路] 用反证法: 假设存在无偏估计量 $\hat{g}(X)$, 则

$$E[\hat{g}(X)] = g(\theta), \quad \forall \theta$$

分析左边 (期望) 关于 θ 的函数性质:

- 离散分布 (如二项): 左边展开后是关于参数的多项式, 若 $g(\theta)$ 不是多项式则矛盾
- 连续分布 (如正态): 分析左边关于 θ 的解析性质, 与 $g(\theta)$ 的性质对比得矛盾

核心: 左边的函数类型有限制, 若 $g(\theta)$ 不满足该限制, 则不存在无偏估计量。

 **作业 3** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, 1)$, 证明 $g(\mu) = |\mu|$ 没有无偏估计量。

解 假设存在 $g(\mu) = |\mu|$ 的无偏估计量 $\hat{g}(X)$, 则需满足

$$E[\hat{g}(X)] = |\mu|, \quad \forall \mu \in \mathbb{R}$$

注意到正态分布的期望

$$E[\hat{g}(X)] = \int_{-\infty}^{\infty} \hat{g}(x) \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2}} dx$$

右边作为 μ 的函数, 可以验证它关于 μ 是解析函数 (光滑且可展开为幂级数)。但 $|\mu|$ 在 $\mu = 0$ 处不可导, 因此不是解析函数, 矛盾。故 $g(\mu) = |\mu|$ 没有无偏估计量。

 **作业 4** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的无偏估计量。

解 均匀分布 $U(\theta_1, \theta_2)$ 的顺序统计量期望为

$$E[X_{(1)}] = \frac{n\theta_1 + \theta_2}{n+1}, \quad E[X_{(n)}] = \frac{\theta_1 + n\theta_2}{n+1}$$

联立解得

$$\theta_1 = \frac{nE[X_{(1)}] - E[X_{(n)}]}{n-1}, \quad \theta_2 = \frac{nE[X_{(n)}] - E[X_{(1)}]}{n-1}$$

故 θ_1, θ_2 的无偏估计量为

$$\hat{\theta}_1 = \frac{nX_{(1)} - X_{(n)}}{n-1}, \quad \hat{\theta}_2 = \frac{nX_{(n)} - X_{(1)}}{n-1}$$

东邪的 tip 3.28 (均匀分布必记)

$$f(x) = \frac{1}{\theta_2 - \theta_1}, \quad F(x) = \frac{x - \theta_1}{\theta_2 - \theta_1}$$

$$E[X_{(1)}] = \frac{n\theta_1 + \theta_2}{n+1}, \quad E[X_{(n)}] = \frac{\theta_1 + n\theta_2}{n+1}$$

 **笔记** 将期望 $E[X_{(1)}]$ 和 $E[X_{(n)}]$ 直接替换为样本观测值 $X_{(1)}$ 和 $X_{(n)}$, 即可得到无偏估计量。本质上就是用样本值替换期望值, 这是构造无偏估计量的标准操作。

 **作业 5** 设 $\hat{\theta}$ 和 θ^* 为 θ 的无偏估计量, 若 $\tilde{\theta} = a\hat{\theta} + b\theta^*$, 问: a, b 满足什么条件时, $\tilde{\theta}$ 也是 θ 的无偏估计量?

解 由期望的线性性质:

$$E[\tilde{\theta}] = E[a\hat{\theta} + b\theta^*] = aE[\hat{\theta}] + bE[\theta^*] = a\theta + b\theta = (a+b)\theta$$

要使 $\tilde{\theta}$ 也是 θ 的无偏估计量, 需 $E[\tilde{\theta}] = \theta$, 故条件为

$$a + b = 1$$

 **作业 6** 设 $X \sim U(0, \theta)$, $X_1, X_2, \dots, X_n$ i.i.d. 为来自 X 的样本, 试分别求 θ^2, θ^{-1} 的无偏估计量。

解 $X \sim U(0, \theta)$ 的顺序统计量最大值期望为 $E[X_{(n)}] = \frac{n\theta}{n+1}$, 故

$$E\left[\frac{n+1}{n}X_{(n)}\right] = \theta$$

即 $\hat{\theta} = \frac{n+1}{n}X_{(n)}$ 是 θ 的无偏估计量。

求 θ^2 的无偏估计量:

需要 $E[X_{(n)}^2]$, 利用 $U(0, \theta)$ 的顺序统计量密度 $f_{(n)}(x) = \frac{nx^{n-1}}{\theta^n}$:

$$E[X_{(n)}^2] = \int_0^\theta x^2 \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n\theta^2}{n+2}$$

故 θ^2 的无偏估计量为

$$\hat{\theta}^2 = \frac{n+2}{n}X_{(n)}^2$$

求 θ^{-1} 的无偏估计量:

$$E[X_{(n)}^{-1}] = \int_0^\theta x^{-1} \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta(n-1)}$$

故 θ^{-1} 的无偏估计量为

$$\widehat{\theta^{-1}} = \frac{n-1}{n}X_{(n)}^{-1} = \frac{n-1}{nX_{(n)}}$$

东邪的 tip 3.29 ($U(0, \theta)$ 顺序统计量矩公式)

$U(0, \theta)$ 的 $X_{(n)}$ 密度为 $f_{(n)}(x) = \frac{nx^{n-1}}{\theta^n}$, 求 $E[X_{(n)}^k]$ 有通用公式:

$$E[X_{(n)}^k] = \int_0^\theta x^k \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta x^{n+k-1} dx = \frac{n}{\theta^n} \cdot \frac{\theta^{n+k}}{n+k} = \frac{n\theta^k}{n+k}$$

记住这一个公式就够了:

$$E[X_{(n)}^k] = \frac{n\theta^k}{n+k}$$

代入不同的 k :

- $k = 1$: $E[X_{(n)}] = \frac{n\theta}{n+1}$
- $k = 2$: $E[X_{(n)}^2] = \frac{n\theta^2}{n+2}$
- $k = -1$: $E[X_{(n)}^{-1}] = \frac{n\theta^{-1}}{n-1}$

 **作业 1** 证明:

$$I(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ln f(X; \theta) \right) = -E \left(\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right)$$

证明 记 $S(X; \theta) = \frac{\partial}{\partial \theta} \ln f(X; \theta)$, 称为得分函数。

第一步: 证明 $E[S(X; \theta)] = 0$ 。

由于 $\int f(x; \theta) dx = 1$, 两边对 θ 求导并交换积分与求导顺序, 得

$$\int \frac{\partial}{\partial \theta} f(x; \theta) dx = 0.$$

注意到

$$\frac{\partial}{\partial \theta} f(x; \theta) = f(x; \theta) \cdot S(x; \theta),$$

故 $E[S(X; \theta)] = 0$ 。

第二步: 对 $\int S(x; \theta) f(x; \theta) dx = 0$ 再次对 θ 求导:

$$\int \left(\frac{\partial^2}{\partial \theta^2} \ln f \cdot f + S^2 \cdot f \right) dx = 0,$$

即

$$E \left(\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right) + E(S^2) = 0.$$

第三步: 由 $E[S] = 0$ 得 $\text{Var}(S) = E(S^2)$, 故

$$I(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ln f(X; \theta) \right) = -E \left(\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right).$$

东邪的 tip 3.30

$I\theta = \text{var}$ 是确定的, 其实这里就是要巧妙利用 $E(S)$ 的期望是 0, 他期望是 0 的原因就是因为导数和积分可以交换位置然后概率密度积分永远是 1, 然后 $\ln S$ 求导总有一个 $1/s$ 所以此才会有 $f \cdot S = f/d\theta$ 。求期望就是要乘 f 的所以这里的积分最后都能写成期望

3.5 第七周作业

 **作业 7** 设 W 是 θ 的无偏估计量, 若 W 满足

(1) W 是观察值 (样本) 的线性函数;

(2) $E_{\theta}W = \theta, \forall \theta \in \Theta$;

(3) 若对任意一个满足 (1),(2) 的估计 W^* , 有

$$\text{Var}_{\theta}(W) \leq \text{Var}_{\theta}(W^*), \quad \forall \theta \in \Theta,$$

则称 W 是 θ 的最优线性无偏估计量。如总体 $X \sim N(\mu, \sigma^2)$, $(\mu, \sigma^2) \in \Theta = \{(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma^2 > 0\}$ 。证明 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 μ 的最优线性无偏估计量。该结论只对正态总体正确吗?

解 验证条件 (1): $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是观察值的线性函数, 条件 (1) 成立。

验证条件 (2): 由于 $X \sim N(\mu, \sigma^2)$,

$$E_{\mu} \bar{X} = \frac{1}{n} \sum_{i=1}^n EX_i = \frac{1}{n} \cdot n\mu = \mu, \quad \forall (\mu, \sigma^2) \in \Theta,$$

故 $\bar{X}$ 是 μ 的无偏估计, 条件 (2) 成立。

验证条件 (3): 设 $W^* = \sum_{i=1}^n c_i X_i$ 是任意满足条件 (1)(2) 的估计量, 则由无偏性:

$$EW^* = \sum_{i=1}^n c_i \mu = \mu \cdot \sum_{i=1}^n c_i = \mu,$$

故 $\sum_{i=1}^n c_i = 1$ 。又由于 $X_1, \dots, X_n$ 独立同分布,

$$\text{Var}_{\theta}(W^*) = \sigma^2 \sum_{i=1}^n c_i^2.$$

由 Cauchy-Schwarz 不等式:

$$\sum_{i=1}^n c_i^2 \geq \frac{(\sum_{i=1}^n c_i)^2}{n} = \frac{1}{n},$$

等号当且仅当 $c_1 = \dots = c_n = \frac{1}{n}$ 时成立, 即 $W^* = \bar{X}$ 。故

$$\text{Var}_{\theta}(W^*) \geq \frac{\sigma^2}{n} = \text{Var}_{\theta}(\bar{X}), \quad \forall \theta \in \Theta.$$

条件 (3) 成立, $\bar{X}$ 是 μ 的最优线性无偏估计量。

该结论只对正态总体正确吗? 不是。上述证明中仅用到了 X_i 独立同分布、 $EX_i = \mu$ 、 $\text{Var}(X_i) = \sigma^2 < \infty$, 并未用到正态性。由 Gauss-Markov 定理, 对任意有限方差的总体, $\bar{X}$ 都是 μ 的最优线性无偏估计量 (BLUE)。

东邪的 tip 3.31

这是一个新定义的题, 先验证条件 (1), 再验证无偏 (即期望是参数), 然后验证方差最小。

验证方差最小时, 任意取一个满足条件的估计量 W^* 。题目规定了线性函数无偏只能写成 $W^* = \sum_{i=1}^n c_i X_i$ 的形式。注意这里

$$EW^* = \sum_{i=1}^n c_i E(X_i),$$

每个 $E(X_i)$ 都等于 μ , 所以整个 $EW^* = \mu \cdot \sum_{i=1}^n c_i$ 。又因为无偏要求期望等于参数 μ , 故 $\sum_{i=1}^n c_i = 1$ 。要让 $\text{Var}_{\theta}(W^*)$ 最小, 由于 $X_1, \dots, X_n$ 独立, 协方差项全为 0, 直接提系数平方出来:

$$\text{Var}_{\theta}(W^*) = \sigma^2 \sum_{i=1}^n c_i^2.$$

定理 3.1 (Cauchy-Schwarz 不等式)

设 $a_1, \dots, a_n, b_1, \dots, b_n \in \mathbb{R}$, 则

$$\left(\sum_{i=1}^n a_i b_i \right)^2 \leq \left(\sum_{i=1}^n a_i^2 \right) \left(\sum_{i=1}^n b_i^2 \right),$$

等号当且仅当 $\frac{a_1}{b_1} = \dots = \frac{a_n}{b_n}$ (即 a_i 与 b_i 成比例) 时成立。即两向量内积不超过模长之积, 等号当两向量平行时取到。 $|\mathbf{a} \cdot \mathbf{b}| \leq |\mathbf{a}| |\mathbf{b}|$



作业 11 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明:

(1) $\bar{X}$ 是 λ 的 UMVUE;

(2) $\tilde{\lambda}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}$ 为 λ^2 的无偏估计量。该估计是 UMVUE 吗?

解 (1) 泊松分布 $P(\lambda)$ 的概率质量函数为

$$P(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots$$

可以写成指数族形式, 充分完备统计量为 $T = \sum_{i=1}^n X_i$ 。

$\bar{X}$ 是 T 的函数, 且

$$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \lambda,$$

故 $\bar{X}$ 是 λ 的无偏估计。由 Lehmann-Scheffé 定理, 基于完备充分统计量的无偏估计是 UMVUE, 故 $\bar{X}$ 是 λ 的 UMVUE。

(2) 首先验证无偏性。对于 $P(\lambda)$, 有 $E(X_i) = \lambda$, $\text{Var}(X_i) = \lambda$, 故 $E(X_i^2) = \lambda^2 + \lambda$ 。从而

$$E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) = \lambda^2 + \lambda,$$

$$E(\bar{X}) = \lambda,$$

$$E(\tilde{\lambda}^2) = (\lambda^2 + \lambda) - \lambda = \lambda^2.$$

故 $\tilde{\lambda}^2$ 是 λ^2 的无偏估计量。

下面判断其是否为 UMVUE。充分完备统计量为 $T = \sum_{i=1}^n X_i \sim P(n\lambda)$ 。将 $\tilde{\lambda}^2$ 改写为 T 的函数:

$$\tilde{\lambda}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}.$$

注意到

$$\sum_{i=1}^n X_i^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n\bar{X}^2 = (n-1)s_n^2 + \frac{T^2}{n},$$

其中 $s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。但 $\tilde{\lambda}^2$ 不能仅由 T 表示 (含有 $\sum X_i^2$ 项, 依赖样本的更多信息), 故 $\tilde{\lambda}^2$ 不是完备充分统计量 T 的函数。

而基于 T 的 λ^2 的 UMVUE 应当是 $g(T)$ 满足 $E[g(T)] = \lambda^2$ 的唯一函数。计算可得

$$g(T) = \frac{T(T-1)}{n^2} = \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n X_i - 1)}{n^2}$$

满足

$$E[g(T)] = \frac{E[T(T-1)]}{n^2} = \frac{n^2 \lambda^2}{n^2} = \lambda^2,$$

且 $g(T)$ 是完备充分统计量的函数, 故 $g(T)$ 才是 λ^2 的 UMVUE。

因此 $\tilde{\lambda}^2$ 不是 λ^2 的 UMVUE。

东邪的 tip 3.32 (fisher 函数和似然函数的关系)

似然函数与 Fisher 信息量的关系。对数似然函数为

$$\ell(\theta) = \sum_{i=1}^n \ln f(x_i; \theta),$$

对 θ 求二阶导：

$$\frac{\partial^2 \ell}{\partial \theta^2} = \sum_{i=1}^n \frac{\partial^2}{\partial \theta^2} \ln f(x_i; \theta).$$

由于 $X_1, \dots, X_n$ 独立同分布，取期望后每一项相同，故

$$-E \left[\frac{\partial^2 \ell}{\partial \theta^2} \right] = -\sum_{i=1}^n E \left[\frac{\partial^2}{\partial \theta^2} \ln f(X_i; \theta) \right] = nI(\theta).$$

即 n 个样本的总 Fisher 信息量是单个样本的 n 倍，C-R 下界 $\frac{1}{nI(\theta)}$ 中的 n 由此而来。

 **作业 12** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 已知 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 和 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 分别是 μ 和 σ^2 的 UMVUE。计算 μ 和 σ^2 的 C-R 下界。

东邪的 tip 3.33 (得分函数和 fisher 函数的关系)

得分取对数是为了让 $L(\theta)$ 连乘变连加，而且对 $\ln$ 求导自然出现 $\frac{1}{f}$ ，直接完成归一化。

$\frac{\partial}{\partial \theta} \ln f$ 叫做得分函数 (score function)，它衡量的是：当 θ 变化时，观测到当前数据 X 的“惊讶程度”变化有多快。

$I(\theta)$ fisher 函数就是这个得分函数的方差也是二阶矩（因为可以证明得分函数期望为 0，所以它的二阶矩就等于方差）。

解 正态总体 $X \sim N(\mu, \sigma^2)$ 的对数密度为

$$\ln f(x; \mu, \sigma^2) = -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x - \mu)^2}{2\sigma^2}.$$

东邪的 tip 3.34

因为有两个参数既可以对 μ 求导也能对 σ 求导

计算 μ 的 C-R 下界：将 σ^2 视为已知，对 μ 求导：

$$\frac{\partial}{\partial \mu} \ln f = \frac{x - \mu}{\sigma^2}.$$

Fisher 信息量为

$$I(\mu) = E \left[\left(\frac{\partial}{\partial \mu} \ln f \right)^2 \right] = E \left[\frac{(X - \mu)^2}{\sigma^4} \right] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}.$$

故 μ 的 C-R 下界为

$$\frac{1}{nI(\mu)} = \frac{\sigma^2}{n}.$$

而 $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ ，达到 C-R 下界，故 $\bar{X}$ 是 μ 的 UMVUE。

计算 σ^2 的 C-R 下界：将 μ 视为已知，令 $\lambda = \sigma^2$ ，对 λ 求导：

$$\frac{\partial}{\partial \lambda} \ln f = -\frac{1}{2\lambda} + \frac{(x - \mu)^2}{2\lambda^2}.$$

Fisher 信息量为

$$I(\lambda) = E \left[\left(-\frac{1}{2\lambda} + \frac{(X - \mu)^2}{2\lambda^2} \right)^2 \right].$$

展开并利用 $(X - \mu)^2 \sim \lambda \chi^2(1)$ ，即 $E(X - \mu)^2 = \lambda$ ， $E(X - \mu)^4 = 3\lambda^2$ ：

$$I(\lambda) = \frac{1}{4\lambda^2} - \frac{E(X - \mu)^2}{2\lambda^3} + \frac{E(X - \mu)^4}{4\lambda^4} = \frac{1}{4\lambda^2} - \frac{1}{2\lambda^2} + \frac{3}{4\lambda^2} = \frac{1}{2\lambda^2} = \frac{1}{2\sigma^4}.$$

故 σ^2 的 C-R 下界为

$$\frac{1}{nI(\sigma^2)} = \frac{2\sigma^4}{n}.$$

而 $\text{Var}(s^2) = \frac{2\sigma^4}{n-1} > \frac{2\sigma^4}{n}$, 故 s^2 未达到 C-R 下界, 但仍是 σ^2 的 UMVUE。

东邪的 tip 3.35

因为 UMVUE 是针对某个特定参数定义的——方差最小的无偏估计量, 不同参数当然对应不同的估计量。C-R 下界是所有无偏估计方差的一个充分条件, 不是必要条件——达到下界一定是 UMVUE, 但 UMVUE 不一定达到下界。因为 2π 是常数, $\ln(2\pi\lambda) = \ln(2\pi) + \ln\lambda$, 对 λ 求导时 $\ln(2\pi)$ 直接消掉, 只剩 $\frac{1}{\lambda}$ 。

 **作业 14** 在定理 3.3.3 的条件下, 若 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的估计量, 满足

$$E_{\theta}\hat{g}(X_1, X_2, \dots, X_n) = g(\theta) + b(\theta), \quad \forall \theta \in \Theta \subset \mathbf{R},$$

$b(\theta)$ 为估计的偏差, 则有

$$\text{Var}_{\theta}(\hat{g}(X_1, X_2, \dots, X_n)) \geq [b'(\theta) + g'(\theta)]^2 / nI(\theta).$$

证明 设 $\hat{g} = \hat{g}(X_1, X_2, \dots, X_n)$, 由题设条件,

$$E_{\theta}\hat{g} = g(\theta) + b(\theta).$$

对两边关于 θ 求导, 在定理 3.3.3 的正则条件下可交换积分与微分, 得

$$\frac{d}{d\theta} E_{\theta}\hat{g} = g'(\theta) + b'(\theta).$$

另一方面,

$$\frac{d}{d\theta} E_{\theta}\hat{g} = \frac{d}{d\theta} \int \hat{g} \cdot L(\theta; \mathbf{x}) d\mathbf{x} = \int \hat{g} \cdot \frac{\partial \ln L(\theta; \mathbf{x})}{\partial \theta} \cdot L(\theta; \mathbf{x}) d\mathbf{x} = E_{\theta} \left[\hat{g} \cdot \frac{\partial \ln L}{\partial \theta} \right],$$

其中 $L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta)$ 为似然函数。又由正则条件知

$$E_{\theta} \left[\frac{\partial \ln L}{\partial \theta} \right] = 0,$$

故

$$E_{\theta} \left[\hat{g} \cdot \frac{\partial \ln L}{\partial \theta} \right] = \text{Cov}_{\theta} \left(\hat{g}, \frac{\partial \ln L}{\partial \theta} \right).$$

因此

$$\text{Cov}_{\theta} \left(\hat{g}, \frac{\partial \ln L}{\partial \theta} \right) = g'(\theta) + b'(\theta).$$

由 Cauchy-Schwarz 不等式,

$$\left[\text{Cov}_{\theta} \left(\hat{g}, \frac{\partial \ln L}{\partial \theta} \right) \right]^2 \leq \text{Var}_{\theta}(\hat{g}) \cdot \text{Var}_{\theta} \left(\frac{\partial \ln L}{\partial \theta} \right).$$

由 Fisher 信息量的定义及 i.i.d. 条件,

$$\text{Var}_{\theta} \left(\frac{\partial \ln L}{\partial \theta} \right) = nI(\theta).$$

将以上各式代入, 得

$$[g'(\theta) + b'(\theta)]^2 \leq \text{Var}_{\theta}(\hat{g}) \cdot nI(\theta),$$

即

$$\text{Var}_{\theta}(\hat{g}) \geq \frac{[g'(\theta) + b'(\theta)]^2}{nI(\theta)}.$$

 **作业 15** 设 $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 都是 $g(\theta)$ 的无偏估计量, 并且 $\hat{g}_1(\mathbf{X})$ 还是 $g(\theta)$ 的 UMVUE, 证明: $\hat{g}_1(\mathbf{X})$ 与 $\hat{g}_2(\mathbf{X})$ 的相关系数非负。

证明 设 $\hat{g}_1 = \hat{g}_1(\mathbf{X})$, $\hat{g}_2 = \hat{g}_2(\mathbf{X})$, 对任意 $\alpha \in \mathbf{R}$, 令

$$\hat{g}_\alpha = (1 - \alpha)\hat{g}_1 + \alpha\hat{g}_2.$$

由 $\hat{g}_1$, $\hat{g}_2$ 均为 $g(\theta)$ 的无偏估计量, 得

$$E_\theta(\hat{g}_\alpha) = (1 - \alpha)g(\theta) + \alpha g(\theta) = g(\theta),$$

故 $\hat{g}_\alpha$ 也是 $g(\theta)$ 的无偏估计量。因 $\hat{g}_1$ 是 $g(\theta)$ 的 UMVUE, 对一切无偏估计量有最小方差, 故

$$\text{Var}_\theta(\hat{g}_1) \leq \text{Var}_\theta(\hat{g}_\alpha), \quad \forall \alpha \in \mathbf{R}.$$

展开右边:

$$\text{Var}_\theta(\hat{g}_\alpha) = (1 - \alpha)^2 \text{Var}_\theta(\hat{g}_1) + 2\alpha(1 - \alpha) \text{Cov}_\theta(\hat{g}_1, \hat{g}_2) + \alpha^2 \text{Var}_\theta(\hat{g}_2).$$

令 $D_1 = \text{Var}_\theta(\hat{g}_1)$, $D_2 = \text{Var}_\theta(\hat{g}_2)$, $C = \text{Cov}_\theta(\hat{g}_1, \hat{g}_2)$, 则条件 $D_1 \leq \text{Var}_\theta(\hat{g}_\alpha)$ 化为

$$D_1 \leq (1 - \alpha)^2 D_1 + 2\alpha(1 - \alpha)C + \alpha^2 D_2,$$

整理得

$$0 \leq \alpha^2(D_1 - 2C + D_2) - 2\alpha(D_1 - C) + 0,$$

即

$$\varphi(\alpha) := \alpha^2(D_1 - 2C + D_2) - 2\alpha(D_1 - C) \geq 0, \quad \forall \alpha \in \mathbf{R}.$$

$\varphi(\alpha)$ 是关于 α 的二次函数且对一切实数非负, 故其判别式满足

$$\Delta = 4(D_1 - C)^2 - 4(D_1 - 2C + D_2)D_1 \leq 0.$$

展开得

$$D_1^2 - 2CD_1 + C^2 - D_1^2 + 2CD_1 - D_1D_2 \leq 0,$$

$$C^2 \leq D_1D_2,$$

即

$$\text{Cov}_\theta(\hat{g}_1, \hat{g}_2)^2 \leq \text{Var}_\theta(\hat{g}_1) \text{Var}_\theta(\hat{g}_2).$$

这与 Cauchy-Schwarz 不等式一致。进一步, 取 $\alpha = 1$, 则 $\hat{g}_\alpha = \hat{g}_2$, 条件给出

$$D_1 \leq D_2,$$

取 $\alpha \rightarrow 0^+$ 方向分析 $\varphi(\alpha) \geq 0$: $\varphi(\alpha)/\alpha \geq 0$ 对小正 α 成立, 即

$$\alpha(D_1 - 2C + D_2) - 2(D_1 - C) \geq 0 \text{ 当 } \alpha \rightarrow 0^+,$$

取极限得

$$-2(D_1 - C) \geq 0 \implies C \geq D_1 \geq 0.$$

从而

$$\text{Cov}_\theta(\hat{g}_1, \hat{g}_2) \geq D_1 = \text{Var}_\theta(\hat{g}_1) \geq 0.$$

因此相关系数

$$\rho(\hat{g}_1, \hat{g}_2) = \frac{\text{Cov}_\theta(\hat{g}_1, \hat{g}_2)}{\sqrt{\text{Var}_\theta(\hat{g}_1) \text{Var}_\theta(\hat{g}_2)}} \geq \frac{D_1}{\sqrt{D_1 D_2}} = \sqrt{\frac{D_1}{D_2}} \geq 0.$$

故 $\hat{g}_1(\mathbf{X})$ 与 $\hat{g}_2(\mathbf{X})$ 的相关系数非负。

[例 3.2.12(0-1 分布)] 设 $X_1, X_2, \dots, X_n$ i.i.d., 都服从 (0-1) 分布 $B(1, \theta)$, θ 的先验分布为 Beta 分布 $\text{Beta}(a, b)$, 其概率密度为

$$\pi(\theta) = \begin{cases} \frac{1}{B(a, b)} \theta^{a-1} (1 - \theta)^{b-1}, & \theta \in (0, 1); \\ 0, & \theta \notin (0, 1), \end{cases}$$

其中 $a > 0, b > 0$ 为给定的常数, $B(a, b)$ 为 Beta 函数. 求 θ 的后验均值估计.

 **作业 16** (0-1 分布) 考虑例 3.2.12 中的贝叶斯估计量, 其中 θ 的贝叶斯估计量为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i + a}{n + a + b}.$$

(1) 求该估计量的均方误差.

解 令 $S = \sum_{i=1}^n X_i \sim B(n, \theta)$, 则 $ES = n\theta$, $\text{Var}(S) = n\theta(1 - \theta)$.

计算偏差:

$$E\hat{\theta} - \theta = \frac{n\theta + a}{n + a + b} - \theta = \frac{a - (a + b)\theta}{n + a + b}.$$

计算方差:

$$\text{Var}(\hat{\theta}) = \frac{\text{Var}(S)}{(n + a + b)^2} = \frac{n\theta(1 - \theta)}{(n + a + b)^2}.$$

均方误差:

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2 = \frac{n\theta(1 - \theta) + [a - (a + b)\theta]^2}{(n + a + b)^2}.$$

东邪的 tip 3.36

就是尽量引入期望或者方差因为有固定的公式, 也是因为方差和期望是稳定的

 **笔记** 拆分 $(\hat{\theta} - \theta) = (\hat{\theta} - E\hat{\theta}) + (E\hat{\theta} - \theta)$ 是为了把随机波动 (方差) 和系统误差 (偏差) 分开, 展开后交叉项期望为 0, 故

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2.$$

计算时利用 $S \sim B(n, \theta)$ 的结论 $ES = n\theta$, $\text{Var}(S) = n\theta(1 - \theta)$, 再通过线性变换性质

$$E(cS + d) = cES + d, \quad \text{Var}(cS) = c^2\text{Var}(S)$$

传递到 $\hat{\theta} = \frac{S + a}{n + a + b}$, 分别算出偏差和方差后相加即得 MSE.

3.5.1 3.4

 **作业 1** 设 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{a.s.} a > 0$, 证明:

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{a}.$$

证明 因 $Y_n \xrightarrow{a.s.} a$, 由依概率收敛与几乎处处收敛的关系, $Y_n \xrightarrow{P} a$, 从而

$$\frac{1}{Y_n} \xrightarrow{P} \frac{1}{a}.$$

由 Slutsky 定理, 若 $X_n \xrightarrow{d} X$, $Z_n \xrightarrow{P} c$ (常数), 则 $X_n Z_n \xrightarrow{d} cX$. 取 $Z_n = \frac{1}{Y_n}$, $c = \frac{1}{a}$, 得

$$\frac{X_n}{Y_n} = X_n \cdot \frac{1}{Y_n} \xrightarrow{d} \frac{1}{a} \cdot X = \frac{X}{a}.$$

 **作业 1** 若估计序列 $\{\hat{\theta}_n\}$ 满足 $\lim_{n \rightarrow \infty} E_\theta(\hat{\theta}_n - \theta)^2 = 0$, $\forall \theta \in \Theta$, 则称 $\hat{\theta}_n$ 为 θ 的均方相合估计量. 证明: 均方相合估计必是相合估计量.

证明 由 Chebyshev 不等式, 对任意 $\varepsilon > 0$,

$$P(|\hat{\theta}_n - \theta| \geq \varepsilon) \leq \frac{E_\theta(\hat{\theta}_n - \theta)^2}{\varepsilon^2}.$$

因 $\lim_{n \rightarrow \infty} E_\theta(\hat{\theta}_n - \theta)^2 = 0$, 故

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0,$$

即 $\hat{\theta}_n \xrightarrow{P} \theta$, $\hat{\theta}_n$ 是 θ 的相合估计量.

作业 2 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, $\hat{\theta}_n = X_{(n)}$ 是 θ 的均方相合估计量吗?

解 $X_{(n)}$ 的密度函数为

$$f_{X_{(n)}}(x) = \frac{nx^{n-1}}{\theta^n}, \quad 0 < x < \theta.$$

计算期望与二阶矩:

$$E(X_{(n)}) = \int_0^\theta x \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{n+1}\theta,$$

$$E(X_{(n)}^2) = \int_0^\theta x^2 \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{n+2}\theta^2.$$

从而

$$E_\theta(X_{(n)} - \theta)^2 = E(X_{(n)}^2) - 2\theta E(X_{(n)}) + \theta^2 = \frac{n}{n+2}\theta^2 - \frac{2n}{n+1}\theta^2 + \theta^2 = \frac{2\theta^2}{(n+1)(n+2)} \rightarrow 0.$$

故 $X_{(n)}$ 是 θ 的均方相合估计量。

作业 4 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明: $\bar{X}$, s_n^2 都是 λ 的相合估计量。

证明 对于 $P(\lambda)$, 有 $E(X_1) = \lambda$, $\text{Var}(X_1) = \lambda$, $E(X_1^2) = \lambda^2 + \lambda$ 。

$\bar{X}$ 的相合性: 由大数定律, $\bar{X} \xrightarrow{P} E(X_1) = \lambda$, 故 $\bar{X}$ 是 λ 的相合估计量。

s_n^2 的相合性: 样本方差

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2.$$

由大数定律, $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X_1^2) = \lambda^2 + \lambda$, $\bar{X}^2 \xrightarrow{P} \lambda^2$ 。由连续映射定理,

$$s_n^2 \xrightarrow{P} (\lambda^2 + \lambda) - \lambda^2 = \lambda,$$

故 s_n^2 是 λ 的相合估计量。

作业 5 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, 试证

$$T(X_1, X_2, \dots, X_n) = \sqrt[n]{X_1 X_2 \cdots X_n}$$

为 $g(\theta) = \frac{\theta}{e}$ 的相合估计量。

证明 令 $Y_i = \ln X_i$ 。因 $X_i \sim U(0, \theta)$, 故

$$E(Y_i) = \int_0^\theta \ln x \cdot \frac{1}{\theta} dx = \ln \theta - 1,$$

$$\text{Var}(Y_i) = E(Y_i^2) - (EY_i)^2 < \infty.$$

由大数定律,

$$\frac{1}{n} \sum_{i=1}^n \ln X_i \xrightarrow{P} \ln \theta - 1 = \ln \frac{\theta}{e}.$$

因指数函数连续, 由连续映射定理,

$$T = \exp\left(\frac{1}{n} \sum_{i=1}^n \ln X_i\right) = \sqrt[n]{X_1 X_2 \cdots X_n} \xrightarrow{P} \frac{\theta}{e} = g(\theta),$$

故 T 是 $g(\theta)$ 的相合估计量。

作业 6 设总体的二阶矩存在, $X_1, X_2, \dots, X_n$ 是总体的简单随机样本, 则

$$T(X_1, X_2, \dots, X_n) = \frac{2}{n(n+1)} \sum_{i=1}^n i X_i$$

是一阶原点矩的相合估计量。

证明 设总体一阶原点矩为 $\mu = E(X_1)$ 。计算 T 的期望:

$$E(T) = \frac{2}{n(n+1)} \sum_{i=1}^n i \cdot E(X_i) = \frac{2\mu}{n(n+1)} \sum_{i=1}^n i = \frac{2\mu}{n(n+1)} \cdot \frac{n(n+1)}{2} = \mu.$$

计算 T 的方差, 设 $\text{Var}(X_1) = \sigma^2 < \infty$:

$$\text{Var}(T) = \frac{4}{n^2(n+1)^2} \sum_{i=1}^n i^2 \sigma^2 = \frac{4\sigma^2}{n^2(n+1)^2} \cdot \frac{n(n+1)(2n+1)}{6} = \frac{2\sigma^2(2n+1)}{3n(n+1)} \rightarrow 0.$$

由 Chebyshev 不等式, $T \xrightarrow{P} \mu$, 故 T 是一阶原点矩的相合估计量。

 **作业 8** (指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta) = \frac{1}{\theta} e^{-x/\theta}$, $x > 0$, 试证 θ 的 MLE 之渐近分布为 $N\left(\theta, \frac{\theta^2}{n}\right)$ 。

证明 对数似然函数为

$$\ell(\theta) = -n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n X_i.$$

令 $\ell'(\theta) = 0$, 解得 MLE 为 $\hat{\theta} = \bar{X}$ 。

对于指数分布, $E(X_1) = \theta$, $\text{Var}(X_1) = \theta^2$ 。由中心极限定理,

$$\sqrt{n}(\bar{X} - \theta) \xrightarrow{d} N(0, \theta^2),$$

即

$$\hat{\theta} = \bar{X} \xrightarrow{d} N\left(\theta, \frac{\theta^2}{n}\right).$$

故 θ 的 MLE 的渐近分布为 $N\left(\theta, \frac{\theta^2}{n}\right)$ 。

第4章 纯作业

4.1 第一周作业

page44

- 作业3 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 其中 μ 是已知数, 而 σ^2 是未知的, 指出下列各量哪些是统计量, 哪些不是统计量, 并说明理由:

$$\sum_{i=1}^n X_i, \quad X_1 + 2\mu, \quad \max_{1 \leq i \leq n} \{X_i\}, \quad \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}, \quad \sum_{i=1}^n (X_i - \mu)^2.$$

- 作业4 某机床加工出的零件的直径服从正态分布 $N(\mu, \sigma^2)$, μ, σ^2 未知。为对 μ, σ^2 作出估计, 随机选取加工出来的 n 个零件进行测量, 得到 n 个数据

$$x_1, x_2, \dots, x_n.$$

试写出该问题的统计模型 (即参数空间和样本分布族)。

- 作业6 (柯西分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., X_1 服从柯西分布, 概率密度为

$$f(x, \sigma) = \frac{1}{\pi \sigma} \frac{1}{1 + (x/\sigma)^2}, \quad -\infty < x < \infty,$$

求

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

的抽样分布。

page45

- 作业1 证明 (2.2.3) 式。
作业2 (几何分布) 设总体 X 服从几何分布

$$P\{X = k\} = p(1-p)^{k-1}, \quad k = 1, 2, \dots,$$

$X_1, X_2, \dots, X_n$ 是取自 X 的简单随机样本, 求 $X_{(1)}, X_{(n)}$ 的分布。

- 作业3 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$, 试分别求出 $X_{(1)}$ 和 $X_{(n)}$ 的概率密度。

4.2 第二周作业

page45

- 作业4 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F(x)$ 有概率密度 $f(x)$, 求:

- (1) $X_{(1)}$ 和 $X_{(n)}$ 的联合分布函数及联合概率密度;
- (2) $R = X_{(n)} - X_{(1)}$ 的分布函数及概率密度。

- 作业5 从某总体抽取一个容量为 5 的样本:

$$-2.8, -1, 1.5, 2.1, 3.4.$$

写出该样本的经验分布函数并画出它的图形。

- 作业6 证明: 正态分布 $N(\mu, \sigma^2)$ 的上 α ($0 < \alpha < 1$) 分位数 z_α 与标准正态分布的上 α 分位数 u_α 之间有以下关系:

$$z_\alpha = \mu + \sigma u_\alpha.$$

page46

作业 1 (χ^2 分布) 设 $X \sim \chi^2(n)$, 证明:

$$E(X^k) = 2^k \left(\frac{n}{2} + k - 1\right) \left(\frac{n}{2} + k - 2\right) \cdots \frac{n}{2}, \quad k = 1, 2, \dots$$

特别地, 有

$$E(X) = n, \quad \text{Var}(X) = 2n.$$

作业 2 (t 分布) 设 $X \sim t(n)$, 则当 $k < n$ 时, $E(X^k)$ 存在且有

$$E(X^k) = \begin{cases} 0, & \text{当 } k \text{ 为奇数;} \\ \frac{n^{k/2} \Gamma\left(\frac{k+1}{2}\right) \Gamma\left(\frac{n-k}{2}\right)}{\sqrt{\pi} \Gamma\left(\frac{n}{2}\right)}, & \text{当 } k \text{ 为偶数.} \end{cases}$$

当 $k \geq n$ 时, $E(X^k)$ 是否存在?

作业 3 (χ^2 分布) 设 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$, X_1, X_2 相互独立, 则 $X_1 + X_2$ 与 X_1/X_2 相互独立。

作业 5 设 $F \sim F(m, n)$, 证明

$$F_{1-\alpha}(m, n) F_{\alpha}(n, m) = 1, \quad \forall \alpha \in (0, 1).$$

作业 设 $X_1, X_2, \dots, X_n$ 独立, $A_{2 \times n}$ 已知,

$$Y = AX,$$

讨论 Y 与 X 的分布类型是否相同。

作业 (χ^2 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$\mathbf{X} = (X_1, \dots, X_n)^T,$$

A 为 n 阶对称方阵。证明:

$$\mathbf{X}^T A \mathbf{X} \sim \chi^2(r)$$

当且仅当 A 为幂等矩阵, 即

$$A^2 = A,$$

并且

$$\text{rank}(A) = r.$$

4.3 第三周

作业 设 $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, 又设 $X_{n+1} \sim N(\mu, \sigma^2)$, 且与 $X_1, \dots, X_n$ 相互独立。记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

证明

$$T = \sqrt{\frac{n}{n+1}} \frac{\bar{X} - X_{n+1}}{s} \sim t(n-1).$$

作业 2.4 第 1 题 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

求 $\text{Var}(s^2)$ 。

作业 2.4 第 2 题 设 $X_1, \dots, X_m$ i.i.d., $X_1 \sim N(\mu_1, \sigma^2)$; $Y_1, \dots, Y_n$ i.i.d., $Y_1 \sim N(\mu_2, \sigma^2)$, 且这两组随机变量相

互独立。记

$$s_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \quad s_2^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

1. 求

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{\sigma^2}$$

的分布;

2. 比较 s_1^2 与

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}$$

的方差。

 **作业 2.4 第 3 题** 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$, 求

$$Z = \frac{\sum_{i=1}^{n-1} X_i}{X_n}$$

的分布。

 **作业 1** (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 分别用一阶矩和二阶矩求 λ 的矩估计量。

 **作业 2** (二项分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim B(k, p)$, 求 p 的矩估计量。

 **作业 3** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的矩估计量。

 **作业 5** (双边指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x)$,

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x|}{\sigma}\right),$$

求 σ 的矩估计量。

4.4 第五周作业

 **作业 7** 设 $X_1, X_2, \dots, X_n$ i.i.d., 试分别求下列总体中 θ 的最大似然估计量。

2. (韦布尔分布) $f(x; \theta) = \frac{x}{\theta^2} e^{-x^2/\theta^2}$, $x > 0$, $\theta > 0$.

 **作业 8** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U\left(\theta - \frac{1}{2}, \theta + \frac{1}{2}\right)$, 证明任意

$$T \in \left[X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2}\right]$$

都是 θ 的最大似然估计量。

 **作业 10** (双参数指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x; \alpha, \beta)$,

$$f(x; \alpha, \beta) = \begin{cases} \beta \exp\{-\beta(x - \alpha)\}, & x \geq \alpha, \\ 0, & \text{其他,} \end{cases}$$

其中 $\beta > 0$ 。试求 α, β 的最大似然估计量。

 **作业 11** (截尾几何分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., 为来自截尾几何分布总体 X 的样本:

$$P\{X = k\} = \theta^{k-1}(1 - \theta), \quad k = 1, 2, \dots, r;$$

$$P\{X = r + 1\} = \theta^r.$$

记

$$M = \#\{i : X_i = r + 1, i = 1, 2, \dots, n\},$$

试证明 θ 的 MLE 为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i - n}{\sum_{i=1}^n X_i - M}.$$

作业 12 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta_1, \theta_2)$,

$$f(x, \theta_1, \theta_2) = \begin{cases} \frac{\theta_1}{\theta_2} x^{\theta_1-1} \exp\left(-\frac{x^{\theta_1}}{\theta_2}\right), & x \geq 0, \\ 0, & \text{其他,} \end{cases}$$

其中 θ_1 已知, 求 θ_2 的最大似然估计量。

作业 18 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 其中 σ^2 已知, μ 的先验分布为 $N(\nu, \tau^2)$ 。

1. 求 μ 的后验分布;
2. 求 μ 的后验均值估计。

作业 20 (帕雷托 (Pareto) 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, 其中 θ 的先验分布为 $\text{Pareto}(a, b)$, 其概率密度为

$$\pi(\theta) = \frac{ba^b}{\theta^{b+1}}, \quad a < \theta < \infty, a > 0, b > 0.$$

1. 求 θ 的后验分布;
2. 求 θ 的后验均值估计。

作业 1 (泊松分布) 设 $X \sim P(\lambda)$, 试求样本量为 1 时 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量, 并说明该估计的不合理性。

作业 2 (二项分布) 设 $X \sim B(n, p)$, 证明 $g(p) = \frac{1}{1+p^2}$ 不存在无偏估计量。

作业 3 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, 1)$, 证明 $g(\mu) = |\mu|$ 没有无偏估计量。

作业 4 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的无偏估计量。

作业 5 设 $\hat{\theta}$ 和 θ^* 为 θ 的无偏估计量, 若 $\tilde{\theta} = a\hat{\theta} + b\theta^*$, 问: a, b 满足什么条件时, $\tilde{\theta}$ 也是 θ 的无偏估计量?

作业 6 设 $X \sim U(0, \theta)$, $X_1, X_2, \dots, X_n$ i.i.d. 为来自 X 的样本, 试分别求 θ^2, θ^{-1} 的无偏估计量。

4.5 第七周作业

作业 7 设 W 是 θ 的无偏估计量, 若 W 满足

- (1) W 是观察值 (样本) 的线性函数;
- (2) $E_\theta W = \theta, \forall \theta \in \Theta$;
- (3) 若对任意一个满足 (1),(2) 的估计 W^* , 有

$$\text{Var}_\theta(W) \leq \text{Var}_\theta(W^*), \quad \forall \theta \in \Theta,$$

则称 W 是 θ 的最优线性无偏估计量。如总体 $X \sim N(\mu, \sigma^2)$, $(\mu, \sigma^2) \in \Theta = \{(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma^2 > 0\}$ 。

证明 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 μ 的最优线性无偏估计量。该结论只对正态总体正确吗?

作业 11 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明:

- (1) $\bar{X}$ 是 λ 的 UMVUE;
- (2) $\tilde{\lambda}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}$ 为 λ^2 的无偏估计量。该估计是 UMVUE 吗?

作业 12 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 已知 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 和 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 分别是 μ 和 σ^2 的 UMVUE。计算 μ 和 σ^2 的 C-R 下界。

作业 14 在定理 3.3.3 的条件下, 若 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的估计量, 满足

$$E_\theta \hat{g}(X_1, X_2, \dots, X_n) = g(\theta) + b(\theta), \quad \forall \theta \in \Theta \subset \mathbf{R},$$

$b(\theta)$ 为估计的偏差, 则有

$$\text{Var}_\theta(\hat{g}(X_1, X_2, \dots, X_n)) \geq [b'(\theta) + g'(\theta)]^2 / nI(\theta).$$

作业 15 设 $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 都是 $g(\theta)$ 的无偏估计量, 并且 $\hat{g}_1(\mathbf{X})$ 还是 $g(\theta)$ 的 UMVUE, 证明: $\hat{g}_1(\mathbf{X})$ 与 $\hat{g}_2(\mathbf{X})$ 的相关系数非负。

作业 16 (0-1 分布) 考虑例 3.2.12 中的贝叶斯估计量, 其中 θ 的贝叶斯估计量为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i + a}{n + a + b}.$$

(1) 求该估计量的均方误差。

作业 1 设 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{a.s.} a > 0$, 证明:

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{a}.$$

作业 1 若估计序列 $\{\hat{\theta}_n\}$ 满足 $\lim_{n \rightarrow \infty} E_{\theta}(\hat{\theta}_n - \theta)^2 = 0$, $\forall \theta \in \Theta$, 则称 $\hat{\theta}_n$ 为 θ 的均方相合估计量。证明: 均方相合估计必是相合估计量。

作业 2 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, $\hat{\theta}_n = X_{(n)}$ 是 θ 的均方相合估计量吗?

作业 4 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明: $\bar{X}$, s_n^2 都是 λ 的相合估计量。

作业 5 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, 试证

$$T(X_1, X_2, \dots, X_n) = \sqrt[n]{X_1 X_2 \cdots X_n}$$

为 $g(\theta) = \frac{\theta}{e}$ 的相合估计量。

作业 6 设总体的二阶矩存在, $X_1, X_2, \dots, X_n$ 是总体的简单随机样本, 则

$$T(X_1, X_2, \dots, X_n) = \frac{2}{n(n+1)} \sum_{i=1}^n i X_i$$

是一阶原点矩的相合估计量。

作业 8 (指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta) = \frac{1}{\theta} e^{-x/\theta}$, $x > 0$, 试证 θ 的 MLE 之渐近分布为 $N\left(\theta, \frac{\theta^2}{n}\right)$ 。