



数理统计

Elegant $\text{\LaTeX}$ 经典之作

作者: Ethan Deng & Liam Huang

组织: Elegant $\text{\LaTeX}$ Program

时间: April 9, 2022

版本: 4.3

自定义: 信息



不要以为抹消过去，重新来过，即可发生什么改变。——比企谷八幡

目录

第 1 章 第一章基础知识	1
第 2 章 参数估计	14
2.1 3.3 点估计量评价	17
2.2 估计量的大样本性质	20
2.3 渐进相对效率	23
2.3.1 区间估计	23
2.3.2 正态的性质们	24
第 3 章 假设检验	26
3.1 基础知识	26
3.2 正态总体参数的检验	27
3.3 非正态分布	28
3.4 奈曼皮尔逊	28
3.5 4.5 无偏检验和一致无偏检验	31
3.6 4.6 拟合优度检验	31
第 4 章 回归分析	33
4.1 简单线性回归模型	33
4.2 投影与幂等矩阵	34
第 5 章 作业	35
5.1 第一周作业	35
5.2 第二次作业	40
5.2.1 45,3,4,6	40
5.2.2 46,1,2,3	42
5.3 第三次作业	45
5.4 第五周作业	48
5.5 无偏估计	52
5.6 第七周作业	55
5.6.1 3.4	64
5.7 第八周作业	66
5.7.1 3.5	69
5.8 第九周作业	72
5.8.1 4.1	74
5.8.2 4.2	77
5.9 第 10 周作业	80
5.9.1 4.3	80
5.10 第 11 周作业	82
5.10.1 4.4	82
5.11 12 周	88
5.12 13 周	91
5.13 14 周	93

第 6 章 纯作业	95
6.1 第一周作业	95
6.2 第二周作业	95
6.3 第三周	96
6.4 第五周作业	97
6.5 第七周作业	98
6.6 第八周作业	99
6.6.1 3.5	99
6.7 第九周作业	100
6.8 4.1	100
6.9 4.2	100
6.10 第 10 周作业	101
6.10.1 4.3	101
6.11 第 11 周作业	101
6.12 4.4	101
6.13 12 周作业	102
第 7 章 基础工具层	103
7.1 顺序统计量	103
7.2 抽样分布, 卡方, t , F	105
7.2.1 卡方 t 与伽马函数	107
7.3 正态三定理	108
7.3.1 前置引理	109
7.4 柯西分布	110
第 8 章 能力一	112
8.1 矩估计	112
8.2 MLE	112
8.2.1 如何算 mle	113
8.3 贝叶斯	113
8.3.1 后验	113
8.3.2 beta 函数	114
8.3.3 帕累托	116
第 9 章 能力二	117
9.1 无偏估计	117
9.2 umvue+CR	118
9.2.1 fisher 信息	118
9.2.2 CR	120
9.3 umvue	121
9.3.1 完备充分统计量	121
9.3.2 因子分解定理	122
9.3.3 指数族的优越性	123
9.4 相和与渐进正态	124
9.4.1 相和	124
9.5 MLE 与渐进正态分布	126

9.5.1 渐近正态	127
9.5.2 渐近效率	129
第 10 章 能力三	130
10.1 置信区间	130
10.2 枢轴量法 (Pivotal quantity method)	132
第 11 章 能力 4	134
11.1 功效函数与两类错误	134
11.2 正态总体检验	135
11.3 NP-UMP	137
11.4 卡方拟合优度检验	139
第 12 章 能力五综合应用	141
12.1 最小二乘与检验	141
12.2 方差分析	142
第 13 章 一些思考	144
13.1 posong 与二项	144
13.2 ump 与 umvue	144

第1章 第一章基础知识

定义 1.1 (偏度系数 Skewness Coefficient)

设随机变量 X 的均值为 μ , 标准差为 σ , 其总体偏度 γ_1 定义为三阶标准化矩:

$$\gamma_1 = E \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{E[(X - \mu)^3]}{\sigma^3}$$

对于样本 $x_1, x_2, \dots, x_n$, 样本偏度 g_1 定义为:

$$g_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right]^{3/2}}$$

当 $\gamma_1 > 0$ 时, 分布为右偏; 当 $\gamma_1 < 0$ 时, 分布为左偏; 对于对称分布, 若其三阶中心矩存在, 则 $\gamma_1 = 0$ 。

东邪的 tip 1.1

一阶中心矩永远等于 0, 二阶会抹杀正负号无法看见方向此外, 三次方对离均值较远的“尾部”更加敏感。在统计学中, 偏度主要关心的就是那个“尾巴”有多长。三次方能把远离均值的极端值权重放大, 从而更准确地捕捉到分布的倾斜趋势。

例题 1.1 设某种电子元件的寿命 X 服从指数分布 $\mathcal{E}(\lambda)$, 其概率密度为

$$f(x; \lambda) = \begin{cases} \frac{1}{\lambda} e^{-\frac{x}{\lambda}}, & x > 0; \\ 0, & \text{其他,} \end{cases}$$

其中 $\lambda > 0$ 。求样本 $(X_1, X_2, \dots, X_n)^T$ 的概率分布。

解 依题意有 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \lambda)$, 故所求的概率分布为

$$\prod_{i=1}^n f(x_i; \lambda) = \begin{cases} \frac{1}{\lambda^n} \exp \left(-\frac{1}{\lambda} \sum_{i=1}^n x_i \right), & x_1, x_2, \dots, x_n > 0; \\ 0, & \text{其他.} \end{cases}$$

定义 1.2

设 $(X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本, $f(x; \theta)$ 为总体的概率密度函数 (或分布律)。由于样本中的每个观测值 $X_1, X_2, \dots, X_n$ 相互独立且与总体同分布 (i.i.d.), 则称它们的联合概率密度函数 (或联合分布律) 为该样本的概率分布, 记为:

$$L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

其中, $x_1, x_2, \dots, x_n$ 为样本观测值, θ 为待估参数。

 **笔记** 关于“联合分布连乘积”意义的直观理解: 黑箱摸球实验

为了理解为什么需要将 n 个样本的密度函数相乘, 我们可以设定如下实验场景:

- 场景设定: 假设一个黑箱中的纸条数字服从指数分布 $\mathcal{E}(\lambda)$, 但参数 λ 未知。我们独立抽样得到三张纸条, 数字分别为 $x_1 = 1, x_2 = 2, x_3 = 3$ 。
- 连乘的逻辑:
 - 抽到 1 的可能性由 $f(1; \lambda)$ 决定;
 - 抽到 2 的可能性由 $f(2; \lambda)$ 决定;
 - 抽到 3 的可能性由 $f(3; \lambda)$ 决定。

由于抽样是独立的, 这三个数字“同时出现”的总可能性 (联合密度) 就是它们各自可能性的乘积:

$$L(\lambda) = f(1; \lambda) \times f(2; \lambda) \times f(3; \lambda)$$

• 公式推导的意义：

- 评估证据：如果我们代入不同的 λ (如 $\lambda = 1$ 和 $\lambda = 5$)，连乘积结果更大的那个 λ ，在逻辑上就更像是产生这组数据的“真相”。
- 信息压缩：通过连乘，我们发现所有的样本信息最终都浓缩在了 $\sum x_i$ (样本总和) 中。
- 决策基础：这个连乘得到的“联合分布”式子，是后续进行极大似然估计 (寻找最优参数) 的唯一数学依据。

结论：连乘积不是单纯的数学堆砌，它是将分散的观测数据 (证词) 汇聚成统一逻辑证据 (结案报告) 的过程。

2.1

定义 1.3 (总体、样本与抽样)

设 X 表示研究对象某个指标，其取值分布 F_X (或总体分布) 称为总体。通过观察或试验，从总体中获取部分个体指标取值的过程称为抽样。

把一次抽样结果看成随机向量

$$(X_1, X_2, \dots, X_n)^T,$$

则称其为来自总体 X (或 F_X) 的一个样本；其概率分布称为样本分布。对应的具体取值

$$(x_1, x_2, \dots, x_n)$$

称为样本观察值。其中 n 称为样本大小，也称样本容量。



东邪的 tip 1.2 (概率论里面学的都是总体)

1. 概率论里，通常先给定随机变量 X 的分布，再研究它的性质；
2. 数理统计里，则把研究对象的某个指标记为 X ，把它的分布看作总体分布，再根据样本去反推这个分布中的未知信息。

定义 1.4 (简单随机样本)

若样本 $X_1, X_2, \dots, X_n$ 满足：

- 各分量同分布，即每个 X_i 都与总体 X 有相同分布；
- 各分量相互独立，

则称 $X_1, X_2, \dots, X_n$ 为来自总体 X 的简单随机样本，记作

$$X_1, X_2, \dots, X_n \text{ i.i.d.}$$

若总体分布函数为 $F(x)$ (或概率密度为 $f(x)$)，常记作

$$X_1 \sim F(x) \quad (\text{或 } X_1 \sim f(x)).$$



东邪的 tip 1.3

从 X 中选取具体的 X_1 就是抽样，一次抽样并不意味着只得到一个数；一次抽样可以抽取 n 个个体，从而得到一个容量为 n 的样本

$$X_1, X_2, \dots, X_n.$$

其中每个 X_i 是样本观察值，而整组数据才称为一个样本。

例题 1.2 设总体 $X \sim E(\lambda)$, 其概率密度为

$$f(x; \lambda) = \begin{cases} \frac{1}{\lambda} e^{-x/\lambda}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

若 $X_1, X_2, \dots, X_n$ 为来自该总体的简单随机样本, 则样本分布为

$$\prod_{i=1}^n f(x_i; \lambda) = \begin{cases} \frac{1}{\lambda^n} \exp\left(-\frac{1}{\lambda} \sum_{i=1}^n x_i\right), & x_1, x_2, \dots, x_n > 0, \\ 0, & \text{其他.} \end{cases}$$

 **笔记** 所以这个概率分布就是一次抽样抽到这个样本的概率对吧也就是 100 个观测值概率的乘积; 若总体是连续型, 这里写出的则是联合概率密度, 而不是单点概率。

定义 1.5 (参数、参数空间与分布族)

总体分布中出现的常数称为参数; 若有多个参数, 它们组成的向量称为参数向量; 其值未知时称为未知参数。参数所有可能取值构成的集合称为参数空间, 常记为 Θ 。

若总体概率密度 (或概率函数) 写成

$$f(x; \theta), \quad \theta \in \Theta,$$

则由参数空间中所有可能参数值所对应的一族总体分布

$$\{f(x; \theta) : \theta \in \Theta\}$$

称为总体分布族; 对应的一族样本分布

$$\left\{ \prod_{i=1}^n f(x_i; \theta) : \theta \in \Theta \right\}$$

称为样本分布族。



 **笔记** 在数理统计中, 未知的通常不是样本本身, 而是总体分布中的参数。比如正态总体 $N(\mu, \sigma^2)$ 中未知的是 μ, σ^2 , 指数分布 $E(\lambda)$ 中未知的是 λ , 二项分布 $B(n, p)$ 中未知的是 p 。因此把总体写成

$$f(x; \theta)$$

就是在说明: 分布的形式已知, 但其中参数 θ 的真实取值未知。这样一来, 问题就从“研究一个模糊的总体”转化为“研究未知参数 θ ”。

定义 1.6 (统计模型与参数统计问题)

样本分布族称为统计模型。若总体分布形式已知, 只需对其中未知参数作出推断, 则称这类问题为参数统计问题。



 **笔记** 因此, 统计模型通常由两部分确定: 一是参数空间 Θ , 二是由 Θ 所决定的样本分布族。换言之, 所谓“建立统计模型”, 本质上就是说明样本来自哪一族分布, 以及其中哪些参数是未知的。

定义 1.7 (统计量与抽样分布)

设 $X_1, X_2, \dots, X_n$ 是来自总体的样本。若一个量

$$T = T(X_1, X_2, \dots, X_n)$$

是样本的完全已知函数, 即它只依赖于样本而不含未知参数, 则称 T 为统计量。

代入样本观察值

$$x_1, x_2, \dots, x_n$$

后所得的

$$T(x_1, x_2, \dots, x_n)$$

称为统计量的观测值。

由于样本 $(X_1, X_2, \dots, X_n)$ 是随机向量，统计量作为样本的函数也是随机变量；统计量的概率分布称为它的抽样分布。



定义 1.8 (常见统计量)

由样本构造的常见统计量有：样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

样本方差

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

以及极差

$$R = \max_{1 \leq i \leq n} X_i - \min_{1 \leq i \leq n} X_i.$$

它们都只依赖于样本，因而都是统计量。



2.2

定义 1.9 (顺序统计量)

设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本，将 $X_1, X_2, \dots, X_n$ 按从小到大的顺序排列为

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)},$$

称 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 为 $X_1, X_2, \dots, X_n$ 的顺序统计量；称 $X_{(r)}$ 为第 r 个顺序统计量。

显见 $X_{(1)} = \min_{1 \leq i \leq n} \{X_i\}$ 是样本中的最小值，而 $X_{(n)} = \max_{1 \leq i \leq n} \{X_i\}$ 是最大值。对第 r 个顺序统计量 $X_{(r)}$ 的分布有如下结论。



例题 1.3 灯泡寿命与顺序统计量 为了直观理解这些抽象符号，我们看一个生活中的“灯泡寿命”例子。

1. 什么是 $X_1, X_2, \dots, X_n$? (原始样本)

想象你买了 3 个型号完全一样的灯泡（此时 $n = 3$ ），装在客厅的吊灯里。

- X_1 ：第 1 个灯泡实际亮了多少小时。
- X_2 ：第 2 个灯泡实际亮了多少小时。
- X_3 ：第 3 个灯泡实际亮了多少小时。

当你还没拆封时，它们每个人的寿命都服从厂家给出的分布 $F(x)$ 。比如厂家说“平均寿命 1000 小时”，这就是总体分布。

2. 什么是 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$? (排序后的统计量)

等你把这 3 个灯泡用坏了，你会得到三个具体的数，比如： $X_1 = 1200$ 小时， $X_2 = 800$ 小时， $X_3 = 1050$ 小时。顺序统计量就是把这些数按从小到大重新排队：

- $X_{(1)} = 800$ ：这是第一个坏掉的灯泡寿命（最小值）。
- $X_{(2)} = 1050$ ：这是第二个坏掉的灯泡寿命（中位数）。
- $X_{(3)} = 1200$ ：这是最后一个坏掉的灯泡寿命（最大值）。

3. 公式 (2.2.2) 在说什么 ? (直观推导)

公式 $f_{(r)}(x) = rC_n^r F^{r-1}(x)[1 - F(x)]^{n-r} f(x)$ 看着吓人，其实在讲一个排列组合的故事。假设你想求“第二个灯泡在 $x = 1000$ 小时准时坏掉”的概率密度，这意味着在那一时刻：

- 正好有 1 个灯泡寿命就是 1000（对应 $f(x)$ ）。
- 有 $r - 1$ 个（即 1 个）灯泡比 1000 短，已经先坏了（对应 $F(x)^{r-1}$ ）。
- 有 $n - r$ 个（即 1 个）灯泡比 1000 长，还在亮着（对应 $[1 - F(x)]^{n-r}$ ）。
- rC_n^r （也就是 $\frac{n!}{(r-1)!(n-r)!}$ ）：是因为你并不关心到底是哪一只灯泡先坏，哪一只后坏，所以要算上所有的排列组合情况。

总结

- X_i 是杂乱无章的原始数据（比如班里随机 10 个人的身高）。
- $X_{(r)}$ 是排好序的数据（比如这 10 个人里身高排第 3 的那个人）。

在可靠性工程里，如果你把灯泡串联， $X_{(1)}$ （第一个坏的）就决定了电路什么时候断；如果你是并联备份， $X_{(n)}$ （最后一个坏的）才决定了系统什么时候彻底瘫痪。

定理 1.1 (顺序统计量的分布)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 是相应的顺序统计量，则对 $1 \leq r \leq n$ 有

$$P\{X_{(r)} \leq x\} = rC_n^r \int_0^{F(x)} t^{r-1}(1-t)^{n-r} dt. \quad (2.2.1)$$

若 $F(x)$ 具有概率密度 $f(x)$ ，则 $X_{(r)}$ 也有概率密度

$$f_{(r)}(x) = rC_n^r F^{r-1}(x)[1 - F(x)]^{n-r} f(x). \quad (2.2.2)$$

 **笔记** 顺序统计量与二项分布的关系 这个积分的物理意义来自于一个著名的恒等式。第 r 个顺序统计量 $X_{(r)} \leq x$ 等价于“至少有 r 个样本落在了 x 的左边”。用二项分布来写就是：

$$P\{X_{(r)} \leq x\} = \sum_{k=r}^n C_n^k [F(x)]^k [1 - F(x)]^{n-k}$$

数学家们发现，这个离散的求和公式，竟然可以完美地写成一个连续积分的形式：作业 2.2.3

$$\sum_{k=r}^n C_n^k p^k (1-p)^{n-k} = \frac{n!}{(r-1)!(n-r)!} \int_0^p t^{r-1}(1-t)^{n-r} dt$$

这里 $p = F(x)$ 。所以，这个积分的数学意义就是“累积概率的连续化表达”。

东邪的 tip 1.4 (学习新公式都要把他拆成几个部分)

回忆一下 $F(X) = P(X \leq x)$ ，积分区域其实就是每一个点都要带入自变量位置然后乘上他那个点的微元也就是 dt 再累加。F 上面是 $r-1$ 代表前面的 $r-1$ 个， $n-r$ 代表 r 后面的 $n-r$ 个。 $n-r+1+r-1=n$

东邪的 tip 1.5

有 c 几几自然想到排列组合。上面 P 以求导， $F(x)$ 自然替换 t 的位置就成了下面。1. 代数上的等价首先，你要知道 rC_n^r 其实只是多项式系数 (Multinomial Coefficient) 的另一种写法：

$$rC_n^r = r \cdot \frac{n!}{r!(n-r)!} = r \cdot \frac{n!}{r \cdot (r-1)!(n-r)!} = \frac{n!}{(r-1)!1!(n-r)!}$$

这个公式的右边非常直观，它代表把 n 个不同的样本分成了三组：

- 第一组：有 $r - 1$ 个样本，它们都小于 x ；
- 第二组：有 1 个样本，它恰好等于 x （这就是我们要找的第 r 个）；
- 第三组：有 $n - r$ 个样本，它们都大于 x 。

例题 1.4 班级考试成绩与分位数 为了帮你透彻理解这些定义，我们用一个“班级考试成绩”的例子来拆解。假

设一个班级有 n 个学生，他们的分数就是样本 $X_1, X_2, \dots, X_n$ 。

1. 样本中位数 (Sample Median) ——找“最中间”的人

中位数的规则很简单：如果人数是奇数，就取正中间那个；如果是偶数，就取中间两个人的平均分。

- **场景 A：人数为奇数** ($n = 5$)：假设成绩排序后是：60, 70, **75**, 85, 90。这里 $n = 2k + 1 = 5$ ，所以 $k = 2$ 。中位数 $M = X_{(k+1)} = X_{(3)} = 75$ 分。
- **场景 B：人数为偶数** ($n = 6$)：假设成绩排序后是：60, 70, **75, 80**, 85, 90。这里 $n = 2k = 6$ ，所以 $k = 3$ 。中位数 $M = \frac{1}{2}(X_{(3)} + X_{(4)}) = \frac{75+80}{2} = 77.5$ 分。

2. 样本上 α 分位数——找“前 10%”的门槛

“上 α 分位数”其实就是：从高往低数，排在前面那 α 比例的门槛。

- **例子**： $n = 10$ 个人，想找上 $\alpha = 0.2$ 分位数（即前 20% 的分数线）
- 计算索引： $[n(1 - \alpha) + 0.5] = [10(1 - 0.2) + 0.5] = [8.5] = 8$ 。
- 结论：排序后的第 8 个数 $X_{(8)}$ 就是上 0.2 分位数。
- 直观理解：总共 10 个人，第 8、9、10 名是前 30%。第 8 名正好是跨入“前 20%”梯队的那个守门员。

3. 总体分位数 (x_α) ——理想状态的“及格线”

总体分位数是针对整个分布（比如全国所有考生的理想模型）来说的。

- **例子**：假设全国成绩服从 0 到 100 的均匀分布 $U[0, 100]$
- 分布函数 $F(x) = \frac{x}{100}$ （对于 $0 \leq x \leq 100$ ）。
- **求上 $\alpha = 0.1$ 分位数**（即前 10% 的分数线）：根据定义，我们要找 x_α 使得 $F(x_\alpha) \geq 1 - 0.1 = 0.9$ 。
 $\frac{x}{100} = 0.9 \implies x = 90$ 。
- **物理意义**：在理想模型中，只要你考到 90 分，你就超过了 90% 的人，成功挤进前 10%。

4. 为什么定义里要用 $\inf$ (下确界)？

这是为了处理那些“不连续”的情况（比如掷骰子）。

- 假设你想找掷骰子点数的“上 0.5 分位数”（中位数）。点数的分布函数是阶梯状的。当 $x = 3$ 时， $F(3) = 0.5$ ；当 x 稍微大一点点，概率可能就跳上去了。
- **$\inf$ 的作用**：它像一个自动定位装置，即便分布函数在某个地方有断层或平台，它也能帮你精准锁定第一个“达标” ($\geq 1 - \alpha$) 的那个点。

总结

- M (中位数) 是为了看“大众水平”。
- x_α (上分位数) 是为了看“优秀水平”的门槛。
- 样本分位数就是用手头这几个具体的数，去估算那个理想中的“门槛”。

定义 1.10 (分位数与中位数)

对于分布函数 $F(x)$ 以及给定的数 $\alpha \in (0, 1)$ ，定义 x_α 为

$$x_\alpha = \inf\{x : F(x) \geq 1 - \alpha\},$$

称其为该分布的上 α 分位数（或者下 $1 - \alpha$ 分位数）。分布 F 的中位数定义为

$$M_F = \frac{1}{2}(\sup\{x : F(x) \leq 0.5\} + \inf\{x : F(x) \geq 0.5\}).$$

设 $X_1, X_2, \dots, X_n$ 是来自分布函数为 $F(x)$ 之分布的简单随机样本。样本的上 α 分位数定义为 $X_{([n(1-\alpha)+0.5])}$ 。样本中位数定义为

$$M = \begin{cases} X_{(k+1)}, & n = 2k + 1; \\ \frac{1}{2}(X_{(k)} + X_{(k+1)}), & n = 2k, \end{cases}$$

其中 k 为正整数。

由定义有 $F(x_\alpha) \geq 1 - \alpha$ 且 $F(x_\alpha - 0) \leq 1 - \alpha$ ；对于连续型分布，有 $F(x_\alpha) = 1 - \alpha$ 。 $X_{([n(1-\alpha)+0.5])}$ 和

M 分别是与总体量 x_α 和 M_F 对应的统计量。由顺序统计量可以引入经验分布函数的概念。



东邪的 tip 1.6

看到 $\inf$ 也就是下极限，还有 $\sup$ 也就是知道他的出现只是为了解决离散的点或者极限不在集合里面比如 $x \in (0, 1)$ 他没有最大值但是有上界



笔记 指示函数 I 的直观理解 指示函数 (Indicator Function) 是数学中用来表达“逻辑判断”的工具。我们可以把它想象成一个“检测开关”或一个“投票器”。其核心规则只有一条：“满足条件就投 **1** 票，不满足就投 **0** 票。”

针对公式中的符号 $I_{[X_i, \infty)}(x)$ ，我们可以将其拆解为以下三个部分：

- x ：是你现在手里拿着的那个“尺子”或观测点（比如 $x = 2$ ）；
- $[X_i, \infty)$ ：是检测的“合格区间”，表示所有大于等于 X_i 的范围；
- I ：是执行检测的程序逻辑。

具体运行逻辑如下：

- 如果你的尺子 x 掉进了区间 $[X_i, \infty)$ 里面（即 $x \geq X_i$ ），那么这个 I 就输出 **1**；
- 如果你的尺子 x 还没够到 X_i （即 $x < X_i$ ），那么这个 I 就输出 **0**。

在经验分布函数 $F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{[X_i, \infty)}(x)$ 中，这个 I 就在为每一个样本点 X_i 进行检测：凡是那些“躺在 x 左边”的样本，都会让开关变成 1，从而被计入总数中。

例题 1.5 奶茶店等待时间与经验分布函数 假设你在奶茶店随机观测了 $n = 5$ 个人的等待时间（单位：分钟），排序后为：

$$X_{(1)} = 5, \quad X_{(2)} = 10, \quad X_{(3)} = 12, \quad X_{(4)} = 15, \quad X_{(5)} = 25$$

1. 为什么要用指示函数加和再平均？

我们要计算 $F_5(13)$ ，即等待时间小于 13 分钟的概率。公式为：

$$F_5(13) = \frac{1}{5} \sum_{i=1}^5 I_{[X_i, \infty)}(13)$$

这里的每一项都在投票：

- $X_1 = 5 \leq 13$ ，投 1 票；
- $X_2 = 10 \leq 13$ ，投 1 票；
- $X_3 = 12 \leq 13$ ，投 1 票；
- $X_4 = 15 > 13$ ，投 0 票；
- $X_5 = 25 > 13$ ，投 0 票。

总票数为 3，平均票数为 $3/5 = 0.6$ 。这就是我们利用样本对总体概率的“平均估计”。

2. 现实意义总结

- **估算真相**：在不知道奶茶店排队规律（总体分布）的情况下，0.6 是我们根据现有数据能给出的最合理答案。
- **动态更新**：如果你再多测几个人，分母 n 变大，分子也会更新，这个估计会越来越准。

3. 数学意义总结

经验分布函数将离散的观测转化为一个右连续的阶梯函数。根据格列汶科定理，当 $n \rightarrow \infty$ 时，这种基于“求平均”得来的经验估计，将以概率 1 一致地收敛于真正的自然规律。

定义 1.11 (经验分布函数)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, 对任意实数 x , 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{[X_i, \infty)}(x) = \frac{1}{n} \{X_i : X_i \leq x, i = 1, 2, \dots, n\}^\#, \quad (2.2.6)$$

称函数 $F_n(x)$ 为 $X_1, X_2, \dots, X_n$ 的经验分布函数, 式中 $I_A(x)$ 表示集合 A 的指示函数: 当 $x \in A$ 时, $I_A(x) = 1$, 否则 $I_A(x) = 0$ 。

易见, 经验分布函数也可写成

$$F_n(x) = \begin{cases} 0, & x < X_{(1)}; \\ k/n, & X_{(k)} \leq x < X_{(k+1)}, k = 1, 2, \dots, n-1; \\ 1, & x \geq X_{(n)}. \end{cases} \quad (2.2.7)$$



定理 1.2 (经验分布函数的性质)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F_n(x)$ 为其经验分布函数。则对于任意实数 x , 有

1. $P\{\lim_{n \rightarrow \infty} F_n(x) = F(x)\} = 1$.
2. $\lim_{n \rightarrow \infty} P\left\{\frac{\sqrt{n}(F_n(x) - F(x))}{\sqrt{F(x)[1-F(x)]}} \leq y\right\} = \int_{-\infty}^y \phi(u) du$, 其中 $\phi(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$ 为 $N(0, 1)$ 的概率密度函数。



 **笔记** 公式 (2.2.2) 的构造逻辑 该公式的左侧实际上是对经验分布函数 $F_n(x)$ 进行的标准化 (Standardization) 处理。

1. 统计背景

由于 $nF_n(x)$ 服从二项分布 $B(n, p)$, 其中 $p = F(x)$, 根据二项分布的性质:

- 均值 $E[F_n(x)] = p = F(x)$
- 方差 $Var(F_n(x)) = \frac{p(1-p)}{n} = \frac{F(x)[1-F(x)]}{n}$

2. 构造标准化变量

根据中心极限定理 (CLT), 一个随机变量减去期望再除以其标准差, 当 $n \rightarrow \infty$ 时服从标准正态分布:

$$\frac{F_n(x) - E[F_n(x)]}{\sqrt{Var(F_n(x))}} = \frac{F_n(x) - F(x)}{\sqrt{F(x)[1-F(x)]/n}} = \frac{\sqrt{n}(F_n(x) - F(x))}{\sqrt{F(x)[1-F(x)]}}$$

3. 与高斯分布的联系

等式右侧的 $\int_{-\infty}^y \phi(u) du$ 正是标准正态分布 (高斯分布) 的累积分布函数 $\Phi(y)$ 。这表明经验分布函数的点收敛速度是 $\frac{1}{\sqrt{n}}$ 阶的。

定理 1.3 (格列汶科 (Glivenko) 定理)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F_n(x)$ 为其经验分布函数, 记 $D_n = \sup_{-\infty < x < \infty} |F_n(x) - F(x)|$, 则有

$$P\left\{\lim_{n \rightarrow \infty} D_n = 0\right\} = 1.$$



 **笔记** $D_n = \sup |F_n(x) - F(x)|$:

这是 $F_n(x)$ 和 $F(x)$ 之间最大的垂直偏差。之所以用 $\sup$ (上确界), 是因为我们要确保在 x 轴的任何一个点上, 两者都要足够接近。

$$P\{\lim_{n \rightarrow \infty} D_n = 0\} = 1:$$

这意味着这种收敛是“几乎处处收敛”的。无论真实的分布 $F(x)$ 是正态分布、均匀分布还是某种奇怪的分布, 只要样本量够大, 样本就能百分之百代表总体。

2.3

定义 1.12 (卡方分布, 那个像 x 的就念卡)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$ 。令 $\xi = \sum_{i=1}^n X_i^2$, 则称 ξ 的分布为具有自由度 n 的 χ^2 分布。记作 $\xi \sim \chi^2(n)$ 。



东邪的 tip 1.7 (卡方分布要记的公式)

$$E(Y) = k, \quad \text{Var}(Y) = 2k.$$

 **笔记** 自由度更准确地说, 是指真正能自由变化的独立信息个数。

例如, 若

$$Y = Z_1^2 + \dots + Z_n^2, \quad Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1),$$

则 $Y \sim \chi^2(n)$ 。这是因为这里有 n 个彼此独立的标准正态变量, 所以自由度就是 n 。

但若存在约束, 自由度就会减少。例如在样本方差中,

$$\sum_{i=1}^n (X_i - \bar{X})^2$$

虽然看起来有 n 项, 但由于

$$\sum_{i=1}^n (X_i - \bar{X}) = 0,$$

其中一项实际上可由其余各项决定, 因此真正能自由变化的只有 $n-1$ 个, 故自由度为 $n-1$ 。

东邪的 tip 1.8

卡方是一个具体的值他是由每一次所有的 x_i 的平方和算出来的。从 1 到 10 随机抽五个数。每抽一次都可以算出一个卡方。然后把每抽五次当成一个动作, 抽 100 次这样卡也有分布了他服从的技术自由度为 5 的卡方分布。只要对于一个量或者一个设计求出的值, 只要每一次结果不一样他的值就会有分布。但这里有一个问题 1 到 10 是均匀分布到, 要求正太分布的话可以换成从 100000 个人里面抽五个人记录他们的身高。还要进行标准正态化。

 **笔记 1. 理论定义与背景**

若 n 个随机变量 $X_i \sim N(0, 1)$ 且相互独立, 则其平方和 $\xi = \sum_{i=1}^n X_i^2$ 服从自由度为 n 的卡方分布, 记作 $\xi \sim \chi^2(n)$ 。它是衡量观察值与理论值偏离程度的核心工具。

2. 理论模型与皮尔逊统计量

- 理论原型: $\chi^2 = \sum X_i^2$, 基于理想的标准正态变量。
- 应用工具: 皮尔逊统计量 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 。该公式通过分母 E 进行归一化, 使观测偏差在数学特性上趋近于理想卡方分布。

3. 与样本方差的“桥梁”关系

样本方差 s^2 与卡方分布通过以下标准化公式紧密相连:

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$$

两者本质皆为“平方和”: χ^2 是均值为 0、方差为 1 的理论平方和; 而样本方差是经离差标准化与缩放后的现实平方和。由此, 卡方分布成为了推断总体方差、进行区间估计的数学依据。

定理 1.4

设 $\xi \sim \chi^2(n)$, 则 ξ 的概率密度为

$$f(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}, & x > 0; \\ 0, & x \leq 0. \end{cases} \quad (1.1)$$



伽马函数 (Gamma Function)

伽马函数是阶乘函数在复数域上的扩展, 其积分定义为:

$$\Gamma(z) = \int_0^{\infty} t^{z-1} e^{-t} dt \quad (\text{Re}(z) > 0) \quad (1.2)$$

东邪的 tip 1.9

所以分母上 2 的 n 次方上为了和 x 配凑出 x/2 的形式。而陪完了以后积分就是 n/2-1+1= 拉姆达 n/2



笔记 1. 结构拆解: 三位一体

我们可以把这个概率密度函数看作是一个“核心部件”装在一个“标准化外壳”里:

$$f(x) = \underbrace{\frac{1}{2^{n/2} \Gamma(n/2)}}_{\text{归一化常数}} \cdot \underbrace{e^{-x/2}}_{\text{指数衰减项}} \cdot \underbrace{x^{n/2-1}}_{\text{形状调节项}} \quad (1.3)$$

- 形状调节项 ($x^{n/2-1}$): 决定了函数在 $x \rightarrow 0$ 时的形态。若 $n = 2$, 该项为 1, 曲线从纵轴出发; 若 $n > 2$, 它决定了曲线从原点爬升的速度。
- 指数衰减项 ($e^{-x/2}$): 源自正态分布的“基因”, 负责让概率在 x 增大时快速收敛, 防止概率“飘走”。
- 归一化常数: 它的唯一作用是确保曲线下方的总面积 (全概率) 恒等于 1。

定理 1.5 (n 个平方和加 m 个平方和加起来自然是 m+n 个平方和, 就是这两个得独立)

设 $\xi \sim \chi^2(m)$, $\eta \sim \chi^2(n)$, ξ 与 η 相互独立, 则有

$$\xi + \eta \sim \chi^2(m+n).$$



引理 1.1

设 $X_1, X_2, \dots, X_n$ 相互独立, 且

$$X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n.$$

设 $A = (a_{ij})_{n \times n}$ 为一个 $n \times n$ 正交矩阵, 记

$$X = (X_1, X_2, \dots, X_n)^T, \quad Y = AX.$$

则 Y 的各分量 $Y_1, Y_2, \dots, Y_n$ 相互独立, 且

$$Y_i \sim N\left(\sum_{k=1}^n a_{ik} \mu_k, \sigma^2\right), \quad i = 1, 2, \dots, n.$$



1. **独立性保持:** 原始变量 $X_1, \dots, X_n$ 是相互独立的。经过正交矩阵 A 变换后, 新生成的变量 $Y_1, \dots, Y_n$ 依然保持相互独立。
2. **分布形式与方差不变:** 每个 Y_i 依然服从正态分布。最关键的是, 方差 σ^2 保持不变, 只有均值发生了线性变换 (变为 $\sum_{k=1}^n a_{ik} \mu_k$)。

定理 1.6 (柯赫伦 (Cochran) 定理)

设 $X_1, X_2, \dots, X_n$ i.i.d., 且 $X_1 \sim N(0, 1)$, 又设 $A_1, A_2, \dots, A_k$ 为非负定的 $n \times n$ 矩阵, 记

$$X = (X_1, X_2, \dots, X_n)^T, \\ Q_i = X^T A_i X, \quad i = 1, 2, \dots, k.$$

若

$$Q_1 + Q_2 + \dots + Q_k = \sum_{i=1}^n X_i^2,$$

且

$$\text{rank}(A_i) = n_i, \quad i = 1, 2, \dots, k,$$

则 $Q_1, Q_2, \dots, Q_k$ 相互独立且分别有

$$Q_i \sim \chi^2(n_i)$$

的充要条件为

$$n = \sum_{i=1}^k n_i.$$



笔记 [柯赫伦 (Cochran) 定理: 平方和的“拆分艺术”]

- 这个定理 (定理 1.6) 在数理统计中具有奠基性的地位, 它本质上回答了一个核心问题: 什么时候我们可以把一个总平方和拆成几个相互独立的卡方分布?
- **1.** 定理背景假设你有 n 个相互独立且服从标准正态分布 $N(0, 1)$ 的随机变量 $X_1, X_2, \dots, X_n$ 。它们的总平方和 $\sum_{i=1}^n X_i^2$ 本身就是一个自由度为 n 的卡方分布 $\chi^2(n)$ 。
- **2.** 定理的核心逻辑如果你试图将这个总平方和拆解为 k 个二次型之和, 即 $Q_1 + Q_2 + \dots + Q_k = \sum_{i=1}^n X_i^2$, 其中每个 $Q_i = X^T A_i X$, 且 $\text{rank}(A_i) = n_i$ 。
- 定理给出了一个充分必要条件: 当且仅当这些矩阵的秩之和正好等于变量的总个数时, 即 $n = \sum_{i=1}^k n_i$, 这 k 个拆分出来的部分 Q_i 就会具备极好的数学性质:
 - 相互独立: 它们之间互不影响, 没有冗余的信息交叉。
 - 服从卡方分布: 每一个 Q_i 都服从自由度为 n_i 的卡方分布, 即 $Q_i \sim \chi^2(n_i)$ 。

定义 1.13 (t 分布- student 分布)

设随机变量 X, Y 相互独立, $X \sim N(0, 1)$, $Y \sim \chi^2(n)$ 。令

$$\xi = \frac{X}{\sqrt{Y/n}},$$

则 ξ 的分布称为具有自由度 n 的 t 分布, 记作 $\xi \sim t(n)$ 。



1. 为什么要这么构造? (解决“未知方差”的痛点)

在理想状态下, 我们算标准分

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

时, 需要知道总体的标准差 σ 。但在现实的生物统计或实验中, 我们根本不知道真正的 σ 。

- 我们只能用样本标准差 S 来代替 σ 。
- 当你把 σ 换成 S 后, 这个统计量就不再服从正态分布了, 因为它分母上的 S 也是一个带有随机性的变量。
- 于是数学家构造了 $\xi = \frac{X}{\sqrt{Y/n}}$:
 - **分子 X :** 对应标准正态分布 $N(0, 1)$ 。

- **分母 Y/n** : 对应样本方差的分布 (即卡方分布除以自由度)。
- **独立性**: 分子分母相互独立。

这样构造出来的结果, 就是一个专门处理小样本、且总体方差未知情形的分布。

定理 1.7

设 $\xi \sim t(n)$, 则 ξ 的概率密度为

$$f(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < x < \infty.$$



东邪的 tip 1.10 (t 分布密度公式的拆解)

- 咱们得把这个公式拆成核 (**Kernel**) 和归一化常数 (**Coefficient**) 两部分, 用逻辑去“拼”出它。
- **1. 先抓“灵魂”**: 核部分 $\left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$ 。
- 这是决定分布形状的部分。
- 底数 $\left(1 + \frac{x^2}{n}\right)$: 你可以把它看作是正态分布 $e^{-x^2/2}$ 的一种“变体”。当 $n \rightarrow \infty$ 时, 根据重要极限公式 $(1 + 1/n)^n \rightarrow e$, 这个底数最终会变回正态分布。
- 指数 $-\frac{n+1}{2}$: 这里的 n 代表分母里卡方变量的自由度, 1 代表分子里标准正态变量的自由度。两者加起来除以 2, 就是总体的“能量分配”。
- **2. 再配“外壳”**: 系数部分 $\frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)}$ 。
- 这部分的唯一目的就是让全域积分等于 1。
- **Gamma 的位次**: 分子永远是“大的”, 即核里那个指数的正值 $\frac{n+1}{2}$; 分母是“小的”, 即原始自由度的一半 $\frac{n}{2}$ 。
- 常数项 $\sqrt{n\pi}$: $\sqrt{\pi}$ 是正态分布带出来的, $\sqrt{n}$ 是为了抵消核里那个 x^2/n 带来的缩放。

定义 1.14 (费希尔-斯内德克分布 (Fisher-Snedecor distribution).)

设随机变量 X, Y 相互独立, $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$, 令

$$\xi = \frac{X/m}{Y/n},$$

则 ξ 的分布称为具有自由度 m 和 n 的 F 分布, 记作 $\xi \sim F(m, n)$ 。



笔记

1. 它是怎么构造出来的?

你可以把它理解为“比率的比率”。

正如图片中定义的, 如果你有两个相互独立的随机变量 X 和 Y , 它们分别服从自由度为 m 和 n 的卡方分布, 那么它们的“单位贡献比”

$$\xi = \frac{X/m}{Y/n}$$

就服从自由度为 (m, n) 的 F 分布。

2. 它有什么核心作用?

在数学和数据分析实践中, F 分布主要用来干这三件事:

- **比较方差 (方差齐性检验)**: 用来判断两组独立数据的波动程度 (方差) 是否显著不同。如果 F 值很大, 说明分子的波动远大于分母。
- **方差分析 (ANOVA)**: 这是它最出名的舞台。通过比较“组间差异”与“组内差异”的比值, 来判断多个样本均值之间是否存在显著差异。这在你感兴趣的生物统计研究中极其常用。
- **线性回归的显著性检验**: 用来判断你建立的整个回归模型是否真的有效, 还是仅仅是随机噪声凑出来

的。

定理 1.8 (F 的概率密度)

设 $\xi \sim F(m, n)$, 则 ξ 的概率密度为

$$f(x) = \begin{cases} \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} m^{\frac{m}{2}} n^{\frac{n}{2}} x^{\frac{m}{2}-1} (n+mx)^{-\frac{m+n}{2}}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$



定理 1.9 (正态总体样本均值与样本方差的分布定理)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

则

1. $\bar{X} \sim N(\mu, \sigma^2/n)$;
2. $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$;
3. $\bar{X}$ 与 s^2 相互独立。



1. 样本均值的分布

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

说明从正态总体抽样后, 样本均值仍然服从正态分布, 且波动变小到了 σ^2/n 。也就是: 均值的估计越来越稳定。

2. 样本方差的分布

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$$

说明样本方差经过标准化后服从卡方分布。也就是: 方差也有明确的抽样分布, 所以才能做方差估计和区间推断。

3. 样本均值与样本方差相互独立

$$\bar{X} \text{ 与 } s^2 \text{ 相互独立}$$

这是正态总体下非常特殊、非常重要的性质。也就是: 位置信息 (均值) 和离散程度信息 (方差) 彼此分开, 不互相干扰。

第2章 参数估计

例题 2.1 设总体 $X \sim N(\mu, 4)$, 其中 μ 未知, 记 $\theta = \mu$, $\Theta = \mathbb{R}$. 对总体作 4 次观测, 得样本 $X = (X_1, X_2, X_3, X_4)^T$. 若观测值为 $x = (8, 9, 11, 10)^T$, 则:

1. **估计量**: 取样本均值作为 μ 的点估计量, 即 $\hat{\mu}(X) = \bar{X} = \frac{1}{4}(X_1 + X_2 + X_3 + X_4)$.
2. **估计值**: 将样本观测值代入估计量, 得 $\hat{\mu}(x) = \bar{x} = \frac{8+9+11+10}{4} = 9.5$.
3. **置信区间**: 由于 $\bar{X} \sim N(\mu, \frac{4}{4}) = N(\mu, 1)$, 取置信水平 95%, 由 $z_{0.975} = 1.96$, 得 μ 的 95% 置信区间为 $[\bar{X} - 1.96 \frac{2}{\sqrt{4}}, \bar{X} + 1.96 \frac{2}{\sqrt{4}}] = [\bar{X} - 1.96, \bar{X} + 1.96]$. 代入 $\bar{x} = 9.5$, 得 $[9.5 - 1.96, 9.5 + 1.96] = [7.54, 11.46]$. 因此, 本例中估计量为 $\hat{\mu}(X) = \bar{X}$, 估计值为 $\hat{\mu}(x) = 9.5$, 95% 置信区间为 $[7.54, 11.46]$.

定义 2.1 (样本中心矩)

设 $X_1, X_2, \dots, X_n$ i.i.d., 是取自总体 X 的一个样本, 则称 $\hat{\alpha}_k$ 为总体 X 的 k 阶样本原点矩, $\hat{\beta}_k$ 为总体 X 的 k 阶样本中心矩.

笔记

- 二阶样本中心矩: $\hat{\beta}_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, 用来描述样本的离散程度, 也就是数据围绕样本均值的波动大小. 它与样本方差本质上是同一个东西, 只差一个修正系数.
- 三阶样本中心矩: $\hat{\beta}_3 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3$, 用来描述样本分布的偏斜程度. 若它大于 0, 通常表示分布右偏; 若小于 0, 通常表示分布左偏; 若接近 0, 通常表示分布较对称.
- 四阶样本中心矩: $\hat{\beta}_4 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^4$, 用来描述样本分布的峰态, 反映数据分布是更尖、更平, 或者尾部是否更厚.

笔记 $X \sim F_\theta(x)$ 表示随机变量 X 服从一个由参数 θ 决定的分布, 也就是说 X 的分布函数为 $F_\theta(x)$. 其中 θ 取不同的值, 就对应这一族分布中的不同具体分布. $F(x)$ 可以是正态分布可以是均匀分布这个只是抽象的表示.

例题 2.2 设总体均值为 μ , 现不直接估计 μ , 而是要估计参数 $\theta = \mu^2$. 令 $\alpha = \mu$, 则 θ 可写为 $\theta = \theta(\alpha) = \alpha^2$. 又因为 μ 的一个自然估计量是样本均值 $\alpha(X) = \bar{X}$, 故由代入估计法, 将 $\theta(\alpha) = \alpha^2$ 中的 α 用 $\alpha(X) = \bar{X}$ 代替, 得到 θ 的估计量为

$$\theta(\alpha(X)) = (\bar{X})^2.$$

因此, μ^2 的代入估计量为 $\bar{X}^2$.

东邪的 tip 2.1

矩阵就是用来同时解方程的

笔记 上述方法称为矩估计法. 其基本思想是: 若总体分布中含有 k 个未知参数 $\theta = (\theta_1, \theta_2, \dots, \theta_k)^T$, 则选取总体的前 k 个原点矩 $\alpha_1, \alpha_2, \dots, \alpha_k$, 并将它们表示为参数的函数, 即 $\alpha_l = \alpha_l(\theta_1, \theta_2, \dots, \theta_k)$, $l = 1, \dots, k$. 再用相应的样本原点矩 $\frac{1}{n} \sum_{i=1}^n X_i$, $\frac{1}{n} \sum_{i=1}^n X_i^2, \dots, \frac{1}{n} \sum_{i=1}^n X_i^k$ 分别代替总体原点矩, 得到关于 $\theta_1, \theta_2, \dots, \theta_k$ 的方程组

$$\begin{cases} \alpha_1(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i, \\ \alpha_2(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^2, \\ \vdots \\ \alpha_k(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^k. \end{cases}$$

将该方程组的解 $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)^T$ 作为参数 θ 的估计量, 称为矩估计量.

例题 2.3 设总体 $X \sim N(\mu, \sigma^2)$, 其中 μ, σ^2 都未知. 现用矩估计法估计参数 μ 与 σ^2 .

总体的一阶原点矩与二阶原点矩分别为 $E(X) = \mu$ 与 $E(X^2) = \mu^2 + \sigma^2$. 用样本原点矩 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 和

$\frac{1}{n} \sum_{i=1}^n X_i^2$ 分别代替它们，得到方程组

$$\mu = \bar{X}, \quad \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

解得

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2.$$

因此， μ 与 σ^2 的矩估计量分别为 $\bar{X}$ 和 $\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$ 。

定义 2.2 (似然函数 likelihood function, 要求互相独立服从一种类型的分布)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x; \theta)$, $\theta \in \Theta$ 。令

$$L(\theta; x) = L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

为样本 $X = (X_1, \dots, X_n)^T$ 的概率密度 (或概率函数), 视其为 θ 的函数, 称为相应于样本 X 的似然函数; 也称 $L(\theta; X)$ 为相应于样本 X 的似然函数。

东邪的 tip 2.2

似然就是想通过这个函数确定参数的大小

定义 2.3 (MLE 用来确定参数的)

设相应于样本 $X = (X_1, X_2, \dots, X_n)^T$ 的似然函数为 $L(\theta; x)$ 。若 $\hat{\theta}(x) = \hat{\theta}(x_1, x_2, \dots, x_n)$ 满足

$$L(\hat{\theta}(x); x) = \max_{\theta \in \Theta} L(\theta; x),$$

则称 $\hat{\theta}(X)$ 为 θ 的最大似然估计量, 简记为 MLE (Maximum likelihood estimator)。

定理 2.1 (求最大似然估计量的三种常见情形)

设似然函数为 $L(\theta; x)$, 则求最大似然估计量时, 常见有以下三种情形:

- 若 $L(\theta; x)$ 关于 θ 连续可导, 且 Θ 为开区域, 则通常先解似然方程组

$$\frac{\partial L(\theta; x)}{\partial \theta_j} = 0, \quad j = 1, 2, \dots, k,$$

或等价地解对数似然方程组

$$\frac{\partial \ln L(\theta; x)}{\partial \theta_j} = 0, \quad j = 1, 2, \dots, k.$$

- 若 $L(\theta; x)$ 关于 θ 有间断点, 则不能直接用似然方程, 需结合似然函数的具体形式分段讨论, 在定义域内直接比较其大小。
- 若参数 θ 取离散值, 则常通过比较相邻参数值处似然函数的大小, 来确定使 $L(\theta; x)$ 取得最大值的参数。

定理 2.2 (最大似然估计在一一变换下会“跟着变过去”)

设 $X \sim f(x; \theta)$, $\theta \in \Theta$, X 是来自于该分布的一个样本, $\hat{\theta}(X)$ 是 θ 的最大似然估计量。设 $\eta = g(\theta)$ 是由 Θ 到 $\hat{\Theta}$ 上的一一映射, 则 $g(\hat{\theta}(X))$ 是 η 的最大似然估计量。

 笔记 可以让整个最大的 θ 可以不止一个

定义 2.4 (M 估计)

设样本为 $X_1, \dots, X_n$, 参数为 θ 。若 $\hat{\theta}$ 是通过最小化

$$\sum_{i=1}^n \rho(X_i, \theta)$$

得到的估计, 其中 ρ 是关于误差的某个对称凸函数, 则称 $\hat{\theta}$ 为参数 θ 的一个 **M** 估计。

等价地, 若 $\hat{\theta}$ 满足估计方程

$$\sum_{i=1}^n \psi(X_i, \theta) = 0,$$

其中 ψ 常可看作某个函数 ρ 的导数, 则由该方程得到的估计也称为 **M** 估计。



东邪的 tip 2.3

很多 **M** 估计就是为了减弱离群点的影响

例题 2.4 设样本为

$$x_1 = 1, \quad x_2 = 2, \quad x_3 = 10,$$

现用 **M** 估计来估计位置参数 θ 。

1. 若取

$$\rho(u) = u^2,$$

则对应的 **M** 估计为最小化

$$\sum_{i=1}^3 \rho(x_i - \theta) = (1 - \theta)^2 + (2 - \theta)^2 + (10 - \theta)^2.$$

解得

$$\hat{\theta} = \frac{1 + 2 + 10}{3} = \frac{13}{3}.$$

此时得到的就是样本均值。

2. 若取

$$\rho(u) = |u|,$$

则对应的 **M** 估计为最小化

$$\sum_{i=1}^3 \rho(x_i - \theta) = |1 - \theta| + |2 - \theta| + |10 - \theta|.$$

解得

$$\hat{\theta} = 2.$$

此时得到的就是样本中位数。

这说明: **M** 估计的核心思想是先选定损失函数 ρ , 再令总损失最小; 不同的 ρ 会导出不同的估计量。

定义 2.5 (Bayes 估计)

设样本 $X = (X_1, X_2, \dots, X_n)^T$ 来自条件分布 $f(x | \theta)$, 参数 θ 的先验分布为 $\pi(\theta)$ 。在给定样本 X 后, 由贝叶斯公式, θ 的后验分布为

$$p(\theta | X) = \frac{f(X | \theta) \pi(\theta)}{\int_{\Theta} f(X | \theta) \pi(\theta) d\theta}.$$

对于待估参数函数 $g(\theta)$ ，若以其后验均值

$$\hat{g}(X) = \int_{\Theta} g(\theta) p(\theta | X) d\theta = \frac{\int_{\Theta} g(\theta) f(X | \theta) \pi(\theta) d\theta}{\int_{\Theta} f(X | \theta) \pi(\theta) d\theta}$$

作为点估计，则称 $\hat{g}(X)$ 为 $g(\theta)$ 的 **Bayes** 估计，也称后验均值估计。



东邪的 tip 2.4 ($\propto$ 表示正比于)

(proportional to), $A \propto B$ 即 $A = c \cdot B$ ，其中 c 为与关心变量无关的常数。在贝叶斯推断中，由于

$$p(\mu | \mathbf{X}) = \frac{f(\mathbf{X} | \mu) \cdot \pi(\mu)}{f(\mathbf{X})}$$

分母 $f(\mathbf{X})$ 与 μ 无关，故直接写

$$p(\mu | \mathbf{X}) \propto f(\mathbf{X} | \mu) \cdot \pi(\mu)$$

省去分母使计算更简洁，配方完成后自然归一化。



笔记 三个关键概念：

1. 先验分布 $\pi(\theta)$ ：在看到数据之前，你对 θ 的主观判断。比如你觉得一枚硬币正面概率大概在 0.5 左右，这就是先验。
2. 似然函数 $f(X | \theta)$ ：给定参数 θ ，观测到样本 X 的概率。这是数据给你的信息。
3. 后验分布 $p(\theta | X)$ ：看到数据 X 之后，对 θ 的更新判断：

$$p(\theta | X) = \frac{f(X | \theta) \pi(\theta)}{\int_{\Theta} f(X | \theta) \pi(\theta) d\theta}$$

简单说就是：后验 $\propto$ 似然 $\times$ 先验，分母只是归一化常数让概率加起来等于 1。

东邪的 tip 2.5

然后大公式里面的积分就是归一化常数和条件概率里面分母的累加是一样的这里是积分

例题 2.5 抛硬币的 Bayes 估计 设正面概率 θ 的先验为 $\pi(\theta) \sim \text{Beta}(2, 2)$ ，抛硬币 10 次观测到 7 次正面。由 Beta-Binomial 共轭，后验为

$$\theta | X \sim \text{Beta}(2 + 7, 2 + 3) = \text{Beta}(9, 5),$$

Bayes 估计（后验均值）为 $\hat{\theta} = \frac{9}{14} \approx 0.643$ ，相比频率派 MLE $\hat{\theta}_{\text{MLE}} = 0.7$ ，结果被先验适当拉向 0.5。

2.1 3.3 点估计量评价

定义 2.6 ($g(\theta)$ 的无偏估计量)

设 $\hat{g}(\mathbf{X})$ 是 $g(\theta)$ 的估计量，若对于任意 $\theta \in \Theta$ 都有

$$E_{\theta}(\hat{g}(\mathbf{X})) = g(\theta),$$

则称 $\hat{g}(\mathbf{X})$ 为 $g(\theta)$ 的无偏估计量。



估计量的期望等于真实值，就叫无偏估计

例题 2.6 样本均值是总体均值的无偏估计 设总体均值 μ 未知，取样本 $X_1, X_2, X_3 = 4, 5, 9$ ，样本均值为

$$\bar{X} = \frac{4 + 5 + 9}{3} = 6.$$

若真实总体均值 $\mu = 6$, 则 $E(\bar{X}) = \mu = 6$, 即 $\bar{X}$ 是 μ 的无偏估计。

 **笔记** 无偏性与有效性衡量的是估计方法的好坏, 而非样本本身。对同一批样本, 不同估计量的优劣由以下两个标准评价:

- 无偏性: 估计量的期望等于真实参数, 即无系统误差。
- 有效性: 在所有无偏估计量中, 方差最小, 即估计结果最稳定。

「样本取得好不好」对应的是抽样方法 (如随机抽样、分层抽样), 是独立的概念。

定义 2.7 (有效估计量)

设 $\hat{g}(\mathbf{X})$ 和 $\tilde{g}(\mathbf{X})$ 都是 $g(\theta)$ 的无偏估计量, 若

$$\text{Var}_{\theta}(\tilde{g}(\mathbf{X})) \geq \text{Var}_{\theta}(\hat{g}(\mathbf{X})), \quad \forall \theta \in \Theta,$$

且大于号至少在某个 $\theta \in \Theta$ 成立, 则称 $\hat{g}(\mathbf{X})$ 比 $\tilde{g}(\mathbf{X})$ 有效。比值

$$e = \frac{\text{Var}_{\theta}(\hat{g}(\mathbf{X}))}{\text{Var}_{\theta}(\tilde{g}(\mathbf{X}))}$$

称为 $\tilde{g}(\mathbf{X})$ 相对于 $\hat{g}(\mathbf{X})$ 的效率。



东邪的 tip 2.6

$g(\mathbf{X})$ 就是对 $\mathbf{X}$ 操作算出一个 θ 然后, 看见 Var 就知道他比较稳定性了

例题 2.7 样本均值与样本中位数的有效性比较 设总体 $X \sim N(\mu, 1)$, 取样本量 $n = 5$ 。样本均值 $\bar{X}$ 与样本中位数 m 都是 μ 的无偏估计, 但

$$\text{Var}(\bar{X}) = \frac{1}{5} = 0.2, \quad \text{Var}(m) \approx \frac{\pi}{2 \times 5} \approx 0.314.$$

效率为 $e = \frac{0.2}{0.314} \approx 0.637$, 故 $\bar{X}$ 比 m 更有效。

定义 2.8 (一致最小方差无偏估计量)

设 $\hat{g}(\mathbf{X})$ 是 $g(\theta)$ 的一个无偏估计量, 且 $\text{Var}_{\theta}(\hat{g}(\mathbf{X})) < \infty$ 。若对 $g(\theta)$ 的任意无偏估计量 $g^*(\mathbf{X})$, 都有

$$\text{Var}_{\theta}(\hat{g}(\mathbf{X})) \leq \text{Var}_{\theta}(g^*(\mathbf{X})), \quad \forall \theta \in \Theta,$$

则称 $\hat{g}(\mathbf{X})$ 为 $g(\theta)$ 的一致最小方差无偏估计量, 简记作 UMVUE (Uniformly minimum variance unbiased estimator)。



在所有无偏估计里, 方差最小的那个就叫 UMVUE。

定理 2.3 (UMVUE 的充要条件)

设 $\mathcal{U}$ 非空, 则 $\delta(\mathbf{X}) \in \mathcal{U}$ 为 $g(\theta)$ 的 UMVUE 的充要条件是: 对任意 $\delta_0(\mathbf{X}) \in \mathcal{U}_0$, 有

$$E_{\theta}(\delta(\mathbf{X})\delta_0(\mathbf{X})) = 0, \quad \forall \theta \in \Theta.$$



东邪的 tip 2.7

$\mathcal{U}$ 是所有无偏估计的集合 $\mathcal{U}_0$ 就是期望是 0 的无偏估计的集合

 **笔记** 符号说明:

- $\mathcal{U}$: $g(\theta)$ 的所有无偏估计量构成的集合
- $\mathcal{U}_0$: 所有零无偏估计量的集合, 即满足 $E_{\theta}(\delta_0(\mathbf{X})) = 0$ 的估计量
- $\delta(\mathbf{X})$: 待验证是否为 UMVUE 的候选估计量

定理的本质: $\delta(\mathbf{X})$ 是 UMVUE $\iff$ 它与所有零无偏估计量正交, 即

$$E_{\theta}(\delta(\mathbf{X})\delta_0(\mathbf{X})) = 0, \quad \forall \theta \in \Theta, \forall \delta_0 \in \mathcal{U}_0.$$

直觉上, δ_0 是「纯噪声」(期望为零, 不含有效信息)。 δ 与所有噪声正交, 说明其中没有掺入任何多余成分, 因此方差已达最小。

UMVUE 如果存在, 则在以概率 1 相等的意义下是唯一的, 这就是下面的定理。

定理 2.4 (UMVUE 的唯一性)

设 $\delta(\mathbf{X})$, $\delta'(\mathbf{X})$ 都是 $g(\theta)$ 的 UMVUE, 则

$$P_\theta(\delta(\mathbf{X}) = \delta'(\mathbf{X})) = 1, \quad \forall \theta \in \Theta.$$

定义 2.9 (正则条件)

设分布族为 $\{f(x; \theta) : \theta \in \Theta\}$, 其中 θ 为一维未知参数, 所谓正则条件是指:

1. Θ 为开区间;
2. 分布族有共同支撑, 即支撑集 $A = \{x : f(x; \theta) > 0\}$ 与 θ 无关;
3. $\forall x \in A$, $\frac{\partial f(x; \theta)}{\partial \theta}$ 在 Θ 上存在, 且满足 $E_\theta\left(\frac{\partial \ln f(x; \theta)}{\partial \theta}\right) = 0, \quad \forall \theta \in \Theta$;
4. Fisher 信息量

$$I(\theta) = E_\theta \left[\left(\frac{\partial \ln f(x; \theta)}{\partial \theta} \right)^2 \right] = \int_A \left(\frac{\partial \ln f(x; \theta)}{\partial \theta} \right)^2 f(x; \theta) dx > 0, \quad \forall \theta \in \Theta.$$

 **笔记** 正则条件的本质是保证 C-R 下界的推导在数学上成立, 每个条件各自排除一类麻烦:

- 条件 1 (Θ 为开区间): 保证对 θ 求导合法, 排除参数在边界处导数无意义的情况。
- 条件 2 (支撑集与 θ 无关): 排除积分上下限随 θ 变动的情况 (如 $U(0, \theta)$), 从而保证积分与求导可交换顺序。
- 条件 3 (得分函数期望为零): 即 $E_\theta\left(\frac{\partial \ln f(x; \theta)}{\partial \theta}\right) = 0$, 是积分与求导交换顺序的直接体现, 也是推导 C-R 下界的关键一步。
- 条件 4 ($I(\theta) > 0$): 保证 Fisher 信息量有限且为正, 使得 C-R 下界 $\frac{1}{I(\theta)}$ 有实际意义。

四个条件合在一起, 确保对数似然函数关于 θ 足够光滑, C-R 不等式方可成立。

 **笔记** [Fisher 信息量] Fisher 信息量 $I(\theta)$ 度量样本 X 中包含的关于参数 θ 的信息量, 定义为

$$I(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ln f(X; \theta) \right).$$

为什么取对数? 取对数是为了归一化:

$$\frac{\partial}{\partial \theta} \ln f = \frac{1}{f} \cdot \frac{\partial f}{\partial \theta},$$

相当于把导数除以 f 本身, 变成相对变化率, 消除量纲影响。

为什么取方差? $S(X; \theta) = \frac{\partial}{\partial \theta} \ln f(X; \theta)$ 仍是随机变量, 方差是描述其平均波动程度最自然的选择。又由 $E[S] = 0$, 故

$$I(\theta) = \text{Var}(S) = E(S^2),$$

方差等于二阶矩, 计算更方便。 $I(\theta)$ 越大, θ 越好估计。

定理 2.5 (Cramér-Rao 不等式)

设总体分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足正则条件 1—4, 待估函数 $g(\theta)$ 有一阶导数 $g'(\theta)$ 。 $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$ 是取自总体的一个样本, $\hat{g}(\mathbf{X}) = \hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的无偏估计量, 且满足

$$\frac{\partial}{\partial \theta} \int_{A^n} \hat{g}(x_1, \dots, x_n) \prod_{i=1}^n f(x_i; \theta) dx_1 \cdots dx_n = \int_{A^n} \hat{g}(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \left(\prod_{i=1}^n f(x_i; \theta) \right) dx_1 \cdots dx_n,$$

[需要满足积分顺序可交换] 则有

$$\text{Var}_\theta(\hat{g}(\mathbf{X})) \geq \frac{(g'(\theta))^2}{nI(\theta)}, \quad \forall \theta \in \Theta. \quad (2.1)$$



笔记 该定理给出了任意无偏估计量方差的下界 $\frac{(g'(\theta))^2}{nI(\theta)}$, 称为 **C-R** 下界, 无论构造多么巧妙的无偏估计量, 其方差都不可能低于此值。下界由三部分决定:

1. $(g'(\theta))^2$: 待估函数本身的复杂程度, $g(\theta)$ 变化越剧烈, 下界越大;
2. $I(\theta)$: Fisher 信息量, 反映总体模型本身所含的信息量, $I(\theta)$ 越大, 参数越容易估计准确; $I(\theta)$ 可视为大小为 1 的样本所提供的信息量;
3. n : 样本量越大, 下界越小, 估计越精准; $nI(\theta)$ 称为样本的 **Fisher** 信息量, 反映样本 $(X_1, X_2, \dots, X_n)^T$ 所提供的总信息。

若某无偏估计量的方差恰好等于 C-R 下界, 则它已达到最优, 必为 UMVUE, 无法再改进; 若方差远大于下界, 则说明仍有改进空间。

2.2 估计量的大样本性质

定义 2.10 (相合估计量与强相合估计量)

设 $\hat{g}_n = \hat{g}_n(X_1, X_2, \dots, X_n)$ 为 $g(\theta)$ 的估计量。

若对任意固定的 $\theta \in \Theta$, 对任给的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P_\theta\{|\hat{g}_n - g(\theta)| > \varepsilon\} = 0,$$

则称 $\hat{g}_n$ 为 $g(\theta)$ 的相合估计量, 简记为 $\hat{g}_n \xrightarrow{P} g(\theta)$ 。

若对任何固定的 $\theta \in \Theta$ 都有

$$P_\theta\left\{\lim_{n \rightarrow \infty} \hat{g}_n = g(\theta)\right\} = 1,$$

则称 $\hat{g}_n$ 为 $g(\theta)$ 的强相合估计量, 简记为 $\hat{g}_n \xrightarrow{a.s.} g(\theta)$ 。

强相合估计量必为相合估计量。



- 弱相合 $\Leftrightarrow$ 依概率收敛 ($\xrightarrow{P}$)
- 强相合 $\Leftrightarrow$ 几乎处处收敛 ($\xrightarrow{a.s.}$) almost surely

定理 2.6 (强相合估计量经过连续函数变换后仍然是强相合的。)

设 $G(\theta_1, \theta_2, \dots, \theta_k)$ 在参数空间 $\Theta \subset \mathbf{R}^k$ 上连续, $\hat{T}_{in}$ 为 θ_i 的强相合估计量, $i = 1, 2, \dots, k$, 则 $G(\hat{T}_{1n}, \hat{T}_{2n}, \dots, \hat{T}_{kn})$ 为 $G(\theta_1, \theta_2, \dots, \theta_k)$ 的强相合估计量。



定理 2.7 (矩估计量的强相合性)

设总体有直到 k ($k \geq 2$) 阶的矩 $\alpha_i, i = 1, \dots, k, \beta_j, j = 2, \dots, k$ 。若 $g(\theta)$ 可表示为

$$g(\theta) = G(\alpha_1, \alpha_2, \dots, \alpha_k, \beta_2, \dots, \beta_k)$$

且 G 为连续函数, 记 $\hat{\alpha}_i, \hat{\beta}_j$ 分别为样本原点矩和样本中心矩, 则

$$G(\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_k, \hat{\beta}_2, \dots, \hat{\beta}_k)$$

为 $g(\theta)$ 的强相合估计量。



笔记 矩估计量具有强相合性需满足三个条件: 总体有足够高阶的矩存在; $g(\theta)$ 能写成各阶矩的连续函数; 用样本矩替换总体矩。满足这三条, 矩估计量就是强相合的。

定理 2.8 (最大似然估计量的存在性与相合性)

设分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足:

1. Θ 是有限集;
2. 对于不同的参数值 θ 和 θ' , 所对应的分布不同;
3. $\{f(x; \theta) : \theta \in \Theta\}$ 有共同支撑, 即 $A = \{x : f(x; \theta) > 0\}$ 与 θ 无关。

则对于简单随机样本 $(X_1, X_2, \dots, X_n)^T$, θ 的最大似然估计量 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 存在, 且 $\hat{\theta}_n$ 为 θ 的相合估计量。



笔记 三个条件的直觉如下: Θ 是有限集: θ 的取值范围不能无限大, 保证最大值能取到; 不同参数对应不同分布: 保证参数是“可识别的”, 不然两个不同的 θ 长得一样, 根本无法区分; 共同支撑与 θ 无关: 保证似然函数对 θ 求导时不会出现支撑集随 θ 变化的麻烦, 数学上处理起来干净。

定理 2.9 (MLE 相合性 (Consistency) 定理)

设分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足:

- (1) Θ 为 $\mathbf{R}$ (一维实空间) 中的开集; **开集保证可以对 θ 求导**
- (2) 不同的参数值 θ 和 θ' 所对应的分布不同; **如果不同 θ 分布相同就分不清那个是真实参数**
- (3) $\{f(x; \theta) : \theta \in \Theta\}$ 有共同支撑 A ; **保证似然函数的结构在整个参数空间上一致, 也就是似然方程有意义**
- (4) $f(x; \theta)$ 对 θ 的偏导数 $\frac{\partial f(x; \theta)}{\partial \theta}$ 在 Θ 上存在, 并且当简单随机样本 $(X_1, X_2, \dots, X_n)^T \in A^n$ 时, 似然方程

$$\frac{\partial}{\partial \theta} \prod_{i=1}^n f(X_i; \theta) = 0$$

有唯一解 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$, **保证 MLE 存在且唯一——有唯一解才能保证估计量是良定义的, 才能谈收敛到真实值。**

则 $\hat{\theta}_n \xrightarrow{P} \theta$ ($n \rightarrow \infty$), 即 $\hat{\theta}_n$ 为 θ 的相合估计量。



笔记 本定理说的是: 在一定条件下, MLE 是相合估计量——即样本量 $n \rightarrow \infty$ 时, 最大似然估计量依概率收敛到真实参数值。相合性 (Consistency): 估计量随样本量增大越来越准, 极限上依概率收敛到真实参数值, 即

$$\hat{\theta}_n \xrightarrow{P} \theta \quad (n \rightarrow \infty).$$

直觉就是: 数据越多, 估计越靠谱, 样本无穷大时误差趋于 0。一句话总结: (1)(3)(4) 保证 MLE 能算出来且唯一, (2) 保证算出来的东西有意义。

定义 2.11 (渐近正态性)

若 $g(\theta)$ 的估计 $\hat{g}_n = \hat{g}_n(X_1, X_2, \dots, X_n)$ 满足

$$\sqrt{n}(\hat{g}_n - g(\theta)) \xrightarrow{L} N(0, V(\theta)) \quad (n \rightarrow \infty),$$

则称估计量 $\hat{g}_n$ 是渐近正态的。由上式, 当 n 充分大时, 近似地有

$$\hat{g}_n \sim N\left(g(\theta), \frac{V(\theta)}{n}\right),$$

称该分布为估计量 $\hat{g}_n$ 的渐近分布, $V(\theta)/n$ 称为 $\hat{g}_n$ 的渐近方差。



笔记 本定义说的是: 估计量 $\hat{g}_n$ 的误差经过 $\sqrt{n}$ 放大后, 在大样本下近似服从正态分布。

直觉是: 单个估计误差 $\hat{g}_n - g(\theta)$ 随 n 增大趋于 0, 太小了看不清楚形状, 乘以 $\sqrt{n}$ 把它“放大”到合适的尺度, 这时候形状依分布收敛 ($\xrightarrow{L}$, 即弱收敛) 到正态分布。

实际用途是: 样本量足够大时, 可以直接用 $\hat{g}_n \sim N(g(\theta), V(\theta)/n)$ 来做区间估计和假设检验, 不需要知道

$\hat{g}_n$ 的精确分布。

L 是来自法语“Loi”，意思是“分布/定律”，法国概率学派的传统记号。

定理 2.10 (MLE 渐近正态性)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta)$, $\theta \in \Theta$, 分布族 $\{f(x; \theta) : \theta \in \Theta\}$ 满足:

- (1) Θ 是开区间; (保证可以对 θ 求导)
- (2) $A = \{x : f(x; \theta) > 0\}$ 与 θ 无关, 即分布族有共同支撑; (保证似然函数结构一致, 对所有 θ 有意义)
- (3) $\forall x \in A$, $f(x; \theta)$ 对 θ 三次可微, 且三阶导数是 θ 的连续函数; (保证可以对似然函数做 Taylor 展开)
- (4) 对积分 $\int_A f(x; \theta) dx$ 可在积分号下对 θ 微分两次; (保证期望和导数可以交换顺序, Fisher 信息量的两个等价公式成立)
- (5) Fisher 信息量 $I(\theta)$ 满足 $0 < I(\theta) < \infty$; (保证渐近方差 $1/I(\theta)$ 有意义且非退化)
- (6) $\forall \theta_0 \in \Theta$, 存在正数 a 和函数 $M(x)$, 使得

$$\left| \frac{\partial^3 \ln f(x; \theta)}{\partial \theta^3} \right| \leq M(x), \quad x \in A, \theta_0 - a < \theta < \theta_0 + a$$

及 $E_{\theta_0}(|M(X)|) < \infty$; (控制 Taylor 展开余项, 保证展开合法)

设 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 为似然方程的根, 并且满足 $\hat{\theta}_n \xrightarrow{P} \theta_0$, 则

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{L} N\left(0, \frac{1}{I(\theta_0)}\right).$$

♡

定理 2.11 (Delta 方法—也就是原来相当于 $y=x$ 现在更普遍)

设 $\hat{\theta}_n$ 为 θ 的估计量, 满足

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{L} N(0, V(\theta)),$$

$h(\theta)$ 在 Θ 上可导, 且 $h'(\theta) \neq 0$, 则

$$\sqrt{n}(h(\hat{\theta}_n) - h(\theta)) \xrightarrow{L} N(0, (h'(\theta))^2 V(\theta)) \quad (n \rightarrow \infty).$$

♡

那导乘外导罢了

推论 2.1 (在正则条件下, MLE 的渐近方差恰好达到 C-R 下界)

在定理 3.4.5 和定理 3.4.6 的条件下, 有

$$\sqrt{n}(h(\hat{\theta}) - h(\theta)) \xrightarrow{L} N\left(0, \frac{[h'(\theta)]^2}{I(\theta)}\right).$$

注意, 上式表明 $h(\theta)$ 的最大似然估计量 $h(\hat{\theta})$ 的渐近方差与 C-R 下界一致。这就是说, 在该推论的正则条件下, 最大似然估计量 $h(\hat{\theta})$ 的渐近方差达到了 C-R 下界, 称这样的估计量为有效估计量。

♡

 **笔记** [模拟估计方法比较] 三种方法的核心区别在于对总体分布 F 的已知程度:

- 简单模拟法: F 完全已知, 直接从 F 中抽取 k 组样本, 用样本方差估计 $\text{Var}(T)$ 。优点: 最简单直接; 缺点: 要求分布完全已知, 实际中很少满足。
- 参数自助法: F_c 类型已知但参数 c 未知, 先用观测数据估计 $\hat{c}$, 再从 $F_{\hat{c}}$ 中产生 B 组样本, 计算

$$\widehat{\text{MSE}}_{pb}(T) = \frac{1}{B} \sum_{j=1}^B (T^{(j)} - \theta(F_{\hat{c}}))^2.$$

优点: 利用了分布类型的先验信息, 估计更精准; 缺点: 依赖分布类型假设正确。

- 一般自助法 (非参数自助法): F 完全未知, 用经验分布函数 F_n 代替 $F_{\hat{c}}$, 即在 $\{x_1, x_2, \dots, x_n\}$ 中有放回地抽取容量为 n 的样本 B 次, 计算每组样本下 $T^{(j)}$, 再估计方差。优点: 无需任何分布假设, 适用范围最

广；缺点：完全依赖样本，小样本下效果差。

2.3 渐进相对效率

 **笔记** 设 $(X_1, X_2, \dots, X_n)^T$ 为来自于分布 $F(x, \theta)$ 的样本， $\hat{\theta}_{1n}$ 和 $\hat{\theta}_{2n}$ 为 θ 的两个不同的估计量，分别满足

$$\sqrt{n}(\hat{\theta}_{1n} - \theta) \xrightarrow{L} N(0, \sigma_1^2), \quad \sqrt{n}(\hat{\theta}_{2n} - \theta) \xrightarrow{L} N(0, \sigma_2^2),$$

称 σ_1^2/σ_2^2 为 $\hat{\theta}_{2n}$ 相对于 $\hat{\theta}_{1n}$ 的渐进效率。

定理 2.12 (渐进效率)

进一步，设 $\hat{\theta}_n$ 为 θ 的基于样本 $(X_1, X_2, \dots, X_n)^T$ 的估计量，满足 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{L} N(0, \sigma_1^2)$ 。若样本容量 n 的整函数 $m = m(n)$ 满足

$$\lim_{n \rightarrow \infty} \frac{m(n)}{n} = \gamma \quad (\gamma > 0),$$

则

$$\sqrt{n}(\hat{\theta}_{m(n)} - \theta) \xrightarrow{L} N\left(0, \frac{\sigma_1^2}{\gamma}\right).$$



东邪的 tip 2.8

渐进效率本质上是在回答一个问题：两个估计量，谁用更少的数据就能达到同样的精度？

核心直觉

$\hat{\theta}_{2n}$ 相对于 $\hat{\theta}_{1n}$ 的渐进效率是 $e = \sigma_1^2/\sigma_2^2$ 。这个比值的含义是：用 $\hat{\theta}_{1n}$ 需要 n 个样本才能达到的精度，用 $\hat{\theta}_{2n}$ 只需要 en 个样本就够了。定理 3.4.7 正是在严格化这句话——如果把样本量从 n 缩减到 $m(n) \approx \gamma n$ ，估计量的渐近方差就从 σ_1^2 膨胀到 σ_1^2/γ 。

典型用途

1. **比较两个估计量的优劣**。例如同样估计正态分布的均值 μ ：样本均值 $\bar{X}$ 的渐近方差是 σ^2 ，样本中位数的渐近方差是 $\pi\sigma^2/2$ ，故样本中位数相对于 $\bar{X}$ 的渐进效率为 $2/\pi \approx 0.637$ ，意味着中位数需要多用约 57% 的样本才能达到均值的精度。
2. **衡量估计量离最优有多远**。将 $\hat{\theta}_{1n}$ 取为渐近方差恰好达到 C-R 下界 $1/I(\theta)$ 的估计量（如 MLE），则

$$e = \frac{1/I(\theta)}{\sigma_2^2}.$$

若 $e = 1$ ，称 $\hat{\theta}_{2n}$ 是**渐近有效的**，即大样本下已无法做得更好。

3. **在有限资源下做决策**。若收集数据有成本，渐进效率直接告诉我们：换一个效率为 e 的估计量，等价于把样本量乘以 e 。效率为 0.8 的估计量意味着多花了 25% 的采样成本。

2.3.1 区间估计

定义 2.12 (置信区间)

设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x; \theta)$, $\theta \in \Theta$, $0 < \alpha < 1$ 为一个给定的数。若统计量 $\theta_1(\mathbf{X}) = \theta_1(X_1, X_2, \dots, X_n)$, $\theta_2(\mathbf{X}) = \theta_2(X_1, X_2, \dots, X_n)$ 满足 $\theta_1(\mathbf{X}) \leq \theta_2(\mathbf{X})$ ，并且

$$P_\theta\{\theta_1(\mathbf{X}) \leq \theta \leq \theta_2(\mathbf{X})\} \geq 1 - \alpha, \quad \forall \theta \in \Theta,$$

则称 $[\theta_1(\mathbf{X}), \theta_2(\mathbf{X})]$ 是参数 θ 的置信度为 $100(1 - \alpha)\%$ 的置信区间。若

$$P_\theta\{\theta \leq \theta_2(\mathbf{X})\} \geq 1 - \alpha, \quad \forall \theta \in \Theta,$$

则称 $\theta_2(\mathbf{X})$ 是参数 θ 的置信度为 $100(1-\alpha)\%$ 的置信上限. 若

$$P_{\theta}\{\theta \geq \theta_1(\mathbf{X})\} \geq 1 - \alpha, \quad \forall \theta \in \Theta,$$

则称 $\theta_1(\mathbf{X})$ 是参数 θ 的置信度为 $100(1-\alpha)\%$ 的置信下限.



东邪的 tip 2.9

置信区间回答的问题是：能否用数据构造一个区间，使其大概率覆盖未知参数 θ ？约可靠需要的区间长度越长，区间长度越长精度就越低

笔记

θ 是固定的未知常数，而 $[\theta_1(\mathbf{X}), \theta_2(\mathbf{X})]$ 是随机的，随样本变化. 置信度 $1-\alpha$ 的正确含义是：在相同条件下重复抽样，每次用同样的方法构造区间，其中至少有 $100(1-\alpha)\%$ 的区间会包含真实的 θ .

注意一个常见误解：置信度 $1-\alpha$ 并非指“ θ 有 $1-\alpha$ 的概率落在该区间内”—— θ 是常数而非随机变量，随机的是区间本身，而非 θ .

置信上限与置信下限对应单侧约束：置信上限关心 θ 不超过某值，置信下限关心 θ 不低于某值，双侧约束即为通常的置信区间.

定理 2.13 (枢轴量方法)

构造置信区间的枢轴量方法概括如下：

1. 找一个与被估计量 θ 有关的统计量 $T = T(\mathbf{X})$ ，通常可选取一个点估计量；
2. 构造 T 和被估计量 θ 的一个函数 $G(T, \theta)$ ，使得其分布与未知参数无关， $G(T, \theta)$ 称为枢轴量；
3. 选取 $G(T, \theta)$ 的一个取值范围 S ，满足 $P(G(T, \theta) \in S) = 1 - \alpha$ ，此时 S 与未知参数无关；
4. 将 $G(T, \theta) \in S$ 作等价变换，化为 $\theta_1(\mathbf{X}) \leq \theta \leq \theta_2(\mathbf{X})$ 的形式，则 $[\theta_1(\mathbf{X}), \theta_2(\mathbf{X})]$ 即是置信度为 $100(1-\alpha)\%$ 的置信区间.



笔记 “枢轴”的意思是转动的轴心， $G(T, \theta)$ 充当的角色正是如此：它一边连着数据（通过 $\bar{X}$ ），一边连着未知参数（通过 μ ），但它自己的分布是固定已知的. 可以把它想象成一个翻译器：左边输入数据，右边输出关于 μ 的约束，中间的概率计算完全不需要知道 μ .

东邪的 tip 2.10

也就这个流程就是先找到一个 T ， T 必须和 θ 相关，也就是正态分布的平均数就是 θ ，指数分布的拉姆达，和均匀分布的 θ ，然后 T 得是渐进正态或者正态的，然后把 T 标准化根据置信区间得到标准化完了以后的范围然后解方程对吗

正态、指数、均匀等分布的充分统计量 T 的精确分布已知，无需渐近，可直接精确变换为 $N(0, 1)$ 、 χ^2 或 Beta 等已知分布；对于其他分布，精确分布难以求得，此时借助 CLT 说明 T 渐近正态，再标准化得到渐近枢轴量.

2.3.2 正态的性质们

笔记 设 $Z \sim N(0, 1)$ ，令 $Q = Z^2$ ，则 $Q \sim \chi^2(1)$.

变换方向： $q = z^2$ ，绝对值越大 q 越大：

$$|z| > 1 \Rightarrow q > 1 (\text{往右移}), \quad |z| < 1 \Rightarrow q < 1 (\text{往左移})$$

密度变换（换到 Q 的空间，需要雅可比修正）：

$\pm z$ 映射到同一个 q , 两侧叠加, 区间从 $2 dz$ 压缩到 dq :

$$f_Q(q) = 2 \cdot f_Z(\sqrt{q}) \cdot \frac{1}{2\sqrt{q}} = \frac{f_Z(\sqrt{q})}{\sqrt{q}}, \quad q > 0$$

求期望 (在 Z 的空间积分, 密度不变):

$$E[Q] = E[Z^2] = \int_{-\infty}^{+\infty} z^2 f_Z(z) dz = 1$$

关键区别: 求期望是在原空间加权平均, 积分变量未换, 密度不动; 变量变换是换了积分变量, 必须乘雅可比项保证概率守恒。

第3章 假设检验

3.1 基础知识

 **笔记** 经典假设检验的逻辑：不问“ H_0 为真的概率是多少”，而是问“假设 H_0 成立，观测到这个结果的概率有多小”。

- 若概率小于 α ，则“这太反常了，拒绝 H_0 ”
- 若概率不够小，则“没有足够证据拒绝 H_0 ”

注意：拒绝不了 H_0 不等于 H_0 为真，只是证据不够。

定义 3.1 (基本概念)

假设检验的核心要素：

1. 假设的建立

H_0 (原假设/零假设)：保守的假设，默认成立； H_1 (对立假设/备择假设)：研究者想证明的。研究假设放 H_1 而不是 H_0 ，因为只有拒绝 H_0 时结论的可靠度才是已知的。

2. 检验规则

样本空间分成拒绝域 S 和接受域 S^c ，用检验统计量把拒绝域用一个数表示，分界点叫临界值。检验函数为

$$\phi(\mathbf{X}) = \begin{cases} 1, & \mathbf{X} \in S \\ 0, & \mathbf{X} \in S^c \end{cases}$$

3. 两类错误

第一类错误 (弃真)： H_0 真却拒绝；第二类错误 (取伪)： H_0 假却接受。两类错误此消彼长，样本量固定时无法同时控制。



定义 3.2 (功效函数与显著性水平)

功效函数 (势函数) 统一描述两类错误的概率：

$$\beta_\phi(\theta) = E_\theta(\phi(\mathbf{X})) = P_\theta(\mathbf{X} \in S)$$

- $\theta \in \Theta_0$ 时， $\beta_\phi(\theta)$ 是第一类错误概率，越小越好
- $\theta \in \Theta_1$ 时， $\beta_\phi(\theta)$ 是检验的功效，越大越好

显著性水平：实际中优先控制第一类错误，要求

$$\sup_{\theta \in \Theta_0} \beta_\phi(\theta) \leq \alpha$$

α 称为检验水平 (常取 0.01, 0.05, 0.1)，在此约束下再尽量减小第二类错误。上式左端称为检验的真实水平， α 称为名义水平。



例题 3.1 某批产品不合格品率 p 未知，抽取 $n = 5$ 件检验，检验假设

$$H_0 : p \leq 0.04 \quad H_1 : p > 0.04$$

取检验统计量 $Y = \sum_{i=1}^5 X_i$ (5 件中不合格品总数)， $Y \sim B(5, p)$ 。取临界值 $k = 1$ ，拒绝域 $S = \{Y > 1\}$ ，检验函数为

$$\phi(\mathbf{X}) = \begin{cases} 1, & Y > 1 \\ 0, & Y \leq 1 \end{cases}$$

验证显著性水平：取 $p = 0.04$ 时第一类错误概率最大，

$$P_{0.04}(Y > 1) = \sum_{j=2}^5 \binom{5}{j} (0.04)^j (0.96)^{5-j} \approx 0.0148 \leq \alpha = 0.05$$

功效函数： $\beta_\phi(p) = P_p(Y > 1)$ ，当 $p = 0.5$ 时 $\beta_\phi(0.5) \approx 0.81$ ，即真实不合格率为 0.5 时有 81% 的概率正确拒绝 H_0 。

判断：抽样后数出不合格品数 y ，若 $y > 1$ 则拒绝 H_0 ，否则接受 H_0 。

 **笔记** 关于检验统计量的选取：选它的原则是能反映参数的变化。此例中不合格品数 Y 越大越支持 H_1 ，所以用 Y 作统计量， Y 大就倾向于拒绝 H_0 ，因为 $E(Y) = np$ ， p 越大 Y 期望越大。

关于临界值的确定：先定 α ，再找满足 $P_{p \leq 0.04}(Y > k) \leq \alpha$ 的最小 k ，在不超过 α 的前提下 k 尽量小，使拒绝域尽量大，从而减小第二类错误。

关于两类错误的根源：本质都是抽样的随机性——样本不能完美反映总体。第一类错误是好货被冤枉（ p 不超标但样本恰好不合格多），第二类错误是坏货被放过（ p 超标但样本恰好不合格少）。

关于功效：功效越高说明检验越灵敏，越能发现 H_0 为假。 $\theta \in \Theta_0$ 时功效要小， $\theta \in \Theta_1$ 时功效要大。

3.2 正态总体参数的检验

定义 3.3 (正态总体参数的检验——枢轴量)

设 $X_1, X_2, \dots, X_n$ 来自 $N(\mu, \sigma^2)$ ，对参数建立假设 $H_0 \leftrightarrow H_1$ ，根据条件选取对应枢轴量。

单个正态总体：

- σ^2 已知，检验 μ ： $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$ ，称为 Z 检验
- σ^2 未知，检验 μ ： $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ ，称为 t 检验
- μ 未知，检验 σ^2 ： $\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$ ，称为 χ^2 检验

两个正态总体：

- σ_1^2, σ_2^2 已知，检验 $\mu_1 - \mu_2$ ： Z 检验
- $\sigma_1^2 = \sigma_2^2$ 未知，检验 $\mu_1 - \mu_2$ ：两样本 t 检验
- μ_1, μ_2 未知，检验 σ_1^2/σ_2^2 ： $F = \frac{S_1^2}{S_2^2} \sim F(m-1, n-1)$ ，称为 F 检验

定义 3.4 (正态总体参数的检验——拒绝域)

根据 H_1 的方向确定拒绝域形式， $c_{\alpha/2}$ 或 c_α 为对应分布的分位数。

- 双侧检验 $H_1: \theta \neq \theta_0$ ： $|T| > c_{\alpha/2}$
- 单侧检验 $H_1: \theta > \theta_0$ ： $T > c_\alpha$
- 单侧检验 $H_1: \theta < \theta_0$ ： $T < -c_\alpha$

 **笔记** 与置信区间的关系：枢轴量完全相同，区别只在使用方式——置信区间是解不等式得到参数范围，假设检验是代入 θ_0 看统计量是否落入拒绝域。

单侧 vs 双侧：取决于 H_1 的方向。 $H_1: \mu \neq \mu_0$ 用双侧，查 $z_{\alpha/2}$ ； $H_1: \mu > \mu_0$ 或 $H_1: \mu < \mu_0$ 用单侧，查 z_α 。
 σ^2 已知用 Z ，未知用 t ； σ^2 未知时用样本标准差 S 替代，分布从正态变为 t 分布，自由度为 $n-1$ 。

定理 3.1 (正态总体方差检验)

设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$ ，样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ，则

单总体：检验 $H_0: \sigma^2 = \sigma_0^2$ ，构造统计量

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$$

自由度为 $n-1$ ，因计算 S^2 时使用了 $\bar{X}$ ，损失一个自由度。

两总体：检验 $H_0: \sigma_1^2 = \sigma_2^2$ ，构造统计量

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1)$$



3.3 非正态分布

3.4 奈曼皮尔逊

定义 3.5 (一致最优检验)

设 $\phi(X)$ 是检验水平为 α 的检验，若对任何检验水平为 α 的检验 $\phi^*(X)$ 有

$$\beta_\phi(\theta) \geq \beta_{\phi^*}(\theta), \quad \forall \theta \in \Theta_1$$

其中 $\beta_\phi(\theta)$, $\beta_{\phi^*}(\theta)$ 分别是 ϕ 和 ϕ^* 的功效函数，则称 ϕ 为检验水平为 α 的一致最优检验 (Uniformly Most Powerful Test)，简记作 **UMP** 检验。



笔记 UMP 检验的逻辑如下：

1. 先固定水平 α ，即要求 $\beta_\phi(\theta) \leq \alpha, \quad \forall \theta \in \Theta_0$
2. 在所有满足上述约束的检验中
3. 若存在某个 ϕ ，使得对每个 $\theta \in \Theta_1$ 都有

$$\beta_\phi(\theta) \geq \beta_{\phi^*}(\theta), \quad \forall \phi^*$$

则称 ϕ 为 UMP 检验。

因此，“ ϕ 的功效最大”并非推导结论，而是定义本身：我们在寻找功效最大的检验，若找到，便称之为 UMP。

笔记 UMP 检验即在第一类错误已被控制 ($\beta_\phi(\theta) \leq \alpha, \forall \theta \in \Theta_0$) 的前提下，找一个使第二类错误对所有 $\theta \in \Theta_1$ 同时最小的检验。

“Uniformly” 正是指这个“同时”：不是只在某个特定 θ 下最优，而是一致地对整个 Θ_1 最优。

东邪的 tip 3.1

UMP 检验的意义有两层：

1. 评价标准：定义了什么样的检验是「最好的」，使不同检验之间可以比较优劣。
2. 指导构造：后续 Neyman-Pearson 引理将证明，满足

$$\left\{ \frac{f(X; \theta_1)}{f(X; \theta_0)} > c \right\}$$

形式的似然比检验即可达到 UMP。

因此 UMP 定义是目标，N-P 引理是实现路径

笔记 Lambda，希腊字母，大写写作 Λ ，小写写作 λ 。

定理 3.2 (Neyman-Pearson 引理)

设 $\alpha \in [0, 1]$, 考虑简单假设检验 $H_0: f = f_0$ vs $H_1: f = f_1$, 则:

1. (存在性) 必存在检验函数

$$\phi(\mathbf{X}) = \begin{cases} 1, & \Lambda(\mathbf{X}) > k \\ r, & \Lambda(\mathbf{X}) = k \\ 0, & \Lambda(\mathbf{X}) < k \end{cases}$$

其中 $\Lambda(\mathbf{X}) = \prod_{i=1}^n f_1(X_i) / \prod_{i=1}^n f_0(X_i)$ 为似然比, 常数 $k > 0$, $r \in [0, 1]$ 由 $E_0[\phi(\mathbf{X})] = \alpha$ 确定。

2. (充分性) 满足上述条件的 ϕ 是水平 α 的 UMP 检验。

3. (必要性) 若 ϕ 是水平 α 的 UMP 检验, 则必存在 k 使上述似然比形式几乎处处成立; 且若 $E_1(\phi(\mathbf{X})) < 1$, 则必有 $E_0(\phi(\mathbf{X})) = \alpha$ 。



笔记 因为分布族满足 MLR 条件, 不同 θ_1 的似然比都是 $T(\mathbf{X})$ 的单增函数, 从而所有 θ_1 对数据点的排序一致, 最优拒绝域对所有 θ_1 都是 $T(\mathbf{X}) > c$, UMP 存在。

定义 3.6 (单调似然比分布族)

若分布族 $\{f(x; \theta), \theta \in \Theta\}$ 满足:

1. 不同参数值对应的分布不同;
2. 存在统计量 $T = T(\mathbf{X})$, 使得对任何 $\theta_1 < \theta_2$, 似然比

$$\frac{\prod_{i=1}^n f(X_i; \theta_2)}{\prod_{i=1}^n f(X_i; \theta_1)}$$

作为 $\mathbf{X}$ 的函数只依赖于 $T(\mathbf{X})$, 且是 $T(\mathbf{X})$ 的单增 (单减) 函数, 则称该分布族为单增 (单减) 似然比分布族, 二者统称为单调似然比分布族。



笔记 MLR 不是一个操作, 不是一个定理, 而是我们对分布族提出的一个要求: 对任意 $\theta_1 < \theta_2$, 似然比 $\frac{\prod f(X_i; \theta_2)}{\prod f(X_i; \theta_1)}$ 是某个统计量 $T(\mathbf{X})$ 的单增函数。满足这个要求的分布族叫 MLR 族, 正态、泊松、指数族都满足。不满足的分布族, UMP 一般不存在。

东邪的 tip 3.2

θ_1 和 θ_2 是确定的, X_i 是变化的, 每取一组 $\mathbf{X}$, 似然比的值都会变。比值越大说明分子发生概率越大, θ_2 越可能; 反之 θ_1 更可能。

例题 3.2 设 $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, 1)$, 取 $\theta_0 < \theta_1$, 似然比为

$$\Lambda_{\theta_1}(\mathbf{X}) = e^{n(\theta_1 - \theta_0)\bar{X} - \frac{n}{2}(\theta_1^2 - \theta_0^2)}$$

其中 $e^{-\frac{n}{2}(\theta_1^2 - \theta_0^2)}$ 是只含 θ 的常数, 与数据无关, 所以似然比完全由 $\bar{X}$ 决定。又因为 $\theta_1 > \theta_0$, 系数 $n(\theta_1 - \theta_0) > 0$, 故 $\Lambda_{\theta_1}(\mathbf{X})$ 是 $\bar{X}$ 的单增函数。因此正态分布族取 $T(\mathbf{X}) = \bar{X}$, 不管 θ_1 取何值, 对数据点的排序都由 $\bar{X}$ 决定, MLR 条件成立。

定理 3.3 (单调似然比与 UMP 检验)

设 $\{f(x; \theta), \theta \in \Theta\}$ 为单增似然比分布族, $\theta_0 \in \Theta$ 且 $\{\theta > \theta_0\} \cap \Theta$ 非空, 对假设检验问题

$$H_0: \theta \leq \theta_0; \quad H_1: \theta > \theta_0$$

及任意 $\alpha \in (0, 1)$, 有:

1. (存在性与最优性) 存在形如

$$\phi(\mathbf{X}) = \begin{cases} 1, & T(\mathbf{X}) > c \\ r, & T(\mathbf{X}) = c \\ 0, & T(\mathbf{X}) < c \end{cases}$$

的检验 ϕ , 满足 $E_{\theta_0}(\phi(\mathbf{X})) = \alpha$, 且该检验是水平 α 的 UMP 检验。

2. (功效函数单调性) $\beta_\phi(\theta)$ 单增, 且在 $\{\theta : 0 < \beta_\phi(\theta) < 1\}$ 上严格单增。

3. (最小化第一类错误) 对任何 $\theta < \theta_0$,

$$\beta_\phi(\theta) = \min\{\beta_{\phi^*}(\theta) : E_{\theta_0}(\phi^*(\mathbf{X})) = \alpha\}.$$



笔记 实际操作顺序是:

1. 先由 $P_{H_0}(X > c) = \alpha$ 解出 $c = 1.645$

2. c 带入 x , x 变成了 $f(x)$ 他对应的拒绝域也要跟着变

3. 再由 $c = \ln k + 0.5$ 倒推出 $k \approx 3.14$

k 是最后算出来的, 不是一开始就知道的。

定理 3.4 (推论: 左单边检验)

设分布族为单增似然比分布族, 则对于

$$H_0 : \theta \geq \theta_0; \quad H_1 : \theta < \theta_0$$

UMP 检验的拒绝域方向相反:

$$\phi(\mathbf{X}) = \begin{cases} 1, & T(\mathbf{X}) < c \\ r, & T(\mathbf{X}) = c \\ 0, & T(\mathbf{X}) > c \end{cases}$$

且结论中 $\beta_\phi(\theta)$ 单增改为单减。



例题 3.3 柯西分布 $f(x; \theta) = \frac{1}{\pi[1 + (x - \theta)^2]}$ 不满足 MLR 条件。取 $\theta_1 = 0$, $\theta_2 = 1$, 似然比为

$$\Lambda(x) = \frac{1 + x^2}{1 + (x - 1)^2}$$

计算几个具体值:

x	-2	0	2	10	100
$\Lambda(x)$	0.5	0.5	2.5	1.23	1.02

$\Lambda(x)$ 先增后减, 不是任何统计量的单调函数, 故柯西分布不满足 MLR 条件, 对单边假设检验一般不存在 UMP 检验。

推论 3.1 (4.4.3)

设 X 的分布族为指数分布族:

$$f(x; \theta) = C(\theta)h(x)\exp(Q(\theta)t(x)), \quad \theta \in \Theta \subset \mathbf{R},$$

Θ 为自然参数空间: $\Theta = \left\{ \theta : \int_{-\infty}^{+\infty} h(x)\exp(Q(\theta)t(x))dx < +\infty \right\}$, $Q(\theta)$ 是 θ 的严格单调函数。令

$$T(\mathbf{X}) = T(X_1, X_2, \dots, X_n) = \sum_{i=1}^n t(X_i),$$

则有

- (1) 若 $Q(\theta)$ 为严格单增函数, 则检验问题 (4.4.12) 的检验水平为 α 的 UMP 检验由式 (4.4.13) 和 (4.4.14) 确定.
- (2) 若 $Q(\theta)$ 为严格单减函数, 则检验问题 (4.4.12) 的显著性水平为 α 的 UMP 检验由式 (4.4.20) 和 (4.4.14) 确定.



3.5 4.5 无偏检验和一致无偏检验

3.6 4.6 拟合优度检验

定理 3.5 (4.6.1)

若 (4.6.1) 的原假设 H_0 成立, 则

$$U_i = F_0(X_i), \quad i = 1, 2, \dots, n$$

相互独立, 并且服从均匀分布 $U(0, 1)$.



定义 3.7 (PP 图与 QQ 图)

设 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 为样本顺序统计量, F_0 为待检验的理论分布.

PP 图 (概率-概率图): 以理论累积概率 $F_0(X_{(i)})$ 为横轴, 经验累积概率 $\frac{i}{n}$ 为纵轴作散点图. 若 H_0 成立, 点应落在 45° 对角线附近, 对分布中间部分敏感.

QQ 图 (分位数-分位数图): 以理论分位数 $F_0^{-1}\left(\frac{i}{n}\right)$ 为横轴, 样本顺序统计量 $X_{(i)}$ 为纵轴作散点图. 若 H_0 成立, 点应落在 45° 对角线附近, 对分布尾部敏感, 实际中更常用.



定义 3.8 (皮尔逊 χ^2 统计量)

设总体 X 的可能取值为 $a_1, a_2, \dots, a_M$, n_j 为样本中取值为 a_j 的观察频数, np_j 为对应的理论期望频数, 构造皮尔逊 χ^2 统计量:

$$\chi^2 = \sum_{j=1}^M \frac{(n_j - np_j)^2}{np_j}$$



定理 3.6 (4.6.2)

在原假设 H_0 下, $\chi^2 \xrightarrow{L} \chi^2(M-1) \quad (n \rightarrow \infty)$.



定义 3.9 (皮尔逊 χ^2 拟合优度检验)

检验假设

$$H_0: P(X = a_j) = p_j, \quad j = 1, 2, \dots, M$$

其中 p_j 已知, $\sum_{j=1}^M p_j = 1$. 在显著性水平 α 下, 检验函数为

$$\varphi = \begin{cases} 1, & \chi^2 > \chi_\alpha^2(M-1) \\ 0, & \chi^2 \leq \chi_\alpha^2(M-1) \end{cases}$$

使用条件: 每个格子的期望频数 $np_j \geq 5$.



笔记 皮尔逊 χ^2 检验用于离散型与一般分布时的区别:

1. 离散型 (有限值, 参数已知): 分布已给出每个取值的概率 p_j , 直接构造 χ^2 统计量, 自由度为 $M-1$.

2. 连续型 (一般分布): 连续分布每个点的概率为 0, 无法直接数频数, 需人为将实数轴划分为 M 个区间, 统计每个区间内的观察频数, 转化为离散问题后再使用 χ^2 统计量。
3. 参数未知时: 若 p_j 中含有未知参数, 需先用 MLE 估计, 每估计一个参数自由度减少一个, 自由度变为

$$\chi^2 \xrightarrow{L} \chi^2(M-1-k)$$

其中 k 为估计的参数个数。

第4章 回归分析

定理 4.1 (5.1.1)

若对任意 x ,

$$E(Y | X = x) = a + bx, \quad (5.1.4)$$

则

$$E(Y | X = x) = \mu_2 + \rho \sqrt{\frac{\text{Var}(Y)}{\text{Var}(X)}} (x - \mu_1),$$

其中

$$\mu_1 = E(X), \quad \mu_2 = E(Y), \quad \rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}.$$



4.1 简单线性回归模型

定义 4.1 (简单线性回归模型)

设

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

其中 $\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2)$, x_i 为已知常数, $\beta_0, \beta_1, \sigma^2$ 未知。



定理 4.2 (OLS 估计量)

最小二乘估计量为

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}.$$



定理 4.3 (点预测)

给定新观测点 x^* , 因变量的点预测值为

$$\hat{Y}(x^*) = \hat{\beta}_0 + \hat{\beta}_1 x^*.$$



定理 4.4 (OLS 估计量)

最小化残差平方和 $Q(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2$, 对 β_0, β_1 各偏导令为零:

$$\frac{\partial Q}{\partial \beta_0} = 0 \Rightarrow \sum (Y_i - \beta_0 - \beta_1 x_i) = 0, \quad \frac{\partial Q}{\partial \beta_1} = 0 \Rightarrow \sum x_i (Y_i - \beta_0 - \beta_1 x_i) = 0.$$

解正规方程组得

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x},$$

其中 $S_{xx} = \sum (x_i - \bar{x})^2$, $S_{xy} = \sum (x_i - \bar{x})(Y_i - \bar{Y})$ 。



笔记 用平方而非绝对值的理由: $|e_i|$ 不可微, 无法求导; e_i^2 给出闭合解。更深层: 正态误差下 OLS = MLE; Gauss-Markov 定理保证 OLS 是 BLUE。

东邪的 tip 4.1

斜率 = 协方差 ÷ 方差: $\hat{\beta}_1 = S_{xy}/S_{xx} = \widehat{\text{Cov}}(x, Y)/\widehat{\text{Var}}(x)$ 。截距由“直线过中心点 $(\bar{x}, \bar{Y})$ ”反推。

4.2 投影与幂等矩阵

定义 4.2 (幂等矩阵)

矩阵 P 满足 $P^2 = P$, 则称 P 为幂等矩阵。



定理 4.5 (幂等矩阵的二次型服从 χ^2 分布)

设 $\mathbf{X} \sim N(\mathbf{0}, \sigma^2 I_n)$, P 为 $n \times n$ 对称幂等矩阵, $\text{rank}(P) = r$, 则

$$\frac{\mathbf{X}^T P \mathbf{X}}{\sigma^2} \sim \chi^2(r).$$



例题 4.1 投影定理: 5.2.2 设 $\mathbf{u} = \frac{1}{\sqrt{n}}(1, 1, \dots, 1)^T$, 则 $\mathbf{u}^T \mathbf{u} = 1$, 令 $P = I_n - \mathbf{u} \mathbf{u}^T$.

验证幂等:

$$P^2 = (I_n - \mathbf{u} \mathbf{u}^T)^2 = I_n - 2\mathbf{u} \mathbf{u}^T + \underbrace{\mathbf{u} (\mathbf{u}^T \mathbf{u}) \mathbf{u}^T}_{=1} = I_n - \mathbf{u} \mathbf{u}^T = P. \quad \checkmark$$

验证秩: $\text{rank}(\mathbf{u} \mathbf{u}^T) = 1$, 故 $\text{rank}(P) = n - 1$.

由幂等矩阵定理:

$$\frac{\mathbf{X}^T (I_n - \mathbf{u} \mathbf{u}^T) \mathbf{X}}{\sigma^2} \sim \chi^2(n - 1).$$

第5章 作业

5.1 第一周作业

 **作业 3** 汽车制造商的生产记录表明了每个班的产品数量（每个班的最大产量是 720 辆汽车）。

668	711	625	701	688	667	694	630	547	703	688	697	703
656	677	700	702	688	691	664	688	679	708	699	667	703

1. 画出茎叶图。
2. 计算样本均值和样本中位数。
3. 均值和中位数间的关系关于数据的形状说明了什么？

解

(1) 使用 R 语言的 `stem()` 函数处理该组生产记录数据。为了使茎叶图的结构更加紧凑并消除不必要的空行，我们将 `scale` 参数调整为 0.5。得到结果如下：

```
> data <- c(668, 711, 625, 701, 688, 667, 694, 630, 547, 703, 688, 697, 703,
+          656, 677, 700, 702, 688, 691, 664, 688, 679, 708, 699, 667, 703)
> stem(data, scale = 0.5)
```

The decimal point is 1 digit(s) to the right of the |

```
54 | 7
56 |
58 |
60 |
62 | 50
64 | 6
66 | 4777879
68 | 88881479
70 | 01233381
```

(2) 利用 R 语言中的 `mean()` 和 `median()` 函数计算样本统计量：

- 样本均值： $\bar{x} \approx 678.6154$
- 样本中位数： $M = 688$

(3) 根据计算结果可知，均值(678.6154) < 中位数(688)。在统计学中，当均值小于中位数时，通常说明数据分布呈现左偏（负偏态）。这反映出生产记录中存在极少数产量显著较低的班次（如 547），这些“长尾”数据拉低了整体的平均水平，使得分布曲线向左延伸。

 **作业 4** 在一项血清胆固醇含量 (mg/L) 的研究中，记录了 20 个成年患者的胆固醇含量：

133	137	148	149	152	167	174	179	189	192
201	209	210	211	218	238	245	248	253	257

试求 (1) 样本均值和样本中位数；(2) 极差、四分位数间距和样本方差。

解 (1) 利用 R 语言中的 `mean()` 和 `median()` 函数计算样本统计量：

- 样本均值： $\bar{x} = 195.5$
- 样本中位数： $M = 196.5$


(2) 利用 R 语言计算该组数据的离散程度指标：

- 极差 (**Range**): $R = \max(x) - \min(x) = 257 - 133 = 124$ 。

- 四分位数间距 (IQR): 通过 $\text{IQR}()$ 函数计算得到 $\text{IQR} = Q_3 - Q_1 = 59.75$ 。
- 样本方差 (Sample Variance): 使用 $\text{var}()$ 函数计算 (采用 $n-1$ 修正):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \approx 1605.842$$

 **作业 5** 用上题中的观测值画出箱线图，并由此说明总体分布的形状。



解 使用 R 语言绘制血清胆固醇含量的箱线图 (见上图)，并结合图形特征对总体分布形状进行分析：

- 对称性分析：从图中可以看出，中位数 (箱体中的黑实线) 位置稍稍偏向箱体的右侧 (靠近上四分位数 Q_3)，且左侧的须线 (whisker) 相对于右侧须线略长。
- 偏态说明：结合上题计算结果，均值 ($\bar{x} = 195.5$) 小于中位数 ($M = 196.5$)。箱线图呈现出左侧间距 (最小值到中位数) 略大于右侧间距 (最大值到中位数) 的特征，这表明总体分布呈现轻微的左偏 (负偏态) 分布。
- 离群值判断：在箱线图的上下须线之外未发现孤立的点，说明在该样本数据中不存在明显的异常值 (离群点)。

page44

 **作业 3** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$ ，其中 μ 是已知数，而 σ^2 是未知的，指出下列各量哪些是统计量，哪些不是统计量，并说明理由：

$$\sum_{i=1}^n X_i, \quad X_1 + 2\mu, \quad \max_{1 \leq i \leq n} \{X_i\}, \quad \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}, \quad \sum_{i=1}^n (X_i - \mu)^2.$$

东邪的 tip 5.1

统计量只能由样本 $X_1, \dots, X_n$ 和已知常数构成

解 是，是，是，不是，是

 **笔记** 统计量就是：拿到一组真实样本数据后，对这些数据做具体运算得到的结果。

例如测得

$$x_1, x_2, \dots, x_n,$$

则相加、取平均、取最大值、排序、求平方和等得到的量，通常都是统计量。

 **作业 4** 某机床加工出的零件的直径服从正态分布 $N(\mu, \sigma^2)$ ， μ, σ^2 未知。为对 μ, σ^2 作出估计，随机选取加工出来的 n 个零件进行测量，得到 n 个数据

$$x_1, x_2, \dots, x_n.$$

试写出该问题的统计模型（即参数空间和样本分布族）。

解 设

$$X_1, X_2, \dots, X_n$$

为随机选取的 n 个零件直径，由题意可知

$$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2),$$

其中参数 μ, σ^2 均未知。

因此，该问题的统计模型可写为：

- 参数空间为

$$\Theta = \{(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}.$$

- 样本分布族为：样本 $(X_1, X_2, \dots, X_n)$ 的联合概率密度为

$$f(x_1, x_2, \dots, x_n; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right], \quad (\mu, \sigma^2) \in \Theta.$$

故该问题的统计模型就是由参数空间

$$\Theta = \{(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$$

和样本分布族

$$\left\{P_{\mu, \sigma^2} : (X_1, \dots, X_n) \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2), (\mu, \sigma^2) \in \Theta\right\}$$

所组成的统计模型。

东邪的 tip 5.2

考前看一眼就行了

 **作业 6**（柯西分布）设 $X_1, X_2, \dots, X_n$ i.i.d., X_1 服从柯西分布，概率密度为

$$f(x, \sigma) = \frac{1}{\pi\sigma} \frac{1}{1 + (x/\sigma)^2}, \quad -\infty < x < \infty,$$

求

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

的抽样分布。

解 设每个样本的特征函数为

$$\varphi_X(t) = E(e^{itX}).$$

由柯西分布的已知结论，

$$X_i \sim \text{Cauchy}(0, \sigma) \implies \varphi_{X_i}(t) = e^{-\sigma|t|}.$$

由于 $X_1, X_2, \dots, X_n$ 相互独立，故

$$\varphi_{\bar{X}}(t) = E(e^{it\bar{X}}) = E\left(e^{it\frac{1}{n}\sum_{i=1}^n X_i}\right) = \prod_{i=1}^n E\left(e^{i(t/n)X_i}\right).$$

于是

$$\varphi_{\bar{X}}(t) = \prod_{i=1}^n \varphi_{X_i}\left(\frac{t}{n}\right) = \left(e^{-\sigma|t|/n}\right)^n = e^{-\sigma|t|}.$$

东邪的 tip 5.3

independent and identically distributed 相互独立而且同分布所以第二行能写成 n 次方，第一行只是把加号从指数取下来变成了乘法。这题的终点就是让 e 头上都是单独的 X_i ，只要是单独的 X_i 他们的 ϕ_{X_i} 就是一样就可以用乘 n 次去掉那个 $1/n$

这正是参数为 σ 的柯西分布的特征函数，因此

$$\bar{X} \sim \text{Cauchy}(0, \sigma).$$

故 $\bar{X}$ 的抽样分布仍为柯西分布，其概率密度为

$$f_{\bar{X}}(x) = \frac{1}{\pi\sigma} \frac{1}{1 + (x/\sigma)^2}, \quad -\infty < x < \infty.$$

东邪的 tip 5.4

题目要求样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

的抽样分布，即确定 $\bar{X}$ 服从什么分布并求出其密度函数。

由于直接由密度求 $\bar{X}$ 的分布需要进行多重卷积，计算较为繁琐，因此转而先求 $\bar{X}$ 的特征函数，再由特征函数来确定其分布。

求得 $\bar{X}$ 的特征函数后，将其与已知分布的特征函数进行比较，识别出 $\bar{X}$ 所服从的分布，进而写出其密度函数，从而得到所求的抽样分布。

page45

 **作业 1** 证明 (2.2.3) 式。

$$\sum_{k=r}^n C_n^k p^k (1-p)^{n-k} = r C_n^r \int_0^p t^{r-1} (1-t)^{n-r} dt.$$

解 令 $S(p) = \sum_{k=r}^n C_n^k p^k (1-p)^{n-k}$ ，对 p 求导，利用

$$k C_n^k = n C_{n-1}^{k-1}, \quad (n-k) C_n^k = n C_{n-1}^k$$

得

$$S'(p) = n \sum_{k=r}^n C_{n-1}^{k-1} p^{k-1} (1-p)^{n-k} - n \sum_{k=r}^n C_{n-1}^k p^k (1-p)^{n-k-1}$$

两个求和指标相同，错位相消，只剩 $k=r$ 的首项：

$$S'(p) = n C_{n-1}^{r-1} p^{r-1} (1-p)^{n-r} = r C_n^r p^{r-1} (1-p)^{n-r}$$

两边从 0 到 p 积分， $S(0) = 0$ ，故

$$S(p) = r C_n^r \int_0^p t^{r-1} (1-t)^{n-r} dt. \quad \blacksquare$$

东邪的 tip 5.5

这个证明一边有积分一边没积分，就应该想到对左边求导，再从 0 到 p 积分。观察 $r C_n^r$ 前面有系数 r ，以此类推 C_n^k 前面对 p 求导也会带出系数 k 。前导后不导是第一项，前不导后导是第二项，他们共同的目的是都凑出一个 n ，这样两项就可以错位相消。

笔记 [组合恒等式的记忆]

$$C_n^k = \frac{n!}{k!(n-k)!}$$

东邪的 tip 5.6

两个恒等式都是从分母的 $(n-k)!$ 或 $k!$ 里拆出一个因子变成系数。

kC_n^k : k 乘进去消掉分母的 $k!$ 变成 $(k-1)!$, 同时从 $n!$ 拿出一个 n 变成 $n \cdot (n-1)!$, 分母剩 $(k-1)!(n-k)!$, 正好是 nC_{n-1}^{k-1} 。

$(n-k)C_n^k$: $(n-k)$ 乘进去消掉分母的 $(n-k)!$ 变成 $(n-k-1)!$, 同时从 $n!$ 拿出一个 n 变成 $n \cdot (n-1)!$, 分母剩 $k!(n-k-1)!$, 即 $k!(n-1-k)!$, 正好是 nC_{n-1}^k 。

两个式子都靠拿出 n 保证下面变成 $n-1$, k 或 $n-k$ 各自消掉对应的阶乘。

- $kC_n^k = nC_{n-1}^{k-1}$: 左边从 n 人里选 k 人再指定 1 个队长; 右边先指定队长再从剩下 $n-1$ 人选 $k-1$ 人。
- $(n-k)C_n^k = nC_{n-1}^k$: 左边从 n 人里选 k 人再从未选的 $n-k$ 人里指定 1 个; 右边先指定那个人再从剩下 $n-1$ 人选 k 人。

作业 2 (几何分布) 设总体 X 服从几何分布

$$P\{X = k\} = p(1-p)^{k-1}, \quad k = 1, 2, \dots,$$

$X_1, X_2, \dots, X_n$ 是抽自 X 的简单随机样本, 求 $X_{(1)}, X_{(n)}$ 的分布。

解 设 $q = 1 - p$ 。由 $P(X = k) = pq^{k-1}$ 得尾概率

$$P(X > m) = q^m, \quad P(X \leq m) = 1 - q^m, \quad m = 0, 1, 2, \dots$$

1. $X_{(1)}$: $P(X_{(1)} > m) = (P(X > m))^n = (q^n)^m$, 这正是参数 $1 - q^n$ 的几何分布的尾概率, 故 $X_{(1)} \sim \text{Geo}(1 - q^n)$:

$$P(X_{(1)} = m) = (1 - q^n)(q^n)^{m-1}, \quad m = 1, 2, \dots$$

2. $X_{(n)}$: $P(X_{(n)} \leq m) = (P(X \leq m))^n = (1 - q^m)^n$, 逐点差分

$$P(X_{(n)} = m) = (1 - q^m)^n - (1 - q^{m-1})^n, \quad m = 1, 2, \dots$$

($X_{(n)}$ 非标准分布, 无更简形式。)

东邪的 tip 5.7 (F 里面是具体的数字因为我们默认是小于等于)

$$P(X \leq x) = F(x) \rightarrow \text{CDF (Cumulative Distribution Function, 累积分布函数/分布函数)}$$

就是因为默认都是 X 小于等于就把他省略了呗专注一个变量就是 x 也就是具体的数字。因为概率论我们最终想知道的就是具体的概率, 也就扔出 5 的概率只有离散型能知道, 扔小于 5 的概率离散和连续都能知道

东邪的 tip 5.8

求分布就是求分布函数。

离散型求的是具体大于一个数字的概率, 比如 X_1 大于 m 的概率; 因为知道这个公式, 每一个点 (也就是等于 m 点) 的概率都能用相邻两个求到。

连续型求的是 X_1 的概率密度; 因为知道了概率密度, 小于一个数的概率可以用积分它来求到。

作业 3 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$, 试分别求出 $X_{(1)}$ 和 $X_{(n)}$ 的概率密度。

解 总体 $X \sim U[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$, 其密度与分布函数为

$$f(x) = 1, \quad F(x) = x - \theta + \frac{1}{2}, \quad \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2}.$$

由通用公式 $f_{(n)}(x) = n[F(x)]^{n-1}f(x)$ 及 $f_{(1)}(x) = n[1 - F(x)]^{n-1}f(x)$, 代入得:

$$f_{X_{(n)}}(x) = n \left(x - \theta + \frac{1}{2} \right)^{n-1}, \quad f_{X_{(1)}}(x) = n \left(\theta + \frac{1}{2} - x \right)^{n-1},$$

均在 $\theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2}$ 上成立, 其余为 0。

东邪的 tip 5.9

求 $F_{X_{(1)}}(x) = P(X_{(1)} \leq x)$ 不好直接下手: $\{X_{(1)} \leq x\} = \{\exists i, X_i \leq x\}$ 是个“并集”事件, 独立性用不上 (并集不能直接拆乘积)。

转而求补集 $1 - P(X_{(1)} > x)$: $\{X_{(1)} > x\} = \{\text{所有 } X_i > x\}$ 是“交集”事件, 独立性下可以直接拆成乘积。每个 X_i : $P(X_i > x) = 1 - F(x)$ ——积分积出来的本来就是“ $\leq x$ ”的概率 $F(x)$, 取补即得“ $> x$ ”。

由独立性:

$$P(X_{(1)} > x) = [1 - F(x)]^n \implies F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n.$$

最后求导, $F'_{X_{(1)}}(x)$ 就是密度 $f_{X_{(1)}}(x)$ 。

5.2 第二次作业

5.2.1 45,3,4,6

 **作业** 4 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F(x)$ 有概率密度 $f(x)$, 求:

1. $X_{(1)}$ 和 $X_{(n)}$ 的联合分布函数及联合概率密度;
2. $R = X_{(n)} - X_{(1)}$ 的分布函数及概率密度。

解 设 $U = X_{(1)}$, $V = X_{(n)}$, 即

$$F_{U,V}(x, y) = P(U \leq x, V \leq y) = P(X_{(1)} \leq x, X_{(n)} \leq y).$$

对 $x \leq y$,

$$F_{U,V}(x, y) = P(V \leq y) - P(U > x, V \leq y) = [F(y)]^n - [F(y) - F(x)]^n$$

($x > y$ 时退化为 $[F(y)]^n$)。求 $\partial^2 / \partial x \partial y$ ($x < y$):

$$f_{U,V}(x, y) = n(n-1)[F(y) - F(x)]^{n-2} f(x) f(y), \quad x < y.$$

令 $R = V - U$, $T = U$, 即 $U = T$, $V = T + R$, 雅可比 $J = 1$ 。代入并积去 T :

$$f_R(r) = \int_{-\infty}^{\infty} f_{U,V}(t, t+r) dt = n(n-1) \int_{-\infty}^{\infty} [F(t+r) - F(t)]^{n-2} f(t) f(t+r) dt, \quad r > 0,$$

$r \leq 0$ 时 $f_R(r) = 0$ 。

东邪的 tip 5.10

联合分布也是我们想要求具体的, 也就是 $X_{(1)} \leq x$ 且 $X_{(n)} \leq y$ 的概率。

对 $X_{(n)}$ 来说, 它小于 y 很好求, 因为它小于 y 意味着所有人都得小于 y , 每一个小于 y 的概率乘起来就行了。

但是 $X_{(1)}$ 小于 x 不好求, 它能求的只是大于 x 。

所以这里用 $X_{(n)}$ 小于 y 的概率, 减去 $X_{(n)}$ 小于 y 且 $X_{(1)}$ 大于 x 的概率。然后就是分别对 x 求偏导和对 y 求偏导

东邪的 tip 5.11

我简单理解雅可比就是把变量换了以后需不需要在前面乘系数乘多少对。求什么设什什, 然后需要一个辅助的让他们两能凑出原来两个开始变量, 才能求雅各比系数, 求出雅各比系数把原来概率密度代入

新的变量，然后通过积分把辅助的变量积掉剩下的就是要求的概率密度

作业 5 从某总体抽取一个容量为 5 的样本：

$$-2.8, -1, 1.5, 2.1, 3.4.$$

写出该样本的经验分布函数并画出它的图形。

解 将样本按从小到大排列为

$$x_{(1)} = -2.8, \quad x_{(2)} = -1, \quad x_{(3)} = 1.5, \quad x_{(4)} = 2.1, \quad x_{(5)} = 3.4.$$

经验分布函数定义为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I\{x_i \leq x\}.$$

这里 $n = 5$ ，所以


$$F_5(x) = \begin{cases} 0, & x < -2.8, \\ \frac{1}{5}, & -2.8 \leq x < -1, \\ \frac{2}{5}, & -1 \leq x < 1.5, \\ \frac{3}{5}, & 1.5 \leq x < 2.1, \\ \frac{4}{5}, & 2.1 \leq x < 3.4, \\ 1, & x \geq 3.4. \end{cases}$$

其图形是一个右连续的阶梯函数，在

$$x = -2.8, -1, 1.5, 2.1, 3.4$$

这五个点处分别向上跳跃 $\frac{1}{5}$ 。

可用下列 TikZ 代码作图：



东邪的 tip 5.12

经验分布函数就是：看样本里有多少比例不超过 x 。图像的纵轴就是累积比例，横轴就是具体的节点。也就是 $F_5(x)$ 图像

作业 6 证明：正态分布 $N(\mu, \sigma^2)$ 的上 α ($0 < \alpha < 1$) 分位数 z_α 与标准正态分布的上 α 分位数 u_α 之间有以下关系：

$$z_\alpha = \mu + \sigma u_\alpha$$

证明 设 $Y = \frac{X - \mu}{\sigma} \sim N(0, 1)$ 。标准化得

$$P(X > z_\alpha) = P\left(Y > \frac{z_\alpha - \mu}{\sigma}\right).$$

由定义 $P(X > z_\alpha) = \alpha = P(Y > u_\alpha)$ ，而标准正态分布函数严格单调，故

$$\frac{z_\alpha - \mu}{\sigma} = u_\alpha \implies z_\alpha = \mu + \sigma u_\alpha.$$

东邪的 tip 5.13

概率小于 α 积分得积到哪里, 不等式两边同时标准化, $z\alpha$ 标准化以后就 $\mu\alpha$ 标准正态阿尔法的分位数

5.2.2 46,1,2,3

ection

 **作业 1** 设 $X \sim \chi^2(n)$, 证明:

$$E(X^k) = 2^k \left(\frac{n}{2} + k - 1\right) \left(\frac{n}{2} + k - 2\right) \cdots \frac{n}{2}, \quad k = 1, 2, \cdots$$

特别地, 有 $E(X) = n, \text{Var}(X) = 2n$ 。

证明 设 $X \sim \chi^2(n)$, 其密度为

$$f(x) = \frac{1}{2^{n/2}\Gamma(n/2)} x^{\frac{n}{2}-1} e^{-x/2}, \quad x > 0.$$

故

$$E(X^k) = \int_0^\infty x^k f(x) dx = \frac{1}{2^{n/2}\Gamma(n/2)} \int_0^\infty x^{\frac{n}{2}+k-1} e^{-x/2} dx.$$

由积分公式 $\int_0^\infty x^{a-1} e^{-x/2} dx = 2^a \Gamma(a)$, 取 $a = \frac{n}{2} + k$, 得

$$E(X^k) = \frac{2^{\frac{n}{2}+k} \Gamma(\frac{n}{2} + k)}{2^{n/2}\Gamma(n/2)} = 2^k \frac{\Gamma(\frac{n}{2} + k)}{\Gamma(n/2)}.$$

再由 $\Gamma(z+1) = z\Gamma(z)$ 反复递推, 即得

$$E(X^k) = 2^k \frac{\Gamma(\frac{n}{2} + k)}{\Gamma(n/2)} = 2^k \left(\frac{n}{2} + k - 1\right) \left(\frac{n}{2} + k - 2\right) \cdots \frac{n}{2}.$$

注 由上式可顺便验证卡方分布的期望与方差。

当 $k = 1$ 时,

$$E(X) = 2 \cdot \frac{n}{2} = n.$$

当 $k = 2$ 时,

$$E(X^2) = 2^2 \left(\frac{n}{2} + 1\right) \frac{n}{2} = 4 \cdot \frac{n+2}{2} \cdot \frac{n}{2} = n(n+2) = n^2 + 2n.$$

因此

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = (n^2 + 2n) - n^2 = 2n.$$

东邪的 tip 5.14

分母其实就是原来的 $\Gamma(n/2) \cdot 2^{n/2}$, 因为这就是原来的归一化系数。然后由于 x 头上的指数从 $\frac{n}{2} - 1$ 又加上了一个 k ——它如果正常乘 1 去积分, 结果就是分母那个系数; 现在 x 头上多了 k , 所以 Γ 里面和 2 的头上都要加 k 。每次往外拿出一个因子, 于是前面的系数从 $\frac{n}{2} + k - 1$ 一直往下乘, 把 k 个因子取完、降到 $\frac{n}{2}$; 上下的 Γ 函数消掉, $2^{n/2}$ 也消掉。

 **作业 2** 设 $X \sim t(n)$, 则当 $k < n$ 时, $E(X^k)$ 存在且有

$$E(X^k) = \begin{cases} 0, & \text{当 } k \text{ 为奇数;} \\ n^{\frac{k}{2}} \frac{\Gamma(\frac{k+1}{2})\Gamma(\frac{n-k}{2})}{\sqrt{\pi}\Gamma(\frac{n}{2})}, & \text{当 } k \text{ 为偶数.} \end{cases}$$

当 $k \geq n$ 时, $E(X^k)$ 是否存在?

东邪的 tip 5.15

证明不存在就想不收敛也就是积分趋紧于无穷。

证明 设 $X \sim t(n)$, 密度 $f(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$. 当 $|x| \rightarrow \infty$ 时,
 $|x|^k f(x) \sim C|x|^{k-n-1} \quad (C > 0 \text{ 为常数}).$

由幂函数积分判别法, $\int_{-\infty}^{\infty} x^{k-n-1} dx$ 收敛 $\iff k-n-1 < -1 \iff k < n$.
 故 $E(|X|^k) < \infty \iff k < n$, 即 $t(n)$ 分布的 k 阶矩存在当且仅当 $k < n$.

东邪的 tip 5.16

密度函数本质上来讲就是为了归一化的系数, 所以他的影响不大会爆炸的就是 x 的次方这项

作业 3 设 $X_1 \sim \chi^2(m), X_2 \sim \chi^2(n)$, X_1, X_2 相互独立, 则 $X_1 + X_2$ 与 X_1/X_2 相互独立.

证明 设 $U = X_1 + X_2, W = \frac{X_1}{X_1 + X_2}$, 则 $u > 0, 0 < w < 1$, 反解得 $X_1 = Uw, X_2 = U(1-w)$, 雅可比
 $\left| \frac{\partial(x_1, x_2)}{\partial(u, w)} \right| = \begin{vmatrix} w & u \\ 1-w & -u \end{vmatrix} = u.$

由 $X_1 \sim \chi^2(m), X_2 \sim \chi^2(n)$ 独立, 代入联合密度并整理得

$$f_{U,W}(u, w) = f_{X_1, X_2}(uw, u(1-w)) \cdot u = \underbrace{\frac{1}{2^{\frac{m+n}{2}} \Gamma(\frac{m}{2}) \Gamma(\frac{n}{2})} u^{\frac{m+n}{2}-1} e^{-u/2}}_{g(u)} \cdot \underbrace{w^{\frac{m}{2}-1} (1-w)^{\frac{n}{2}-1}}_{h(w)}, \quad u > 0, 0 < w < 1.$$

$f_{U,W} = g(u)h(w)$ 可分离变量, 故 $U \perp W$. 又 $\frac{X_1}{X_2} = \frac{w}{1-w}$ 是 W 的函数, 故 $U \perp \frac{X_1}{X_2}$, 即 $X_1 + X_2$ 与 $\frac{X_1}{X_2}$ 相互独立.

东邪的 tip 5.17

带入以后本来 u 头上应该是减二的, 但是由于雅各比油弄出一个 u ,

$$X_1 + X_2 \sim \chi^2(m+n).$$

因此

$$g(u) = f_U(u) = \frac{1}{2^{\frac{m+n}{2}} \Gamma(\frac{m+n}{2})} u^{\frac{m+n}{2}-1} e^{-u/2}, \quad u > 0.$$

笔记 $V = \frac{X_1}{X_2}$ 与 $W = \frac{X_1}{X_1 + X_2}$ 满足

$$V = \frac{W}{1-W} \quad (\text{即 } V \text{ 是 } W \text{ 的函数; 反解得 } W = \frac{V}{1+V}).$$

已知 U 与 W 独立, 而独立变量的函数仍保持独立性, 故 U 与 V 也独立.

作业 设 $F \sim F(m, n)$, 证明

$$F_{1-\alpha}(m, n) F_{\alpha}(n, m) = 1, \quad \forall \alpha \in (0, 1).$$

解 设随机变量 $X \sim F(m, n)$. 由 F 分布的性质可知

$$\frac{1}{X} \sim F(n, m).$$

记

$$c = F_{1-\alpha}(m, n),$$

则由分位点定义,

$$P(X \leq c) = 1 - \alpha, \quad P(X > c) = \alpha.$$

于是

$$P\left(\frac{1}{X} < \frac{1}{c}\right) = P(X > c) = \alpha.$$

又因为 $\frac{1}{X} \sim F(n, m)$, 所以按 $F(n, m)$ 分布的 α 分位点定义, 有

$$F_{\alpha}(n, m) = \frac{1}{c} = \frac{1}{F_{1-\alpha}(m, n)}.$$

从而

$$F_{1-\alpha}(m, n) F_{\alpha}(n, m) = 1.$$

证毕。

一般来说, Y 与 X 的分布类型**不一定相同**。

因为 Y 是 $X_1, \dots, X_n$ 的线性组合, 其分布类型取决于 X_i 的具体分布以及矩阵 A 的形式。线性变换通常会改变随机变量的维数与分布结构, 所以不能笼统地说二者分布类型相同。

但在某些特殊情形下分布类型保持不变。例如当 $X_1, \dots, X_n$ 服从正态分布时, $Y = AX$ 仍服从正态分布, 因此这时 Y 与 X 同属正态型分布。

故结论是:

一般不同; 只有在某些特殊分布族 (如正态分布) 下才可能相同。

 **作业 5** (χ^2 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$\mathbf{X} = (X_1, \dots, X_n)^T,$$

A 为 n 阶对称方阵。证明:

$$\mathbf{X}^T A \mathbf{X} \sim \chi^2(r)$$

当且仅当 A 为幂等矩阵, 即

$$A^2 = A,$$

并且

$$\text{rank}(A) = r.$$

解 由于 A 为实对称矩阵, 存在正交矩阵 Q , 使

$$Q^T A Q = \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

令 $Y = Q^T X$ 。因为 $X \sim N_n(0, I_n)$ 且 Q 为正交矩阵, 所以

$$Y \sim N_n(0, I_n),$$

故 $Y_1, \dots, Y_n$ 相互独立, 且都服从 $N(0, 1)$ 。于是

$$X^T A X = X^T Q \Lambda Q^T X = Y^T \Lambda Y = \sum_{i=1}^n \lambda_i Y_i^2.$$

若 $A^2 = A$, 则

$$\Lambda^2 = \Lambda,$$

从而 $\lambda_i^2 = \lambda_i$, 故 $\lambda_i = 0$ 或 1 。又因

$$\text{rank}(A) = \text{rank}(\Lambda) = r,$$

故恰有 r 个 $\lambda_i = 1$, 其余为 0 。因此

$$X^T A X = \sum_{i=1}^r Y_i^2 \sim \chi^2(r).$$

反之, 若 $X^T A X \sim \chi^2(r)$, 则其矩母函数为

$$M_{X^T A X}(t) = \prod_{i=1}^n (1 - 2\lambda_i t)^{-1/2} = (1 - 2t)^{-r/2}.$$

由此可知恰有 r 个 $\lambda_i = 1$, 其余 $\lambda_i = 0$. 于是

$$\Lambda^2 = \Lambda, \quad \text{rank}(\Lambda) = r.$$

再由 $A = Q\Lambda Q^T$, 得

$$A^2 = Q\Lambda^2 Q^T = Q\Lambda Q^T = A, \quad \text{rank}(A) = r.$$

故

$$X^T A X \sim \chi^2(r)$$

当且仅当 A 为幂等矩阵, 且 $\text{rank}(A) = r$.

5.3 第三次作业

 **作业** 设 $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, 又设 $X_{n+1} \sim N(\mu, \sigma^2)$, 且与 $X_1, \dots, X_n$ 相互独立. 记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

证明

$$T = \sqrt{\frac{n}{n+1}} \frac{\bar{X} - X_{n+1}}{s} \sim t(n-1).$$

解 由正态总体性质, $\bar{X} \sim N(\mu, \sigma^2/n)$, $\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$, 且二者独立; 又 $X_{n+1} \sim N(\mu, \sigma^2)$ 与 $X_1, \dots, X_n$ (从而与 $\bar{X}, s^2$) 独立, 故

$$\bar{X} - X_{n+1} \sim N\left(0, \frac{n+1}{n}\sigma^2\right) \quad \text{且与 } s^2 \text{ 独立.}$$

令

$$Z = \frac{\bar{X} - X_{n+1}}{\sqrt{\frac{n+1}{n}}\sigma} \sim N(0, 1), \quad U = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1),$$

且 $Z \perp U$. 由 t 分布定义,

$$\frac{Z}{\sqrt{U/(n-1)}} = \sqrt{\frac{n}{n+1}} \cdot \frac{\bar{X} - X_{n+1}}{s} = T \sim t(n-1).$$

东邪的 tip 5.18

t 分布需要标准正态和卡方. 标准正态自然就是 $\bar{X} - X_{n+1}$ 提供, 减法只是把均值拉到了 0, 但还要把方差归一, 所以还要除以 $\sqrt{\frac{n+1}{n}}$. 下面卡方分布总是要除以 $n-1$, 然后它除以 σ^2 的部分总要和分子消掉——每次分母都只会剩一个 s , 也只会提供一个 s . 公式中剩下的部分都是正态分布提供的。

 **作业 2.4 第 1 题** 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

求 $\text{Var}(s^2)$.

解 由 $X_1, \dots, X_n \sim N(0, 1)$, 故 $\sigma^2 = 1$, 从而

$$(n-1)s^2 \sim \chi^2(n-1) \implies D((n-1)s^2) = 2(n-1).$$

又 $D((n-1)s^2) = (n-1)^2 D(s^2)$, 故

$$(n-1)^2 D(s^2) = 2(n-1) \implies D(s^2) = \frac{2}{n-1}.$$

东邪的 tip 5.19

卡方分布 $\chi^2(n-1)$ 的方差就是 $2(n-1)$ ，也就是“2 倍自由度”。然后 $(n-1)s^2$ 是把 s^2 乘了 $(n-1)$ 倍，方差就会变大 $(n-1)^2$ 倍，即 $D((n-1)s^2) = (n-1)^2 D(s^2)$ 。两边一约，剩下 $D(s^2) = \frac{2}{n-1}$ 。

 **作业 2.4 第 2 题** 设 $X_1, \dots, X_m$ i.i.d., $X_1 \sim N(\mu_1, \sigma^2)$; $Y_1, \dots, Y_n$ i.i.d., $Y_1 \sim N(\mu_2, \sigma^2)$ ，且这两组随机变量相互独立。记

$$s_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \quad s_2^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

1. 求

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{\sigma^2}$$

的分布；

2. 比较 s_1^2 与

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}$$

的方差。

解

1. 由 $\frac{(m-1)s_1^2}{\sigma^2} \sim \chi^2(m-1)$, $\frac{(n-1)s_2^2}{\sigma^2} \sim \chi^2(n-1)$ ，且两者独立，由可加性

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{\sigma^2} \sim \chi^2(m+n-2).$$

2. 记 $W = \frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}$ 。由 $\chi^2(k)$ 方差为 $2k$ 及 $D(aX) = a^2 D(X)$ ：

$$\frac{(m-1)s_1^2}{\sigma^2} \sim \chi^2(m-1) \implies D(s_1^2) = \frac{2\sigma^4}{m-1},$$

$$\frac{(m+n-2)W}{\sigma^2} \sim \chi^2(m+n-2) \implies D(W) = \frac{2\sigma^4}{m+n-2}.$$

由 $m+n-2 > m-1$ ，得 $D(W) < D(s_1^2)$ ，即 W 的方差更小。

东邪的 tip 5.20

其实就是按照自由度算方差再把系数产生的影响除掉，记住是除以系数的平方

 **作业 2.4 第 3 题** 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$ ，求

$$Z = \frac{\sum_{i=1}^{n-1} X_i}{X_n}$$

的分布。

解 设 $Y = \sum_{i=1}^{n-1} X_i \sim N(0, n-1)$ ，与 $X_n \sim N(0, 1)$ 独立 (Y 仅依赖 $X_1, \dots, X_{n-1}$)。标准化后 $\frac{Y}{\sqrt{n-1}} \sim N(0, 1)$ 仍与 X_n 独立，两个独立标准正态之比服从标准柯西分布，故

$$\frac{Y/\sqrt{n-1}}{X_n} \sim C(0, 1).$$

由 $Z = \frac{Y}{X_n} = \sqrt{n-1} \cdot \frac{Y/\sqrt{n-1}}{X_n}$ 及柯西分布的尺度性质 $aC(0, 1) = C(0, a)$ ，得

$$Z \sim C(0, \sqrt{n-1}).$$

东邪的 tip 5.21

其实就是要弄成两个标准正态分布想除就是标准柯西，柯西分布很特殊他压根没有方差那个 1 不是方差所以乘系数不用平方

 **作业 1** (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 分别用一阶矩和二阶矩求 λ 的矩估计量。

解 由 $E(X) = \lambda$, $E(X^2) = \lambda^2 + \lambda$:

1. 一阶矩: 令 $\bar{X} = \lambda$, 得 $\hat{\lambda}_1 = \bar{X}$ 。

2. 二阶矩: 令 $\frac{1}{n} \sum_{i=1}^n X_i^2 = \lambda^2 + \lambda$, 解得 (舍负根)

$$\hat{\lambda}_2 = \frac{-1 + \sqrt{1 + \frac{4}{n} \sum_{i=1}^n X_i^2}}{2}.$$

东邪的 tip 5.22

本质就是列“理论矩 = 样本矩”的方程, x_i 全部视为已知数, 解出未知参数即可。

 **作业 2** (二项分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim B(k, p)$, 求 p 的矩估计量。

解 由 $X_1 \sim B(k, p)$ 知

$$E(X) = kp.$$

由矩估计法, 令样本一阶原点矩等于总体一阶原点矩, 即

$$\bar{X} = kp.$$

解得 p 的矩估计量为

$$\hat{p} = \frac{\bar{X}}{k}.$$

东邪的 tip 5.23

有几个参数列几个方程其实 k 是已经知道的就 p 一个未知数

 **作业 3** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的矩估计量。

解 由 $E(X) = \frac{\theta_1 + \theta_2}{2}$, $E(X^2) = \frac{\theta_1^2 + \theta_1\theta_2 + \theta_2^2}{3}$, 记 $m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$, 令

$$\theta_1 + \theta_2 = 2\bar{X}, \quad \theta_1^2 + \theta_1\theta_2 + \theta_2^2 = 3m_2.$$

由恒等式 $(\theta_1 + \theta_2)^2 = \theta_1^2 + 2\theta_1\theta_2 + \theta_2^2$ 得

$$\theta_1\theta_2 = (2\bar{X})^2 - 3m_2 = 4\bar{X}^2 - 3m_2.$$

故 θ_1, θ_2 是方程 $t^2 - 2\bar{X}t + (4\bar{X}^2 - 3m_2) = 0$ 的两根, 解得

$$\hat{\theta}_{1,2} = \bar{X} \mp \sqrt{3(m_2 - \bar{X}^2)}.$$

 **笔记** $[U(\theta, \theta)]$ 的矩

$$E(X^k) = \int_{\theta_1}^{\theta_2} x^k \cdot \frac{1}{\theta_2 - \theta_1} dx = \frac{\theta_2^{k+1} - \theta_1^{k+1}}{(k+1)(\theta_2 - \theta_1)}.$$

用因式分解约去 $(\theta_2 - \theta_1)$: $a^2 - b^2 = (a-b)(a+b)$, $a^3 - b^3 = (a-b)(a^2 + ab + b^2)$, 得

$$E(X) = \frac{\theta_1 + \theta_2}{2}, \quad E(X^2) = \frac{\theta_1^2 + \theta_1\theta_2 + \theta_2^2}{3}.$$

 **笔记** 用的是二元二次方程的根与系数关系, 也叫韦达定理。

如果

$$t^2 - St + P = 0$$

的两根是 r_1, r_2 , 那么

$$r_1 + r_2 = S, \quad r_1 r_2 = P.$$

 **作业 5** (双边指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x)$,

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x|}{\sigma}\right),$$

求 σ 的矩估计量。

解 由密度函数

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x|}{\sigma}\right)$$

可知该分布关于 0 对称, 且

$$E(X) = 0, \quad E(X^2) = 2\sigma^2.$$

由于 $E(X)$ 不含参数 σ , 故取二阶原点矩作矩估计。令

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = E(X^2) = 2\sigma^2,$$

解得

$$\hat{\sigma} = \sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}.$$

故 σ 的矩估计量为

$$\hat{\sigma} = \sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}.$$

东邪的 tip 5.24

就是要最后得出一个 σ 和真是函数的关系

 **笔记** [$\hat{\theta}$ 的含义] 写“解”之前, θ 是理论世界里那个抽象常数; 写“解”之后, 式子已经变成纯粹由数据 $X_1, \dots, X_n$ 算出来的东西——这是个新对象 (统计量), “^就是标记”这个东西变了”的符号。

5.4 第五周作业

 **作业 7** 设 $X_1, X_2, \dots, X_n$ i.i.d., 试分别求下列总体中 θ 的最大似然估计量。

2. (韦布尔分布) $f(x; \theta) = \frac{x}{\theta^2} e^{-x^2/\theta^2}$, $x > 0$, $\theta > 0$.

东邪的 tip 5.25

先连乘再去对数, 再求导, 去对数不影响因为是单增的。

解 似然函数为

$$L(\theta) = \prod_{i=1}^n \frac{x_i}{\theta^2} e^{-x_i^2/\theta^2} = \frac{\prod_{i=1}^n x_i}{\theta^{2n}} \exp\left(-\frac{\sum_{i=1}^n x_i^2}{\theta^2}\right)$$

取对数得 $\ln L(\theta) = \sum_{i=1}^n \ln x_i - 2n \ln \theta - \frac{\sum_{i=1}^n x_i^2}{\theta^2}$, 对 θ 求导令其为零得 $-\frac{2n}{\theta} + \frac{2 \sum_{i=1}^n x_i^2}{\theta^3} = 0$, 化简得 $\sum_{i=1}^n x_i^2 = n\theta^2$, 故

$$\hat{\theta} = \sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2}$$

 **作业 8** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U\left(\theta - \frac{1}{2}, \theta + \frac{1}{2}\right)$, 证明任意

$$T \in \left[X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2}\right]$$

都是 θ 的最大似然估计量。

证明 均匀分布的密度函数为

$$f(x; \theta) = \begin{cases} 1 & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 0 & \text{其他} \end{cases}$$

故似然函数为 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$, 当且仅当所有 x_i 均落在 $[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$ 内时 $L(\theta) = 1$, 否则 $L(\theta) = 0$ 。上述条件等价于

$$\theta - \frac{1}{2} \leq x_{(1)} \quad \text{且} \quad x_{(n)} \leq \theta + \frac{1}{2}$$

即 $x_{(n)} - \frac{1}{2} \leq \theta \leq x_{(1)} + \frac{1}{2}$, 故对任意 $T \in [X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2}]$, 均有 $L(T) = 1 = \max_{\theta} L(\theta)$, 即 T 为 θ 的最大似然估计量。

东邪的 tip 5.26

注意需要所有 x_i 都落在 $[\theta - 1/2, \theta + 1/2]$

 **作业 10** (双参数指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x; \alpha, \beta)$,

$$f(x; \alpha, \beta) = \begin{cases} \beta \exp\{-\beta(x - \alpha)\}, & x \geq \alpha, \\ 0, & \text{其他,} \end{cases}$$

其中 $\beta > 0$ 。试求 α, β 的最大似然估计量。

解 似然函数为

$$L(\alpha, \beta) = \prod_{i=1}^n \beta e^{-\beta(x_i - \alpha)} \cdot \mathbf{1}(\alpha \leq x_{(1)}) = \beta^n e^{-\beta \sum_{i=1}^n (x_i - \alpha)} \cdot \mathbf{1}(\alpha \leq x_{(1)})$$

固定 β , 由于 $L(\alpha, \beta) \propto e^{n\beta\alpha}$ 关于 α 单调递增, 故在约束 $\alpha \leq x_{(1)}$ 下最大值在边界处取得, 即 $\hat{\alpha} = X_{(1)}$ 。将 $\hat{\alpha}$ 代入取对数得

$$\ln L(\beta) = n \ln \beta - \beta \sum_{i=1}^n (x_i - x_{(1)})$$

对 β 求导令其为零: $\frac{d \ln L}{d \beta} = \frac{n}{\beta} - \sum_{i=1}^n (x_i - x_{(1)}) = 0$, 解得

$$\hat{\beta} = \frac{n}{\sum_{i=1}^n (X_i - X_{(1)})}$$

东邪的 tip 5.27

我明白了因为关于 α 是单增的所以压根没有极值点。其实就是为了让似然函数最大然后找极值点或者最大值

 **笔记** [截尾几何分布] $X = r + 1$ 表示“截尾”: 前 r 次全部失败 ($T > r$) 才记为 $r + 1$, 并非“第 $r + 1$ 次恰好成功”。

$$P(X = r + 1) = P(T > r) = \theta^r, \quad \sum_{k=1}^r \theta^{k-1}(1 - \theta) + \theta^r = 1 \checkmark$$

东邪的 tip 5.28

这个 $P(X = k)$ 其实就是第 k 次成功, 也就是 $1 - \theta$; 前面 $k - 1$ 次都不成功, 就是 θ 。

 **作业 11** (截尾几何分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., 为来自截尾几何分布总体 X 的样本:

$$P\{X = k\} = \theta^{k-1}(1 - \theta), \quad k = 1, 2, \dots, r;$$

$$P\{X = r + 1\} = \theta^r.$$

记

$$M = \#\{i : X_i = r + 1, i = 1, 2, \dots, n\},$$

试证明 θ 的 MLE 为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i - n}{\sum_{i=1}^n X_i - M}.$$

证明 注意 k 是 PMF 的哑变量, 写似然函数时用观测值 x_i 代入。记截尾个数 $M = \#\{i : x_i = r + 1\}$, $S = \sum_{i=1}^n x_i$ 。似然函数为

$$L(\theta) = \prod_{x_i \leq r} \theta^{x_i-1} (1-\theta) \cdot \prod_{x_i=r+1} \theta^r = \theta^{\sum_{x_i \leq r} (x_i-1) + rM} (1-\theta)^{n-M}$$

由于每个截尾观测都记为 $x_i = r + 1$, 有 $\sum_{x_i=r+1} x_i = (r+1)M$, 于是

$$\sum_{x_i \leq r} (x_i - 1) + rM = \underbrace{\sum_{x_i \leq r} x_i - (n - M)}_{=\sum_{x_i \leq r} (x_i - 1)} + rM = \underbrace{\sum_{x_i \leq r} x_i + (r+1)M - n}_{=S} = S - n$$

故对数似然

$$\ln L(\theta) = (S - n) \ln \theta + (n - M) \ln(1 - \theta)$$

令 $\frac{d \ln L}{d\theta} = \frac{S - n}{\theta} - \frac{n - M}{1 - \theta} = 0$, 即 $(S - n)(1 - \theta) = (n - M)\theta$, 解得

$$\hat{\theta} = \frac{S - n}{S - M} = \frac{\sum_{i=1}^n X_i - n}{\sum_{i=1}^n X_i - M}$$

东邪的 tip 5.29

$P\{X = k\}$ 告诉我们每个 x_i 服从什么分布。具体的 x_i 在 θ 下出现的概率取决于它是否超过 r :

- 若 $x_i \leq r$, 贡献为 $\theta^{x_i-1}(1-\theta)$ 。例如 $x_i = 1$, 贡献就是 $(1-\theta)$ 。
- 若 $x_i = r + 1$ (截尾), 贡献为 θ^r 。

$M = \#\{i : x_i = r + 1\}$ 是截尾样本的个数。截尾的含义是: 真实值 $\geq r + 1$ 的观测 (如 5, 6, 7, 8, ...) 统统被记录为 $r + 1$, 一共有 M 个。

每个截尾样本贡献 θ^r , 共 M 个, 所以指数上多出 rM :

$$\prod_{x_i=r+1} \theta^r = \theta^{rM}$$

牢记: M 是个数, 不是某个 x_i 的值。

 **作业 12** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta_1, \theta_2)$,

$$f(x, \theta_1, \theta_2) = \begin{cases} \frac{\theta_1}{\theta_2} x^{\theta_1-1} \exp\left(-\frac{x^{\theta_1}}{\theta_2}\right), & x \geq 0, \\ 0, & \text{其他,} \end{cases}$$

其中 θ_1 已知, 求 θ_2 的最大似然估计量。

解 似然函数为

$$L(\theta_2) = \prod_{i=1}^n \frac{\theta_1}{\theta_2} x_i^{\theta_1-1} \exp\left(-\frac{x_i^{\theta_1}}{\theta_2}\right)$$

取对数得

$$\ln L(\theta_2) = n \ln \theta_1 - n \ln \theta_2 + (\theta_1 - 1) \sum_{i=1}^n \ln x_i - \frac{1}{\theta_2} \sum_{i=1}^n x_i^{\theta_1}$$

对 θ_2 求导并令其为零:

$$\frac{d \ln L}{d\theta_2} = -\frac{n}{\theta_2} + \frac{\sum_{i=1}^n x_i^{\theta_1}}{\theta_2^2} = 0$$

解得 θ_2 的最大似然估计量为

$$\hat{\theta}_2 = \frac{1}{n} \sum_{i=1}^n X_i^{\theta_1}$$

东邪的 tip 5.30

计算要点就是别着急算连乘不好算就先取对数取完对数还是恶性就是求完到再算先把不相关的像全部删除

 **作业 18** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 其中 σ^2 已知, μ 的先验分布为 $N(\nu, \tau^2)$ 。

1. 求 μ 的后验分布;
2. 求 μ 的后验均值估计。

解 似然函数为

$$f(\mathbf{X}|\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) \propto \exp\left(-\frac{n(\bar{x} - \mu)^2}{2\sigma^2}\right)$$

先验分布为

$$\pi(\mu) \propto \exp\left(-\frac{(\mu - \nu)^2}{2\tau^2}\right)$$

后验分布满足 $p(\mu|\mathbf{X}) \propto f(\mathbf{X}|\mu) \cdot \pi(\mu)$, 将指数部分合并:

$$-\frac{n(\bar{x} - \mu)^2}{2\sigma^2} - \frac{(\mu - \nu)^2}{2\tau^2} = -\frac{1}{2} \left(\frac{n}{\sigma^2} + \frac{1}{\tau^2} \right) \left(\mu - \frac{\frac{n\bar{x}}{\sigma^2} + \frac{\nu}{\tau^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}} \right)^2 + \text{常数}$$

令 $\frac{1}{\tau_1^2} = \frac{n}{\sigma^2} + \frac{1}{\tau^2}$, $\mu_1 = \tau_1^2 \left(\frac{n\bar{x}}{\sigma^2} + \frac{\nu}{\tau^2} \right)$, 则

1. 后验分布为

$$\mu|\mathbf{X} \sim N(\mu_1, \tau_1^2)$$

2. μ 的后验均值估计 (Bayes 估计) 为

$$\hat{\mu} = \mu_1 = \frac{\frac{n}{\sigma^2} \bar{X} + \frac{1}{\tau^2} \nu}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

东邪的 tip 5.31

其实我们已经知道了正态分布是共轭更新了他的后验也一定是正态我们只是需要算后验正态的中心也就是 μ 和方差也就是 σ 平方是多少就行了, 就是和 μ 没有关系的其实都是具体的数一顿算可以提取到外面的。他可以扔也是因为幂指数加法拆开了以后其实还是乘法。

东邪的 tip 5.32

其实算完后验以后我们就像弄出一个平方和然后剩下的部分直接当 $1/\text{方差}$ 了 $\exp$ 里面就符合正态标准写的形式我们就能分清楚谁谁方差谁是 μ 了。自然后验是正态他的期望就是我们算出来的 μ_1

 **笔记** 第一步: 利用恒等式

$$\sum_{i=1}^n (x_i - \mu)^2 = n(\bar{x} - \mu)^2 + \sum_{i=1}^n (x_i - \bar{x})^2$$

右边第二项与 μ 无关, 用 $\propto$ 略去; 前置系数 $\frac{1}{\sqrt{2\pi}\sigma}$ 同理略去, 故

$$f(\mathbf{X}|\mu) \propto \exp\left(-\frac{n(\bar{x} - \mu)^2}{2\sigma^2}\right)$$

 **作业 20** (帕雷托 (Pareto) 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, 其中 θ 的先验分布为 $\text{Pareto}(a, b)$, 其

概率密度为

$$\pi(\theta) = \frac{ba^b}{\theta^{b+1}}, \quad a < \theta < \infty, a > 0, b > 0.$$

1. 求 θ 的后验分布;
2. 求 θ 的后验均值估计。

解 似然函数为

$$f(\mathbf{X}|\theta) = \prod_{i=1}^n \frac{1}{\theta} \cdot \mathbf{1}(\theta \geq x_{(n)}) = \theta^{-n} \cdot \mathbf{1}(\theta \geq x_{(n)})$$

先验分布为 $\pi(\theta) \propto \theta^{-(b+1)} \cdot \mathbf{1}(\theta > a)$, 后验分布满足

$$p(\theta|\mathbf{X}) \propto \theta^{-n} \cdot \theta^{-(b+1)} \cdot \mathbf{1}(\theta \geq \max(x_{(n)}, a)) = \theta^{-(n+b+1)} \cdot \mathbf{1}(\theta \geq \max(x_{(n)}, a))$$

对比帕累托分布标准形式, 令 $a' = \max(x_{(n)}, a)$, $b' = n + b$, 则

1. 后验分布为

$$\theta|\mathbf{X} \sim \text{Pareto}(\max(x_{(n)}, a), n + b)$$

2. θ 的后验均值估计 (Bayes 估计) 为

$$\hat{\theta} = \frac{(n + b) \max(x_{(n)}, a)}{n + b - 1}$$

东邪的 tip 5.33

也就是用似然乘先验得倒后验以后对着标准的式子看看谁谁 a 谁是 b 然后求期望其实是固定的公式

 **笔记** 后验分布满足

$$p(\theta | \mathbf{X}) \propto \theta^{-n} \cdot \theta^{-(b+1)} \cdot \mathbf{1}(\theta \geq \max(x_{(n)}, a)).$$

第一步: 合并指数,

$$p(\theta | \mathbf{X}) \propto \theta^{-(n+b+1)} \cdot \mathbf{1}(\theta \geq \max(x_{(n)}, a)).$$

第二步: 对比帕累托标准形式 $\text{Pareto}(a', b') \propto \theta^{-(b'+1)} \cdot \mathbf{1}(\theta > a')$, 比较指数得 $b' = n + b$, 比较指示函数得 $a' = \max(x_{(n)}, a)$ 。

第三步: 后验分布为

$$\theta | \mathbf{X} \sim \text{Pareto}(\max(x_{(n)}, a), n + b).$$

第四步: 套帕累托均值公式 $E[\theta] = \frac{b'a'}{b'-1}$, 得 Bayes 估计

$$\hat{\theta} = \frac{(n + b) \max(x_{(n)}, a)}{n + b - 1}.$$

5.5 无偏估计

 **作业 1** (泊松分布) 设 $X \sim P(\lambda)$, 试求样本量为 1 时 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量, 并说明该估计的不合理性。

东邪的 tip 5.34

所以他想让我找到一个函数 $h(X)$, 代入 X 后期望等于 $e^{-2\lambda}$

解 设 $\hat{g}(X)$ 为 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量, 需满足

$$E[\hat{g}(X)] = \sum_{k=0}^{\infty} \hat{g}(k) \cdot \frac{\lambda^k e^{-\lambda}}{k!} = e^{-2\lambda}$$

求期望只是把权重从 X 变成了 $g(X)$ 其他的不变

$$E[h(X)] = \sum_{k=0}^{\infty} h(k) \cdot P(X=k) = \sum_{k=0}^{\infty} h(k) \cdot \frac{\lambda^k e^{-\lambda}}{k!}$$

注意到 $e^{-2\lambda} = e^{-\lambda} \cdot e^{-\lambda}$, 而泊松分布中 $k=0$ 时 $P(X=0) = e^{-\lambda}$, 故令

$$\hat{g}(k) = (-1)^k$$

验证:

$$E[(-1)^X] = \sum_{k=0}^{\infty} (-1)^k \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(-\lambda)^k}{k!} = e^{-\lambda} \cdot e^{-\lambda} = e^{-2\lambda} \checkmark$$

故 $\hat{g}(X) = (-1)^X$ 是 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量。

不合理性: $g(\lambda) = e^{-2\lambda} \in (0, 1)$, 而估计量 $(-1)^X$ 的取值只有 ± 1 , 当 X 为奇数时估计值为 $-1 < 0$, 与 $g(\lambda)$ 的真实范围完全不符, 因此该估计虽无偏但实际意义很差。

 **笔记** $P(X=0)$ 是确定的

东邪的 tip 5.35

- e 的级数定义: $e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$, 令 $x=1$ 得 $e = \sum_{n=0}^{\infty} \frac{1}{n!}$ (注意 $0! = 1$, 首项为 1)。
- 代入任意值即可使用: 如令 $x = -\lambda$, 得 $e^{-\lambda} = \sum_{k=0}^{\infty} \frac{(-\lambda)^k}{k!}$ 。

东邪的 tip 5.36 (看见阶乘求和的时候就要想 e)

上面 k 次方是为了求 k 次导自动变成第一项 1 也就是 e 永远展开的第一项. $e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}$

 **作业 2** (二项分布) 设 $X \sim B(n, p)$, 证明 $g(p) = \frac{1}{1+p^2}$ 不存在无偏估计量。

解 假设存在 $g(p) = \frac{1}{1+p^2}$ 的无偏估计量 $\hat{g}(X)$, 则需满足

$$E[\hat{g}(X)] = \sum_{k=0}^n \hat{g}(k) \binom{n}{k} p^k (1-p)^{n-k} = \frac{1}{1+p^2}$$

对所有 $p \in (0, 1)$ 成立。但左边展开后是关于 p 的次数不超过 n 的多项式, 而右边 $\frac{1}{1+p^2}$ 不是多项式, 两者不可能恒等, 矛盾。故 $g(p) = \frac{1}{1+p^2}$ 不存在无偏估计量。

东邪的 tip 5.37

分母含参数就不是多项式

 **笔记** [不存在无偏估计量的证明套路] 用反证法: 假设存在无偏估计量 $\hat{g}(X)$, 则

$$E[\hat{g}(X)] = g(\theta), \quad \forall \theta$$

分析左边 (期望) 关于 θ 的函数性质:

- 离散分布 (如二项): 左边展开后是关于参数的多项式, 若 $g(\theta)$ 不是多项式则矛盾
- 连续分布 (如正态): 分析左边关于 θ 的解析性质, 与 $g(\theta)$ 的性质对比得矛盾

核心: 左边的函数类型有限制, 若 $g(\theta)$ 不满足该限制, 则不存在无偏估计量。

 **作业 3** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, 1)$, 证明 $g(\mu) = |\mu|$ 没有无偏估计量。

解 假设存在 $g(\mu) = |\mu|$ 的无偏估计量 $\hat{g}(X)$, 则需满足

$$E[\hat{g}(X)] = |\mu|, \quad \forall \mu \in \mathbb{R}$$

注意到正态分布的期望

$$E[\hat{g}(X)] = \int_{-\infty}^{\infty} \hat{g}(x) \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2}} dx$$

右边作为 μ 的函数, 可以验证它关于 μ 是解析函数 (光滑且可展开为幂级数)。但 $|\mu|$ 在 $\mu = 0$ 处不可导, 因此不是解析函数, 矛盾。故 $g(\mu) = |\mu|$ 没有无偏估计量。

东邪的 tip 5.38

无偏估计量关于 μ 无穷可微

 **作业 4** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的无偏估计量。

解 均匀分布 $U(\theta_1, \theta_2)$ 的顺序统计量期望为

$$E[X_{(1)}] = \frac{n\theta_1 + \theta_2}{n+1}, \quad E[X_{(n)}] = \frac{\theta_1 + n\theta_2}{n+1}$$

联立解得

$$\theta_1 = \frac{nE[X_{(1)}] - E[X_{(n)}]}{n-1}, \quad \theta_2 = \frac{nE[X_{(n)}] - E[X_{(1)}]}{n-1}$$

故 θ_1, θ_2 的无偏估计量为

$$\hat{\theta}_1 = \frac{nX_{(1)} - X_{(n)}}{n-1}, \quad \hat{\theta}_2 = \frac{nX_{(n)} - X_{(1)}}{n-1}$$

东邪的 tip 5.39

$E(X_1)$ 里面的 X_1 是实验前的, θ_1 那个 X_1 是真实的 X_1 , 只要没带具体数字就是大写, 代入具体数字了就是小写。

 **笔记** 因为期望是线性的, 对 $\hat{\theta}_1 = \frac{nX_{(1)} - X_{(n)}}{n-1}$ 取期望:

$$E[\hat{\theta}_1] = \frac{nE[X_{(1)}] - E[X_{(n)}]}{n-1} = \theta_1$$

正好等于 θ_1 , 所以它是无偏估计量。

$\hat{\theta}_1$ 不是一个具体数字, 而是公式本身, 是随机变量, 故 $X_{(1)}$ 仍为大写, 我们还在实验前。

东邪的 tip 5.40 (均匀分布必记)

$$f(x) = \frac{1}{\theta_2 - \theta_1}, \quad F(x) = \frac{x - \theta_1}{\theta_2 - \theta_1}$$

$$E[X_{(1)}] = \frac{n\theta_1 + \theta_2}{n+1}, \quad E[X_{(n)}] = \frac{\theta_1 + n\theta_2}{n+1}$$

 **笔记** 将期望 $E[X_{(1)}]$ 和 $E[X_{(n)}]$ 直接替换为样本观测值 $X_{(1)}$ 和 $X_{(n)}$, 即可得到无偏估计量。本质上就是用样本值替换期望值, 这是构造无偏估计量的标准操作。

 **作业 5** 设 $\hat{\theta}$ 和 θ^* 为 θ 的无偏估计量, 若 $\tilde{\theta} = a\hat{\theta} + b\theta^*$, 问: a, b 满足什么条件时, $\tilde{\theta}$ 也是 θ 的无偏估计量?

解 由期望的线性性质:

$$E[\tilde{\theta}] = E[a\hat{\theta} + b\theta^*] = aE[\hat{\theta}] + bE[\theta^*] = a\theta + b\theta = (a+b)\theta$$

要使 $\tilde{\theta}$ 也是 θ 的无偏估计量, 需 $E[\tilde{\theta}] = \theta$, 故条件为

$$a + b = 1$$

东邪的 tip 5.41

要让 $\tilde{\theta}$ 这个公式是无偏估计量其实就是问他的期望不等于 θ

 **作业 6** 设 $X \sim U(0, \theta)$, $X_1, X_2, \dots, X_n$ i.i.d. 为来自 X 的样本, 试分别求 θ^2, θ^{-1} 的无偏估计量。

解 $X \sim U(0, \theta)$ 的顺序统计量最大值期望为 $E[X_{(n)}] = \frac{n\theta}{n+1}$, 故

$$E\left[\frac{n+1}{n}X_{(n)}\right] = \theta$$

即 $\hat{\theta} = \frac{n+1}{n}X_{(n)}$ 是 θ 的无偏估计量。

求 θ^2 的无偏估计量:

需要 $E[X_{(n)}^2]$, 利用 $U(0, \theta)$ 的顺序统计量密度 $f_{(n)}(x) = \frac{nx^{n-1}}{\theta^n}$:

$$E[X_{(n)}^2] = \int_0^\theta x^2 \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n\theta^2}{n+2}$$

故 θ^2 的无偏估计量为

$$\hat{\theta}^2 = \frac{n+2}{n}X_{(n)}^2$$

求 θ^{-1} 的无偏估计量:

$$E[X_{(n)}^{-1}] = \int_0^\theta x^{-1} \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta(n-1)}$$

故 θ^{-1} 的无偏估计量为

$$\widehat{\theta^{-1}} = \frac{n-1}{n}X_{(n)}^{-1} = \frac{n-1}{nX_{(n)}}$$

东邪的 tip 5.42

- 此题让我们找到一个公式对 X_i 操作, 使其期望等于 θ^2 或 θ^{-1} 。
- θ 一般用最大值作估计量, 先把 $X_{(n)}$ 弄出来再进行下一步。
- 求 $E[X_{(n)}^2]$ 就是把积分里的 x 变成 x^2 , 求 $E[X_{(n)}^{-1}]$ 就是把原来的 x 换成 $\frac{1}{x}$ 。

两步走:

1. 先找 $E[X_{(n)}^k]$, 因为 $X_{(n)}$ 是 θ 的天然载体。
2. 凑出系数让期望正好等于 θ^2 或 θ^{-1} 。

5.6 第七周作业

 作业 1 证明:

$$I(\theta) = \text{Var}\left(\frac{\partial}{\partial\theta} \ln f(X; \theta)\right) = -E\left(\frac{\partial^2}{\partial\theta^2} \ln f(X; \theta)\right)$$

东邪的 tip 5.43

得分函数 S 是关于 X 的函数, 求期望的时候只是把原本的权重 x 换成 S , 原本对应的概率密度 $f(x; \theta)$ 没变, $\ln f$ 就是 $\ln f(x; \theta)$ 简写, 求 S^2 期望就是把权重从 S 变成 S^2 。

证明 记 $S(X; \theta) = \frac{\partial}{\partial\theta} \ln f(X; \theta)$, 称为得分函数。

第一步: 证明 $E[S(X; \theta)] = 0$ 。

由于 $\int f(x; \theta) dx = 1$, 两边对 θ 求导并交换积分与求导顺序, 得

$$\int \frac{\partial}{\partial\theta} f(x; \theta) dx = 0.$$

$$\frac{\partial}{\partial\theta} f = \frac{\partial}{\partial\theta} e^{\ln f} = e^{\ln f} \cdot \frac{\partial}{\partial\theta} \ln f = f \cdot S$$

注意到

$$\frac{\partial}{\partial \theta} f(x; \theta) = f(x; \theta) \cdot S(x; \theta),$$

故 $E[S(X; \theta)] = 0$ 。

第二步：对 $\int S(x; \theta) f(x; \theta) dx = 0$ 再次对 θ 求导：

$$\int \left(\frac{\partial^2}{\partial \theta^2} \ln f \cdot f + S^2 \cdot f \right) dx = 0,$$

即

$$E \left(\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right) + E(S^2) = 0.$$

第三步：由 $E[S] = 0$ 得 $\text{Var}(S) = E(S^2)$ ，故

$$I(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \ln f(X; \theta) \right) = -E \left(\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right).$$

东邪的 tip 5.44

积分公式里面的 f 之所以没有了是因为求期望就是要乘 f 的所以这里的积分，最后都能写成期望。

笔记

$$\frac{\partial}{\partial \theta} (S \cdot f) = \underbrace{\frac{\partial S}{\partial \theta} \cdot f}_{\text{前导后不导}} + \underbrace{S \cdot \frac{\partial f}{\partial \theta}}_{\text{前不导后导}}$$

- 想出是 Sf 像乘是因为出现对 $\ln f$ 对二阶导哪一项必须是对 S 这个已经有一阶导再求一次导剩下的那个就是未求导原始式子
- 前导后不导 $\frac{\partial S}{\partial \theta} \cdot f = \frac{\partial^2}{\partial \theta^2} \ln f \cdot f \rightarrow$ 积分后得 $E \left[\frac{\partial^2}{\partial \theta^2} \ln f \right]$
- 前不导后导 $S \cdot \frac{\partial f}{\partial \theta} = S^2 \cdot f \rightarrow$ 积分后得 $E[S^2]$

东邪的 tip 5.45

$I\theta = \text{var}$ 是确定的，其实这里就是要巧妙利用 $E(S)$ 的期望是 0，他期望是 0 的原因就是因为导数和积分可以交换位置然后概率密度积分永远是 1，然后 $\ln S$ 求导总有一个 $1/s$ 所以此才会有 $f \cdot S = f/d\theta$ 。

 **作业 7** 设 W 是 θ 的无偏估计量，若 W 满足

- (1) W 是观察值（样本）的线性函数；
- (2) $E_{\theta} W = \theta, \forall \theta \in \Theta$ ；
- (3) 若对任意一个满足 (1), (2) 的估计 W^* ，有

$$\text{Var}_{\theta}(W) \leq \text{Var}_{\theta}(W^*), \quad \forall \theta \in \Theta,$$

则称 W 是 θ 的最优线性无偏估计量。如总体 $X \sim N(\mu, \sigma^2)$, $(\mu, \sigma^2) \in \Theta = \{(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma^2 > 0\}$ 。

证明 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 μ 的最优线性无偏估计量。该结论只对正态总体正确吗？

解 验证条件 (1)： $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是观察值的线性函数，条件 (1) 成立。

验证条件 (2)：由于 $X \sim N(\mu, \sigma^2)$,

$$E_{\mu} \bar{X} = \frac{1}{n} \sum_{i=1}^n EX_i = \frac{1}{n} \cdot n\mu = \mu, \quad \forall (\mu, \sigma^2) \in \Theta,$$

故 $\bar{X}$ 是 μ 的无偏估计，条件 (2) 成立。

验证条件 (3): 设 $W^* = \sum_{i=1}^n c_i X_i$ 是任意满足条件 (1)(2) 的估计量, 则由无偏性:

$$EW^* = \sum_{i=1}^n c_i \mu = \mu \cdot \sum_{i=1}^n c_i = \mu,$$

故 $\sum_{i=1}^n c_i = 1$ 。又由于 $X_1, \dots, X_n$ 独立同分布,

$$\text{Var}_\theta(W^*) = \sigma^2 \sum_{i=1}^n c_i^2.$$

由 Cauchy-Schwarz 不等式:

$$\sum_{i=1}^n c_i^2 \geq \frac{(\sum_{i=1}^n c_i)^2}{n} = \frac{1}{n},$$

等号当且仅当 $c_1 = \dots = c_n = \frac{1}{n}$ 时成立, 即 $W^* = \bar{X}$ 。故

$$\text{Var}_\theta(W^*) \geq \frac{\sigma^2}{n} = \text{Var}_\theta(\bar{X}), \quad \forall \theta \in \Theta.$$

条件 (3) 成立, $\bar{X}$ 是 μ 的最优线性无偏估计量。

该结论只对正态总体正确吗? 不是。上述证明中仅用到了 X_i 独立同分布、 $EX_i = \mu$ 、 $\text{Var}(X_i) = \sigma^2 < \infty$, 并未用到正态性。由 Gauss-Markov 定理, 对任意有限方差的总体, $\bar{X}$ 都是 μ 的最优线性无偏估计量 (BLUE)。

东邪的 tip 5.46

因为独立, 方差可以直接相加:

$$\text{Var}(W^*) = \text{Var}\left(\sum_{i=1}^n c_i X_i\right) = \sum_{i=1}^n c_i^2 \text{Var}(X_i)$$

又因为同分布, 每个 $\text{Var}(X_i) = \sigma^2$, 提出来得 $\sigma^2 \sum_{i=1}^n c_i^2$ 。

 **笔记** [Gauss-Markov 定理] 只要 X_i 满足:

1. 独立同分布
2. $EX_i = \mu$
3. $\text{Var}(X_i) = \sigma^2 < \infty$

不需要正态, $\bar{X}$ 就是 μ 的 BLUE (Best Linear Unbiased Estimator, 最优线性无偏估计量)。

东邪的 tip 5.47

本质上就是模仿 umvue 定义了一个只不过这个得线性

东邪的 tip 5.48

这是一个新定义的题, 先验证条件 (1), 再验证无偏 (即期望是参数), 然后验证方差最小。

验证方差最小时, 任意取一个满足条件的估计量 W^* 。题目规定了线性函数无偏只能写成 $W^* = \sum_{i=1}^n c_i X_i$ 的形式。注意这里

$$EW^* = \sum_{i=1}^n c_i E(X_i),$$

每个 $E(X_i)$ 都等于 μ , 所以整个 $EW^* = \mu \cdot \sum_{i=1}^n c_i$ 。又因为无偏要求期望等于参数 μ , 故 $\sum_{i=1}^n c_i = 1$ 。要让 $\text{Var}_\theta(W^*)$ 最小, 由于 $X_1, \dots, X_n$ 独立, 协方差项全为 0, 直接提系数平方出来:

$$\text{Var}_\theta(W^*) = \sigma^2 \sum_{i=1}^n c_i^2.$$

东邪的 tip 5.49

柯西不等式解决的是平方和与和的平方大小关系对不对，平方和永远大

定理 5.1 (Cauchy-Schwarz 不等式)

设 $a_1, \dots, a_n, b_1, \dots, b_n \in \mathbb{R}$, 则

$$\left(\sum_{i=1}^n a_i b_i \right)^2 \leq \left(\sum_{i=1}^n a_i^2 \right) \left(\sum_{i=1}^n b_i^2 \right),$$

等号当且仅当 $\frac{a_1}{b_1} = \dots = \frac{a_n}{b_n}$ (即 a_i 与 b_i 成比例) 时成立。即两向量内积不超过模长之积, 等号当两向量平行时取到。 $|\mathbf{a} \cdot \mathbf{b}| \leq \|\mathbf{a}\| \|\mathbf{b}\|$



作业 11 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明:

(1) $\bar{X}$ 是 λ 的 UMVUE;

(2) $\tilde{\lambda}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}$ 为 λ^2 的无偏估计量。该估计是 UMVUE 吗?

解 (1) 泊松分布 $P(\lambda)$ 的概率质量函数为

$$P(X=x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x=0, 1, 2, \dots$$

可以写成指数族形式, 充分完备统计量为 $T = \sum_{i=1}^n X_i$ 。

$\bar{X}$ 是 T 的函数, 且

$$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \lambda,$$

故 $\bar{X}$ 是 λ 的无偏估计。由 Lehmann-Scheffé 定理, 基于完备充分统计量的无偏估计是 UMVUE, 故 $\bar{X}$ 是 λ 的 UMVUE。

东邪的 tip 5.50

n 个样本乘在一起, 只用关注 $\ln \lambda$ 前面的系数——从单个 x 变成 n 个 x_i 的和 $\sum x_i$, 这就是充分统计量 T 。

东邪的 tip 5.51 (判定指数族的标准)

成功将密度/PMF 写成

$$f(x; \theta) = h(x) \cdot \exp\{Q(\theta) \cdot t(x) - A(\theta)\}$$

四个部分全部认出, 即可宣布是指数族, $T = \sum t(X_i)$ 是完备充分统计量。

例: 泊松 $P(\lambda)$

$$P(X=x; \lambda) = \underbrace{\frac{1}{x!}}_{h(x)} \cdot \exp\left\{ \underbrace{\ln \lambda}_{Q(\theta)} \cdot \underbrace{x}_{t(x)} - \underbrace{\lambda}_{A(\theta)} \right\}$$

故 $T = \sum X_i$ 是完备充分统计量。

笔记 [常见指数族的充分统计量]

分布	$t(x)$	充分统计量 T
泊松 $P(\lambda)$	x	$\sum X_i$
正态 $N(\mu, \sigma^2)$, σ^2 已知	x	$\sum X_i$
指数 $\text{Exp}(\lambda)$	x	$\sum X_i$
正态 $N(\mu, \sigma^2)$, 两个都未知	(x, x^2)	$(\sum X_i, \sum X_i^2)$, 二维

(2) 首先验证无偏性。对于 $P(\lambda)$, 有 $E(X_i) = \lambda$, $\text{Var}(X_i) = \lambda$, 故 $E(X_i^2) = \lambda^2 + \lambda$ 。从而

$$E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) = \lambda^2 + \lambda,$$

$$E(\bar{X}) = \lambda,$$

$$E(\tilde{\lambda}^2) = (\lambda^2 + \lambda) - \lambda = \lambda^2.$$

故 $\tilde{\lambda}^2$ 是 λ^2 的无偏估计量。

下面判断其是否为 UMVUE。充分完备统计量为 $T = \sum_{i=1}^n X_i \sim P(n\lambda)$ 。将 $\tilde{\lambda}^2$ 改写为 T 的函数：

$$\tilde{\lambda}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}.$$

注意到

$$\sum_{i=1}^n X_i^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n\bar{X}^2 = (n-1)s_n^2 + \frac{T^2}{n},$$

其中 $s_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。但 $\tilde{\lambda}^2$ 不能仅由 T 表示 (含有 $\sum X_i^2$ 项, 依赖样本的更多信息), 故 $\tilde{\lambda}^2$ 不是完备充分统计量 T 的函数。

而基于 T 的 λ^2 的 UMVUE 应当是 $g(T)$ 满足 $E[g(T)] = \lambda^2$ 的唯一函数。计算可得

$$g(T) = \frac{T(T-1)}{n^2} = \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n X_i - 1)}{n^2}$$

满足

$$E[g(T)] = \frac{E[T(T-1)]}{n^2} = \frac{n^2\lambda^2}{n^2} = \lambda^2,$$

且 $g(T)$ 是完备充分统计量的函数, 故 $g(T)$ 才是 λ^2 的 UMVUE。

因此 $\tilde{\lambda}^2$ 不是 λ^2 的 UMVUE。

东邪的 tip 5.52

展开中间项: $-2\bar{X} \sum_{i=1}^n X_i = -2\bar{X} \cdot n\bar{X} = -2n\bar{X}^2$, 因为 $\sum_{i=1}^n X_i = n\bar{X}$ 。然后第二个估算就是以 ET 为基础试。

东邪的 tip 5.53

从估计 λ 到估计 λ^2 , 完备充分统计量 $T = \sum X_i$ 不变。区别在于: T/n 对 λ 无偏, 对 λ^2 不无偏, 所以要在 T 的基础上再套一层函数, 找到新的 $g(T)$ 使 $E[g(T)] = \lambda^2$ 。

东邪的 tip 5.54 (fisher 函数和似然函数的关系)

似然函数与 Fisher 信息量的关系。对数似然函数为

$$\ell(\theta) = \sum_{i=1}^n \ln f(x_i; \theta),$$

对 θ 求二阶导:

$$\frac{\partial^2 \ell}{\partial \theta^2} = \sum_{i=1}^n \frac{\partial^2}{\partial \theta^2} \ln f(x_i; \theta).$$

由于 $X_1, \dots, X_n$ 独立同分布, 取期望后每一项相同, 故

$$-E\left[\frac{\partial^2 \ell}{\partial \theta^2}\right] = -\sum_{i=1}^n E\left[\frac{\partial^2}{\partial \theta^2} \ln f(X_i; \theta)\right] = nI(\theta).$$

即 n 个样本的总 Fisher 信息量是单个样本的 n 倍, C-R 下界 $\frac{1}{nI(\theta)}$ 中的 n 由此而来。

作业 12 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 已知 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 和 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 分别是 μ 和 σ^2 的 UMVUE。计算 μ 和 σ^2 的 C-R 下界。

东邪的 tip 5.55

f 是单个观测 X_1 的密度:

$$f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

算单个观测的 Fisher 信息 $I(\theta)$, C-R 下界是 $\frac{1}{nI(\theta)}$, n 在分母上体现。Fisher 信息的等价形式为:

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \ln f(X, \theta) \right]$$

用二阶导数的期望来算, 实际计算更方便。

解

正态总体 $X \sim N(\mu, \sigma^2)$ 的对数密度为

$$\ln f(x; \mu, \sigma^2) = -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{(x-\mu)^2}{2\sigma^2}.$$

东邪的 tip 5.56

因为有两个参数, 既可以对 μ 求导也可以对 σ 求导。求 μ 的 C-R 下界就要先求 μ 的得分函数: 先 $\ln$, 再对 μ 求导。然后因为 Fisher 信息量是得分函数的方差, 又因为得分函数的期望是 0, 所以直接求得分函数的二阶矩就行了。

计算 μ 的 C-R 下界: 将 σ^2 视为已知, 对 μ 求导:

$$\frac{\partial}{\partial \mu} \ln f = \frac{x - \mu}{\sigma^2}.$$

Fisher 信息量为

$$I(\mu) = E \left[\left(\frac{\partial}{\partial \mu} \ln f \right)^2 \right] = E \left[\frac{(X - \mu)^2}{\sigma^4} \right] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}.$$

故 μ 的 C-R 下界为

$$\frac{1}{nI(\mu)} = \frac{\sigma^2}{n}.$$

而 $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$, 达到 C-R 下界, 故 $\bar{X}$ 是 μ 的 UMVUE。

计算 σ^2 的 C-R 下界: 将 μ 视为已知, 令 $\lambda = \sigma^2$, 对 λ 求导:

$$\frac{\partial}{\partial \lambda} \ln f = -\frac{1}{2\lambda} + \frac{(x-\mu)^2}{2\lambda^2}.$$

Fisher 信息量为

$$I(\lambda) = E \left[\left(-\frac{1}{2\lambda} + \frac{(X-\mu)^2}{2\lambda^2} \right)^2 \right].$$

展开并利用 $(X - \mu)^2 \sim \lambda \chi^2(1)$, 即 $E(X - \mu)^2 = \lambda$, $E(X - \mu)^4 = 3\lambda^2$:

$$I(\lambda) = \frac{1}{4\lambda^2} - \frac{E(X - \mu)^2}{2\lambda^3} + \frac{E(X - \mu)^4}{4\lambda^4} = \frac{1}{4\lambda^2} - \frac{1}{2\lambda^2} + \frac{3}{4\lambda^2} = \frac{1}{2\lambda^2} = \frac{1}{2\sigma^4}.$$

故 σ^2 的 C-R 下界为

$$\frac{1}{nI(\sigma^2)} = \frac{2\sigma^4}{n}.$$

而 $\text{Var}(s^2) = \frac{2\sigma^4}{n-1} > \frac{2\sigma^4}{n}$, 故 s^2 未达到 C-R 下界, 但仍是 σ^2 的 UMVUE。

东邪的 tip 5.57

这里用到的就是标准正态分布的平方服从 $\chi^2(1)$ 。 $-\mu$ 是减去均值，分母的 λ 就是方差 σ^2 ，除以 λ 完成标准化，平方后得到 $\chi^2(1)$ 。看到复杂求期望一定得想能套什么公式

东邪的 tip 5.58

因为 UMVUE 是针对某个特定参数定义的——方差最小的无偏估计量，不同参数当然对应不同的估计量。C-R 下界是所有无偏估计方差的一个充分条件，不是必要条件——达到下界一定是 UMVUE，但 UMVUE 不一定达到下界。因为 2π 是常数， $\ln(2\pi\lambda) = \ln(2\pi) + \ln\lambda$ ，对 λ 求导时 $\ln(2\pi)$ 直接消掉，只剩 $\frac{1}{\lambda}$ 。

 **作业 14** 在定理 3.3.3 的条件下，若 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的估计量，满足

$$E_{\theta}\hat{g}(X_1, X_2, \dots, X_n) = g(\theta) + b(\theta), \quad \forall \theta \in \Theta \subset \mathbf{R},$$

$b(\theta)$ 为估计的偏差，则有

$$\text{Var}_{\theta}(\hat{g}(X_1, X_2, \dots, X_n)) \geq [b'(\theta) + g'(\theta)]^2 / nI(\theta).$$

证明 设 $\hat{g} = \hat{g}(X_1, X_2, \dots, X_n)$ ，由题设条件，

$$E_{\theta}\hat{g} = g(\theta) + b(\theta).$$

对两边关于 θ 求导，在定理 3.3.3 的正则条件下可交换积分与微分，得

$$\frac{d}{d\theta} E_{\theta}\hat{g} = g'(\theta) + b'(\theta).$$

另一方面，

$$\frac{d}{d\theta} E_{\theta}\hat{g} = \frac{d}{d\theta} \int \hat{g} \cdot L(\theta; \mathbf{x}) d\mathbf{x} = \int \hat{g} \cdot \frac{\partial \ln L(\theta; \mathbf{x})}{\partial \theta} \cdot L(\theta; \mathbf{x}) d\mathbf{x} = E_{\theta} \left[\hat{g} \cdot \frac{\partial \ln L}{\partial \theta} \right],$$

其中 $L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta)$ 为似然函数。又由正则条件知

$$E_{\theta} \left[\frac{\partial \ln L}{\partial \theta} \right] = 0,$$

故

$$E_{\theta} \left[\hat{g} \cdot \frac{\partial \ln L}{\partial \theta} \right] = \text{Cov}_{\theta} \left(\hat{g}, \frac{\partial \ln L}{\partial \theta} \right).$$

因此

$$\text{Cov}_{\theta} \left(\hat{g}, \frac{\partial \ln L}{\partial \theta} \right) = g'(\theta) + b'(\theta).$$

由 Cauchy-Schwarz 不等式，

$$\left[\text{Cov}_{\theta} \left(\hat{g}, \frac{\partial \ln L}{\partial \theta} \right) \right]^2 \leq \text{Var}_{\theta}(\hat{g}) \cdot \text{Var}_{\theta} \left(\frac{\partial \ln L}{\partial \theta} \right).$$

由 Fisher 信息量的定义及 i.i.d. 条件，

$$\text{Var}_{\theta} \left(\frac{\partial \ln L}{\partial \theta} \right) = nI(\theta).$$

将以上各式代入，得

$$[g'(\theta) + b'(\theta)]^2 \leq \text{Var}_{\theta}(\hat{g}) \cdot nI(\theta),$$

即

$$\text{Var}_{\theta}(\hat{g}) \geq \frac{[g'(\theta) + b'(\theta)]^2}{nI(\theta)}.$$

东邪的 tip 5.59 (对数导数技巧)

$$\frac{\partial L}{\partial \theta} = L \cdot \frac{\partial \ln L}{\partial \theta}$$

推导: $\ln L$ 对 θ 求导, $\frac{\partial \ln L}{\partial \theta} = \frac{1}{L} \cdot \frac{\partial L}{\partial \theta}$, 所以 $\frac{\partial L}{\partial \theta} = L \cdot \frac{\partial \ln L}{\partial \theta}$ 。就是因为要在积分里面保留 L 保留 L 积分就能重新写成期望

 笔记 [协方差基础公式]

$$\text{Cov}(X, Y) = E[XY] - E[X] \cdot E[Y]$$

特别地, 当 $E[Y] = 0$ 时:

$$\text{Cov}(X, Y) = E[XY]$$

东邪的 tip 5.60

$E_\theta \hat{g}$ 才能出 $g(\theta) + b(\theta)$, 最后式子里面是 $g(\theta)$ 和 $b(\theta)$ 的导数, 说明要对 $E_\theta \hat{g}$ 求导。因为独立同分布直接把 Fisher 写成得分函数的方差, 但不够, 里面不是单个 f 而是所有 f 乘起来的 L 。这样我们就有了两个方差, 想到柯西不等式, 另一端位置应该就是协方差的平方, 我们惊喜地发现就是期望求导的平方, 所以需要证明期望求导的平方等于协方差, 而这里利用的是得分函数期望为 0。

东邪的 tip 5.61 (柯西-施瓦茨不等式)

形式	表达式
向量版	$\ \mathbf{u} \cdot \mathbf{v}\ \leq \ \mathbf{u}\ \ \mathbf{v}\ $
求和版	$\left(\sum a_i b_i\right)^2 \leq \left(\sum a_i^2\right) \left(\sum b_i^2\right)$
随机变量版	$\left(E[(X - EX)(Y - EY)]\right)^2 \leq E[(X - EX)^2] \cdot E[(Y - EY)^2]$

 作业 15 设 $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 都是 $g(\theta)$ 的无偏估计量, 并且 $\hat{g}_1(\mathbf{X})$ 还是 $g(\theta)$ 的 UMVUE, 证明: $\hat{g}_1(\mathbf{X})$ 与 $\hat{g}_2(\mathbf{X})$ 的相关系数非负。

证明 分母 $\sqrt{\text{Var}(\hat{g}_1)\text{Var}(\hat{g}_2)} \geq 0$, 只需证 $\text{Cov}_\theta(\hat{g}_1, \hat{g}_2) \geq 0$ 。

令 $\hat{g}_\alpha = (1 - \alpha)\hat{g}_1 + \alpha\hat{g}_2$, 因系数之和 $(1 - \alpha) + \alpha = 1$, 故 $\hat{g}_\alpha$ 是 $g(\theta)$ 的无偏估计。

由 $\hat{g}_1$ 是 UMVUE, 对一切 $\alpha \in \mathbb{R}$:

$$\text{Var}(\hat{g}_1) \leq \text{Var}(\hat{g}_\alpha)$$

记 $D_1 = \text{Var}(\hat{g}_1)$, $D_2 = \text{Var}(\hat{g}_2)$, $C = \text{Cov}(\hat{g}_1, \hat{g}_2)$, 展开得

$$\varphi(\alpha) := \alpha^2(D_1 - 2C + D_2) - 2\alpha(D_1 - C) \geq 0 \quad \forall \alpha \in \mathbb{R}$$

对 $\alpha > 0$ 两边除以 α :

$$\alpha(D_1 - 2C + D_2) - 2(D_1 - C) \geq 0$$

令 $\alpha \rightarrow 0^+$, 得

$$-2(D_1 - C) \geq 0 \implies C \geq D_1 \geq 0$$

故 $\text{Cov}_\theta(\hat{g}_1, \hat{g}_2) \geq 0$, 相关系数非负。

东邪的 tip 5.62

$$\rho(\hat{g}_1, \hat{g}_2) = \frac{\text{Cov}(\hat{g}_1, \hat{g}_2)}{\sqrt{\text{Var}(\hat{g}_1) \cdot \text{Var}(\hat{g}_2)}}$$

要证 $\rho \geq 0$, 分母是根号必然 ≥ 0 , 所以只需证分子 $\text{Cov}(\hat{g}_1, \hat{g}_2) \geq 0$ 。

东邪的 tip 5.63

要给 $\text{Cov}(\hat{g}_1, \hat{g}_2)$ 确定范围, 就要把它放到不等式的一端。现在能构造不等式的唯一信息是 $\hat{g}_1$ 是 UMVUE, 但 Cov 里需要 $\hat{g}_1$ 和 $\hat{g}_2$ 同时出现, 而 UMVUE 条件只对无偏估计有效, 所以需要构造一个 $\hat{g}_\alpha = (1-\alpha)\hat{g}_1 + \alpha\hat{g}_2$, 系数之和 $(1-\alpha) + \alpha = 1$ 是为了保证无偏性。

作业 16

例题 5.1 例 3.2.12 (0-1 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., 都服从 (0-1) 分布 $B(1, \theta)$, θ 的先验分布为 Beta 分布 $\text{Beta}(a, b)$, 其概率密度为

$$\pi(\theta) = \begin{cases} \frac{1}{B(a, b)} \theta^{a-1} (1-\theta)^{b-1}, & \theta \in (0, 1); \\ 0, & \theta \notin (0, 1), \end{cases}$$

其中 $a > 0, b > 0$ 为给定的常数, $B(a, b)$ 为 Beta 函数。求 θ 的后验均值估计。

(0-1 分布) 考虑例 3.2.12 中的贝叶斯估计量, 其中 θ 的贝叶斯估计量为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i + a}{n + a + b}.$$

(1) 求该估计量的均方误差。

解 令 $S = \sum_{i=1}^n X_i \sim B(n, \theta)$, 则 $ES = n\theta$, $\text{Var}(S) = n\theta(1-\theta)$ 。

计算偏差:

$$E\hat{\theta} - \theta = \frac{n\theta + a}{n + a + b} - \theta = \frac{a - (a+b)\theta}{n + a + b}.$$

计算方差:

$$\text{Var}(\hat{\theta}) = \frac{\text{Var}(S)}{(n + a + b)^2} = \frac{n\theta(1-\theta)}{(n + a + b)^2}.$$

均方误差:

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2 = \frac{n\theta(1-\theta) + [a - (a+b)\theta]^2}{(n + a + b)^2}.$$

东邪的 tip 5.64

先验和后验都是贝塔分布的, 但是具体数据也就是似是二项分布的。所以 $n\theta$ 是用到二项分布公式 S 也是。为什么要求和其实就是求和出来的就是一共成功了多少次, 因为只有成功才算 1。求期望就是把常数自然带, 求方差的时候系数得平方

东邪的 tip 5.65

贝叶斯估计量就是后验的期望, 求期望的时候只有 S 求期望会变其他的其实都是常数

笔记 拆分 $(\hat{\theta} - \theta) = (\hat{\theta} - E\hat{\theta}) + (E\hat{\theta} - \theta)$ 是为了把随机波动 (方差) 和系统误差 (偏差) 分开, 展开后交叉项期望为 0, 故

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2.$$

计算时利用 $S \sim B(n, \theta)$ 的结论 $ES = n\theta$, $\text{Var}(S) = n\theta(1-\theta)$, 再通过线性变换性质

$$E(cS + d) = cES + d, \quad \text{Var}(cS) = c^2 \text{Var}(S)$$

传递到 $\hat{\theta} = \frac{S + a}{n + a + b}$, 分别算出偏差和方差后相加即得 MSE。

5.6.1 3.4

作业 1 设 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{a.s.} a > 0$, 证明:

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{a}.$$

证明 因 $Y_n \xrightarrow{a.s.} a$, 由依概率收敛与几乎处处收敛的关系, $Y_n \xrightarrow{P} a$, 从而

$$\frac{1}{Y_n} \xrightarrow{P} \frac{1}{a}.$$

由 Slutsky 定理, 若 $X_n \xrightarrow{d} X$, $Z_n \xrightarrow{P} c$ (常数), 则 $X_n Z_n \xrightarrow{d} cX$. 取 $Z_n = \frac{1}{Y_n}$, $c = \frac{1}{a}$, 得

$$\frac{X_n}{Y_n} = X_n \cdot \frac{1}{Y_n} \xrightarrow{d} \frac{1}{a} \cdot X = \frac{X}{a}.$$

东邪的 tip 5.66

就是为了用 Slutsky 定理几乎处处比依概率收敛强所以可以把他转化为依概率一个依概率一个依分布依概率还收敛到常数就可以用了

作业 1 若估计序列 $\{\hat{\theta}_n\}$ 满足 $\lim_{n \rightarrow \infty} E_{\theta}(\hat{\theta}_n - \theta)^2 = 0$, $\forall \theta \in \Theta$, 则称 $\hat{\theta}_n$ 为 θ 的均方相合估计量。证明: 均方相合估计必是相合估计量。

证明 由 Chebyshev 不等式, 对任意 $\varepsilon > 0$,

$$P(|\hat{\theta}_n - \theta| \geq \varepsilon) \leq \frac{E_{\theta}(\hat{\theta}_n - \theta)^2}{\varepsilon^2}.$$

因 $\lim_{n \rightarrow \infty} E_{\theta}(\hat{\theta}_n - \theta)^2 = 0$, 故

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \varepsilon) = 0,$$

即 $\hat{\theta}_n \xrightarrow{P} \theta$, $\hat{\theta}_n$ 是 θ 的相合估计量。

东邪的 tip 5.67

就是 MSE 看期末笔记

作业 2 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, $\hat{\theta}_n = X_{(n)}$ 是 θ 的均方相合估计量吗?

解 $X_{(n)}$ 的密度函数为

$$f_{X_{(n)}}(x) = \frac{nx^{n-1}}{\theta^n}, \quad 0 < x < \theta.$$

计算期望与二阶矩:

$$E(X_{(n)}) = \int_0^{\theta} x \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{n+1}\theta,$$

$$E(X_{(n)}^2) = \int_0^{\theta} x^2 \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{n+2}\theta^2.$$

从而

$$E_{\theta}(X_{(n)} - \theta)^2 = E(X_{(n)}^2) - 2\theta E(X_{(n)}) + \theta^2 = \frac{n}{n+2}\theta^2 - \frac{2n}{n+1}\theta^2 + \theta^2 = \frac{2\theta^2}{(n+1)(n+2)} \rightarrow 0.$$

故 $X_{(n)}$ 是 θ 的均方相合估计量。

东邪的 tip 5.68

思路: 直接算 $MSE = E[(X_{(n)} - \theta)^2]$, 若结果 $\rightarrow 0$ 则均方相合。

作业 4 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明: $\bar{X}$, s_n^2 都是 λ 的相合估计量。

证明 对于 $P(\lambda)$, 有 $E(X_1) = \lambda$, $\text{Var}(X_1) = \lambda$, $E(X_1^2) = \lambda^2 + \lambda$ 。

$\bar{X}$ 的相合性：由大数定律， $\bar{X} \xrightarrow{P} E(X_1) = \lambda$ ，故 $\bar{X}$ 是 λ 的相合估计量。

s_n^2 的相合性：样本方差

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2.$$

由大数定律， $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X_1^2) = \lambda^2 + \lambda$ ， $\bar{X}^2 \xrightarrow{P} \lambda^2$ 。由连续映射定理，

$$s_n^2 \xrightarrow{P} (\lambda^2 + \lambda) - \lambda^2 = \lambda,$$

故 s_n^2 是 λ 的相合估计量。

东邪的 tip 5.69 (大数定律只管均值收敛到期望不管别的)

判断用大数定律还是 MSE 证相合性，看估计量的结构：

- 估计量是样本均值形式（或能写成某函数的样本均值）→ 直接用大数定律（+ 连续映射定理）；
- 估计量结构复杂，不好看出收敛到哪，但 bias 和 variance 好算 → 用 MSE。

 **笔记** 大数定律二阶以上的矩也管只要看到 $1/n$ 后面不管是 he 还是平方和都要想到能不能把平方和换成二阶矩

东邪的 tip 5.70

一个用的是大样本依概率收敛到二阶矩，一个用的是二阶矩的平方。正常来说估计期望用均值，估计方差用样本方差，只不过 Poisson 分布的期望和方差都是 λ ，所以它们都叫 λ 的相合估计量。

 **作业 5** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$ ，试证

$$T(X_1, X_2, \dots, X_n) = \sqrt[n]{X_1 X_2 \cdots X_n}$$

为 $g(\theta) = \frac{\theta}{e}$ 的相合估计量。

证明 令 $Y_i = \ln X_i$ 。因 $X_i \sim U(0, \theta)$ ，故

$$E(Y_i) = \int_0^\theta \ln x \cdot \frac{1}{\theta} dx = \ln \theta - 1,$$

$$\text{Var}(Y_i) = E(Y_i^2) - (EY_i)^2 < \infty.$$

由大数定律，

$$\frac{1}{n} \sum_{i=1}^n \ln X_i \xrightarrow{P} \ln \theta - 1 = \ln \frac{\theta}{e}.$$

因指数函数连续，由连续映射定理，

$$T = \exp\left(\frac{1}{n} \sum_{i=1}^n \ln X_i\right) = \sqrt[n]{X_1 X_2 \cdots X_n} \xrightarrow{P} \frac{\theta}{e} = g(\theta),$$

故 T 是 $g(\theta)$ 的相合估计量。

东邪的 tip 5.71

就是想看 T 能不能通过大数定理证明是依概率收敛的然后再通过线性变化继承这个收敛。看见连乘就想 $\ln$ 先变成累加，为了切比雪夫大数定理所以需要方差小于无穷这步是为了大数定理吗，由大数定律：

$$\frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{P} E[Y_1]$$

右边的 $E[Y_1]$ 就是第一步已经算出来的值 $\ln \theta - 1$ ，直接代入即得。

 **作业 6** 设总体的二阶矩存在， $X_1, X_2, \dots, X_n$ 是总体的简单随机样本，则

$$T(X_1, X_2, \dots, X_n) = \frac{2}{n(n+1)} \sum_{i=1}^n i X_i$$

是一阶原点矩的相合估计量。

证明 设总体一阶原点矩为 $\mu = E(X_1)$ 。计算 T 的期望：

$$E(T) = \frac{2}{n(n+1)} \sum_{i=1}^n i \cdot E(X_i) = \frac{2\mu}{n(n+1)} \sum_{i=1}^n i = \frac{2\mu}{n(n+1)} \cdot \frac{n(n+1)}{2} = \mu.$$

计算 T 的方差，设 $\text{Var}(X_1) = \sigma^2 < \infty$ ：

$$\text{Var}(T) = \frac{4}{n^2(n+1)^2} \sum_{i=1}^n i^2 \sigma^2 = \frac{4\sigma^2}{n^2(n+1)^2} \cdot \frac{n(n+1)(2n+1)}{6} = \frac{2\sigma^2(2n+1)}{3n(n+1)} \rightarrow 0.$$

由 Chebyshev 不等式， $T \xrightarrow{P} \mu$ ，故 T 是一阶原点矩的相合估计量。

东邪的 tip 5.72

Chebyshev 把“概率问题”转成“矩问题”：

$$P(|T - \mu| \geq \varepsilon) \leq \frac{E(T - \mu)^2}{\varepsilon^2} = \frac{\text{MSE}}{\varepsilon^2}$$

要让右边 $\rightarrow 0$ ，需 $\text{MSE} = \text{Var}(T) + \text{Bias}^2(T) \rightarrow 0$ ，两项缺一不可：

- $E(T) = \mu$ (无偏) $\Rightarrow \text{Bias} = 0$
- $\text{Var}(T) \rightarrow 0$ (方差项归零)

本题 T 是不等权平均，不能直接用 LLN，只能手算矩 + Chebyshev。

作业 8 (指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta) = \frac{1}{\theta} e^{-x/\theta}$, $x > 0$ ，试证 θ 的 MLE 之渐近分布为 $N\left(\theta, \frac{\theta^2}{n}\right)$ 。

证明 对数似然函数为

$$\ell(\theta) = -n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n X_i.$$

令 $\ell'(\theta) = 0$ ，解得 MLE 为 $\hat{\theta} = \bar{X}$ 。

对于指数分布， $E(X_1) = \theta$ ， $\text{Var}(X_1) = \theta^2$ 。由中心极限定理，

$$\sqrt{n}(\bar{X} - \theta) \xrightarrow{d} N(0, \theta^2),$$

即

$$\hat{\theta} = \bar{X} \xrightarrow{d} N\left(\theta, \frac{\theta^2}{n}\right).$$

故 θ 的 MLE 的渐近分布为 $N\left(\theta, \frac{\theta^2}{n}\right)$ 。

东邪的 tip 5.73

先求得分函数然后让得分函数等于 0 解出 MLE，通过中心极限定理然后再把方差，和均值从 0 和 θ^2 移动到他该在的位置

5.7 第八周作业

作业 9 在习题 3.3.11 中，估计 λ^2 时，求 $\bar{X}^2$ 相对于 $\tilde{\lambda}^2$ 的渐近效率。

东邪的 tip 5.74

Delta 方法是以最原始的 X_i 为基础的，所以方差也是乘它的方差；Delta 里面的 μ 本来就是期望，所以导完了带入的就是原始的期望。

解 设 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P(\lambda)$, 习题 3.3.11 中 λ^2 的无偏估计量为

$$\tilde{\lambda}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}.$$

第一步: 求 $\bar{X}^2$ 的渐近方差. 由 Delta 方法, 令 $g(x) = x^2$, $g'(x) = 2x$, 对 Poisson 分布有 $\text{Var}(X) = \lambda$, 故

$$\sqrt{n}(\bar{X}^2 - \lambda^2) \xrightarrow{d} N(0, 4\lambda^3),$$

即 $\bar{X}^2$ 的渐近方差为 $\frac{4\lambda^3}{n}$.

第二步: 求 $\tilde{\lambda}^2$ 的渐近方差. 令 $Y_i = X_i^2 - X_i$, 则 $\tilde{\lambda}^2 = \bar{Y}$, 由 CLT,

$$\sqrt{n}(\tilde{\lambda}^2 - \lambda^2) \xrightarrow{d} N(0, \text{Var}(Y)).$$

对 Poisson 分布, 利用各阶矩:

$$E[X^2] = \lambda^2 + \lambda, \quad E[X^3] = \lambda^3 + 3\lambda^2 + \lambda, \quad E[X^4] = \lambda^4 + 6\lambda^3 + 7\lambda^2 + \lambda,$$

计算

$$E[Y^2] = E[(X^2 - X)^2] = E[X^4 - 2X^3 + X^2] = (\lambda^4 + 6\lambda^3 + 7\lambda^2 + \lambda) - 2(\lambda^3 + 3\lambda^2 + \lambda) + (\lambda^2 + \lambda) = \lambda^4 + 4\lambda^3 + 2\lambda^2,$$

故

$$\text{Var}(Y) = E[Y^2] - (E[Y])^2 = \lambda^4 + 4\lambda^3 + 2\lambda^2 - \lambda^4 = 4\lambda^3 + 2\lambda^2,$$

即 $\tilde{\lambda}^2$ 的渐近方差为 $\frac{4\lambda^3 + 2\lambda^2}{n}$.

第三步: 计算渐近效率.

$$e(\bar{X}^2, \tilde{\lambda}^2) = \frac{4\lambda^3/n}{(4\lambda^3 + 2\lambda^2)/n} = \frac{4\lambda^3}{4\lambda^3 + 2\lambda^2} = \frac{2\lambda}{2\lambda + 1}.$$

东邪的 tip 5.75

这里之所以要重新设 $\bar{Y}$ 和 $\bar{Y}$ 的均值因为中心极限定理 clt 也只能作用在样本均值上, 他描述的是样本均值和期望差的分布。

东邪的 tip 5.76

- Delta 方法: 已知 $\hat{\theta}$ 的渐近方差, 推 $g(\hat{\theta})$ 的渐近方差

$$\text{需要求导, 渐近方差} = [g'(\theta)]^2 \cdot \sigma^2$$

- CLT 直接用: 估计量本身就是样本均值 $\bar{Y}$

$$\text{不需要求导, 渐近方差} = \text{Var}(Y)$$

作业 10 设 $X_1, \dots, X_n \text{ i.i.d.}, X_1 \sim f(x, \theta), \hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 是 θ 的渐近正态估计量:

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{L} N(0, V(\theta)), \quad \forall \theta \in \Theta,$$

$V(\theta)$ 是 θ 的连续函数. 证明: $V(\hat{\theta})$ 为 $V(\theta)$ 的相合估计量.

证明 由渐近正态条件, $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{L} N(0, V(\theta))$, 注意到

$$\hat{\theta}_n - \theta = \frac{1}{\sqrt{n}} \cdot \sqrt{n}(\hat{\theta}_n - \theta),$$

右边 $\sqrt{n}(\hat{\theta}_n - \theta)$ 依分布收敛到有界的 $N(0, V(\theta))$, 再除以 $\sqrt{n} \rightarrow \infty$, 故

$$\hat{\theta}_n - \theta \xrightarrow{P} 0 \implies \hat{\theta}_n \xrightarrow{P} \theta.$$

又因 $V(\theta)$ 是 θ 的连续函数, 由连续映射定理,

$$V(\hat{\theta}_n) \xrightarrow{P} V(\theta).$$

故 $V(\hat{\theta})$ 是 $V(\theta)$ 的相合估计量.

东邪的 tip 5.77

其实就是要证明 $\hat{\theta}$ 依概率收敛到 θ 后直接用线性性质收敛就知道了。

东邪的 tip 5.78

先求 $\hat{\theta}$ 与 θ 之差的分布，然后把根号 n 除进去，方差变为 $\frac{V(\theta)}{n}$ ， $n \rightarrow \infty$ 所以方差趋近于 0，均值也是 0，

$$\hat{\theta}_n - \theta = \frac{1}{\sqrt{n}} \cdot \sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{P} 0$$

因为极限是常数，依分布收敛与依概率收敛等价，故 $\hat{\theta}_n \xrightarrow{P} \theta$ 。再由 V 连续 + 连续映射定理， $V(\hat{\theta}_n) \xrightarrow{P} V(\theta)$ 。

 **笔记** 一般情况下，依分布收敛不能推出依概率收敛，但有一个重要例外：当极限为常数时，二者等价，即

$$\hat{\theta}_n \xrightarrow{L} c \iff \hat{\theta}_n \xrightarrow{P} c.$$

 **作业 12** 设在定理 3.4.6 中， $h(\theta)$ 二阶可导并且 $h'(\theta_0) = 0$ ， $h''(\theta_0) \neq 0$ 。利用泰勒公式 $h(\hat{\theta}) - h(\theta_0) = \frac{1}{2}(\hat{\theta} - \theta_0)^2(h''(\theta_0) + R)$ ，证明

$$n(h(\hat{\theta}) - h(\theta_0)) \xrightarrow{L} \frac{1}{2}A(\theta_0)h''(\theta_0)\chi^2(1),$$

其中 $\chi^2(1)$ 为自由度是 1 的 χ^2 分布。

证明 由定理 3.4.6，MLE $\hat{\theta}$ 满足

$$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, A(\theta_0)).$$

由 Taylor 展开，

$$h(\hat{\theta}) - h(\theta_0) = \frac{1}{2}(\hat{\theta} - \theta_0)^2(h''(\theta_0) + R),$$

其中 $R \xrightarrow{P} 0$ (因为 $\hat{\theta} \xrightarrow{P} \theta_0$ ， h'' 连续)。两边乘以 n ：

$$n(h(\hat{\theta}) - h(\theta_0)) = \frac{1}{2} \left[\sqrt{n}(\hat{\theta} - \theta_0) \right]^2 (h''(\theta_0) + R).$$

由渐近正态条件，

$$\left[\sqrt{n}(\hat{\theta} - \theta_0) \right]^2 \xrightarrow{d} A(\theta_0) \cdot Z^2,$$

其中 $Z \sim N(0, 1)$ ， $Z^2 \sim \chi^2(1)$ ，即

$$\left[\sqrt{n}(\hat{\theta} - \theta_0) \right]^2 \xrightarrow{d} A(\theta_0)\chi^2(1).$$

又因 $R \xrightarrow{P} 0$ ，故 $h''(\theta_0) + R \xrightarrow{P} h''(\theta_0)$ 。由 Slutsky 定理，

$$n(h(\hat{\theta}) - h(\theta_0)) \xrightarrow{d} \frac{1}{2}A(\theta_0)h''(\theta_0)\chi^2(1).$$

东邪的 tip 5.79

$A(\theta_0)$ 就是 MLE 的渐近方差，等于 Fisher 信息的倒数：

$$A(\theta_0) = \frac{1}{I(\theta_0)}$$

东邪的 tip 5.80

看见 fisher 分之一就要想 MLE 先凑出 mle 引入 fisher 分之一，

东邪的 tip 5.81

R 是 Taylor 展开的余项： $R = h''(\xi) - h''(\theta_0)$ ，其中 ξ 夹在 $\hat{\theta}$ 与 θ_0 之间。

$\hat{\theta} \xrightarrow{P} \theta_0$ (MLE 相合) $\Rightarrow \xi \xrightarrow{P} \theta_0 \Rightarrow h''$ 连续，故 $h''(\xi) \xrightarrow{P} h''(\theta_0) \Rightarrow R = h''(\xi) - h''(\theta_0) \xrightarrow{P} 0$

 **笔记** 因为 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, A(\theta_0))$, 可以写成 $\sqrt{A(\theta_0)} \cdot Z$, $Z \sim N(0, 1)$, 平方之后:

$$\left[\sqrt{n}(\hat{\theta} - \theta_0)\right]^2 \xrightarrow{d} \left[\sqrt{A(\theta_0)} \cdot Z\right]^2 = A(\theta_0) \cdot Z^2$$

其中 $X \sim N(0, \sigma^2) \Rightarrow X = \sigma Z \Rightarrow X^2 = \sigma^2 Z^2$, $Z^2 \sim \chi^2(1)$ (标准正态的平方就是自由度为 1 的卡方分布). 故 $A(\theta_0)$ 是常数, $Z^2 \sim \chi^2(1)$.

5.7.1 3.5

定义 5.1 (Beta 分布)

若随机变量 X 的密度函数为

$$f(x; a, b) = \frac{x^{a-1}(1-x)^{b-1}}{B(a, b)}, \quad 0 < x < 1,$$

其中 $a > 0$, $b > 0$, $B(a, b) = \int_0^1 t^{a-1}(1-t)^{b-1} dt$, 则称 X 服从参数为 (a, b) 的 Beta 分布, 记作 $X \sim \text{Beta}(a, b)$.



 **笔记** $\text{Beta}(1, n)$ 是 n 个独立 $U(0, 1)$ 样本最小值 $Y_{(1)}$ 的分布. 设 $Y_i \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 则

$$P(Y_{(1)} > y) = P(\text{所有 } Y_i > y) = (1-y)^n,$$

对 y 求导得密度函数

$$f_{Y_{(1)}}(y) = n(1-y)^{n-1}, \quad 0 < y < 1,$$

恰为 $\text{Beta}(1, n)$ 的密度. 对于 $U(\theta, \theta+1)$ 分布, 令 $Y_i = X_i - \theta \sim U(0, 1)$, 则

$$X_{(1)} - \theta = Y_{(1)} \sim \text{Beta}(1, n),$$

该分布与 θ 无关, 故 $X_{(1)} - \theta$ 构成枢轴量. 类似地, n 个独立 $U(0, 1)$ 样本最大值 $Y_{(n)} \sim \text{Beta}(n, 1)$, 密度函数为 $f(y) = ny^{n-1}$, $0 < y < 1$.

 **作业 1** (均匀分布) 设 $X_1, X_2, \dots, X_n \text{ i.i.d.}$, $X_1 \sim U(\theta, \theta+1)$, 求 θ 的置信度为 $100(1-\alpha)\%$ 的置信区间.

解 设 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} U(\theta, \theta+1)$, 求 θ 的置信度为 $100(1-\alpha)\%$ 的置信区间.

第一步: 选取统计量. $U(\theta, \theta+1)$ 的充分统计量为极值统计量, 取 **二维向量, 二维充分统计量是“信息仓库”, 枢轴量是从里面取出来的“一维工具”, 计算都在一维层面进行**

$$T = (X_{(1)}, X_{(n)}),$$

其中 $X_{(1)} = \min_i X_i$, $X_{(n)} = \max_i X_i$.

第二步: 构造枢轴量. 注意到 $X_i - \theta \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 令

$$G = X_{(1)} - \theta \sim \text{Beta}(1, n),$$

其密度函数为 $f(u) = n(1-u)^{n-1}$, $0 < u < 1$, 与 θ 无关, 故 G 为枢轴量.

第三步: 选取范围 S . 选取 $S = [a, b]$ 满足 $P(a \leq X_{(1)} - \theta \leq b) = 1 - \alpha$. 取等尾:

$$P(X_{(1)} - \theta < a) = \frac{\alpha}{2}, \quad P(X_{(1)} - \theta > b) = \frac{\alpha}{2}.$$

由 $\text{Beta}(1, n)$ 的分布函数 $F(u) = 1 - (1-u)^n$, 解得

$$a = 1 - \left(1 - \frac{\alpha}{2}\right)^{1/n}, \quad b = 1 - \left(\frac{\alpha}{2}\right)^{1/n}.$$

第四步: 等价变换. 由 $a \leq X_{(1)} - \theta \leq b$ 反解 θ :

$$X_{(1)} - b \leq \theta \leq X_{(1)} - a.$$

故 θ 的置信度为 $100(1-\alpha)\%$ 的置信区间为

$$\left[X_{(1)} - 1 + \left(\frac{\alpha}{2}\right)^{1/n}, X_{(1)} - 1 + \left(1 - \frac{\alpha}{2}\right)^{1/n} \right].$$

东邪的 tip 5.82

只是从原来正态的一连串操作变成了把最小值-0

$Y_i = X_i - \theta \sim U(0, 1)$, 分布不含 θ , 所以它本身其实也可以做 pivot.

但我们不用单个 Y_i , 而是用 $X_{(1)} - \theta$, 原因是:

$X_{(1)}$ 是充分统计量, 包含了样本关于 θ 的全部信息, 用它构造的置信区间更短 (更精确). 用单个 $X_i - \theta$ 浪费了其他样本的信息。“

作业 2 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, μ 已知, 求 σ^2 的置信度为 $100(1-\alpha)\%$ 的置信区间. 它与 μ 未知时的区间估计有何差别?

解 设 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, μ 已知, 求 σ^2 的置信度为 $100(1-\alpha)\%$ 的置信区间.

第一步: 选取统计量. μ 已知, 取

$$T = \sum_{i=1}^n (X_i - \mu)^2.$$

第二步: 构造枢轴量. 由于 $\frac{X_i - \mu}{\sigma} \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 故

$$G = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n),$$

其分布与 σ^2 无关, 故 G 为枢轴量.

第三步: 选取范围 S . 取等尾区间, 查 $\chi^2(n)$ 分布表得 $\chi_{\alpha/2}^2(n)$ 和 $\chi_{1-\alpha/2}^2(n)$, 满足

$$P\left(\chi_{1-\alpha/2}^2(n) \leq \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \leq \chi_{\alpha/2}^2(n)\right) = 1 - \alpha.$$

第四步: 等价变换. 对不等式反解 σ^2 :

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)} \leq \sigma^2 \leq \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)}.$$

故 σ^2 的置信度为 $100(1-\alpha)\%$ 的置信区间为

$$\left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)} \right].$$

与 μ 未知时的差别. μ 未知时, 需用 $\bar{X}$ 替代 μ , 枢轴量变为

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$$

自由度从 n 减少为 $n-1$, 损失了一个自由度. 这导致 χ^2 分布的分位数变大, 置信区间变宽, 即 μ 未知时对 σ^2 的估计精度更低.

东邪的 tip 5.83

正确的理解是:

这 n 个偏差 $(X_1 - \bar{X}), \dots, (X_n - \bar{X})$ 之间有一个约束:

$$\sum_{i=1}^n (X_i - \bar{X}) = 0$$

所以前 $n-1$ 个偏差可以随意取, 但第 n 个被前面所有人决定了, 不自由了.

类比: n 个数加起来必须等于 0, 你只能自由选 $n-1$ 个, 最后一个没有选择权.

笔记

$$T \text{ 反映 } \theta \xrightarrow{\text{构造}} G(T, \theta) \begin{cases} \text{含有 } \theta \\ \text{分布不受 } \theta \text{ 控制} \end{cases}$$

- T : 和 θ 数值相关, θ 变 T 也变.

- G : 把 T 和 θ 组合在一起, 但组合的方式恰好让 θ 从分布里消失.

 **作业 3** (指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., X_1 服从指数分布, 密度为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0; \\ 0, & \text{其他.} \end{cases}$$

- (1) 证明 $2n\bar{X}/\theta \sim \chi^2(2n)$;
- (2) 求 θ 的 $100(1-\alpha)\%$ 的置信下限;
- (3) 记 $T_{0.95}$ 为方程 $P\{X_1 > T_{0.95}\} = 0.95$ 的解, 求 $T_{0.95}$ 的 $100(1-\alpha)\%$ 置信下限.

解

(1) 由于 $X_i \sim \Gamma(1, \theta)$, 故 $\sum_{i=1}^n X_i \sim \Gamma(n, \theta)$, 从而

$$\frac{2}{\theta} \sum_{i=1}^n X_i = \frac{2n\bar{X}}{\theta} \sim \Gamma(n, 2) = \chi^2(2n).$$

(2) 由第 (1) 题, 枢轴量为

$$G = \frac{2n\bar{X}}{\theta} \sim \chi^2(2n),$$

其分布与 θ 无关. 求置信下限, 只需单侧约束:

$$P\left(\frac{2n\bar{X}}{\theta} \leq \chi_{\alpha}^2(2n)\right) = 1 - \alpha.$$

反解 θ :

$$\theta \geq \frac{2n\bar{X}}{\chi_{\alpha}^2(2n)}.$$

故 θ 的置信度为 $100(1-\alpha)\%$ 的置信下限为

$$\theta_1 = \frac{2n\bar{X}}{\chi_{\alpha}^2(2n)}.$$

(3) 由指数分布的生存函数, 生存函数的定义是:

$$S(x) = P\{X > x\} = 1 - F(x),$$

就是“存活超过 x 的概率”, 是 CDF 的补.

$$P\{X_1 > T_{0.95}\} = e^{-T_{0.95}/\theta} = 0.95,$$

解得

$$T_{0.95} = -\theta \ln 0.95.$$

$T_{0.95}$ 是 θ 的增函数, 故由第 (2) 题的置信下限 θ_1 , 得 $T_{0.95}$ 的置信度为 $100(1-\alpha)\%$ 的置信下限为

$$-\theta_1 \ln 0.95 = -\frac{2n\bar{X} \ln 0.95}{\chi_{\alpha}^2(2n)}.$$

东邪的 tip 5.84

内在联系三个分布的密度都含有 $e^{-x/\beta}$ 这一项, 本质上都是指数衰减族, 区别只在于前面的多项式部分 $x^{\alpha-1}$. 这个也和高斯积分有关

 **笔记** 指数分布与 χ^2 分布均是 Gamma 分布的特例. Gamma 分布的密度函数为

$$f(x) = \frac{1}{\beta^{\alpha} \Gamma(\alpha)} x^{\alpha-1} e^{-x/\beta}, \quad x > 0.$$

令 $\alpha = 1$, $\beta = \theta$, 化简得 $f(x) = \frac{1}{\theta} e^{-x/\theta}$, 与指数分布密度完全一致, 故

$$X_i \sim \text{Exp}(1/\theta) \iff X_i \sim \Gamma(1, \theta).$$

令 $\alpha = n/2$, $\beta = 2$, 化简得 $f(x) = \frac{1}{2^{n/2}\Gamma(n/2)}x^{n/2-1}e^{-x/2}$, 与 $\chi^2(n)$ 密度完全一致, 故

$$\chi^2(n) = \Gamma\left(\frac{n}{2}, 2\right).$$

三者关系概括为

$$\text{Exp}(1/\theta) = \Gamma(1, \theta), \quad \chi^2(n) = \Gamma\left(\frac{n}{2}, 2\right).$$

 **笔记** 概率分布按密度函数结构可分为三大族:

- 指数族: 密度函数可以写成

$$f(x; \theta) = h(x) \exp(\eta(\theta)T(x) - A(\theta)),$$

几乎所有常见分布均属此族, 包括正态、指数、Gamma、Beta、Poisson、二项、负二项等. 此族分布性质好, 各阶矩均存在.

- 重尾族: 密度函数尾部为多项式衰减 $\sim x^{-\alpha}$, 而非指数衰减, 包括 Cauchy 分布、 t 分布、Pareto 分布等. 此族分布的期望、方差可能不存在, 经典统计方法对其往往失效.
- 有界支撑族: 定义在有限区间上, 无尾部衰减问题, 包括均匀分布 $U(a, b)$ 、Beta 分布 $\text{Beta}(\alpha, \beta)$ 、三角分布等.

统计推断中大多数理论针对指数族建立, 指数衰减族是指数族的重要子集, 三者关系为

$$\text{指数衰减族} \subset \text{指数族} \supset \text{有界支撑族}, \quad \text{重尾族} \cap \text{指数族} = \emptyset.$$

5.8 第九周作业

 **作业 4** (0-1 分布) 某批产品不合格品率 p 未知, 今抽取 100 件检验, 发现 2 件不合格, 试给出不合格品率的置信度 95% 的置信上限。

解 $X_i \sim B(1, p)$, $\hat{p} = \bar{X} = \frac{2}{100} = 0.02$, $n = 100$ 足够大, 由中心极限定理

$$\frac{\sqrt{n}(\hat{p} - p)}{\sqrt{p(1-p)}} \xrightarrow{d} N(0, 1)$$

大样本下以 $\hat{p}$ 替换分母中的 p , 得枢轴量

$$U = \frac{\sqrt{n}(\hat{p} - p)}{\sqrt{\hat{p}(1-\hat{p})}} \approx N(0, 1)$$

置信度 95% 的单侧置信上限, 由 $P(U \leq z_{0.05}) = 0.95$, 查表得 $z_{0.05} = 1.645$, 解不等式

$$\sqrt{n}(\hat{p} - p) \leq z_{0.05} \sqrt{\hat{p}(1-\hat{p})}$$

$$p \geq \hat{p} - \frac{z_{0.05} \sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}$$

故置信上限为

$$\begin{aligned} \bar{p} &= \hat{p} + \frac{z_{0.05} \sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} = 0.02 + \frac{1.645 \times \sqrt{0.02 \times 0.98}}{\sqrt{100}} \\ &= 0.02 + \frac{1.645 \times 0.1400}{10} = 0.02 + 0.0230 = 0.0430 \end{aligned}$$

故不合格品率的置信度 95% 的置信上限为 $\bar{p} = 0.0430$ 。

东邪的 tip 5.85

先判断是什么分布然后为了用 CLT 求和或者均值。中心极限定理要求独立，方差有限，样本量够到，样本的平均值呈正态分布。 $\hat{p}$ 读作 *phat* $\text{Var}\left(\frac{1}{n} \sum X_i\right)$ 这个东西不管 X_i 是什么分布都会稳定地出一个 $\frac{1}{n}$ ，所以 CLT 的时候稳定地要乘一个 $\sqrt{n}$ 来消掉它（因为方差要平方， $(\sqrt{n})^2 = n$ ）。剩下的就是 X_i 本身的方差，这里是 $p(1-p)$ ，所以极限分布是 $N(0, p(1-p))$ 。xi 要不然是 0 要不然就是 1 不是概率

 **笔记** 因为 CLT 作用的对象是样本均值（或样本和），单个 X_i 是 0-1 分布，没法用 CLT。要凑出 $\hat{p} = \frac{1}{n} \sum X_i$ ，才能用 CLT 说它近似正态。

 **笔记**

- $\hat{p} - p$: 是为了让均值变成 0（中心化）
- $\times \sqrt{n}$: 是为了让方差变成有限常数，不是变成 0

具体来说 $\hat{p}$ 的方差是 $\frac{p(1-p)}{n}$ ，乘 $\sqrt{n}$ 后方差变成 $p(1-p)$ ，一个不依赖 n 的常数，这样 $n \rightarrow \infty$ 时分布才能稳定收敛到 $N(0, p(1-p))$ 。

 **作业 5** 设 $X_1, X_2, \dots, X_m$ 与 $Y_1, Y_2, \dots, Y_n$ 是分别来自 $N(\mu_1, \sigma_1^2)$ 与 $N(\mu_2, \sigma_2^2)$ 的两个独立样本。

- (1) 若 σ_1^2, σ_2^2 已知，求 $\mu_2 - \mu_1$ 的置信度为 $1 - \alpha$ 的置信区间。
- (2) 若 $\sigma_1^2 = \sigma_2^2$ 已知，为使置信度为 90% 的 $\mu_2 - \mu_1$ 的置信区间长为 $\frac{2}{5}\sigma_1$ ，问样本大小 $n_1 = n_2$ 应取多大？
- (3) 若 $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2$ 都未知，求 σ_2^2/σ_1^2 的一个 $1 - \alpha$ 置信度的置信区间。

解 由两样本独立且均服从正态分布，有

$$\bar{Y} - \bar{X} \sim N\left(\mu_2 - \mu_1, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right)$$

标准化得枢轴量

$$U = \frac{(\bar{Y} - \bar{X}) - (\mu_2 - \mu_1)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim N(0, 1)$$

由 $P(|U| \leq z_{\alpha/2}) = 1 - \alpha$ ，解得 $\mu_2 - \mu_1$ 的置信度为 $1 - \alpha$ 的置信区间为

$$\left(\bar{Y} - \bar{X} - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}, \bar{Y} - \bar{X} + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \right)$$

 **笔记** 双侧置信区间总概率 $1 - \alpha$ 被两端各分一半：

$$P(|U| \leq z_{\alpha/2}) = 1 - \alpha$$

两侧各留 $\frac{\alpha}{2}$ 的概率在尾部，所以查的是 $z_{\alpha/2}$ 而不是 z_α 。如果是单侧（只求上限或下限），才用 z_α 。

解

- 第 (2) 问：令 $n_1 = n_2 = n$ ， $\sigma_1^2 = \sigma_2^2 = \sigma^2$ ，由 (1) 知置信区间长为

$$2z_{\alpha/2} \sqrt{\frac{2\sigma^2}{n}}$$

置信度 90% 时 $\alpha = 0.1$ ， $z_{0.05} = 1.645$ 。令区间长等于 $\frac{2}{5}\sigma$ ：

$$2 \times 1.645 \times \sqrt{\frac{2\sigma^2}{n}} = \frac{2}{5}\sigma$$

$$1.645 \sqrt{\frac{2}{n}} = \frac{1}{5}$$

$$\frac{2}{n} = \left(\frac{1}{5 \times 1.645} \right)^2 = \frac{1}{67.65}$$

$$n = 135.3$$

故 $n_1 = n_2$ 至少应取 136。

- 第 (3) 问：由样本方差的性质，

$$\frac{(m-1)S_1^2}{\sigma_1^2} \sim \chi^2(m-1), \quad \frac{(n-1)S_2^2}{\sigma_2^2} \sim \chi^2(n-1)$$

两者独立，故枢轴量

$$F = \frac{S_2^2/\sigma_2^2}{S_1^2/\sigma_1^2} = \frac{S_2^2}{S_1^2} \cdot \frac{\sigma_1^2}{\sigma_2^2} \sim F(n-1, m-1)$$

由 $P(F_{\alpha/2}(n-1, m-1) \leq F \leq F_{1-\alpha/2}(n-1, m-1)) = 1 - \alpha$ ，对 σ_2^2/σ_1^2 解不等式，得置信度为 $1 - \alpha$ 的置信区间为

$$\left(\frac{S_2^2}{S_1^2} \cdot \frac{1}{F_{1-\alpha/2}(n-1, m-1)}, \frac{S_2^2}{S_1^2} \cdot \frac{1}{F_{\alpha/2}(n-1, m-1)} \right)$$

东邪的 tip 5.86

第一问 $\mu_2 - \mu_1$ 就是要求的所以他们两未知没关系，但是要求的是 σ_2^2/σ_1^2 平方的置信区间 μ_1, μ_2 不知道就不行，得想办法找一个分布不受 μ_1, μ_2 影响所以只能找 F 分布于其他两个变量 $n-1$ 和 $m-1$ 都是我们已经知道的查表解就行了

5.8.1 4.1

 **作业** 1 设 $X_1, X_2, \dots, X_n$ 为独立同分布样本， $X_1 \sim N(\mu, 1)$ 。对检验问题 $H_0: \mu = 0$; $H_1: \mu > 0$ ，用检验函数

$$\phi(\mathbf{X}) = \phi(X_1, X_2, \dots, X_n) = \begin{cases} 1, & \text{若 } \bar{X}_n > 1.3 \\ 0, & \text{若 } \bar{X}_n \leq 1.3 \end{cases}$$

进行检验，其中 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。设样本容量 $n = 10$ ，试回答下列问题：

- (1) 该检验的真实水平是多少？
- (2) 当 $\mu = 1.0$ 和 $\mu = 1.5$ 时，该检验犯第二类错误的概率分别是多少？
- (3) 若取检验水平 $\alpha = 0.05$ ，给出用 $\bar{X}_n$ 作为检验统计量的检验函数。

解 由题意， $X_i \sim N(\mu, 1)$ ， $n = 10$ ，故

$$\bar{X}_{10} \sim N\left(\mu, \frac{1}{10}\right), \quad \frac{\bar{X}_{10} - \mu}{1/\sqrt{10}} \sim N(0, 1).$$

- (1) 真实水平为 $H_0: \mu = 0$ 下犯第一类错误的概率：

$$\alpha = P_{\mu=0}(\bar{X}_{10} > 1.3) = P\left(Z > \frac{1.3}{1/\sqrt{10}}\right) = 1 - \Phi(4.11) \approx 0.$$

故该检验的真实水平近似为 0。

东邪的 tip 5.87

已经知道 z_α 求检验函数里的 1.3 是 $\bar{X}$ 的原始尺度（标准化之前）， $\bar{X}$ 在 H_0 下服从

$$\bar{X}_{10} \sim N\left(0, \frac{1}{10}\right)$$

- (2) 第二类错误概率为

$$\beta(\mu) = P_\mu(\bar{X}_{10} \leq 1.3) = \Phi\left(\sqrt{10}(1.3 - \mu)\right).$$

- 当 $\mu = 1.0$ 时： $\beta(1.0) = \Phi(\sqrt{10} \times 0.3) = \Phi(0.949) \approx 0.8289$ 。
- 当 $\mu = 1.5$ 时： $\beta(1.5) = \Phi(\sqrt{10} \times (-0.2)) = \Phi(-0.632) \approx 0.2638$ 。

东邪的 tip 5.88

算第二类错误都是往负无穷积分只是看 μ 不一样, X 相对轴的 x 位置不一样罢了。

(3) 设临界值为 c , 要求真实水平等于 0.05:

$$P_{\mu=0}(\bar{X}_{10} > c) = 0.05 \implies 1 - \Phi(\sqrt{10}c) = 0.05 \implies \sqrt{10}c = 1.645 \implies c = \frac{1.645}{\sqrt{10}} \approx 0.520.$$

故取检验水平 $\alpha = 0.05$ 时, 检验函数为

$$\phi(\mathbf{X}) = \begin{cases} 1, & \bar{X}_{10} > 0.520, \\ 0, & \bar{X}_{10} \leq 0.520. \end{cases}$$

东邪的 tip 5.89

这个 H_1 就是解读出来单侧检验就拒绝域放真无穷那边, 积分面积是 0.05; Φ 是标准正态的累积分布函数 (CDF), 表示小于等于某值的概率, 故大于 c 的概率用 $1 - \Phi$:

$$P_{\mu=0}(\bar{X}_{10} > c) = 1 - \Phi(\sqrt{10}c) = 0.05$$

定义 5.2 (检验函数)

检验函数 $\phi(\mathbf{X})$ 是一个决策规则:

- 输出 1: 拒绝 H_0
- 输出 0: 接受 H_0



东邪的 tip 5.90

后面先标注是一类是实际情况拒绝 h_0 , 二类是实际情况接受了 h_0 。功效函数算出来都是实际情况拒绝 h_0 的概率, θ 真实在 H_0 内算的就是一类错误, θ 真实在 h_1 内他算出来的概率就是正确的拒绝, 1-他就是没能拒绝的也就是漏网之鱼。

- 第一类错误: H_0 为真, 却拒绝了 H_0 (弃真错误)
- 第二类错误: H_1 为真, 却未能拒绝 H_0 (取伪错误)

 作业 2 设 $X_1, X_2, \dots, X_{10}$ 是来自 $U(0, \theta)$ 的样本。今用检验函数

$$\phi(\mathbf{X}) = \begin{cases} 1, & \text{若 } X_{(10)} > 0.95 \\ 0, & \text{若 } X_{(10)} \leq 0.95 \end{cases}$$

检验 $H_0: \theta = 1; H_1: \theta > 1$, 其中 $\mathbf{X} = (X_1, \dots, X_{10})^T$, $X_{(10)} = \max(X_1, X_2, \dots, X_{10})$ 。请回答下列问题:

- (1) 该检验的真实水平是多少?
- (2) 求该检验的功效函数。
- (3) 仍然用 $X_{(10)}$ 作为检验统计量, 写出检验水平 $\alpha = 0.05$ 时的检验函数。

解 由题意, $X_i \sim U(0, \theta)$, 其 CDF 为 $F(x) = \frac{x}{\theta}$, $0 \leq x \leq \theta$ 。最大次序统计量 $X_{(10)} = \max(X_1, \dots, X_{10})$ 的 CDF 为

$$F_{(10)}(x) = P(X_{(10)} \leq x) = \left(\frac{x}{\theta}\right)^{10}, \quad 0 \leq x \leq \theta.$$

(1) 真实水平为 $H_0: \theta = 1$ 下犯第一类错误的概率:

$$\alpha = P_{\theta=1}(X_{(10)} > 0.95) = 1 - P_{\theta=1}(X_{(10)} \leq 0.95) = 1 - (0.95)^{10} \approx 1 - 0.5987 = 0.4013.$$

(2) 功效函数为在参数 θ 下拒绝 H_0 的概率:

$$\beta(\theta) = P_{\theta}(X_{(10)} > 0.95) = 1 - \left(\frac{0.95}{\theta}\right)^{10}, \quad \theta \geq 0.95.$$

注意当 $\theta < 0.95$ 时, $X_{(10)} \leq \theta < 0.95$ 几乎必然成立, 故 $\beta(\theta) = 0$ 。

(3) 设临界值为 c , 要求真实水平等于 0.05:

$$P_{\theta=1}(X_{(10)} > c) = 0.05 \implies 1 - c^{10} = 0.05 \implies c^{10} = 0.95 \implies c = 0.95^{1/10} \approx 0.9949.$$

故取检验水平 $\alpha = 0.05$ 时, 检验函数为

$$\phi(\mathbf{X}) = \begin{cases} 1, & X_{(10)} > 0.95^{1/10} \approx 0.9949, \\ 0, & X_{(10)} \leq 0.95^{1/10} \approx 0.9949. \end{cases}$$

东邪的 tip 5.91

Cumulative Distribution Function, 累积分布函数。第一类错误概率误会了与第二类错误概率都是功效函数的特殊情形。以 $H_0: \theta = 1, H_1: \theta > 1$ 为例:

- 第一类错误概率 = 功效函数在 H_0 处的值: $\beta(1)$
- 第二类错误概率 = $1 - \beta(\theta)$, $\theta > 1$ 因为原本的 β 函数就是正确击中的概率, 去掉以后就是漏网之鱼

功效函数 $\beta(\theta)$ 是一个统一的框架, 第一类、第二类错误只是从不同角度看它在不同区域的值。

 **作业 3** 证明: 二项分布 $B(n, p)$ 的分布函数 $P\{X \leq x\} = \sum_{i=0}^x \binom{n}{i} p^i (1-p)^{n-i}$ 是 p 的单调减函数。

证明 设 $m = \lfloor x \rfloor$, 对 p 求偏导:

$$\frac{\partial F}{\partial p} = \sum_{i=0}^m C_n^i [ip^{i-1}(1-p)^{n-i} - (n-i)p^i(1-p)^{n-i-1}].$$

提取公因子 $p^{i-1}(1-p)^{n-i-1}$ 并化简括号内:

$$= \sum_{i=0}^m C_n^i p^{i-1}(1-p)^{n-i-1}(i-np).$$

利用恒等式 $iC_n^i = nC_{n-1}^{i-1}$, 每一项化为:

$$C_n^i p^{i-1}(1-p)^{n-i-1}(i-np) = nC_{n-1}^{i-1} p^{i-1}(1-p)^{n-i} - nC_{n-1}^i p^i(1-p)^{n-i-1}.$$

令 $T_i = C_{n-1}^i p^i(1-p)^{n-1-i}$, 则上式恰为 $n(T_{i-1} - T_i)$, 故:

$$\frac{\partial F}{\partial p} = n \sum_{i=0}^m (T_{i-1} - T_i).$$

裂项消去中间项, 仅剩首尾:

$$= n(T_{-1} - T_m) = n(0 - T_m) = -nC_{n-1}^m p^m(1-p)^{n-1-m}.$$

由于 $n \geq 1, 0 < p < 1, 0 \leq m \leq n-1$, 故 $\frac{\partial F}{\partial p} < 0$, 即 $F(x; p)$ 是 p 的单调递减函数。

东邪的 tip 5.92

首先提取公因数因为我们只需要证明他永远小于 0, 公因数是大于 0 的部分不需要。然后就是把 $(i-np)$ 拆成两部分分别乘:

- i 那项: $i \cdot C_n^i \xrightarrow{\text{恒等式}} n \cdot C_{n-1}^{i-1}$, 凑出 T_{i-1}
- np 那项: $n \cdot C_n^i \cdot p \xrightarrow{\text{Pascal}} n(C_{n-1}^{i-1} + C_{n-1}^i) \cdot p$, 凑出 T_i

两项合并即为 $n(T_{i-1} - T_i)$, 裂项结构自然出来。

恒等式的作用: 把含 i 的系数变成含 n 的系数, 才能和 $-np$ 那项统一格式裂项。

 **笔记** $T_{-1} = C_{n-1}^{-1} \cdot p^{-1}(1-p)^n = 0$, 因为 $C_{n-1}^{-1} = 0$ (从 $n-1$ 个中取 -1 个无意义, 定义为 0)。

5.8.2 4.2

例题 5.2 设 $X \sim N(\mu, 9)$, 抽得样本容量为 8 的样本:

12.5 13.8 14.1 14.1 14.8 15.0 15.4 16.0

在检验水平 $\alpha = 0.05$ 下, 是否可接受 $\mu = 14$ 之假设?

作业 1 若在例 4.2.1 中, 方差 σ^2 未知, 取检验水平 $\alpha = 0.10$, 试检验假设

$$H_0: \mu = 14; \quad H_1: \mu \neq 14$$

解 方差未知, 用 t 检验。

计算样本均值:

$$\bar{X} = \frac{12.5 + 13.8 + 14.1 + 14.1 + 14.8 + 15.0 + 15.4 + 16.0}{8} = \frac{115.7}{8} = 14.4625$$

计算样本方差:

$$S^2 = \frac{1}{7} \sum_{i=1}^8 (X_i - \bar{X})^2 = \frac{7.9989}{7} \approx 1.1427, \quad S \approx 1.0690$$

构造检验统计量:

$$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} = \frac{14.4625 - 14}{1.0690/\sqrt{8}} = \frac{0.4625}{0.3780} \approx 1.223$$

查表得 $\alpha = 0.10$ 双侧, 自由度 $n - 1 = 7$:

$$t_{0.05}(7) = 1.895$$

因为 $|t| = 1.223 < 1.895$, 不拒绝 H_0 , 即在显著性水平 0.10 下可接受 $\mu = 14$ 。

东邪的 tip 5.93

T 检验需要平均数和标准差

笔记 $P(T > t_{0.10}(n)) = 0.10$

对应的是 0.90 分位数 (左侧面积 = 90%)。

$$\underbrace{0.10}_{\text{表头数字}} = \text{右尾面积} = 1 - \text{分位数百分比}$$

表头对应关系:

$$\alpha = 0.10 \implies t_{0.10} \text{ 是 } 90\% \text{ 分位数}$$

$$\alpha = 0.05 \implies t_{0.05} \text{ 是 } 95\% \text{ 分位数}$$

$$\alpha = 0.025 \implies t_{0.025} \text{ 是 } 97.5\% \text{ 分位数}$$

作业 2 设 $X_1, X_2, \dots, X_{10}$ 是取自 $N(\mu, \sigma^2)$ 的样本。

(1) 试写出检验问题 $H_0: \mu \leq 1$; $H_1: \mu > 1$ 的检验函数, 取 $\alpha = 0.1$;

解 方差未知, $H_1: \mu > 1$ 为右侧检验, 构造 t 统计量:

$$T = \frac{\bar{X} - 1}{S/\sqrt{10}} \sim t(9) \quad (\text{在 } H_0 \text{ 边界 } \mu = 1 \text{ 时})$$

查表得 $t_\alpha(n-1) = t_{0.1}(9) = 1.383$, 检验函数为:

$$\phi(\mathbf{X}) = \begin{cases} 1, & T > 1.383 \\ 0, & T \leq 1.383 \end{cases}$$

即当 $T > 1.383$ 时拒绝 H_0 , 认为 $\mu > 1$ 。

东邪的 tip 5.94

所以他的分母只是为了让上面的分布方差变成 1 对吗

定理 5.2 (假设检验统计量选择)

一、均值检验 (单总体)

设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 。

方差已知 $\rightarrow Z$ 检验:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

方差未知 $\rightarrow t$ 检验:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$$

分母用 S 替代 σ , 引入额外随机性, 分布变胖; n 越大 t 越接近正态。

二、方差检验 (单总体)

检验 $H_0: \sigma^2 = \sigma_0^2$:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$$

三、两总体方差比检验

检验 $H_0: \sigma_1^2 = \sigma_2^2$:

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1)$$



作业 2 设 $X_1, X_2, \dots, X_{10}$ 是取自 $N(\mu, \sigma^2)$ 的样本。

(2) 试写出检验问题 $H_0: \sigma^2 \leq 1$; $H_1: \sigma^2 > 1$ 的检验函数, 取 $\alpha = 0.1$;

(3) 取 $\alpha = 0.05$, 重做 (1), (2), 功效函数有何变化? 由此得出什么结论?

解

(2) μ 未知, 使用统计量

$$\chi^2 = 9S^2 \sim \chi^2(9) \quad (\text{在 } \sigma^2 = 1 \text{ 下})$$

取 $\alpha = 0.1$, 查表得 $\chi_{0.1}^2(9) = 14.684$, 检验函数为

$$\varphi(X) = \begin{cases} 1, & 9S^2 > 14.684 \\ 0, & 9S^2 \leq 14.684 \end{cases}$$

功效函数为

$$\beta(\sigma^2) = P\left(\chi^2(9) > \frac{14.684}{\sigma^2}\right)$$

(3) 取 $\alpha = 0.05$, 查表得 $\chi_{0.05}^2(9) = 16.919$, 第 (2) 题的检验函数变为

$$\varphi(X) = \begin{cases} 1, & 9S^2 > 16.919 \\ 0, & 9S^2 \leq 16.919 \end{cases}$$

功效函数变为

$$\beta(\sigma^2) = P\left(\chi^2(9) > \frac{16.919}{\sigma^2}\right)$$

与 $\alpha = 0.1$ 时相比, 临界值增大, 拒绝域缩小, 功效函数在每个 $\sigma^2 > 1$ 处均减小。由此得出结论: 在样本量固定时, α 与功效相互制约, 降低显著性水平必然导致功效下降; 若要同时控制两类错误, 只能增大样本量。

作业 3 (两个正态总体的比较) 设 $X_1, X_2, \dots, X_m$ 为来自 $N(\mu_1, \sigma_1^2)$ 的样本; $Y_1, Y_2, \dots, Y_n$ 为来自 $N(\mu_2, \sigma_2^2)$ 的样本, 两样本相互独立, σ_1^2, σ_2^2 均未知. 分下面几种情况, 给出 $H_0: \mu_1 = \mu_2$; $H_1: \mu_1 \neq \mu_2$ 的检验函数形式:

(2) $\sigma_1^2 = k\sigma_2^2$, k 为已知常数;

解

(2) 由 $\sigma_1^2 = k\sigma_2^2$, 构造统计量. 两样本独立, 有

$$\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}\right) = N\left(\mu_1 - \mu_2, \sigma_2^2\left(\frac{k}{m} + \frac{1}{n}\right)\right)$$

又

$$\frac{(m-1)S_1^2}{\sigma_1^2} + \frac{(n-1)S_2^2}{\sigma_2^2} = \frac{(m-1)S_1^2}{k\sigma_2^2} + \frac{(n-1)S_2^2}{\sigma_2^2} \sim \chi^2(m+n-2)$$

定义合并估计量

$$S_p^2 = \frac{\frac{(m-1)S_1^2}{k} + (n-1)S_2^2}{m+n-2}$$

则 $\frac{(m+n-2)S_p^2}{\sigma_2^2} \sim \chi^2(m+n-2)$, 在 $H_0: \mu_1 = \mu_2$ 下, 构造 t 统计量

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{k}{m} + \frac{1}{n}}} \sim t(m+n-2)$$

检验函数为

$$\varphi = \begin{cases} 1, & |T| > t_{\alpha/2}(m+n-2) \\ 0, & |T| \leq t_{\alpha/2}(m+n-2) \end{cases}$$

作业 4 (两个正态总体的比较) 样本如第 3 题所示, 试给出检验下列问题的检验函数的形式:

(1) $H_0: \sigma_1^2 \leq \sigma_2^2$; $H_1: \sigma_1^2 > \sigma_2^2$;

(2) $H_0: \sigma_1^2 = k\sigma_2^2$; $H_1: \sigma_1^2 \neq k\sigma_2^2$, 其中 k 为给定的数.

解

(1) μ_1, μ_2 均未知, 使用统计量

$$F = \frac{S_1^2}{S_2^2} \sim F(m-1, n-1) \quad (\text{在 } \sigma_1^2 = \sigma_2^2 \text{ 下})$$

$H_1: \sigma_1^2 > \sigma_2^2$ 为右侧检验, 拒绝域取右尾, 检验函数为

$$\varphi = \begin{cases} 1, & F > F_{\alpha}(m-1, n-1) \\ 0, & F \leq F_{\alpha}(m-1, n-1) \end{cases}$$

(2) 在 $H_0: \sigma_1^2 = k\sigma_2^2$ 下, 构造统计量

$$F = \frac{S_1^2/k}{S_2^2} = \frac{S_1^2}{kS_2^2} \sim F(m-1, n-1)$$

为双侧检验, 检验函数为

$$\varphi = \begin{cases} 1, & F > F_{\alpha/2}(m-1, n-1) \text{ 或 } F < F_{1-\alpha/2}(m-1, n-1) \\ 0, & \text{otherwise} \end{cases}$$

作业 6 用两台仪器 A, B 测量相同的物理量, 设 A 是标准的, 两台仪器的测量值均服从正态分布. 对某物理量用仪器 A 独立测量 10 次, 数值如下:

10.5 10.3 10.4 9.6 9.7 9.8 9.9 10.1 10.2 9.7

对同一量用仪器 B 独立测量了 10 次, 其数值是

10.2 10.7 10.8 10.9 10.4 10.6 11.0 11.1 10.9 11.2

试回答下列问题:

- (1) 仪器 B 有无系统误差?
 (2) 若已知没有系统误差, 仪器 A 和仪器 B 的测量精度是否一致?

 **笔记** “无系统误差” 等同于 $\mu_B = \mu_A$, “测量精度一致” 等同于 $\sigma_B^2 = \sigma_A^2$, $\mu_A, \mu_B, \sigma_A^2, \sigma_B^2$ 分别是两台仪器测量值分布的均值和方差.

解

- (1) 检验 $H_0: \mu_B = \mu_A$, $H_1: \mu_B \neq \mu_A$, σ_A^2, σ_B^2 未知但假设相等 (先不做方差检验, 用两样本 t 检验).

计算样本均值与样本方差:

$$\bar{X} = \frac{1}{10}(10.5 + 10.3 + 10.4 + 9.6 + 9.7 + 9.8 + 9.9 + 10.1 + 10.2 + 9.7) = 10.02$$

$$\bar{Y} = \frac{1}{10}(10.2 + 10.7 + 10.8 + 10.9 + 10.4 + 10.6 + 11.0 + 11.1 + 10.9 + 11.2) = 10.78$$

$$S_A^2 = \frac{1}{9} \sum_{i=1}^{10} (X_i - \bar{X})^2 = \frac{1}{9}(0.48^2 + 0.28^2 + 0.38^2 + 0.42^2 + 0.32^2 + 0.22^2 + 0.12^2 + 0.08^2 + 0.18^2 + 0.32^2)$$

逐项计算: $0.2304 + 0.0784 + 0.1444 + 0.1764 + 0.1024 + 0.0484 + 0.0144 + 0.0064 + 0.0324 + 0.1024 = 0.9360$,
 故

$$S_A^2 = \frac{0.9360}{9} \approx 0.1040, \quad S_A \approx 0.3225$$

$$S_B^2 = \frac{1}{9} \sum_{i=1}^{10} (Y_i - \bar{Y})^2$$

各项: $0.58^2 + 0.08^2 + 0.02^2 + 0.12^2 + 0.38^2 + 0.18^2 + 0.22^2 + 0.32^2 + 0.12^2 + 0.42^2 = 0.3364 + 0.0064 + 0.0004 + 0.0144 + 0.1444 + 0.0324 + 0.0484 + 0.1024 + 0.0144 + 0.1764 = 0.8760$, 故

$$S_B^2 = \frac{0.8760}{9} \approx 0.0973, \quad S_B \approx 0.3120$$

合并方差估计:

$$S_p^2 = \frac{9S_A^2 + 9S_B^2}{18} = \frac{0.9360 + 0.8760}{18} = \frac{1.8120}{18} \approx 0.1007, \quad S_p \approx 0.3173$$

检验统计量:

$$T = \frac{\bar{Y} - \bar{X}}{S_p \sqrt{\frac{1}{10} + \frac{1}{10}}} = \frac{10.78 - 10.02}{0.3173 \times \sqrt{0.2}} = \frac{0.76}{0.3173 \times 0.4472} \approx \frac{0.76}{0.1419} \approx 5.356$$

取 $\alpha = 0.05$, 查表得 $t_{0.025}(18) = 2.101$. 由于 $|T| = 5.356 > 2.101$, 拒绝 H_0 .

结论: 仪器 B 存在显著系统误差.

- (2) 已知无系统误差, 检验 $H_0: \sigma_B^2 = \sigma_A^2$, $H_1: \sigma_B^2 \neq \sigma_A^2$, 使用 F 检验:

$$F = \frac{S_A^2}{S_B^2} = \frac{0.1040}{0.0973} \approx 1.069$$

取 $\alpha = 0.05$, 查表得 $F_{0.025}(9, 9) = 4.03$, $F_{0.975}(9, 9) = \frac{1}{4.03} \approx 0.248$.

由于 $0.248 < F = 1.069 < 4.03$, 不拒绝 H_0 .

结论: 在显著性水平 0.05 下, 无充分理由认为两台仪器测量精度有显著差异.

5.9 第 10 周作业

5.9.1 4.3

 **作业 1** 某单位购进一批产品, 抽 36 件检查, 发现有 3 件不合格, 试问这批产品的不合格品率高于 3% 吗? 你认为次品率不超过多少?

解 设不合格品数 $X \sim B(n, p)$, $n = 36$, 样本比例 $\hat{p} = \frac{3}{36} = \frac{1}{12} \approx 0.0833$.

第一问：建立假设

$$H_0: p \leq 0.03, \quad H_1: p > 0.03$$

检验统计量为

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} = \frac{\frac{1}{12} - 0.03}{\sqrt{\frac{0.03 \times 0.97}{36}}} \approx 1.875$$

取 $\alpha = 0.05$, 单侧临界值 $z_{0.05} = 1.645$ 。因为 $Z \approx 1.875 > 1.645$, 拒绝 H_0 , 认为不合格品率高于 3%。

第二问：构造 p 的置信水平 0.95 的单侧置信上限：

$$p \leq \hat{p} + z_{0.05} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \frac{1}{12} + 1.645 \times \sqrt{\frac{\frac{1}{12} \times \frac{11}{12}}{36}} \approx 0.160$$

即认为次品率不超过 16.0%。

东邪的 tip 5.95

第一步先确定是什么分布如果合格不合格就是二项分布把 n 和 p 算出来 p 就是我们要求的不合格率的概率要求什么算什么。然后

东邪的 tip 5.96

$\bar{X}$ 是 n 个数的平均, 方差比单个 X_i 小 n 倍:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \implies \text{SD}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

标准化须除以自身标准差, 故 $\sqrt{n}$ 必然出现。

例外: 统计量不含 $\bar{X}$ 时 (如 $\frac{(n-1)S^2}{\sigma^2}$) 无 $\sqrt{n}$ 。

口诀: $\bar{X}$ 参与标准化 $\implies$ 分母必有 $\sqrt{n}$ 。

东邪的 tip 5.97

后续写的时候都先列基础的式子把除以根号 n 和除以方差分开

 **笔记** 标准化是除以标准差, 反过来还原就是乘以标准差, 从 $N(0, 1)$ 的尺度换回 $\hat{p}$ 的尺度。

 **作业 2** 设 $X_1, X_2, \dots, X_n$ 为来自 $P(\lambda)$ 的样本, 试给出检验 $H_0: \lambda = \lambda_0; H_1: \lambda \neq \lambda_0$ 的检验函数。若有观测值 5, 7, 8, 6, 9, 10, 在检验水平 $\alpha = 0.05$ 下, 能接受 $\lambda = 3$ 吗?

 **笔记** 单个 $X_i \sim P(\lambda)$: 期望是 λ , 方差是 λ (期望方差相等是 Poisson 分布的特征)。

所以 $\bar{X}$ 的方差是 $\frac{\lambda}{n}$, 标准差是 $\sqrt{\frac{\lambda}{n}}$ 。

解 由 $X_i \sim P(\lambda)$, $\bar{X}$ 是 λ 的充分统计量, 由中心极限定理, 检验统计量为

$$Z = \frac{\bar{X} - \lambda_0}{\sqrt{\lambda_0/n}} \stackrel{H_0}{\approx} N(0, 1)$$

拒绝域为 $|Z| > z_{\alpha/2} = z_{0.025} = 1.96$ 。

计算观测值:

$$\bar{x} = \frac{5 + 7 + 8 + 6 + 9 + 10}{6} = 7.5$$

代入统计量:

$$Z = \frac{7.5 - 3}{\sqrt{3/6}} = \frac{4.5}{\sqrt{0.5}} \approx 6.36$$

因为 $|Z| \approx 6.36 > 1.96$, 拒绝 H_0 , 在显著性水平 $\alpha = 0.05$ 下, 不能接受 $\lambda = 3$ 。

东邪的 tip 5.98

比大小的核心是把它们拉到同一个尺度。因为查表是标准正态尺度，所以也要把观测值拉到这个尺度，这就需要标准化。CLT 只是描述样本均值与期望之间服从正态分布——减去期望只完成了把中心移动到 0，方差部分还要根据原始 X 的分布来决定除以什么：Poisson 分布除以 $\sqrt{\lambda}$ ，正态分布除以 $\sqrt{\sigma^2} = \sigma$ 。

- $z_{0.025} = 1.96$ (双侧 $\alpha = 0.05$)
- $z_{0.05} = 1.645$ (单侧 $\alpha = 0.05$)

5.10 第 11 周作业

5.10.1 4.4

东邪的 tip 5.99

- UMP: 找拒绝域放在哪里。
- UMVUE: 找用哪个统计量来估计 θ 。

东邪的 tip 5.100

这里 f 本质其实就是 $P_{X=k}$ 那个

作业 1 设总体 X 服从参数为 λ 的泊松分布

$$f(x, \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}, \quad x = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 为参数, $X_1, X_2, \dots, X_n$ 是独立同分布样本。考虑假设检验问题:

$$H_0: \lambda \leq \lambda_0; \quad H_1: \lambda > \lambda_0$$

1. 有无 UMP 检验? 为什么?
2. 若有 UMP 检验, 试求出检验水平 $\alpha = 0.05$, $n = 10$, $\lambda_0 = 0.1$ 时的检验函数。

解 第一问: 取 $\lambda_1 < \lambda_2$, 计算似然比

$$\frac{\prod_{i=1}^n f(X_i; \lambda_2)}{\prod_{i=1}^n f(X_i; \lambda_1)} = \frac{\prod_{i=1}^n \frac{\lambda_2^{X_i}}{X_i!} e^{-\lambda_2}}{\prod_{i=1}^n \frac{\lambda_1^{X_i}}{X_i!} e^{-\lambda_1}} = \left(\frac{\lambda_2}{\lambda_1}\right)^{\sum_{i=1}^n X_i} e^{-n(\lambda_2 - \lambda_1)}$$

其中 $e^{-n(\lambda_2 - \lambda_1)}$ 是只含 λ 的常数, 因为 $\lambda_2 > \lambda_1$, 底数 $\frac{\lambda_2}{\lambda_1} > 1$, 故似然比是 $T(\mathbf{X}) = \sum_{i=1}^n X_i$ 的单增函数。泊松分布族满足 MLR 条件, 由 MLR 定理, UMP 检验存在, 拒绝域形式为 $T(\mathbf{X}) = \sum_{i=1}^n X_i > c$ 。

东邪的 tip 5.101

当 H_0 是一个点时, 三个说法是同一件事:

$$\alpha = \underbrace{P_{H_0}(\text{统计量落在拒绝域})}_{\text{第一类错误概率}} = \underbrace{\int_{\text{拒绝域}} f_{H_0}(x) dx}_{\text{拒绝域在 } H_0 \text{ 下的面积}}$$

α 决定了拒绝域的大小也就是在拒绝域里面积分就是 α , 当然这个拒绝域可以放在任意积分为 α 的片段, 我们就想知道把他放在哪里最好

第二问: 当 $\alpha = 0.05$, $n = 10$, $\lambda_0 = 0.1$ 时, 由第一类错误条件

$$E_{\lambda_0}[\phi(\mathbf{X})] = \alpha$$

即在 H_0 成立时 $\sum_{i=1}^n X_i \sim P(n\lambda_0) = P(1)$, 需确定临界值 c 使得

$$P_{\lambda_0} \left(\sum_{i=1}^n X_i > c \right) \leq 0.05$$

查泊松分布表, $\sum X_i \sim P(1)$ 时:

c	$P(\sum X_i \leq c)$	$P(\sum X_i > c)$
2	0.9197	0.0803
3	0.9810	0.0190

因为分布离散, 取 $c = 3$, 随机化参数 r 由 $E_{\lambda_0}[\phi(\mathbf{X})] = \alpha$ 确定:

$$\begin{aligned} P_{\lambda_0} \left(\sum X_i > 3 \right) + r \cdot P_{\lambda_0} \left(\sum X_i = 3 \right) &= 0.05 \\ 0.0190 + r \times (0.9810 - 0.9197) &= 0.05 \\ r &= \frac{0.05 - 0.0190}{0.0613} \approx 0.506 \end{aligned}$$

故检验函数为

$$\phi(\mathbf{X}) = \begin{cases} 1, & \sum_{i=1}^n X_i > 3 \\ 0.506, & \sum_{i=1}^n X_i = 3 \\ 0, & \sum_{i=1}^n X_i < 3 \end{cases}$$

东邪的 tip 5.102

检验函数就是要在真实获得的数据里面画一条线, 左边是接受即 $\phi(X) = 0$, 右边是拒绝即 $\phi(X) = 1$, 这是因为拒绝域需要满足 $E_{H_0}[\phi(X)] = \alpha$; 有时候因为理论分布是离散的, 所以这条线上的点得不是 1 也不是 0, 而是 $(0, 1)$ 之间的数字。

东邪的 tip 5.103 (随机化检验-因为离散但是要保证拒绝概率等于阿尔法)

这叫做随机化检验。在边界点 $\sum X_i = 3$ 处, 不是直接拒绝或不拒绝, 而是以概率 r 拒绝, 以概率 $1 - r$ 不拒绝, 专门用来处理离散分布无法精确控制 α 的情况。

 **作业 2** 某修理部对要求服务人数连续作 n 日记录。 X_i 为第 i 日要求服务的人数。设 $X_1, X_2, \dots, X_n$ 独立同分布, 均服从参数为 θ 的泊松分布。若每日要求服务人数太少将关门。根据 n 日的记录, 要作出符合下面要求的决定:

1. 若每日要求服务平均人数不多于 10 人, 仅有 0.01 的概率开门;
2. 若每日要求服务的平均人数不少于 15 人, 仅有 0.01 的概率关门。

问需观察多少日即 n 为多少时, UMP 检验才能满足上述要求?

东邪的 tip 5.104

需要确定谁是 H_0 谁是 H_1 , 如果不确定就是把题目中出现的状态在 H_0 , 比如这个任务主要是探讨什么时候该关门条件就是不该开门但是开门了就属于第一类错误不应该拒绝拒绝了, 条件二就是不该关门却关门了也就不该接受缺接受了

解 建立假设:

$$H_0: \theta \leq \theta_0 \quad H_1: \theta > \theta_0$$

两个条件翻译成功效函数约束:

- 条件 1: $\theta = 10$ 时, 开门概率不超过 0.01, 即 $\beta_\phi(10) \leq 0.01$
- 条件 2: $\theta = 15$ 时, 关门概率不超过 0.01, 即 $\beta_\phi(15) \geq 0.99$

UMP 检验形式：泊松分布满足 MLR 条件， $T = \sum_{i=1}^n X_i \sim P(n\theta)$ ，拒绝域为 $\sum_{i=1}^n X_i > c$ 。

正态近似： n 较大时 $\sum X_i \approx N(n\theta, n\theta)$ ，故

$$\beta_\phi(\theta) = P_\theta \left(\sum X_i > c \right) = P \left(Z > \frac{c - n\theta}{\sqrt{n\theta}} \right)$$

由两个约束分别得

$$\frac{c - 10n}{\sqrt{10n}} = 2.326, \quad \frac{c - 15n}{\sqrt{15n}} = -2.326$$

解方程组：两式相减消去 c ：

$$\frac{c - 10n}{\sqrt{10n}} - \frac{c - 15n}{\sqrt{15n}} = 4.652$$

代入 $\frac{1}{\sqrt{10}} \approx 0.3162$, $\frac{1}{\sqrt{15}} \approx 0.2582$ ，整理得

$$\sqrt{n} (5 \times 0.3162 + 5 \times 0.2582) = 4.652$$

$$\sqrt{n} \times 2.872 = 4.652$$

$$\sqrt{n} \approx 1.620 \implies n \approx 25$$

故需观察 $n = 25$ 日。

东邪的 tip 5.105

首先看到 UMP 检验就要弄 MLR 才证明是，然后列出 $P_{H_0}(\sum X_i < c) = 0.01$ 和 $P_{H_1}(\sum X_i > c) = 0.01$ ，因为 c 也就是拒绝域左沿是从来不变的，变的只是中心轴，然后列出两个方程，对左边 $\sum X_i$ 归一化的时候右边也得跟着归一化，右边其实就分别等于 $z_{\alpha=0.01}$ 和 $-z_{\alpha=0.01}$ 。

 **笔记** 两道题情况不同。上面那题 $n = 10$, $\lambda_0 = 0.1$ ，所以 $n\lambda_0 = 1$ ，参数很小，可以直接查泊松分布表。这道题 n 是未知的，而且 $\theta = 10$ 或 $\theta = 15$ ，所以 $n\theta$ 很大，泊松分布参数很大时没法直接查表，只能用正态近似：

$$\sum X_i \sim P(n\theta) \approx N(n\theta, n\theta)$$

泊松参数小则直接查表，泊松参数大或未知则用正态近似。

 **笔记** 几个主流分布的似然比形式：

1. 泊松分布 $P(\lambda)$ ：

$$\frac{\prod f(X_i; \lambda_2)}{\prod f(X_i; \lambda_1)} = \left(\frac{\lambda_2}{\lambda_1} \right)^{\sum X_i} e^{-n(\lambda_2 - \lambda_1)}$$

因 $\lambda_2 > \lambda_1$ 时底数 $\frac{\lambda_2}{\lambda_1} > 1$ ，故关于 $\sum X_i$ 单调递增。

2. 正态分布 $N(\mu, \sigma^2)$ ， σ^2 已知：

$$\frac{\prod f(X_i; \mu_2)}{\prod f(X_i; \mu_1)} = \exp \left(\frac{(\mu_2 - \mu_1) \sum X_i}{\sigma^2} - \frac{n(\mu_2^2 - \mu_1^2)}{2\sigma^2} \right)$$

关于 $\bar{X}$ (即 $\sum X_i$) 单调递增。

3. 指数分布 $f(x; \theta) = \theta e^{-\theta x}$ ：

$$\frac{\prod f(X_i; \theta_2)}{\prod f(X_i; \theta_1)} = \left(\frac{\theta_2}{\theta_1} \right)^n e^{-(\theta_2 - \theta_1) \sum X_i}$$

$\theta_2 > \theta_1$ 时关于 $\sum X_i$ 单调递减。

一般规律：指数族分布的似然比均可化为 $e^{Q(\theta) \cdot T(\mathbf{X})}$ 的形式， $Q(\theta)$ 单调即满足 MLR 条件。

东邪的 tip 5.106

检验 μ 是均值有没有偏移，是方向问题，“差多少”；检验 σ^2 是波动是不是太大，是精度问题，“散不散”。题目说仪器正常运行，说明方向没问题，只需要检验散不散，所以检验 σ^2 。

 **作业 3** 一测量仪器正常运行, 对某量重复测量 n 次, 其结果是 $X_1, X_2, \dots, X_n$ 。假设 $X_1 \sim N(\mu, \sigma^2)$ 。今欲检验该仪器测量精度是否满足要求。假定测量精度要求为 $\mu_0 \pm \Delta$ 。试回答下列问题:

1. 怎样将该问题叙述成假设检验问题?
2. 该假设检验问题有无 UMP 检验? 若有给出检验函数的形式;
3. 利用 χ^2 分布表, 确定样本容量 n 的大小, 使得在检验水平为 0.01、测量误差大于 1.1Δ 时, 被检测出的概率大于 0.9。

东邪的 tip 5.107

我们能算的是样本方差 S^2 , 乘以 $(n-1)$ 是为了让它变成正态分布的平方和, 除以 σ^2 是为了让它变成标准正态分布的平方和, 因为只有标准正态分布的平方和才服从卡方分布:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

算 S^2 的时候已经通过减去平均值再平方进行了标准化的第一步:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

解 第一问: 测量精度要求为 $\mu_0 \pm \Delta$, 即要求 $|\mu - \mu_0| \leq \Delta$ 。若仪器精度不满足要求, 则 $|\mu - \mu_0| > \Delta$, 故假设检验问题为

$$H_0: |\mu - \mu_0| \leq \Delta \quad H_1: |\mu - \mu_0| > \Delta$$

等价地, 检验方差是否满足要求, 即

$$H_0: \sigma^2 \leq \Delta^2 \quad H_1: \sigma^2 > \Delta^2$$

第二问: 正态分布关于 σ^2 满足 MLR 条件, $T(\mathbf{X}) = \sum_{i=1}^n (X_i - \mu_0)^2$, UMP 检验存在, 拒绝域形式为

$$\sum_{i=1}^n (X_i - \mu_0)^2 > c$$

注意到在 H_0 成立时

$$\frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\Delta^2} \sim \chi^2(n)$$

由第一类错误条件 $E_{\sigma^2=\Delta^2}[\phi(\mathbf{X})] = \alpha = 0.01$, 确定临界值

$$c = \Delta^2 \chi_{0.01}^2(n)$$

故检验函数为

$$\phi(\mathbf{X}) = \begin{cases} 1, & \sum_{i=1}^n (X_i - \mu_0)^2 > \Delta^2 \chi_{0.01}^2(n) \\ 0, & \sum_{i=1}^n (X_i - \mu_0)^2 \leq \Delta^2 \chi_{0.01}^2(n) \end{cases}$$

第三问: 当测量误差大于 1.1Δ , 即 $\sigma^2 = (1.1\Delta)^2 = 1.21\Delta^2$ 时, 要求功效大于 0.9:

$$\beta_\phi(1.21\Delta^2) = P_{\sigma^2=1.21\Delta^2} \left(\sum_{i=1}^n (X_i - \mu_0)^2 > \Delta^2 \chi_{0.01}^2(n) \right) \geq 0.9$$

注意到此时

$$\frac{\sum_{i=1}^n (X_i - \mu_0)^2}{1.21\Delta^2} \sim \chi^2(n)$$

故条件等价于

$$P \left(\chi^2(n) > \frac{\chi_{0.01}^2(n)}{1.21} \right) \geq 0.9$$

即

$$\frac{\chi_{0.01}^2(n)}{1.21} \leq \chi_{0.9}^2(n)$$

逐一查 χ^2 分布表, 寻找满足

$$\frac{\chi_{0.01}^2(n)}{\chi_{0.9}^2(n)} \leq 1.21$$

的最小 n 。查表得 $n = 152$ 时该比值首次不超过 1.21, 故需 $n = 152$ 。

东邪的 tip 5.108

这里减去的是真实值 μ_0 而不是 X 平均所以自由度是 n

 **作业 5** 设 $X_1, X_2, \dots, X_n$ 是独立同分布的, 其共同概率密度是

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0, \quad \theta > 0.$$

试回答:

1. 什么样的假设检验问题有 UMP 检验?
2. 写出 UMP 检验函数的形式。

解

- (1) 计算似然比, 取 $\theta_1 < \theta_2$:

$$\frac{\prod_{i=1}^n f(X_i; \theta_2)}{\prod_{i=1}^n f(X_i; \theta_1)} = \left(\frac{\theta_2}{\theta_1}\right)^n e^{-(\theta_2 - \theta_1) \sum_{i=1}^n X_i}$$

因 $\theta_2 > \theta_1$, 指数部分关于 $T(\mathbf{X}) = \sum_{i=1}^n X_i$ 单调递减, 故指数分布族满足 MLR 条件。由 MLR 定理, 以下两类单侧假设检验问题有 UMP 检验:

$$(a) \quad H_0: \theta \leq \theta_0, \quad H_1: \theta > \theta_0$$

$$(b) \quad H_0: \theta \geq \theta_0, \quad H_1: \theta < \theta_0$$

双侧检验问题 $H_0: \theta = \theta_0, H_1: \theta \neq \theta_0$ 一般不存在 UMP 检验。

- (2) 由于似然比关于 $\sum X_i$ 单调递减:

对假设 (a) $H_0: \theta \leq \theta_0, H_1: \theta > \theta_0$, θ 越大 $\sum X_i$ 越小, 拒绝域为左侧:

$$\varphi(\mathbf{X}) = \begin{cases} 1, & \sum_{i=1}^n X_i < c_1 \\ 0, & \sum_{i=1}^n X_i \geq c_1 \end{cases}$$

其中 c_1 由 $P_{\theta_0}(\sum X_i < c_1) = \alpha$ 确定。

对假设 (b) $H_0: \theta \geq \theta_0, H_1: \theta < \theta_0$, 拒绝域为右侧:

$$\varphi(\mathbf{X}) = \begin{cases} 1, & \sum_{i=1}^n X_i > c_2 \\ 0, & \sum_{i=1}^n X_i \leq c_2 \end{cases}$$

其中 c_2 由 $P_{\theta_0}(\sum X_i > c_2) = \alpha$ 确定。注意 $\sum_{i=1}^n X_i \sim \Gamma(n, \theta)$, 临界值可由伽马分布表确定。

东邪的 tip 5.109

对 $\theta_1 > \theta_0$, N-P 最优拒绝域为 $T > c$; 对 $\theta_2 < \theta_0$, N-P 最优拒绝域为 $T < c'$ 。两者矛盾: 不存在单一检验函数 ϕ 使得对所有 $\theta \neq \theta_0$ 同时达到最大功效, 故 UMP 检验一般不存在。

 **作业 6** 一设备有 n 个相同或相似的元件, X_i 为第 i 个元件的失效时间, 假定 $X_1, \dots, X_n$ 是来自韦布尔 (Weibull) 分布

$$f(x, \lambda) = \lambda c x^{c-1} e^{-\lambda x^c}, \quad x > 0$$

的样本, 其中 c 是常数, $\lambda > 0$ 是参数。

1. 问题

$$H_0: \frac{1}{\lambda} \leq \frac{1}{\lambda_0}, \quad H_1: \frac{1}{\lambda} > \frac{1}{\lambda_0}$$

有无 UMP 检验? 为什么?

2. 若 (1) 是肯定的回答, 试给出 UMP 检验函数的形式。

3. 设 $\lambda_0 = \frac{1}{12}$, 求样本容量 n , 使得在检验水平为 0.01, $\lambda = \frac{1}{15}$ 时, 其功效函数值至少为 0.95。该问可近似计算。

提示: X_i^c 服从指数分布。

解

(1) 注意 $H_0: \frac{1}{\lambda} \leq \frac{1}{\lambda_0}$ 等价于 $H_0: \lambda \geq \lambda_0$, $H_1: \lambda < \lambda_0$ 。取 $\lambda_1 < \lambda_2$, 计算似然比:

$$\frac{\prod_{i=1}^n f(X_i; \lambda_2)}{\prod_{i=1}^n f(X_i; \lambda_1)} = \left(\frac{\lambda_2}{\lambda_1}\right)^n e^{-(\lambda_2 - \lambda_1) \sum_{i=1}^n X_i^c}$$

因 $\lambda_2 > \lambda_1$, 该似然比关于 $T(\mathbf{X}) = \sum_{i=1}^n X_i^c$ 单调递减, Weibull 分布族满足 MLR 条件, 故 UMP 检验存在。

(2) 似然比关于 $\sum X_i^c$ 单调递减, λ 越小 (即 $\frac{1}{\lambda}$ 越大) 对应 $\sum X_i^c$ 越大, 故拒绝域为右侧:

$$\varphi(\mathbf{X}) = \begin{cases} 1, & \sum_{i=1}^n X_i^c > c_0 \\ 0, & \sum_{i=1}^n X_i^c \leq c_0 \end{cases}$$

由提示, $X_i^c \sim \text{Exp}(\lambda)$, 故 $\sum_{i=1}^n X_i^c \sim \Gamma(n, \lambda)$, 临界值 c_0 由

$$P_{\lambda_0} \left(\sum_{i=1}^n X_i^c > c_0 \right) = \alpha$$

确定。注意 $2\lambda_0 \sum X_i^c \sim \chi^2(2n)$, 故

$$c_0 = \frac{\chi_{\alpha}^2(2n)}{2\lambda_0}$$

(3) 取 $\lambda_0 = \frac{1}{12}$, $\lambda = \frac{1}{15}$, $\alpha = 0.01$, 要求 $\beta_{\varphi} \left(\frac{1}{15} \right) \geq 0.95$ 。

功效函数为

$$\beta_{\varphi} \left(\frac{1}{15} \right) = P_{\lambda=\frac{1}{15}} \left(\sum X_i^c > \frac{\chi_{0.01}^2(2n)}{2\lambda_0} \right) \geq 0.95$$

在 $\lambda = \frac{1}{15}$ 下, $2\lambda \sum X_i^c = \frac{2}{15} \sum X_i^c \sim \chi^2(2n)$, 故条件等价于

$$P \left(\chi^2(2n) > \frac{2\lambda}{2\lambda_0} \chi_{0.01}^2(2n) \right) = P \left(\chi^2(2n) > \frac{\lambda}{\lambda_0} \chi_{0.01}^2(2n) \right) \geq 0.95$$

代入 $\frac{\lambda}{\lambda_0} = \frac{1/15}{1/12} = \frac{12}{15} = 0.8$, 条件变为

$$P(\chi^2(2n) > 0.8 \chi_{0.01}^2(2n)) \geq 0.95$$

即

$$0.8 \chi_{0.01}^2(2n) \leq \chi_{0.95}^2(2n)$$

即

$$\frac{\chi_{0.95}^2(2n)}{\chi_{0.01}^2(2n)} \geq 0.8$$

逐一查 χ^2 分布表, 寻找满足上式的最小 n 。利用正态近似 $\chi^2(m) \approx m \left(1 - \frac{2}{9m} + z \sqrt{\frac{2}{9m}} \right)^3$, 可近似求得 n 的估计值, 再查表验证。查表得满足条件的最小样本容量为

$$n = 76$$

作业 7 设分布族

$$\{f(x; \theta) : \theta \in \Theta\}$$

是单调似然比分布族。对检验问题

$$(a) \quad H_0: \theta = \theta_0, \quad H_1: \theta > \theta_0,$$

$$(b) \quad H_0: \theta = \theta_0, \quad H_1: \theta < \theta_0,$$

试问：

1. 有无 UMP 检验？
2. 若 (1) 回答是肯定的，请写出检验函数的形式。

解

(1) 有 UMP 检验。

分布族满足 MLR 条件，即似然比 $\frac{\prod f(X_i; \theta_2)}{\prod f(X_i; \theta_1)}$ 关于 $T(\mathbf{X})$ 单调， H_0 为单点 $\theta = \theta_0$ ， H_1 为单侧，由 MLR 定理，两个检验问题均存在 UMP 检验。

(2) 对检验问题 (a) $H_0: \theta = \theta_0$ ， $H_1: \theta > \theta_0$ ，似然比单调递增，拒绝域为右侧：

$$\varphi_a(\mathbf{X}) = \begin{cases} 1, & T(\mathbf{X}) > c_1 \\ \gamma_1, & T(\mathbf{X}) = c_1 \\ 0, & T(\mathbf{X}) < c_1 \end{cases}$$

其中 c_1 ， γ_1 由 $E_{\theta_0}[\varphi_a(\mathbf{X})] = \alpha$ 确定。

对检验问题 (b) $H_0: \theta = \theta_0$ ， $H_1: \theta < \theta_0$ ，拒绝域为左侧：

$$\varphi_b(\mathbf{X}) = \begin{cases} 1, & T(\mathbf{X}) < c_2 \\ \gamma_2, & T(\mathbf{X}) = c_2 \\ 0, & T(\mathbf{X}) > c_2 \end{cases}$$

其中 c_2 ， γ_2 由 $E_{\theta_0}[\varphi_b(\mathbf{X})] = \alpha$ 确定。

5.11 12 周

 **作业 1** 有一样本的观测值为：0.473, 0.224, 0.827, 0.223, 0.867, 0.779, 0.554, 0.529, 0.705, 0.656，试用作图法检验该样本是否来自 $U(0, 1)$ 。

解 对均匀分布 $U(0, 1)$ ，其分布函数为 $F(x) = x$ ， $x \in [0, 1]$ 。

第一步：将样本从小到大排序

排序后得：

0.223, 0.224, 0.473, 0.529, 0.554, 0.656, 0.705, 0.779, 0.827, 0.867

第二步：计算经验分布函数值与理论分布函数值

$$F_n(x_{(i)}) = \frac{i}{n} = \frac{i}{10}, \quad F(x_{(i)}) = x_{(i)}$$


第三步：作 P-P 图

以 $F(x_{(i)}) = x_{(i)}$ 为横轴， $F_n(x_{(i)}) = i/10$ 为纵轴描点，若样本来自 $U(0, 1)$ ，各点应落在对角线 $y = x$ 附近。

结论：

由 P-P 图可见，各样本点明显偏离对角线 $y = x$ ，故判断该样本不是来自 $U(0, 1)$ 分布。

i	$x_{(i)}$	$F_n(x_{(i)}) = i/10$	$F(x_{(i)}) = x_{(i)}$
1	0.223	0.1	0.223
2	0.224	0.2	0.224
3	0.473	0.3	0.473
4	0.529	0.4	0.529
5	0.554	0.5	0.554
6	0.656	0.6	0.656
7	0.705	0.7	0.705
8	0.779	0.8	0.779
9	0.827	0.9	0.827
10	0.867	1.0	0.867



作业 2 有一样本的观测值为：0.54, 0.32, 0.68, 0.71, 1.04, 0.94, 1.34, 1.10, 0.44, 1.01，试用作图法检验该样本是否抽自正态总体。

解 用矩估计法估计正态分布参数：

$$\hat{\mu} = \bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = 0.8120, \quad \hat{\sigma} = S = 0.3252$$

第一步：将样本从小到大排序

0.32, 0.44, 0.54, 0.68, 0.71, 0.94, 1.01, 1.04, 1.10, 1.34

第二步：计算经验分布函数值与理论分布函数值

$$F_n(x_{(i)}) = \frac{i}{10}, \quad F(x_{(i)}) = \Phi\left(\frac{x_{(i)} - \hat{\mu}}{\hat{\sigma}}\right)$$

i	$x_{(i)}$	$F_n(x_{(i)}) = i/10$	$F(x_{(i)})$
1	0.32	0.1	0.0651
2	0.44	0.2	0.1263
3	0.54	0.3	0.2014
4	0.68	0.4	0.3424
5	0.71	0.5	0.3769
6	0.94	0.6	0.6531
7	1.01	0.7	0.7287
8	1.04	0.8	0.7584
9	1.10	0.9	0.8121
10	1.34	1.0	0.9478

第三步：作 **P-P** 图

以 $F_n(x_{(i)})$ 为横轴， $F(x_{(i)})$ 为纵轴描点，参考线为对角线 $y = x$ 。

结论：

由 P-P 图可见，各样本点基本落在对角线 $y = x$ 附近，故认为该样本来自正态总体。

 **作业 extra** 对第 1 题做 Kolmogorov 检验.

掷骰子 30 次, 掷出 1、2、3、4、5、6 点的次数分别为 3、6、4、7、4、6, 请检验骰子出现各点概率是否相等?

解 建立假设 $H_0: p_1 = \dots = p_6 = \frac{1}{6}$, 在 H_0 下理论分布函数为 $F_0(x) = \lfloor x \rfloor / 6$.

根据观测数据 ($n = 30$) 计算各点累计差异:

k	n_k	$F_n(k)$	$F_0(k)$	$ F_n(k) - F_0(k) $
1	3	0.1000	0.1667	0.0667
2	6	0.3000	0.3333	0.0333
3	4	0.4333	0.5000	0.0667
4	7	0.6667	0.6667	0.0000
5	4	0.8000	0.8333	0.0333
6	6	1.0000	1.0000	0.0000

故 $D_{30} = 0.0667$, 检验统计量为

$$\sqrt{n} \cdot D_n = \sqrt{30} \times 0.0667 \approx 0.365$$

取 $\alpha = 0.05$, 查表得 $\lambda_{0.05} = 1.358$. 因 $0.365 < 1.358$, 不拒绝 H_0 , 认为骰子各点出现概率相等。

东邪的 tip 5.110

fn 就是实际累积频率 f0 就是假设累积概率, Dn 就是他们的最大差值乘根号 n 就算 k 分布就可以和拒绝域对应的分位数比较了。

 **作业 3** 有一样本的观测值为 9, 6, 13, 22, 18, 37, 36, 52, 41, 36, 试检验该样本是否来自两参数的韦布尔 (Weibull) 分布。

解

第一步: 两参数 Weibull 分布简介

两参数 Weibull 分布的分布函数为:

$$F(x) = 1 - \exp \left[- \left(\frac{x}{\lambda} \right)^k \right], \quad x > 0$$

其中 $k > 0$ 为形状参数, $\lambda > 0$ 为尺度参数。

第二步: 估计参数

用极大似然估计法估计参数, 得:

$$\hat{k} = 1.9155, \quad \hat{\lambda} = 30.4547$$

第三步: 将样本从小到大排序

6, 9, 13, 18, 22, 36, 36, 37, 41, 52

第四步: 计算经验分布函数值与理论分布函数值

$$F_n(x_{(i)}) = \frac{i}{10}, \quad F(x_{(i)}) = 1 - \exp \left[- \left(\frac{x_{(i)}}{\hat{\lambda}} \right)^{\hat{k}} \right]$$

第五步: 作 P-P 图

以 $F_n(x_{(i)})$ 为横轴, $F(x_{(i)})$ 为纵轴描点, 参考线为对角线 $y = x$ 。

结论:

由 P-P 图可见, 各样本点基本落在对角线 $y = x$ 附近, 故认为该样本来自两参数 Weibull 分布。

i	$x_{(i)}$	$F_n(x_{(i)}) = i/10$	$F(x_{(i)})$
1	6	0.1	0.0436
2	9	0.2	0.0923
3	13	0.3	0.1778
4	18	0.4	0.3059
5	22	0.5	0.4151
6	36	0.6	0.7478
7	36	0.7	0.7478
8	37	0.8	0.7659
9	41	0.9	0.8292
10	52	1.0	0.9384

5.12 13 周

 **作业 5.2.1** 酒精贮存：一些化学元素将发生变化，威士忌经贮存颜色变深，味道更鲜美。下表给出了威士忌酒的贮存年限及相应的浓度。试给出原始数据散点图和拟合的直线。给出威士忌酒浓度和贮存年限的关系，预测一下贮存 9 年的威士忌的浓度是多少？

年限	0	0.5	1	2	3	4	5	6	7	8
浓度/ 10^{-6}	104.6	104.1	104.4	105.0	106.0	106.8	107.7	108.7	110.6	112.1

解 由数据 ($n = 10$): $\sum x_i^2 = 204.25$, $\sum x_i y_i = 3973.35$, $\bar{x} = 3.65$, $\bar{y} = 107.0$ 。

$$S_{xx} = 204.25 - 10 \times 3.65^2 = 71.025, \quad S_{xy} = 3973.35 - 10 \times 3.65 \times 107.0 = 67.85$$

$$\hat{\beta}_1 = \frac{67.85}{71.025} \approx 0.9553, \quad \hat{\beta}_0 = 107.0 - 0.9553 \times 3.65 \approx 103.513$$

拟合直线: $\hat{y} = 103.513 + 0.9553x$ 。

预测贮存 9 年: $\hat{y} = 103.513 + 0.9553 \times 9 \approx 112.1 \times 10^{-6}$ 。

 **作业 5.2.2** 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(0, \sigma^2)$, $u \in \mathbb{R}^n$, $u^T u = 1$, 证明:

$$\frac{X^T (I_n - uu^T) X}{\sigma^2}$$

服从自由度为 $n-1$ 的 χ^2 分布, 其中

$$X^T = (X_1, X_2, \dots, X_n),$$

I_n 是 n 阶单位阵。

解 令 $P = I_n - uu^T$, 对 P 验证两条:

对称性: $P^T = I_n - (uu^T)^T = I_n - uu^T = P$ 。

幂等性:

$$P^2 = (I_n - uu^T)^2 = I_n - 2uu^T + u \underbrace{(u^T u)}_{=1} u^T = I_n - uu^T = P.$$

秩: $\text{rank}(uu^T) = 1$, 故 $\text{rank}(P) = n-1$ 。

由幂等矩阵定理, $X \sim N(\mathbf{0}, \sigma^2 I_n)$, P 对称幂等且秩为 $n-1$, 故

$$\frac{X^T P X}{\sigma^2} = \frac{X^T (I_n - uu^T) X}{\sigma^2} \sim \chi^2(n-1).$$

 **作业 6** 对第 1 题的结果作显著性检验, 并对贮存 9 年后的浓度进行置信度为 90% 的区间预测。

解 沿用第 1 题: $n = 10$, $\bar{x} = 3.65$, $\bar{y} = 107.0$, $S_{xx} = 71.025$, $S_{xy} = 67.85$, $\hat{\beta}_1 = 0.9553$, $\hat{\beta}_0 = 103.513$ 。由原始数据得 $S_{yy} = \sum y_i^2 - n\bar{y}^2 = 114558.32 - 114490 = 68.32$ 。

(一) 显著性检验 ($\alpha = 0.05$, $H_0: \beta_1 = 0$)

$$SS_e = S_{yy} - \frac{S_{xy}^2}{S_{xx}} = 68.32 - \frac{67.85^2}{71.025} \approx 3.503, \quad S = \sqrt{\frac{SS_e}{n-2}} \approx 0.6617$$

$$T = \frac{\hat{\beta}_1}{S/\sqrt{S_{xx}}} = \frac{0.9553}{0.6617/\sqrt{71.025}} \approx 12.17$$

因 $|T| = 12.17 > t_{0.025}(8) = 2.306$, 拒绝 H_0 , 线性关系显著。

(二) 90% 预测区间 ($x^* = 9$)

$\hat{y}(9) = 103.513 + 0.9553 \times 9 \approx 112.11$, 预测误差因子

$$\sqrt{1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} = \sqrt{1 + 0.1 + 0.4031} \approx 1.226$$

$$\Delta = t_{0.05}(8) \cdot S \cdot 1.226 = 1.860 \times 0.6617 \times 1.226 \approx 1.509$$

故贮存 9 年浓度的 90% 预测区间为 $(110.60, 113.62) \times 10^{-6}$ 。

 **作业 7** 下面数据是 18 名 5-8 岁儿童的体重和体积。

体重 (kg)	体积 ((dm) ³)	体重 (kg)	体积 ((dm) ³)	体重 (kg)	体积 ((dm) ³)	体重 (kg)	体积 ((dm) ³)
17.1	16.7	15.8	15.2	15.0	14.5	16.7	16.6
10.5	10.4	15.1	14.8	16.0	15.8	16.5	15.9
13.8	13.5	12.1	11.9	17.8	17.6	15.1	15.1
11.9	11.6	18.4	18.3	15.7	15.7	15.1	14.5
10.4	10.2	17.1	16.7				

- 找出儿童的平均体积和体重间的关系。
- 给出置信度为 90% 的体重为 14 kg 的儿童平均体积的置信区间。
- 给出置信度为 90% 的体重为 14 kg 的儿童的体积的预测区间。
- 想想该题意义所在。

1. 计算各统计量: $n = 18$, $\bar{x} \approx 15.006$, $\bar{y} \approx 14.722$, $S_{xx} \approx 96.39$, $S_{xy} \approx 95.24$, 故

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \approx 0.988, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \approx -0.114$$

回归方程为 $\hat{y} = -0.114 + 0.988x$ 。误差方差估计: $SSE \approx 0.61$, $\hat{\sigma} \approx 0.195$ 。

2. 当 $x^* = 14$ 时, $\hat{y}^* \approx 13.72$, $SE_{\hat{y}} = \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} \approx 0.0501$ 。查表 $t_{0.05}(16) = 1.746$, 90% 置信区间为

$$13.72 \pm 1.746 \times 0.0501 \approx (13.63, 13.81) \text{ (dm)}^3$$

3. $SE_{\text{pred}} = \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}} \approx 0.2014$, 90% 预测区间为

$$13.72 \pm 1.746 \times 0.2014 \approx (13.37, 14.07) \text{ (dm)}^3$$

4. 斜率 $\hat{\beta}_1 \approx 1$, 截距近似为零, 说明儿童体积 (dm³) 与体重 (kg) 数值几乎相等, 即儿童身体密度约为 1 kg/dm³, 与水的密度吻合, 符合生理学事实。(2) 的置信区间描述的是平均水平, 区间较窄; (3) 的预测区间针对具体个体, 包含个体随机误差, 故更宽。

5.13 14 周

 **作业 1** 在单因子方差分析中, 到新参数下的统计模型:

$$y_{ij} = \mu + \mu_i + e_{ij}, \quad (6.2.4)$$

用

$$\bar{\mu} = \frac{1}{k} \sum_{i=1}^k \mu'_i$$

代替 (6.2.4) 式中的 μ , 则 y_{ij} 仍可写做

$$y_{ij} = \bar{\mu} + \mu_i + e_{ij},$$

其中 $\mu_i = \mu'_i - \bar{\mu}$.

1. $\{\mu_i\}$ 应满足什么约束条件?
2. 证明假设 $H_0: \mu'_1 = \mu'_2 = \cdots = \mu'_k$ 与假设 $H_0: \mu_1 = \mu_2 = \cdots = \mu_k = 0$ 等价.

解

1. 由 $\mu_i = \mu'_i - \bar{\mu}$, 对 i 求和:

$$\sum_{i=1}^k \mu_i = \sum_{i=1}^k (\mu'_i - \bar{\mu}) = \sum_{i=1}^k \mu'_i - k\bar{\mu} = k\bar{\mu} - k\bar{\mu} = 0.$$

故 $\{\mu_i\}$ 应满足约束条件

$$\sum_{i=1}^k \mu_i = 0.$$

2. 由 $\mu_i = \mu'_i - \bar{\mu}$ 知 $\mu'_i = \mu_i + \bar{\mu}$, 故:

充分性: 若 $\mu'_1 = \mu'_2 = \cdots = \mu'_k$, 设公共值为 c , 则 $\bar{\mu} = c$, 从而

$$\mu_i = \mu'_i - \bar{\mu} = c - c = 0, \quad i = 1, \dots, k.$$

必要性: 若 $\mu_1 = \mu_2 = \cdots = \mu_k = 0$, 则

$$\mu'_i = \mu_i + \bar{\mu} = \bar{\mu}, \quad i = 1, \dots, k,$$

即 $\mu'_1 = \mu'_2 = \cdots = \mu'_k$.

综上, 两假设等价.

 **作业 2** 对某种疾病有五种治疗方式, 包括一种安慰剂. 下面数据给出由疾病出现到治愈所需天数.

治疗方式	痊愈所需天数					
1(安慰剂)	5	8	7	7	10	8
2	4	6	6	3	5	6
3	6	4	4	5	4	3
4	7	4	6	6	3	5
5	9	3	5	7	7	6

1. 对每种治疗方式计算痊愈所需天数的均值和标准差.
2. 对给定数据作方差分析.

解

1. 各组样本量均为 $n_i = 6$, 计算各治疗方式的均值与标准差:

$$\bar{y}_{1\cdot} = \frac{5+8+7+7+10+8}{6} = \frac{45}{6} = 7.5, \quad s_1 = \sqrt{\frac{13.5}{5}} = \sqrt{2.7} \approx 1.643$$

$$\bar{y}_{2\cdot} = \frac{4+6+6+3+5+6}{6} = \frac{30}{6} = 5.0, \quad s_2 = \sqrt{\frac{8}{5}} = \sqrt{1.6} \approx 1.265$$

$$\bar{y}_3 = \frac{6+4+4+5+4+3}{6} = \frac{26}{6} \approx 4.333, \quad s_3 = \sqrt{\frac{16/3}{5}} = \sqrt{\frac{16}{15}} \approx 1.033$$

$$\bar{y}_4 = \frac{7+4+6+6+3+5}{6} = \frac{31}{6} \approx 5.167, \quad s_4 = \sqrt{\frac{65/6}{5}} = \sqrt{\frac{13}{6}} \approx 1.472$$

$$\bar{y}_5 = \frac{9+3+5+7+7+6}{6} = \frac{37}{6} \approx 6.167, \quad s_5 = \sqrt{\frac{125/6}{5}} = \sqrt{\frac{25}{6}} \approx 2.041$$

2. 设 $k=5$, $n_i=6$, $N=30$, 总均值为

$$\bar{y} = \frac{45+30+26+31+37}{30} = \frac{169}{30} \approx 5.633.$$

各平方和为:

$$SS_T = \sum_{i,j} y_{ij}^2 - \frac{(\sum_{i,j} y_{ij})^2}{N} = 1047 - \frac{169^2}{30} = \frac{2849}{30} \approx 94.967,$$

$$SS_A = \sum_{i=1}^5 \frac{(\sum_j y_{ij})^2}{n_i} - \frac{169^2}{30} = \frac{45^2+30^2+26^2+31^2+37^2}{6} - \frac{169^2}{30} = \frac{5931}{6} - \frac{28561}{30} = \frac{1094}{30} \approx 36.467,$$

$$SS_E = SS_T - SS_A = \frac{2849}{30} - \frac{1094}{30} = \frac{1755}{30} = 58.5.$$

自由度: $f_A = k-1 = 4$, $f_E = N-k = 25$, 方差分析表如下:

方差来源	平方和	自由度	均方	F 值
因子 A	$\frac{1094}{30} \approx 36.467$	4	$\frac{547}{60} \approx 9.117$	≈ 3.896
误差 E	58.5	25	2.34	
总计	$\frac{2849}{30} \approx 94.967$	29		

查 F 分布表, $F_{0.05}(4, 25) \approx 2.76$. 由于

$$F = \frac{MS_A}{MS_E} = \frac{547/60}{117/50} = \frac{2735}{702} \approx 3.896 > F_{0.05}(4, 25) \approx 2.76,$$

在显著性水平 $\alpha = 0.05$ 下拒绝 H_0 , 即认为五种治疗方式的疗效存在显著差异.

第6章 纯作业

6.1 第一周作业

page44

- 作业3 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 其中 μ 是已知数, 而 σ^2 是未知的, 指出下列各量哪些是统计量, 哪些不是统计量, 并说明理由:

$$\sum_{i=1}^n X_i, \quad X_1 + 2\mu, \quad \max_{1 \leq i \leq n} \{X_i\}, \quad \sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2}, \quad \sum_{i=1}^n (X_i - \mu)^2.$$

- 作业4 某机床加工出的零件的直径服从正态分布 $N(\mu, \sigma^2)$, μ, σ^2 未知。为对 μ, σ^2 作出估计, 随机选取加工出来的 n 个零件进行测量, 得到 n 个数据

$$x_1, x_2, \dots, x_n.$$

试写出该问题的统计模型 (即参数空间和样本分布族)。

- 作业6 (柯西分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., X_1 服从柯西分布, 概率密度为

$$f(x, \sigma) = \frac{1}{\pi \sigma} \frac{1}{1 + (x/\sigma)^2}, \quad -\infty < x < \infty,$$

求

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

的抽样分布。

page45

- 作业1 证明 (2.2.3) 式。

- 作业2 (几何分布) 设总体 X 服从几何分布

$$P\{X = k\} = p(1-p)^{k-1}, \quad k = 1, 2, \dots,$$

$X_1, X_2, \dots, X_n$ 是取自 X 的简单随机样本, 求 $X_{(1)}, X_{(n)}$ 的分布。

- 作业3 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U[\theta - \frac{1}{2}, \theta + \frac{1}{2}]$, 试分别求出 $X_{(1)}$ 和 $X_{(n)}$ 的概率密度。

6.2 第二周作业

page45

- 作业4 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim F(x)$, $F(x)$ 有概率密度 $f(x)$, 求:

(1) $X_{(1)}$ 和 $X_{(n)}$ 的联合分布函数及联合概率密度;

(2) $R = X_{(n)} - X_{(1)}$ 的分布函数及概率密度。

- 作业5 从某总体抽取一个容量为 5 的样本:

$$-2.8, -1, 1.5, 2.1, 3.4.$$

写出该样本的经验分布函数并画出它的图形。

- 作业6 证明: 正态分布 $N(\mu, \sigma^2)$ 的上 α ($0 < \alpha < 1$) 分位数 z_α 与标准正态分布的上 α 分位数 u_α 之间有以下关系:

$$z_\alpha = \mu + \sigma u_\alpha.$$

page46

作业 1 (χ^2 分布) 设 $X \sim \chi^2(n)$, 证明:

$$E(X^k) = 2^k \left(\frac{n}{2} + k - 1\right) \left(\frac{n}{2} + k - 2\right) \cdots \frac{n}{2}, \quad k = 1, 2, \dots$$

特别地, 有

$$E(X) = n, \quad \text{Var}(X) = 2n.$$

作业 2 (t 分布) 设 $X \sim t(n)$, 则当 $k < n$ 时, $E(X^k)$ 存在且有

$$E(X^k) = \begin{cases} 0, & \text{当 } k \text{ 为奇数;} \\ \frac{n^{k/2} \Gamma\left(\frac{k+1}{2}\right) \Gamma\left(\frac{n-k}{2}\right)}{\sqrt{\pi} \Gamma\left(\frac{n}{2}\right)}, & \text{当 } k \text{ 为偶数.} \end{cases}$$

当 $k \geq n$ 时, $E(X^k)$ 是否存在?

作业 3 (χ^2 分布) 设 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$, X_1, X_2 相互独立, 则 $X_1 + X_2$ 与 X_1/X_2 相互独立。

作业 5 设 $F \sim F(m, n)$, 证明

$$F_{1-\alpha}(m, n) F_{\alpha}(n, m) = 1, \quad \forall \alpha \in (0, 1).$$

作业 设 $X_1, X_2, \dots, X_n$ 独立, $A_{2 \times n}$ 已知,

$$Y = AX,$$

讨论 Y 与 X 的分布类型是否相同。

作业 (χ^2 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$\mathbf{X} = (X_1, \dots, X_n)^T,$$

A 为 n 阶对称方阵。证明:

$$\mathbf{X}^T A \mathbf{X} \sim \chi^2(r)$$

当且仅当 A 为幂等矩阵, 即

$$A^2 = A,$$

并且

$$\text{rank}(A) = r.$$

6.3 第三周

作业 设 $X_1, \dots, X_n$ i.i.d., $X_i \sim N(\mu, \sigma^2)$, 又设 $X_{n+1} \sim N(\mu, \sigma^2)$, 且与 $X_1, \dots, X_n$ 相互独立。记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

证明

$$T = \sqrt{\frac{n}{n+1}} \frac{\bar{X} - X_{n+1}}{s} \sim t(n-1).$$

作业 2.4 第 1 题 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

求 $\text{Var}(s^2)$ 。

作业 2.4 第 2 题 设 $X_1, \dots, X_m$ i.i.d., $X_1 \sim N(\mu_1, \sigma^2)$; $Y_1, \dots, Y_n$ i.i.d., $Y_1 \sim N(\mu_2, \sigma^2)$, 且这两组随机变量相

互独立。记

$$s_1^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2, \quad s_2^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

1. 求

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{\sigma^2}$$

的分布;

2. 比较 s_1^2 与

$$\frac{(m-1)s_1^2 + (n-1)s_2^2}{m+n-2}$$

的方差。

 **作业 2.4 第 3 题** 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim N(0, 1)$, 求

$$Z = \frac{\sum_{i=1}^{n-1} X_i}{X_n}$$

的分布。

 **作业 1** (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 分别用一阶矩和二阶矩求 λ 的矩估计量。

 **作业 2** (二项分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim B(k, p)$, 求 p 的矩估计量。

 **作业 3** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的矩估计量。

 **作业 5** (双边指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x)$,

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x|}{\sigma}\right),$$

求 σ 的矩估计量。

6.4 第五周作业

 **作业 7** 设 $X_1, X_2, \dots, X_n$ i.i.d., 试分别求下列总体中 θ 的最大似然估计量。

2. (韦布尔分布) $f(x; \theta) = \frac{x}{\theta^2} e^{-x^2/\theta^2}$, $x > 0$, $\theta > 0$.

 **作业 8** (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U\left(\theta - \frac{1}{2}, \theta + \frac{1}{2}\right)$, 证明任意

$$T \in \left[X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2}\right]$$

都是 θ 的最大似然估计量。

 **作业 10** (双参数指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x; \alpha, \beta)$,

$$f(x; \alpha, \beta) = \begin{cases} \beta \exp\{-\beta(x - \alpha)\}, & x \geq \alpha, \\ 0, & \text{其他,} \end{cases}$$

其中 $\beta > 0$ 。试求 α, β 的最大似然估计量。

 **作业 11** (截尾几何分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., 为来自截尾几何分布总体 X 的样本:

$$P\{X = k\} = \theta^{k-1}(1 - \theta), \quad k = 1, 2, \dots, r;$$

$$P\{X = r + 1\} = \theta^r.$$

记

$$M = \#\{i : X_i = r + 1, i = 1, 2, \dots, n\},$$

试证明 θ 的 MLE 为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i - n}{\sum_{i=1}^n X_i - M}.$$

作业 12 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta_1, \theta_2)$,

$$f(x, \theta_1, \theta_2) = \begin{cases} \frac{\theta_1}{\theta_2} x^{\theta_1-1} \exp\left(-\frac{x^{\theta_1}}{\theta_2}\right), & x \geq 0, \\ 0, & \text{其他}, \end{cases}$$

其中 θ_1 已知, 求 θ_2 的最大似然估计量。

作业 18 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 其中 σ^2 已知, μ 的先验分布为 $N(\nu, \tau^2)$ 。

1. 求 μ 的后验分布;
2. 求 μ 的后验均值估计。

作业 20 (帕雷托 (Pareto) 分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, 其中 θ 的先验分布为 $\text{Pareto}(a, b)$, 其概率密度为

$$\pi(\theta) = \frac{ba^b}{\theta^{b+1}}, \quad a < \theta < \infty, a > 0, b > 0.$$

1. 求 θ 的后验分布;
2. 求 θ 的后验均值估计。

作业 1 (泊松分布) 设 $X \sim P(\lambda)$, 试求样本量为 1 时 $g(\lambda) = e^{-2\lambda}$ 的无偏估计量, 并说明该估计的不合理性。

作业 2 (二项分布) 设 $X \sim B(n, p)$, 证明 $g(p) = \frac{1}{1+p^2}$ 不存在无偏估计量。

作业 3 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, 1)$, 证明 $g(\mu) = |\mu|$ 没有无偏估计量。

作业 4 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta_1, \theta_2)$, 求 θ_1, θ_2 的无偏估计量。

作业 5 设 $\hat{\theta}$ 和 θ^* 为 θ 的无偏估计量, 若 $\tilde{\theta} = a\hat{\theta} + b\theta^*$, 问: a, b 满足什么条件时, $\tilde{\theta}$ 也是 θ 的无偏估计量?

作业 6 设 $X \sim U(0, \theta)$, $X_1, X_2, \dots, X_n$ i.i.d. 为来自 X 的样本, 试分别求 θ^2, θ^{-1} 的无偏估计量。

6.5 第七周作业

作业 7 设 W 是 θ 的无偏估计量, 若 W 满足

- (1) W 是观察值 (样本) 的线性函数;
- (2) $E_\theta W = \theta, \forall \theta \in \Theta$;
- (3) 若对任意一个满足 (1),(2) 的估计 W^* , 有

$$\text{Var}_\theta(W) \leq \text{Var}_\theta(W^*), \quad \forall \theta \in \Theta,$$

则称 W 是 θ 的最优线性无偏估计量。如总体 $X \sim N(\mu, \sigma^2)$, $(\mu, \sigma^2) \in \Theta = \{(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma^2 > 0\}$ 。

证明 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 μ 的最优线性无偏估计量。该结论只对正态总体正确吗?

作业 11 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明:

- (1) $\bar{X}$ 是 λ 的 UMVUE;
- (2) $\tilde{\lambda}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}$ 为 λ^2 的无偏估计量。该估计是 UMVUE 吗?

作业 12 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, 已知 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 和 $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 分别是 μ 和 σ^2 的 UMVUE。计算 μ 和 σ^2 的 C-R 下界。

作业 14 在定理 3.3.3 的条件下, 若 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的估计量, 满足

$$E_\theta \hat{g}(X_1, X_2, \dots, X_n) = g(\theta) + b(\theta), \quad \forall \theta \in \Theta \subset \mathbf{R},$$

$b(\theta)$ 为估计的偏差, 则有

$$\text{Var}_\theta(\hat{g}(X_1, X_2, \dots, X_n)) \geq [b'(\theta) + g'(\theta)]^2 / nI(\theta).$$

作业 15 设 $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 都是 $g(\theta)$ 的无偏估计量, 并且 $\hat{g}_1(\mathbf{X})$ 还是 $g(\theta)$ 的 UMVUE, 证明: $\hat{g}_1(\mathbf{X})$ 与 $\hat{g}_2(\mathbf{X})$ 的相关系数非负。

作业 16 (0-1 分布) 考虑例 3.2.12 中的贝叶斯估计量, 其中 θ 的贝叶斯估计量为

$$\hat{\theta} = \frac{\sum_{i=1}^n X_i + a}{n + a + b}.$$

(1) 求该估计量的均方误差。

作业 1 设 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{a.s.} a > 0$, 证明:

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{a}.$$

作业 1 若估计序列 $\{\hat{\theta}_n\}$ 满足 $\lim_{n \rightarrow \infty} E_{\theta}(\hat{\theta}_n - \theta)^2 = 0$, $\forall \theta \in \Theta$, 则称 $\hat{\theta}_n$ 为 θ 的均方相合估计量。证明: 均方相合估计必是相合估计量。

作业 2 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, $\hat{\theta}_n = X_{(n)}$ 是 θ 的均方相合估计量吗?

作业 4 (泊松分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim P(\lambda)$, 证明: $\bar{X}$, s_n^2 都是 λ 的相合估计量。

作业 5 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(0, \theta)$, 试证

$$T(X_1, X_2, \dots, X_n) = \sqrt[n]{X_1 X_2 \cdots X_n}$$

为 $g(\theta) = \frac{\theta}{e}$ 的相合估计量。

作业 6 设总体的二阶矩存在, $X_1, X_2, \dots, X_n$ 是总体的简单随机样本, 则

$$T(X_1, X_2, \dots, X_n) = \frac{2}{n(n+1)} \sum_{i=1}^n i X_i$$

是一阶原点矩的相合估计量。

作业 8 (指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta) = \frac{1}{\theta} e^{-x/\theta}$, $x > 0$, 试证 θ 的 MLE 之渐近分布为 $N\left(\theta, \frac{\theta^2}{n}\right)$ 。

6.6 第八周作业

作业 9 在习题 3.3.11 中, 估计 λ^2 时, 求 $\bar{X}^2$ 相对于 $\tilde{\lambda}^2$ 的渐近效率。

作业 10 设 $X_1, \dots, X_n$ i.i.d., $X_1 \sim f(x, \theta)$, $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 是 θ 的渐近正态估计量:

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{L} N(0, V(\theta)), \quad \forall \theta \in \Theta,$$

$V(\theta)$ 是 θ 的连续函数。证明: $V(\hat{\theta})$ 为 $V(\theta)$ 的相合估计量。

作业 12 设在定理 3.4.6 中, $h(\theta)$ 二阶可导并且 $h'(\theta_0) = 0$, $h''(\theta_0) \neq 0$ 。利用泰勒公式 $h(\hat{\theta}) - h(\theta_0) = \frac{1}{2}(\hat{\theta} - \theta_0)^2(h''(\theta_0) + R)$, 证明

$$n(h(\hat{\theta}) - h(\theta_0)) \xrightarrow{L} \frac{1}{2} A(\theta_0) h''(\theta_0) \chi^2(1),$$

其中 $\chi^2(1)$ 为自由度是 1 的 χ^2 分布。

6.6.1 3.5

作业 1 (均匀分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim U(\theta, \theta + 1)$, 求 θ 的置信度为 $100(1 - \alpha)\%$ 的置信区间。

作业 2 设 $X_1, X_2, \dots, X_n$ i.i.d., $X_1 \sim N(\mu, \sigma^2)$, μ 已知, 求 σ^2 的置信度为 $100(1 - \alpha)\%$ 的置信区间。它与 μ 未知时的区间估计有何差别?

作业 3 (指数分布) 设 $X_1, X_2, \dots, X_n$ i.i.d., X_1 服从指数分布, 密度为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta}, & x > 0; \\ 0, & \text{其他.} \end{cases}$$

(1) 证明 $2n\bar{X}/\theta \sim \chi^2(2n)$;

(2) 求 θ 的 $100(1 - \alpha)\%$ 的置信下限;

(3) 记 $T_{0.95}$ 为方程 $P\{X_1 > T_{0.95}\} = 0.95$ 的解, 求 $T_{0.95}$ 的 $100(1 - \alpha)\%$ 置信下限.

6.7 第九周作业

 **作业 4** (0-1 分布) 某批产品不合格品率 p 未知, 今抽取 100 件检验, 发现 2 件不合格, 试给出不合格品率的置信度 95% 的置信上限.

 **作业 5** 设 $X_1, X_2, \dots, X_m$ 与 $Y_1, Y_2, \dots, Y_n$ 是分别来自 $N(\mu_1, \sigma_1^2)$ 与 $N(\mu_2, \sigma_2^2)$ 的两个独立样本.

(1) 若 σ_1^2, σ_2^2 已知, 求 $\mu_2 - \mu_1$ 的置信度为 $1 - \alpha$ 的置信区间.

(2) 若 $\sigma_1^2 = \sigma_2^2$ 已知, 为使置信度为 90% 的 $\mu_2 - \mu_1$ 的置信区间长为 $\frac{2}{5}\sigma_1$, 问样本大小 $n_1 = n_2$ 应取多大?

(3) 若 $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2$ 都未知, 求 σ_2^2/σ_1^2 的一个 $1 - \alpha$ 置信度的置信区间.

6.8 4.1

 **作业 1** 设 $X_1, X_2, \dots, X_n$ 为独立同分布样本, $X_1 \sim N(\mu, 1)$. 对检验问题 $H_0: \mu = 0; H_1: \mu > 0$, 用检验函数

$$\phi(\mathbf{X}) = \phi(X_1, X_2, \dots, X_n) = \begin{cases} 1, & \text{若 } \bar{X}_n > 1.3 \\ 0, & \text{若 } \bar{X}_n \leq 1.3 \end{cases}$$

进行检验, 其中 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. 设样本容量 $n = 10$, 试回答下列问题:

(1) 该检验的真实水平是多少?

(2) 当 $\mu = 1.0$ 和 $\mu = 1.5$ 时, 该检验犯第二类错误的概率分别是多少?

(3) 若取检验水平 $\alpha = 0.05$, 给出用 $\bar{X}_n$ 作为检验统计量的检验函数.

 **作业 2** 设 $X_1, X_2, \dots, X_{10}$ 是来自 $U(0, \theta)$ 的样本. 今用检验函数

$$\phi(\mathbf{X}) = \begin{cases} 1, & \text{若 } X_{(10)} > 0.95 \\ 0, & \text{若 } X_{(10)} \leq 0.95 \end{cases}$$

检验 $H_0: \theta = 1; H_1: \theta > 1$, 其中 $\mathbf{X} = (X_1, \dots, X_{10})^T$, $X_{(10)} = \max(X_1, X_2, \dots, X_{10})$. 请回答下列问题:

(1) 该检验的真实水平是多少?

(2) 求该检验的功效函数.

(3) 仍然用 $X_{(10)}$ 作为检验统计量, 写出检验水平 $\alpha = 0.05$ 时的检验函数.

 **作业 3** 证明: 二项分布 $B(n, p)$ 的分布函数 $P\{X \leq x\} = \sum_{i=0}^x \binom{n}{i} p^i (1-p)^{n-i}$ 是 p 的单调减函数.

6.9 4.2

 **作业 2** 设 $X_1, X_2, \dots, X_{10}$ 是取自 $N(\mu, \sigma^2)$ 的样本.

(2) 试写出检验问题 $H_0: \sigma^2 \leq 1; H_1: \sigma^2 > 1$ 的检验函数, 取 $\alpha = 0.1$;

(3) 取 $\alpha = 0.05$, 重做 (1), (2), 功效函数有何变化? 由此得出什么结论?

 **作业 3** (两个正态总体的比较) 设 $X_1, X_2, \dots, X_m$ 为来自 $N(\mu_1, \sigma_1^2)$ 的样本; $Y_1, Y_2, \dots, Y_n$ 为来自 $N(\mu_2, \sigma_2^2)$ 的样本, 两样本相互独立, σ_1^2, σ_2^2 均未知. 分下面几种情况, 给出 $H_0: \mu_1 = \mu_2; H_1: \mu_1 \neq \mu_2$ 的检验函数形式:

(2) $\sigma_1^2 = k\sigma_2^2$, k 为已知常数;

 **作业 4** (两个正态总体的比较) 样本如第 3 题所示, 试给出检验下列问题的检验函数的形式:

(1) $H_0: \sigma_1^2 \leq \sigma_2^2; H_1: \sigma_1^2 > \sigma_2^2$;

(2) $H_0: \sigma_1^2 = k\sigma_2^2; H_1: \sigma_1^2 \neq k\sigma_2^2$, 其中 k 为给定的数.

- 作业 6 用两台仪器 A, B 测量相同的物理量, 设 A 是标准的, 两台仪器的测量值均服从正态分布. 对某物理量用仪器 A 独立测量 10 次, 数值如下:

10.5 10.3 10.4 9.6 9.7 9.8 9.9 10.1 10.2 9.7

对同一量用仪器 B 独立测量了 10 次, 其数值是

10.2 10.7 10.8 10.9 10.4 10.6 11.0 11.1 10.9 11.2

试回答下列问题:

- (1) 仪器 B 有无系统误差?
- (2) 若已知没有系统误差, 仪器 A 和仪器 B 的测量精度是否一致?

- 笔记 “无系统误差” 等同于 $\mu_B = \mu_A$, “测量精度一致” 等同于 $\sigma_B^2 = \sigma_A^2$, $\mu_A, \mu_B, \sigma_A^2, \sigma_B^2$ 分别是两台仪器测量值分布的均值和方差.

6.10 第 10 周作业

6.10.1 4.3

- 作业 1 某单位购进一批产品, 抽 36 件检查, 发现有 3 件不合格, 试问这批产品的不合格品率高于 3% 吗? 你认为次品率不超过多少?
- 作业 2 设 $X_1, X_2, \dots, X_n$ 为来自 $P(\lambda)$ 的样本, 试给出检验 $H_0: \lambda = \lambda_0; H_1: \lambda \neq \lambda_0$ 的检验函数. 若有观测值 5, 7, 8, 6, 9, 10, 在检验水平 $\alpha = 0.05$ 下, 能接受 $\lambda = 3$ 吗?

6.11 第 11 周作业

6.12 4.4

- 作业 1 设总体 X 服从参数为 λ 的泊松分布

$$f(x, \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}, \quad x = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 为参数, $X_1, X_2, \dots, X_n$ 是独立同分布样本. 考虑假设检验问题:

$$H_0: \lambda \leq \lambda_0; \quad H_1: \lambda > \lambda_0$$

1. 有无 UMP 检验? 为什么?
2. 若有 UMP 检验, 试求出检验水平 $\alpha = 0.05$, $n = 10$, $\lambda_0 = 0.1$ 时的检验函数.

- 作业 2 某修理部对要求服务人数连续作 n 日记录. X_i 为第 i 日要求服务的人数. 设 $X_1, X_2, \dots, X_n$ 独立同分布, 均服从参数为 θ 的泊松分布. 若每日要求服务人数太少将关门. 根据 n 日的记录, 要作出符合下面要求的决定:

1. 若每日要求服务平均人数不多于 10 人, 仅有 0.01 的概率开门;
2. 若每日要求服务的平均人数不少于 15 人, 仅有 0.01 的概率关门.

问需观察多少日即 n 为多少时, UMP 检验才能满足上述要求?

- 作业 3 一测量仪器正常运行, 对某量重复测量 n 次, 其结果是 $X_1, X_2, \dots, X_n$. 假设 $X_1 \sim N(\mu, \sigma^2)$. 今欲检验该仪器测量精度是否满足要求. 假定测量精度要求为 $\mu_0 \pm \Delta$. 试回答下列问题:

1. 怎样将该问题叙述成假设检验问题?
2. 该假设检验问题有无 UMP 检验? 若有给出检验函数的形式;
3. 利用 χ^2 分布表, 确定样本容量 n 的大小, 使得在检验水平为 0.01、测量误差大于 1.1Δ 时, 被检测出的概率大于 0.9.

 **作业 5** 设 $X_1, X_2, \dots, X_n$ 是独立同分布的, 其共同概率密度是

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0, \quad \theta > 0.$$

试回答:

1. 什么样的假设检验问题有 UMP 检验?
2. 写出 UMP 检验函数的形式。

 **作业 6** 一设备有 n 个相同或相似的元件, X_i 为第 i 个元件的失效时间, 假定 $X_1, \dots, X_n$ 是来自韦布尔 (Weibull) 分布

$$f(x, \lambda) = \lambda c x^{c-1} e^{-\lambda x^c}, \quad x > 0$$

的样本, 其中 c 是常数, $\lambda > 0$ 是参数。

1. 问题

$$H_0: \frac{1}{\lambda} \leq \frac{1}{\lambda_0}, \quad H_1: \frac{1}{\lambda} > \frac{1}{\lambda_0}$$

有无 UMP 检验? 为什么?

2. 若 (1) 是肯定的回答, 试给出 UMP 检验函数的形式。
3. 设 $\lambda_0 = \frac{1}{12}$, 求样本容量 n , 使得在检验水平为 0.01, $\lambda = \frac{1}{15}$ 时, 其功效函数值至少为 0.95。该问可近似计算。

提示: X_i^c 服从指数分布。

 **作业 7** 设分布族

$$\{f(x; \theta) : \theta \in \Theta\}$$

是单调似然比分布族。对检验问题

$$(a) \quad H_0: \theta = \theta_0, \quad H_1: \theta > \theta_0,$$

$$(b) \quad H_0: \theta = \theta_0, \quad H_1: \theta < \theta_0,$$

试问:

1. 有无 UMP 检验?
2. 若 (1) 回答是肯定的, 请写出检验函数的形式。

6.13 12 周作业

 **作业 1** 有一样本的观测值为: 0.473, 0.224, 0.827, 0.223, 0.867, 0.779, 0.554, 0.529, 0.705, 0.656, 试用作图法检验该样本是否来自 $U(0, 1)$ 。

 **作业 2** 有一样本的观测值为: 0.54, 0.32, 0.68, 0.71, 1.04, 0.94, 1.34, 1.10, 0.44, 1.01, 试用作图法检验该样本是否来自正态总体。

 **作业 extra** 对第 1 题做 Kolmogorov 检验。

掷骰子 30 次, 掷出 1、2、3、4、5、6 点的次数分别为 3、6、4、7、4、6, 请检验骰子出现各点概率是否相等?

第7章 基础工具层

 **笔记** [统计量是什么问题的答案] 你面对的基本困境是：总体分布未知（比如不知道 μ 是多少），手里只有 $X_1, X_2, \dots, X_n$ 这 n 个数。

n 个数太多了，你不能直接用。你需要把 n 个数压缩成一个数，用来代表“关于 θ 的信息”。这个压缩函数 $T(X_1, \dots, X_n)$ 就是统计量。

唯一的限制： T 里不能含 θ 本身——否则你等于用了还没求的答案，循环了。

定义 7.1 (常见统计量)

设 $X_1, X_2, \dots, X_n$ 为样本，常用统计量有：

$$\text{样本均值 } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

$$\text{样本方差 } s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

$$\text{极差 } R = X_{(n)} - X_{(1)}.$$



7.1 顺序统计量

例题 7.1 为什么需要顺序统计量：从电路寿命说起 你有 $n = 5$ 个灯泡，串联组成一条电路——一个坏了，全线中断。问：这条电路能撑多久？

你知道每个灯泡的寿命 X_i 服从同一分布 $F(x)$ ，也可以算出样本均值 $\bar{X}$ 。但 $\bar{X}$ 在这里毫无用处：它告诉你的是“平均每个灯泡能用多久”，而电路的寿命取决于**最先坏掉的那个**，即

$$T_{\text{串联}} = \min\{X_1, X_2, X_3, X_4, X_5\} = X_{(1)}.$$

如果改成并联电路——**全部坏了才断**，则寿命取决于**最后一个**：

$$T_{\text{并联}} = \max\{X_1, X_2, X_3, X_4, X_5\} = X_{(n)}.$$

- $\bar{X}$ 描述数据的“整体水平”，把每个点的位置信息**平均掉了**。
- $X_{(1)}, \dots, X_{(n)}$ 保留了“第几名”的位置信息，专门回答极值、中间值、排名类问题。

凡是出现问题“最大”“最小”“第 r 小”“中位数”，本质上都是在问顺序统计量——这就是它被发明的根本原因。

东邪的 tip 7.1

均值方差是“融合”数据，顺序统计量是“保留位置”的数据。一类问题问平均水平用前者；一类问题问第几名用后者。两种工具解决两类完全不同的问题。

定理 7.1 (第 r 个顺序统计量的密度)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x)$ ，密度为 $f(x)$ ，则 $X_{(r)}$ 的密度为

$$f_{(r)}(x) = r C_n^r F^{r-1}(x) [1 - F(x)]^{n-r} f(x)$$



 **笔记** [拆解记忆]

- $f(x)$ ：第 r 个恰好落在 x 处
- $F^{r-1}(x)$ ：有 $r-1$ 个已经落在 x 左边
- $[1 - F(x)]^{n-r}$ ：有 $n-r$ 个还在 x 右边

- $rC_n^r = \frac{n!}{(r-1)!(n-r)!}$: 这三组人的全部排列方式数

 **笔记** [顺序统计量] 顺序统计量在一个特定情况下才出现: 参数出现在分布的支撑边界上 (即参数决定数据的范围)。

用顺序统计量:

- $U(\theta_1, \theta_2)$: 数据必须在 $[\theta_1, \theta_2]$ 里, 参数就是边界 $\rightarrow$ 用 $X_{(1)}$ 、 $X_{(n)}$
- $U(0, \theta)$: 数据在 $[0, \theta]$ 里, θ 是上界 $\rightarrow$ 用 $X_{(n)}$
- 双参数指数分布 $f(x) = e^{-(x-\theta)}$, $x \geq \theta$: θ 是数据的下界 $\rightarrow$ 用 $X_{(1)}$

不用顺序统计量:

- $N(\mu, \sigma^2)$: 数据范围是整个实数轴, μ 、 σ^2 出现在密度公式里 $\rightarrow$ 用 $\bar{X}$ 、 s^2
- $P(\lambda)$: λ 出现在概率公式里, 不影响范围 $\rightarrow$ 用 $\bar{X}$

东邪的 tip 7.2

设 $X_1, X_2, \dots, X_8$ i.i.d. $\sim U(0, \theta)$, 观测值为 1, 2, 3, 4, 5, 6, 7, 8, 则 $X_{(8)} = \max\{X_1, \dots, X_8\} = 8$, 用 $X_{(8)}$ 估计 θ 。我们求 $X_{(n)}$ 的期望来估计 θ , 就像我们拿 $\bar{X}$ 的期望估计正态分布的 μ 。求期望里面都是变量不是真实的数字是实验前。

例题 7.2 $X_{(n)}$ 虽然是从 $X_1, \dots, X_8$ 里来的, 但它不是随机抽的一个, 它是特意挑出最大的那个。挑最大值这个动作改变了分布。

具体来说, 设 $\theta = 10$:

$$P(X_i \leq 5) = \frac{5}{10} = 0.5$$

随便一个 X_i 有 50% 概率 ≤ 5 , 合理。

$$P(X_{(8)} \leq 5) = \left(\frac{5}{10}\right)^8 = \frac{1}{256} \approx 0.4\%$$

8 个数里最大值还 ≤ 5 , 概率只有 0.4%。

直觉: 8 个数都取到 5 以下, 这件事几乎不可能发生, 因为总会有某个数跑到 5 以上。所以 $X_{(n)}$ 虽然也是 X_i 里的一个, 但它天生偏大, 分布和普通 X_i 不一样。

东邪的 tip 7.3

这里的 $X_1, \dots, X_8$ 不是最大值 $X_{(8)}$, 而是八个原始样本。最大值小于 5 等于全部八个样本都小于 5 的概率, 每一个都服从 $U(0, \theta)$, 小于 5 的概率都是 $\frac{5}{\theta}$ 。

 **笔记**

$$F_{(n)}(x) = \left(\frac{x}{\theta}\right)^n$$

$$f_{(n)}(x) = \frac{nx^{n-1}}{\theta^n}$$

$$E[X_{(n)}] = \int_0^\theta x \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta x^n dx = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n\theta}{n+1}$$

东邪的 tip 7.4

原本从 0 积分到 θ , 故

$$E[X_{(n)}] = \frac{n\theta + 0}{n+1}$$

现从 θ_1 积分到 θ_2 , 把 θ 换成 θ_2 , 0 换成 θ_1 :

$$E[X_{(n)}] = \frac{n\theta_2 + \theta_1}{n+1}$$

同理, $E[X_{(1)}]$ 把积分区域反过来, 从 θ_2 积分到 θ_1 , n 后面跟着的是 θ_1 , 另外加的是起始点 θ_2 :

$$E[X_{(1)}] = \frac{n\theta_1 + \theta_2}{n+1}$$

笔记

参数在密度公式里 $\rightarrow$ 用 $\bar{X}$ 、 s^2 这类自然统计量; 参数在数据的取值范围上 $\rightarrow$ 用极值 $X_{(1)}$ 、 $X_{(n)}$ 。

笔记 [顺序统计量期望的等间距直觉] n 个点均匀撒在 $[\theta_1, \theta_2]$ 上, 平均来说这 n 个点会把区间切成 $n+1$ 段等长的小段, 每段长度为:

$$\frac{\theta_2 - \theta_1}{n+1}$$

因此:

- $X_{(1)}$ 平均落在距离 θ_1 一段的位置:

$$E[X_{(1)}] = \theta_1 + \frac{\theta_2 - \theta_1}{n+1} = \frac{n\theta_1 + \theta_2}{n+1}$$

- $X_{(n)}$ 平均落在距离 θ_2 一段的位置:

$$E[X_{(n)}] = \theta_2 - \frac{\theta_2 - \theta_1}{n+1} = \frac{\theta_1 + n\theta_2}{n+1}$$

$X_{(1)}$ 是最小值, 靠近 θ_1 , 故 θ_1 权重小 (n 份), θ_2 权重小 (1 份); $X_{(n)}$ 反之。

记忆: n 个点把区间切成 $n+1$ 段, 最小值在第 1 段末, 最大值在第 n 段末。

7.2 抽样分布, 卡方, t, F

定义 7.2 (χ^2 分布)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 令

$$\xi = \sum_{i=1}^n X_i^2$$

则称 ξ 的分布为自由度为 n 的 χ^2 分布, 记作 $\xi \sim \chi^2(n)$ 。



笔记 [要背的公式]

$$E(\xi) = n, \quad \text{Var}(\xi) = 2n.$$

东邪的 tip 7.5

ξ 念做可塞, 是平方和。他的期望是因为 $E(X)$ 都是 0 只有方差起作用每一个点方差都是 1 加起来就是 n 。就是不要想的太复杂因为就是 01 正态分布算一个是很好算把具体数字带进去就行了

笔记 方差定义变形: $\text{Var}(X) = E(X^2) - [E(X)]^2$, 移项得 $E(X^2) = \text{Var}(X) + [E(X)]^2$ 。

笔记 [$\text{Var}(\xi) = 2n$ 的推导] 由独立可加性:

$$\text{Var}(\xi) = \sum_{i=1}^n \text{Var}(X_i^2)$$

对单个 $X_i \sim N(0, 1)$:

$$\text{Var}(X_i^2) = E(X_i^4) - [E(X_i^2)]^2 = 3 - 1 = 2$$

其中 $E(X_i^4) = 3$ 是标准正态的四阶矩 (直接用)。故 $\text{Var}(\xi) = 2n$ 。

定理 7.2 (可加性)

设 $\xi \sim \chi^2(m)$, $\eta \sim \chi^2(n)$, 且 $\xi \perp \eta$, 则

$$\xi + \eta \sim \chi^2(m+n).$$

 **笔记** [自由度的直觉] 有几个独立的标准正态变量参与平方求和, 自由度就是几。一旦存在约束 (例如 $\sum_{i=1}^n (X_i - \bar{X}) = 0$), 自由度减一——这就是样本方差给出 $\chi^2(n-1)$ 而非 $\chi^2(n)$ 的原因。

定义 7.3 (t 分布-标准正态/根号卡方分布/自由度)

设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 $X \perp Y$, 令

$$\xi = \frac{X}{\sqrt{Y/n}}$$

则称 ξ 的分布为自由度为 n 的 t 分布, 记作 $\xi \sim t(n)$ 。

东邪的 tip 7.6

所以看见 t 分布得想谁提供标准正态分布谁提供卡方分布

 **笔记** [为什么要构造 t 分布] 实际中想算标准化统计量 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$, 但 σ 未知, 用样本标准差 S 替换后分母变成随机变量, 不再服从正态分布。这个比值的精确分布就是 t 分布。

东邪的 tip 7.7

σ 已知时分母是常数, 整体服从正态分布, 用 Z 检验。 σ 未知时引入样本标准差 S , 随着 S 被引进, 卡方分布也被引进 (因为 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$), 正态除以根号卡方, 整体变成 t 分布。

 **笔记** [渐近性质]

$$t(n) \xrightarrow{n \rightarrow \infty} N(0, 1)$$

样本量充分大时, t 分布趋向标准正态。

定义 7.4 (F 分布)

设 $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$, 且 $X \perp Y$, 令

$$\xi = \frac{X/m}{Y/n}$$

则称 ξ 的分布为自由度为 (m, n) 的 F 分布, 记作 $\xi \sim F(m, n)$ 。

东邪的 tip 7.8

F 分布本质上描述的事两个卡方分布的关系, 只不过他们都要处以自己的自由度罢了。自由度分子在前分母在后。需要找到两个卡方才能用 F 分布

 **笔记** [倒数性质]

$$\xi \sim F(m, n) \implies \frac{1}{\xi} \sim F(n, m)$$

 **笔记** [分位数关系]

$$F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$$

表中只给出 F_{α} , 遇到 $F_{1-\alpha}$ 用此关系换算。

7.2.1 卡方 t 与伽马函数

 **笔记** 密度函数的统一结构: $f(x) = \text{归一化系数} \times \text{核}$ (决定形状的部分)。

$\chi^2(n)$:

$$f(x) = \underbrace{\frac{1}{2^{n/2}\Gamma(n/2)}}_{\text{归一化系数}} \times \underbrace{x^{\frac{n}{2}-1}e^{-x/2}}_{\text{核}}, \quad x > 0.$$

$t(n)$:

$$f(x) = \underbrace{\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})}}_{\text{归一化系数}} \times \underbrace{\left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}}_{\text{核}}.$$

 **笔记**

$$N(0, 1): \quad \varphi(x) = \underbrace{\frac{1}{\sqrt{2\pi}}}_{\text{归一化}} \cdot \underbrace{e^{-x^2/2}}_{\text{核}}, \quad x \in \mathbb{R}.$$

$$\chi^2(1): \quad f(x) = \underbrace{\frac{1}{\sqrt{2\pi}}}_{\text{归一化 (一模一样!)}} \cdot \underbrace{x^{-1/2}e^{-x/2}}_{\text{核}}, \quad x > 0.$$

$$\chi^2(n): \quad f(x) = \underbrace{\frac{1}{2^{n/2}\Gamma(\frac{n}{2})}}_{\text{归一化}} \cdot \underbrace{x^{\frac{n}{2}-1}e^{-x/2}}_{\text{核}}, \quad x > 0.$$

东邪的 tip 7.9

整个 Γ 函数最重要的就是 x 的头上是什么, 而不是 e 的头上是什么—— x 头上是几, 加 1 就是分母 Γ 了嘛的东西, 和 2 的次方。伽马展开其实就是一个积分的式子对吧, 只不过积分式子长得太长了不好写, 正好我们带入每一个伽马都能用另一个公式算出整个积分的值。其实和我们要弄成标准正态好查表一样弄成标准伽马我们也是好计算

东邪的 tip 7.10

换元 $x = 2u$ 的目标只有一个——让 e 头上变成单纯的 $-u$, 这样才能跟 $\Gamma(z) = \int_0^{\infty} u^{z-1}e^{-u} du$ 这个“标准模板”对上号。因为 x 变成 $2u$ 所以 u 头上自然继承了 x 头上的指数, 由于 dx 变成 $2du$ 所以他会比 x 头上指数多一次

东邪的 tip 7.11

$\Gamma(1/2)$ 与高斯积分本质上是同一个积分, 换元 $x = u^2$ 即可互相转化:

令 $x = u^2$ ($u > 0$), 则 $dx = 2u du$, $x^{-1/2} = u^{-1}$, 代入:

$$\Gamma\left(\frac{1}{2}\right) = \int_0^{\infty} x^{-1/2}e^{-x} dx = \int_0^{\infty} u^{-1}e^{-u^2} \cdot (2u du) = \int_0^{\infty} 2e^{-u^2} du.$$

再由 e^{-u^2} 为偶函数, $2 \int_0^\infty = \int_{-\infty}^\infty$, 得

$$\Gamma\left(\frac{1}{2}\right) = \int_{-\infty}^\infty e^{-u^2} du = \sqrt{\pi}.$$

这个换元 $x = u^2$ 正是 $Y = X^2$ (把 $N(0, 1)$ 变成 $\chi^2(1)$) 在积分层面的体现——所以 $\chi^2(1)$ 和 $N(0, 1)$ 的归一化系数都是 $1/\sqrt{2\pi}$, 本质上是同一个积分换了个变量名。

 **笔记** Γ 函数三条拆解规则:

- $\Gamma(z+1) = z\Gamma(z)$: 递推 (分部积分得到, 本质是阶乘”往下乘”)
- $\Gamma(n) = (n-1)!$: n 为正整数时, 纯阶乘, 不含 π
- $\Gamma(\frac{1}{2}) = \sqrt{\pi}$: 唯一的”魔法常数”, 来自高斯积分 $\int_{-\infty}^\infty e^{-x^2} dx = \sqrt{\pi}$

东邪的 tip 7.12

伽马函数本质是一个积分, 对积分里面的 x 求导指数下来变成前面的系数也就是 z , 指数减去 1 但是 $z-1$ 的为指数伽马就是 z

 **笔记** $\Gamma(z+1) = z\Gamma(z)$ 这条递推, 来自分部积分——本质是”幂函数求导会掉一个指数下来, 指数函数积分还是自己”:

$$\Gamma(z+1) = \int_0^\infty u^z e^{-u} du \stackrel{\text{分部积分}}{=} \left[-u^z e^{-u} \right]_0^\infty + z \int_0^\infty u^{z-1} e^{-u} du = z\Gamma(z).$$

对 u^z 求导得 zu^{z-1} , 对 e^{-u} 积分还是 $-e^{-u}$ (自我复制), 边界项为 0, 分部积分直接给出 $\Gamma(z+1) = z\Gamma(z)$ 。

这正是 Euler 当年的 motivation: $n! = n \cdot (n-1) \cdots 1$ 这种”阶乘递推”, 能不能找一个对所有实数 z 都成立的”连续版”? 答案就是这个积分—— $\Gamma(z)$ 是阶乘往非整数方向的”插值”。

 **笔记** (可选, 更大的图景)”升维 + 极坐标”能推广到 n 维—— $\chi^2(n)$ 本质上是” n 维标准正态向量的模长平方”, $\Gamma(n/2)$ 正是 n 维球体积/表面积公式里的那个 Γ 。所以 $\Gamma(n/2)$ 出现在 $\chi^2(n)$ 里不是巧合, 而是 n 维球几何的直接体现——这部分对考试不直接有用, 但解释了”为什么偏偏是 $\Gamma(n/2)$ ”这个终极问题。

7.3 正态三定理

 **笔记** [正态总体三大定理] 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ 。

定理一:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1), \quad \bar{X} \perp s^2$$

定理二 (σ^2 未知时估计 μ):

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n-1)$$

定理三 (两独立正态总体, $Y_1, \dots, Y_m \stackrel{\text{i.i.d.}}{\sim} N(\mu_2, \sigma_2^2)$):

$$F = \frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2} \sim F(n-1, m-1)$$

定义 7.5 (样本方差)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

分母用 $n-1$ 而非 n , 使得 $E(s^2) = \sigma^2$ (无偏)。



东邪的 tip 7.13

乘 $n-1$ 就变成了 μ 等于 0 的正态分布除以 σ 平方就是变成了标准正态分布,

 **笔记** [定理二的推导]

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}} = \frac{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)s^2/\sigma^2}{n-1}}} = \frac{N(0,1)}{\sqrt{\chi^2(n-1)/(n-1)}} \sim t(n-1)$$

分子是标准正态, 分母是 $\chi^2(n-1)$ 除以自由度再开根, σ^2 上下消掉, 对上 t 分布定义。

东邪的 tip 7.14

根号 n 是给分子做标准化的分母本来就是定理一段样子因为上下都有 σ 平方消掉由于算 t 分布卡方分布得除以自己的自由度再开方所以 $n-1$ 项也没有了

 **笔记** [为什么自由度是 $n-1$] 求和有 n 项, 但存在约束

$$\sum_{i=1}^n (X_i - \bar{X}) = 0$$

知道前 $n-1$ 项, 最后一项被锁死。真正能自由变化的只有 $n-1$ 个, 故自由度为 $n-1$ 。

n 个数, 1 个约束, 剩 $n-1$ 个自由度。

 **笔记** [总体方差与样本方差对比]

- 总体方差: $\sigma^2 = E[(X - \mu)^2]$, 用真实均值 μ , 是分布的参数, 未知。
- 样本方差: $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 用样本均值 $\bar{X}$, 是统计量, 可计算。一个那 E 来求加权平均一个直接用 $n-1$ 求平均

7.3.1 前置引理**引理 7.1 (正交变换引理)**

设 $X_1, \dots, X_n$ 相互独立, $X_i \sim N(\mu_i, \sigma^2)$ (方差相同), A 为 $n \times n$ 正交矩阵 ($A^T A = I$), 令 $Y = AX$, 则 $Y_1, \dots, Y_n$ 相互独立, 且

$$Y_i \sim N\left(\sum_k a_{ik} \mu_k, \sigma^2\right)$$

**东邪的 tip 7.15**

每个 X_i 都是一个数, 就是第 i 次观测的结果。向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$ 只是把 n 次观测的数堆成一列, 方便矩阵运算。

东邪的 tip 7.16

左乘一个矩阵的数学意义是换成左乘的坐标系, 而最后的结果会变成右边的维度, 所以左乘可以维度大于本身。[列看法 (Strang)] AX 是 A 各列的线性组合, X 的分量是权重:

$$AX = x_1 \text{col}_1(A) + x_2 \text{col}_2(A) + \dots + x_n \text{col}_n(A)$$

AX 的结果落在 A 的列空间里。

例题 7.3 列看法具体计算

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}, \quad X = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$$

因为运算的时候是行乘列，作揖 3 这个位置只有每行的第一个位置能和他乘每一行的第一个位置组合起来就是第一列，所以 3 就是第一列的权重同样 4 就是第二列。

$$AX = 3 \begin{pmatrix} 1 \\ 2 \end{pmatrix} + 4 \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 6 \end{pmatrix} + \begin{pmatrix} 8 \\ 4 \end{pmatrix} = \begin{pmatrix} 11 \\ 10 \end{pmatrix}$$

 **笔记** [正交变换的几何意义] 左乘正交矩阵就是在 n 维空间里做旋转（或翻转），把原来的坐标系转到新的坐标系。正交矩阵的旋转保长度——向量的模不变，所以散布程度（方差）也不变，这就是为什么 Y 的每个分量方差还是 σ^2 。

定理 7.3 (柯赫伦定理)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$ ，总平方和分解为

$$\sum_{i=1}^n X_i^2 = Q_1 + Q_2 + \dots + Q_k$$

其中 $Q_i = \mathbf{X}^\top A_i \mathbf{X}$ 为二次型， $\text{rank}(A_i) = n_i$ 。则 $Q_1, \dots, Q_k$ 相互独立且各自 $\sim \chi^2(n_i)$ 的充要条件为

$$n_1 + n_2 + \dots + n_k = n$$



 **笔记** [直觉] 总自由度 n 被完整拆分给每一块，没有浪费也没有重叠，每块才能独立地服从卡方分布。

7.4 柯西分布

定义 7.6 (标准柯西分布)

设 $X, Y \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$ ，令

$$\xi = \frac{X}{Y}$$

则称 ξ 的分布为标准柯西分布，记作 $\xi \sim C(0, 1)$ ，密度函数为

$$f(x) = \frac{1}{\pi(1+x^2)}.$$



 **笔记** [柯西与 t 分布的关系： $t(1) = C(0, 1)$] 回顾 t 分布定义 $\xi = \frac{X}{\sqrt{Y/n}}$ ， $X \sim N(0, 1)$ ， $Y \sim \chi^2(n)$ 。

取 $n = 1$ ： $Y \sim \chi^2(1)$ 即 $Y = Z^2$ ($Z \sim N(0, 1)$)，于是

$$\xi = \frac{X}{\sqrt{Z^2}} = \frac{X}{|Z|}.$$

由 X 关于 0 对称且与 Z 独立， $X/|Z|$ 与 X/Z 同分布，故

$$t(1) = C(0, 1).$$

东邪的 tip 7.17

柯西不是一个孤立的分布，它是 t 分布谱系的左端点 ($n = 1$)，正态是右端点 ($n \rightarrow \infty$ ，已在“渐近性质”里)。中间由自由度 n 连续过渡，“谁提供标准正态、谁提供卡方”的框架完全通用，只是 $n = 1$ 时退化成柯西。

 **笔记** [最大的区别：柯西没有矩]

- 正态: $f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$, 尾部指数衰减, 所有阶矩都存在。
- 柯西: $f(x) = \frac{1}{\pi(1+x^2)}$, 尾部只有 $1/x^2$ 衰减 (“厚尾”),

$$\int_{-\infty}^{\infty} |x| \cdot \frac{1}{\pi(1+x^2)} dx$$

在 $\pm\infty$ 处的发散速度与 $\int \frac{1}{x} dx$ 相同 $\implies E(X)$ 不存在, 方差自然也不存在。

东邪的 tip 7.18

特征函数上看更直接 (联系 44(6)): 正态特征函数 $e^{-t^2/2}$ 在 $t=0$ 处光滑可导; 柯西特征函数 $e^{-|t|}$ 在 $t=0$ 处有“尖点”不可导。特征函数在 0 点的导数对应矩, 不可导 $\iff$ 矩不存在——这就是柯西“差”在哪。

 **笔记** [大数定律失效: $\bar{X}$ 的行为对比]

	$\bar{X}$ 的分布	随 n 变化
正态 $N(\mu, \sigma^2)$	$N(\mu, \sigma^2/n)$	方差 $\rightarrow 0$, $\bar{X} \rightarrow \mu$ (LLN 成立)
柯西 $C(\mu, \gamma)$	$C(\mu, \gamma)$	形状不变, 不收缩, LLN 失效

LLN 需要“均值存在”作为前提, 柯西连均值都没有, 自然谈不上“收敛到均值”。

 **笔记** [尺度性质] 正态的缩放作用在方差上, 按 a^2 走:

$$aX \sim N(a\mu, a^2\sigma^2).$$

柯西的缩放作用在尺度参数上, 按 $|a|$ 走 (一次方):

$$aC(0, 1) = C(0, a).$$

柯西没有“方差”概念, γ 只是描述分布“胖瘦”的尺度参数。

东邪的 tip 7.19

做题识别口诀: 看见“两个独立标准正态相除”或者“ $t(1)$ ” $\rightarrow$ 想到柯西 $\rightarrow$ 矩不存在、LLN 失效、缩放是一次方不是平方。

定义 7.7 (一般柯西分布 $C(\mu, \gamma)$)

$$f(x) = \frac{\gamma}{\pi(\gamma^2 + (x - \mu)^2)}$$

其中 μ 为位置参数, $\gamma > 0$ 为尺度参数。取 $\mu = 0, \gamma = 1$ 即标准柯西 $f(x) = \frac{1}{\pi(1+x^2)}$ 。



东邪的 tip 7.20

$C(\mu, \gamma)$ 里:

- μ 是位置参数 (location), 决定分布“中心”在哪——密度峰值 (最高点) 就在 $x = \mu$ 处, 类比正态的均值 μ 。
- γ 是尺度参数 (scale), 决定分布“胖瘦/宽窄”, 类比正态的 σ (不是 σ^2)。

直观理解 γ : 密度在 $x = \mu$ 处最高, 下降到“峰值的一半”时, 对应的 x 离 μ 的距离就是 γ ——所以 γ 叫“半高宽” (half-width at half-maximum)。 γ 越大, 分布越扁越宽; γ 越小, 分布越尖越窄。

第8章 能力一

8.1 矩估计

 **笔记** 参数估计的根本困境： θ 活在“理论世界”里，数据 $X_1, \dots, X_n$ 活在“经验世界”里，两者之间没有直接的桥。

矩估计法找到的桥就是“矩”——它同时存在于两个世界：

- 理论世界： $E(X^k) = g_k(\theta)$ ，只要分布族确定了，它就是 θ 的一个函数（已知形式，含未知数 θ ）。
- 经验世界：样本矩 $\frac{1}{n} \sum_{i=1}^n X_i^k$ ，纯粹由数据算出来的数，不需要知道 θ 是什么。

大数定律（LLN）保证：当 $n \rightarrow \infty$ 时，

$$\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} E(X^k).$$

也就是“经验世界”算出来的这个数，会收敛到“理论世界”那个含 θ 的数——一个能算、一个含未知数，但本质上是同一个量的两种表达。

矩估计法就是强行让两者相等：

$$g_k(\theta) = \frac{1}{n} \sum_{i=1}^n X_i^k,$$

再把这个方程反解出 θ 。这一步“反解”，就是从经验世界跨回理论世界、解出 θ 的那座桥。

东邪的 tip 8.1

一堆数字，我知道它们服从一个特定的分布，比如泊松分布 $P(\lambda)$ ，但直接看不出来 λ 是多少。所以我们需要找一个含有 λ 的公式，同时这个公式也能用真实数据算出来——含有 λ 的公式，我们选取的是 λ 的（总体）矩 $E(X) = \lambda$ ；能用真实数据算的公式，则是样本矩 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

 **笔记** $\hat{\theta}$ 中的 hat 表示对 θ 的点估计，不特指某种方法，任何估计方法给出的点估计都可以戴 hat。

方法	写法	本质
MLE	$\hat{\theta}_{\text{MLE}}$	最大化似然
矩估计	$\hat{\theta}_M$	样本矩 = 总体矩
贝叶斯估计	$\hat{\theta}_B$	后验期望 $E(\theta \mathbf{X})$

hat 表示身份（点估计），不表示计算方式。

8.2 MLE

定义 8.1 (最大似然估计)

设 $X_1, \dots, X_n$ 是来自总体 $f(x; \theta)$ ($\theta \in \Theta$) 的简单随机样本， $x_1, \dots, x_n$ 为观测值。称

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

为似然函数。若存在 $\hat{\theta} \in \Theta$ 使得

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(\theta),$$

则称 $\hat{\theta}$ 为 θ 的最大似然估计 (MLE)。

东邪的 tip 8.2

$f(x; \theta)$ 这同一个公式：固定 θ 看 x 怎么变 $\rightarrow$ 叫“概率”；固定 x (已观测数据) 看 θ 怎么变 $\rightarrow$ 叫“似然”——同一个表达式，换了阅读方向。

$\hat{\theta}$ 不是似然函数 $L(\theta)$ 的最大值本身，而是取得最大值时对应的 θ

“最优”= 让当前这组数据最可能发生的 θ ，是基于这组样本的估计值，不是真实 θ ；换一组样本， $\hat{\theta}$ 会变，所以它本身是随机变量。

8.2.1 如何算 mle

定义 8.2 (支撑集)

对于随机变量 X 的密度函数 (或概率质量函数) $f(x; \theta)$ ，称集合

$$\text{supp}(f) = \{x \in \mathbb{R} : f(x; \theta) > 0\}$$

为其支撑集——即该分布真正可能取到的 x 值的全体；在支撑集之外， $f(x; \theta) = 0$ 。

- $N(\mu, \sigma^2)$: 支撑集 = $\mathbb{R}$ ——不依赖参数
- $U(0, \theta)$: 支撑集 = $[0, \theta]$ ——依赖 θ

 **笔记** [MLE 的两种算法：看 θ 是否出现在支撑集里]

- θ 不出现在支撑集里 (支撑集不依赖 θ ，如 $N(\mu, \sigma^2)$ 、 $\text{Exp}(\lambda)$ 、泊松等)：
 $f(x; \theta)$ 关于 θ 处处光滑，直接用求导法：

$$\ell(\theta) = \sum_{i=1}^n \ln f(x_i; \theta), \quad \ell'(\theta) = 0 \implies \hat{\theta}.$$

解似然方程即可 (必要时验证 $\ell''(\hat{\theta}) < 0$)。

- θ 出现在支撑集里 (支撑集依赖 θ ，如 $U(0, \theta)$ 、两参数指数 $x \geq \mu$)：

$L(\theta)$ 含指示函数 $\mathbb{I}[\dots]$ ，求导法通常无解。改用边界分析：

1. 可行域：把支撑集条件翻译成“ θ 必须满足的范围” (由观测数据反过来限制 θ)
2. 单调性：在可行域内看 $L(\theta)$ 关于 θ 是增还是减
3. 边界： $\hat{\theta}$ 取可行域中朝增长方向的那一端 (通常是某个顺序统计量 $X_{(1)}$ 或 $X_{(n)}$)

 **笔记** [MLE 的不变性] 若 $\hat{\theta}$ 是 θ 的 MLE，则对任意函数 g ， $g(\hat{\theta})$ 就是 $g(\theta)$ 的 MLE：

$$\widehat{g(\theta)}_{\text{MLE}} = g(\hat{\theta}_{\text{MLE}}).$$

直觉：似然函数 $L(\theta)$ 的峰在 $\theta = \hat{\theta}$ 处；把横轴从 θ 换成 $\eta = g(\theta)$ ，只是给同一个峰换了坐标标签，峰的位置不变——只是从 $\hat{\theta}$ 变成 $g(\hat{\theta})$ 。

例： $X \sim \text{Exp}(\lambda)$ 的 MLE 为 $\hat{\lambda} = 1/\bar{X}$ ，则总体均值 $1/\lambda$ 的 MLE 直接是 $1/\hat{\lambda} = \bar{X}$ ，不需要重新求解。

8.3 贝叶斯

8.3.1 后验

 **笔记** 贝叶斯的世界里， θ 不是固定的未知数，而是一个随机变量，有自己的分布。

 **笔记** [MLE 与 Bayes 的关系] 两者目标相同——都给出 θ 的估计值，区别在于“用什么信息、怎么组合”：

- MLE：只用数据，找“最能解释数据”的 θ

名称	符号	含义
先验分布	$\pi(\theta)$	观测数据之前, 你对 θ 的信念
似然函数	$f(X \theta)$	给定 θ , 数据出现的概率
后验分布	$p(\theta X)$	看到数据之后, 更新后的信念

- Bayes: 先验(预想) + 数据 $\rightarrow$ 融合成新估计

Bayes 不是“判断预想对不对”(假设检验式的二元框架), 而是把先验和数据按可信度加权融合出一个新数值: 硬币例子中先验 $p \approx 0.5$, 数据显示 ≈ 0.8 , 融合后 $\hat{p} \approx 0.7$ ——数据越多越靠近数据, 先验越强越靠近先验。

例题 8.1 抛硬币 $n = 10$ 次, 观测正面 $k = 7$ 次, 估计正面概率 θ 。设先验 $\pi(\theta) \sim \text{Beta}(2, 2)$, 即 $\pi(\theta) \propto \theta(1 - \theta)$ 。

似然函数为

$$f(X | \theta) = \binom{10}{7} \theta^7 (1 - \theta)^3 \propto \theta^7 (1 - \theta)^3.$$

后验分布为

$$p(\theta | X) \propto \theta^7 (1 - \theta)^3 \cdot \theta(1 - \theta) = \theta^8 (1 - \theta)^4,$$

认出这是 $\text{Beta}(9, 5)$, 故 Bayes 估计(后验均值)为

$$\hat{\theta} = E[\theta | X] = \frac{9}{9 + 5} = \frac{9}{14} \approx 0.643.$$

相比频率估计 $7/10 = 0.7$, 先验将结果向 0.5 拉近了一点。

 **笔记** 在贝叶斯推导中, 后验分布的完整表达式为

$$p(\mu | \mathbf{X}) = \frac{f(\mathbf{X} | \mu) \cdot \pi(\mu)}{f(\mathbf{X})}$$

其中分母 $f(\mathbf{X}) = \int f(\mathbf{X} | \mu) \pi(\mu) d\mu$ 对 μ 而言是常数, 故只需保留含 μ 的部分:

$$p(\mu | \mathbf{X}) \propto f(\mathbf{X} | \mu) \cdot \pi(\mu)$$

这一步的合理性在于: 概率密度满足归一化条件 $\int p(\mu | \mathbf{X}) d\mu = 1$, 因此一旦认出核函数的形状, 归一化常数即被唯一确定, 无需显式计算。

例如, 配方后若发现

$$p(\mu | \mathbf{X}) \propto \exp\left(-\frac{(\mu - \mu_1)^2}{2\tau_1^2}\right)$$

则立即断定后验为 $N(\mu_1, \tau_1^2)$, 归一化常数 $\frac{1}{\sqrt{2\pi}\tau_1}$ 自动补齐。

本质: $\propto$ 不是“不关心常数”, 而是“先认出分布族, 再补常数”。此技巧在共轭先验推导中极为常用。

8.3.2 beta 函数

定义 8.3 (Beta 函数)

Beta 函数 (大写 B) 定义为

$$B(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt, \quad \alpha, \beta > 0.$$

它本身是一个数, 用来对 Beta 分布做归一化。例如 $B(2, 2) = \int_0^1 t(1-t) dt = \frac{1}{6}$ 。

与 Gamma 函数的关系:

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$



 **笔记** Beta 函数更深的意义

1. 它是 $[0, 1]$ 上的 Gamma

Gamma 函数管的是 $(0, \infty)$ 上的幂次积分：

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx$$

Beta 函数管的是 $(0, 1)$ 上的幂次积分：

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$$

x 和 $1-x$ 加起来等于 1——这正是它天然描述“比例、概率”的原因。

2. 它是组合数的连续推广

注意二项式系数：

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} = \frac{1}{(n+1) B(k+1, n-k+1)}$$

Beta 函数就是把离散的组合数连续化了。抛硬币用 Beta 先验，本质上是在做连续版本的计数。

东邪的 tip 8.3

$B(\alpha, \beta)$ 两个参数的含义：类比抛硬币， α 和 β 可理解为虚拟的历史数据。

- Beta(2, 2)：相当于“我之前好像见过 1 次正面、1 次反面”，感觉差不多均匀。
- Beta(1, 1)：0 次正面、0 次反面——什么都不知道，即均匀分布 $U(0, 1)$ 。

每次观测到新数据， α 或 β 加一，后验就是把虚拟历史与真实数据合并计数，这就是共轭更新的本质。

 **笔记** 共轭更新：先验与后验属于同一族分布，后验参数 = 先验参数 + 数据计数，无需计算积分。

以 Beta-Binomial 为例，观测到 k 次正面、 $n-k$ 次反面：

$$\underbrace{\text{Beta}(\alpha, \beta)}_{\text{先验}} \xrightarrow{\text{观测 } n \text{ 次}} \underbrace{\text{Beta}(\alpha + k, \beta + n - k)}_{\text{后验}}$$

原因：似然与先验相乘后指数直接合并，

$$\theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \theta^k (1-\theta)^{n-k} = \theta^{(\alpha+k)-1} (1-\theta)^{(\beta+n-k)-1},$$

形状仍是 Beta，故参数直接相加即得后验。

东邪的 tip 8.4

也就是根据实际情况给第一个位置和第二个位置加数字就行了

 **笔记** 共轭先验配对表

似然（数据分布）	先验	后验	Bayes 估计（后验均值）
二项 $B(n, \theta)$	$\text{Beta}(\alpha, \beta)$	$\text{Beta}(\alpha + k, \beta + n - k)$	$\frac{\alpha + k}{\alpha + \beta + n}$
泊松 $P(\lambda)$	$\Gamma(\alpha, \beta)$	$\Gamma(\alpha + n\bar{x}, \beta + n)$	$\frac{\alpha + n\bar{x}}{\beta + n}$
指数 $\text{Exp}(\lambda)$	$\Gamma(\alpha, \beta)$	$\Gamma(\alpha + n, \beta + n\bar{x})$	$\frac{\alpha + n}{\beta + n\bar{x}}$
正态 $N(\theta, \sigma^2)$ (σ^2 已知)	$N(\mu_0, \tau_0^2)$	$N(\mu_1, \tau_1^2)$	μ_1 （需配方求）
均匀 $U(0, \theta)$	$\text{Pareto}(\alpha, \beta)$	$\text{Pareto}(\alpha + n, \max(\beta, x_{(n)}))$	$\frac{\alpha + n}{\alpha + n - 1} \max(\beta, x_{(n)})$

记忆规律：

- 二项、泊松、指数：后验参数 = 先验参数 + 数据的某种计数，直接相加。
- 正态：两个精度加权平均，需单独配方处理。

- 均匀-帕累托：一个参数加 n ，另一个取 $\max$ 。

 **笔记** Gamma 分布 $\Gamma(\alpha, \beta)$ 的密度为 $\pi(\lambda) \propto \lambda^{\alpha-1} e^{-\beta\lambda}$ ，两个参数可类比泊松场景理解： α 为历史观测到的事件总次数， β 为历史观测总时长，均值为 α/β 。

与 $\text{Beta}(\alpha, \beta)$ 对比：

	$\text{Beta}(\alpha, \beta)$	$\Gamma(\alpha, \beta)$
α	正面次数 +1	历史事件总数
β	反面次数 +1	历史观测总时长
均值	$\frac{\alpha}{\alpha + \beta}$	$\frac{\alpha}{\beta}$
支撑	$(0, 1)$	$(0, \infty)$

Beta 分母是 $\alpha + \beta$ （比例归一到 1）；Gamma 分母只有 β （发生率可任意大）。

解 第一步：认出共轭族。数据 $B(1, \theta)$ + 先验 $\text{Beta}(a, b)$ 构成 Binomial/Beta 共轭，后验必为 Beta 分布。

第二步：推导后验参数，得贝叶斯估计量。

$$p(\theta|\mathbf{X}) \propto \theta^{S+a-1}(1-\theta)^{n-S+b-1} \implies \theta|\mathbf{X} \sim \text{Beta}(S+a, n-S+b)$$

取后验期望（Beta 期望公式 $E[\text{Beta}(\alpha, \beta)] = \frac{\alpha}{\alpha+\beta}$ ）：

$$\hat{\theta}_B = \frac{S+a}{n+a+b}, \quad S = \sum_{i=1}^n X_i$$

第三步：将 $\hat{\theta}_B$ 视为普通估计量计算 **MSE**。由 $S \sim B(n, \theta)$ 知 $ES = n\theta$ ， $\text{Var}(S) = n\theta(1-\theta)$ ，后续偏差、方差、MSE 均对 S 求期望。

8.3.3 帕累托

 **笔记** 帕累托分布 $\text{Pareto}(a, b)$ 的标准密度为

$$\pi(\theta) = \frac{ba^b}{\theta^{b+1}}, \quad \theta > a.$$

参数	位置	含义
a	第一个	支撑下界， θ 最小能取什么值
b	第二个	形状参数，控制尾部厚薄

所以后验 $\text{Pareto}(\max(x_{(n)}, a), n+b)$ 中：

- 第一个位置 $\max(x_{(n)}, a)$ ：后验中 θ 的下界；
- 第二个位置 $n+b$ ：更新后的形状参数。

第9章 能力二

9.1 无偏估计

很好的问题，这是入门时最容易懵的地方。

估计量的定义就是：样本的任意函数。

你有数据 $X_1, X_2, \dots, X_n$ ，你想猜 μ 。只要是用这些数据算出来的一个数，就叫估计量，没有任何其他限制。比如 $n = 3$ ，数据是 2, 4, 6：

估计量	公式	算出来
$\bar{X}$	$(2 + 4 + 6)/3$	4
X_1	只取第一个	2
$(X_1 + X_3)/2$	$(2 + 6)/2$	4
常数 5	不管数据，直接报 5	5
$\max(X_i)$	取最大值	6

这五个都是“合法”的估计量——你都可以拿来交给别人说“我估计 $\mu =$ 这个数”。

问题就在这里：到底用哪个？

直觉上 $\bar{X}$ 最好，但“直觉”不是数学。能力二要做的事就是：给出有数学保证的标准，说清楚为什么 $\bar{X}$ 比 X_1 好，好在哪里，好多少。

一句话总结：**估计量 = 数据的函数，函数有无穷多个，所以估计量不唯一。**能力二就是在这无穷多个里面找“最好的”。

 **笔记** 总结一句话：你只做一次实验，估计量是你选的公式，估计值是代入数据后算出的那个数。“多次实验”是数学上验证公式好不好用的思想实验，不是真的要去做很多次。

 **笔记** 第一个：不知道 μ 怎么对准？

“对准”不是你去瞄准一个已知的靶，而是通过代数推导证明一个必然成立的性质。

$X_1, X_2, \dots, X_n$ 来自 $N(\mu, \sigma^2)$ ，所以 $E[X_i] = \mu$ ，于是：

$$E[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \cdot n\mu = \mu$$

这里 μ 始终是个符号，从没有变成具体数字。这个推导对 $\mu = 3$ 成立，对 $\mu = 100$ 也成立，对任何 μ 都成立。

就好像你证明了“一把没有系统误差的尺子，量出来的平均值等于真实长度”——不需要知道真实长度是多少，这是尺子本身的结构性质。

x_1, x_2 都是一次实验里面的个体

东邪的 tip 9.1

也就是说因为他服从这个分布所以不管选第一次实验 x_1 ，第二次实验 x_2 都要把他的均值当作真实正态分布的均值对吧。而不是选取一次实验的最大值，最小值直接当他服从的正态分布的均值。而是选取他的平均值充当

 **笔记** [UMVUE 解决的是选公式的问题] 你确实只做一次实验，得到一个数。但在做实验之前，你要选公式。

方差小的公式，代入数据后得到的数大概率更靠近真值；方差大的公式，这一次的结果可能差很远。

类比：你只射一箭，但要事先选弓。弓 A 精度高，弓 B 精度差。虽然只射一次，但选哪把弓决定了这一箭大概率落在哪里。UMVUE 就是在所有无偏的弓里，选精度最高的那把。

所以 UMVUE 是选公式阶段的理论，不是做完实验之后的事情。

例题 9.1 UMVUE 的具体比较 设 $X_1, X_2, X_3, X_4 \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1)$ ，估计 μ 。三个候选公式均无偏（期望均等于 μ ）：

$$\hat{\mu}_A = \bar{X} = \frac{X_1 + X_2 + X_3 + X_4}{4}, \quad \text{Var}(\hat{\mu}_A) = \frac{1}{4}$$

$$\hat{\mu}_B = \frac{X_1 + X_2}{2}, \quad \text{Var}(\hat{\mu}_B) = \frac{1}{2}$$

$$\hat{\mu}_C = X_1, \quad \text{Var}(\hat{\mu}_C) = 1$$

方差衡量的是：这个公式在不同数据下的结果散布多广。 $\bar{X}$ 的结果永远集中在 μ 附近， X_1 的结果可能飘得很远。

在所有对 μ 的无偏估计量中， $\bar{X}$ 方差最小，故 $\bar{X}$ 是 μ 的 UMVUE。

 **笔记** 这是统计里一个让人头疼的惯例，其实它们是两个不同的东西：

- 实验前： X_1 是随机变量（大写）

还不知道会观测到什么值，可能是 160，可能是 180，服从 $N(\mu, \sigma^2)$ 。这时候可以谈期望： $E[X_1] = \mu$ 。

- 实验后： x_1 是观测值（小写）

已经量完了，是一个固定的数，比如 172。这时候不谈期望，直接代入算： $\bar{x} = (172 + 168 + \dots)/n$ 。

因为教材里经常两个都写大写 X_1 ，没有严格区分。区分的方法就是看语境：出现 $E[\cdot]$ 就当随机变量（实验前）；出现具体数字代入就当观测值（实验后）。

东邪的 tip 9.2

找无偏估计量永远发生在实验前，与具体采样永远无关。需要把所有可能出现的样本进行 $h(X)$ 的映射，再与其出现的概率做乘积，求和得到期望：

$$E[h(X)] = \sum_k h(k) \cdot P(X = k) = g(\theta)$$

这个期望等于我们想估计的目标 $g(\theta)$ ，即为无偏。

 **笔记** 大写 X_1 是“还没揭晓的牌”，小写 x_1 是“已经翻开的牌”。期望只对没揭晓的牌讲。

东邪的 tip 9.3

所以无偏估计量是找一个公式，用这个公式代入所有可能的样本后，按照这些样本的分布分配给它们概率，然后这个期望等于我们想估计的东西。

东邪的 tip 9.4

证明没有无偏函数可以从解析性和多项式来看

9.2 umvue+CR

9.2.1 fisher 信息

 **笔记 Fisher** 想解决的问题：这组数据对 θ 有多“敏感”？

如果 θ 稍微变一点，数据出现的概率就大幅变化——说明数据能精确分辨 θ 的位置，信息量大。如果怎么改 θ 似然函数都几乎不动，说明数据对 θ 几乎无感，信息量小。

 **笔记** 得分函数 $S = \frac{\partial}{\partial \theta} \ln f(X; \theta)$ 正好衡量这件事：它就是对数似然关于 θ 的导数，即似然函数对 θ 变化的敏感程度。

- S 大 $\rightarrow$ 似然对 θ 变化剧烈 $\rightarrow$ 数据信息多
- S 小 $\rightarrow$ 似然对 θ 几乎无感 $\rightarrow$ 数据信息少

 **笔记** $f(X; \theta)$ 是什么：是单个 X 的概率密度函数

就是概率密度函数，但把视角反过来——数据 X 已经观测到了， θ 是未知的。

$$f(X; \theta) = \text{“如果参数是 } \theta, \text{ 观测到这个 } X \text{ 的概率有多大？”}$$

这就是似然函数， θ 变，这个概率跟着变。

- 单个 X ：得分函数为 $S = \frac{\partial}{\partial \theta} \ln f(X; \theta)$ ，只用 $f(X; \theta)$ ，与 $L(\theta)$ 无关。
- 多个 $X_1, \dots, X_n$ ：似然函数 $L(\theta) = \prod_{i=1}^n f(X_i; \theta)$ ，得分函数为

$$S_n = \frac{\partial}{\partial \theta} \ln L(\theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \ln f(X_i; \theta) = \sum_{i=1}^n S(X_i; \theta)$$

此时得分函数与 $L(\theta)$ 产生联系。

东邪的 tip 9.5

$\ln$ 是为了累乘变累加好算，对 θ 求导数因为本来就是腰算他的变化率

 **笔记** 似然函数英文叫 Likelihood function。Likelihood 是“可能性/合理程度”的意思，不是严格的概率，而是“这个 θ 值有多合理？”中文“似然”就是翻译自 likelihood——似乎如此，好像这个参数值是对的。

- $f(x | \theta)$ ：竖线后面是条件，贝叶斯里 θ 被当作随机变量，“在 θ 已知的条件下”
- $f(x; \theta)$ ：分号前面是观测值（已知），分号后面是参数（待估），频率派里 θ 不是随机变量，只是未知常数

 **笔记** 得分函数 $S(X; \theta)$ 本身是随机的，因为 X 是随机的。

对于固定的 θ ，不同的 X 值会给出不同的 S ：

$$S(X; \theta) = \frac{\partial}{\partial \theta} \ln f(X; \theta)$$

X 变， S 就变。所以 S 不是一个数，是一个随机变量。

我们已经知道 $E[S] = 0$ ，均值没有信息。因为 $f(x; \theta)$ 是关于 x 的概率密度，积分恒为 1，两边对 θ 求导所以等于 0。

那用什么来总结“ S 平均能偏离 0 多远”？自然就是方差：

- $\text{Var}(S)$ 大 $\rightarrow S$ 经常取大值 $\rightarrow$ 似然对 θ 平均很敏感 $\rightarrow$ 信息多
- $\text{Var}(S)$ 小 $\rightarrow S$ 总在 0 附近 $\rightarrow$ 似然对 θ 几乎无感 $\rightarrow$ 信息少

 **笔记** $E[S] = 0$ 的推导依赖一步交换：

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx$$

左边对 $\int f dx = 1$ 求导得 0，右边整理后就是 $E[S]$ ，所以 $E[S] = 0$ 。

但这个交换要求积分上下限不含 θ 。 $U(0, \theta)$ 的积分上限就是 θ ，交换不合法：

$$\begin{aligned} \frac{\partial}{\partial \theta} \int_0^\theta \frac{1}{\theta} dx &= \frac{\partial}{\partial \theta} 1 = 0 \\ \int_0^\theta \frac{\partial}{\partial \theta} \frac{1}{\theta} dx &= \int_0^\theta -\frac{1}{\theta^2} dx = -\frac{1}{\theta} \end{aligned}$$

两边不相等，所以 $E[S] = -\frac{1}{\theta} \neq 0$ ，C-R 下界对 $U(0, \theta)$ 直接失效。

东邪的 tip 9.6 (得分函数和 fisher 函数的关系)

得分取对数是为了让 $L(\theta)$ 连乘变连加，而且对 $\ln$ 求导自然出现 $\frac{1}{f}$ ，直接完成归一化。

$\frac{\partial}{\partial \theta} \ln f$ 叫做得分函数 (score function)，它衡量的是：当 θ 变化时，观测到当前数据 X 的“惊讶程度”变

化有多快。

$I(\theta)$ fisher 函数就是这个得分函数的方差也是二阶矩（因为可以证明得分函数期望为 0，所以它的二阶矩就等于方差）。

9.2.2 CR

 **笔记** C-R 下界在说什么：

对任意无偏估计量 $\hat{\theta}$ ，方差不可能低于某个值：

$$\text{Var}(\hat{\theta}) \geq \frac{1}{nI(\theta)}$$

就是给方差划了一条不可逾越的底线。

 **笔记** 为什么被发明：

能力二的核心问题是“哪个估计量更好”，判断标准是方差小。但比较 A 和 B，你只知道 A 比 B 好，不知道 A 是不是最好的。

C-R 下界解决了这个问题——给你一个绝对基准：

- $\text{Var}(\hat{\theta}) = \frac{1}{nI(\theta)} \rightarrow$ 最优，没有比它更好的无偏估计量
- $\text{Var}(\hat{\theta}) > \frac{1}{nI(\theta)} \rightarrow$ 还可能有改进空间

证明 第一步：无偏条件 $E[\hat{\theta}] = \theta$ ，两边对 θ 求导：

$$\int \hat{\theta} \cdot \frac{\partial f}{\partial \theta} dx = 1$$

代入 $\frac{\partial f}{\partial \theta} = f \cdot S$ ，得：

$$E[\hat{\theta} \cdot S] = 1$$

第二步：因为 $E[S] = 0$ ，所以：

$$\text{Cov}(\hat{\theta}, S) = E[\hat{\theta} \cdot S] - E[\hat{\theta}] \cdot E[S] = 1$$

第三步：柯西-施瓦茨不等式：

$$\text{Cov}(\hat{\theta}, S)^2 \leq \text{Var}(\hat{\theta}) \cdot \text{Var}(S) \implies 1 \leq \text{Var}(\hat{\theta}) \cdot I(\theta) \implies \text{Var}(\hat{\theta}) \geq \frac{1}{I(\theta)}$$

n 个样本再除以 n 得 $\frac{1}{nI(\theta)}$ 。

东邪的 tip 9.7

柯西-施瓦茨不等式才能把无偏估计的方差连接到不等式中。我们已经知道无偏估计的期望是 θ ，为了出现 $\frac{\partial f}{\partial \theta}$ 从而引入 S ，所以对两边求导，再利用 $E[S] = 0$ 的信息和 $\text{Var}(S) = I(\theta)$ 完成这个证明。

 **笔记** [正则条件] 正则条件就是允许积分和求导交换顺序的条件：

$$\frac{d}{d\theta} \int \hat{g} \cdot L(\theta; \mathbf{x}) d\mathbf{x} = \int \hat{g} \cdot \frac{\partial L(\theta; \mathbf{x})}{\partial \theta} d\mathbf{x}$$

具体需要满足：

1. 支撑集不依赖 θ ——积分范围不能随 θ 变
2. $f(x; \theta)$ 对 θ 可微
3. 求导后的被积函数有可积上界（控制收敛定理条件）

9.3 umvue

 **笔记** 全称：Uniformly Minimum Variance Unbiased Estimator，一致最小方差无偏估计量。

为什么发明它，从需求倒推：

你想估计 θ ，无偏是基本要求（平均不偏）。但满足无偏的估计量有无数个—— X_1 是无偏的， $\bar{X}$ 也是，随便凑个线性组合还是。怎么选最好的那个？

自然的标准：方差最小——离真值的随机误差最小。

但“最小”要小心：不能只对某个特定 θ 值最小，要对所有 $\theta \in \Theta$ 同时最小，这就是“Uniformly”（一致）的含义。

所以 UMVUE 回答的问题是：

在全部无偏估计量里，有没有一个，不管真实参数取什么值，它的方差都比其他所有无偏估计量小？

有的话，它就是 UMVUE，是无偏类里的理论最优。

东邪的 tip 9.8

uniformity 一致的，一致收敛是 uniform，m 就是最小 v 就是方差 ue 就是无偏估计

9.3.1 完备充分统计量

 **笔记** [充分统计量不能丢信息] 用正态 $N(\mu, 1)$ ， $n = 2$ 来说，取不充分的统计量 $T = X_1$ 。

你观测到 $X_1 = 3, X_2 = 5$ 。

用 $T = X_1 = 3$ 去估计 μ ：你只看第一个观测值，猜 $\mu \approx 3$ 。但 $X_2 = 5$ 还摆在那里，它也服从 $N(\mu, 1)$ ，里面明显还有 μ 的信息——看了 $X_2 = 5$ 之后你会更新判断，觉得 μ 应该在 4 附近。 $T = X_1$ 把 X_2 里的 μ 信息扔掉了，这就是“丢了 θ 信息”。

用 $T = \bar{X} = 4$ 就不丢：知道了 $\bar{X} = 4$ ，再去看 $X_1 = 3, X_2 = 5$ 的具体分法—— X_1 比均值低 1， X_2 比均值高 1——这件事和 μ 是多少完全没关系，只是随机波动。没有任何新的 μ 信息可以被挖出来了。

也就是说，知道了 $\bar{X} = 4$ ，不用再知道到底是 $(3, 5)$ 还是 $(4, 4)$ ，因为对“ μ 大概是多少”这个问题，两种情况提供的信息量完全一样。

一句话： T 是不是充分的，就看“知道 T 之后，样本剩下的部分还能不能更新你对 θ 的判断”。能更新就说明丢了信息，不充分；不能更新就是充分的。

笔记 完备空间类比

完备空间的核心是：极限不会“跑出去”——每个 Cauchy 列的极限都在空间里，没有“洞”。

$\mathbb{Q}$ 不完备：1, 1.4, 1.41, 1.414, ... 是 Cauchy 列，极限 $\sqrt{2}$ 跑到 $\mathbb{Q}$ 外面去了。

$\mathbb{R}$ 完备：任何 Cauchy 列的极限都还在 $\mathbb{R}$ 里，无处可逃。

完备充分统计量的逻辑完全一样：

不完备的 T ：存在非零函数 $g(T)$ ，它的期望“跑到零去了” ($E[g(T)] = 0 \forall \theta$)，但 g 本身不是零。就像 $\sqrt{2}$ 逃出了 $\mathbb{Q}$ ——非零的东西期望上“假装是零”。

完备的 T ：期望等于零这件事无处可逃，只要 $E[g(T)] = 0$ ， g 就必须是零本身，没有任何非零函数能“藏”在零期望后面。

为什么这样定义

设计这个定义的动机就是逼出唯一性。假设 $g_1(T)$ 和 $g_2(T)$ 都是 θ 的无偏估计，那么：

$$E_\theta[g_1(T) - g_2(T)] = 0 \quad \forall \theta$$

完备性直接给出 $g_1(T) = g_2(T)$ ——基于 T 的无偏估计唯一，唯一的那个自然是 UMVUE。定义就是为了这一步设计的。

东邪的 tip 9.9

所以完备统计量就抱着基于 T 的无偏估计只有一个，因为只有一个所以一定是 umvue 对吗

9.3.2 因子分解定理

定理 9.1 (Fisher-Neyman 因子分解定理)

$T(\mathbf{X})$ 是 θ 的充分统计量 $\iff$ 联合密度可分解为

$$f(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$$

其中 g 通过 T 依赖数据， h 完全不含 θ 。

笔记 [因子分解定理的直觉] 联合密度 $f(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i; \theta)$ 包含了样本关于 θ 的全部信息。

因子分解定理说的是：若联合密度能写成

$$f(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$$

则 $T(\mathbf{X})$ 是 θ 的充分统计量。

其中：

- $g(T(\mathbf{x}), \theta)$ ：既含 θ 又含数据，但数据只通过 $T(\mathbf{x})$ 与 θ 互动。 $T(\mathbf{x})$ 就是这个互动中数据那一侧的函数，即充分统计量。
- $h(\mathbf{x})$ ：只含数据，不含 θ ，与 θ 零互动——不管 θ 取何值， $h(\mathbf{x})$ 不变，对推断 θ 毫无贡献。

东邪的 tip 9.10

两句话总结：

- 联合密度保证了关于 θ 的信息完整。
- 因子分解保证了 $T(\mathbf{X})$ 是与 θ 互动的全部， $h(\mathbf{x})$ 里没有任何关于 θ 的额外信息。

例题 9.2 正态总体因子分解， σ^2 已知 $X_i \sim N(\mu, \sigma^2)$ ，联合密度展开后分离：

$$\prod_{i=1}^n f(x_i; \mu) = \underbrace{\exp\left\{\frac{\mu \sum x_i}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}\right\}}_{g(T, \mu), \quad T = \sum x_i} \cdot \underbrace{\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\frac{\sum x_i^2}{2\sigma^2}\right\}}_{h(\mathbf{x}), \text{ 不含 } \mu}$$

故 $T = \sum X_i$ (即 $\bar{X}$) 是 μ 的充分统计量。

 **笔记** [Rao-Blackwell: 把任意无偏估计升级为基于充分统计量的无偏估计] 有了充分统计量 T ，任何无偏估计 $\delta(\mathbf{X})$ 都可以改进：令

$$\varphi(T) = E[\delta(\mathbf{X}) | T]$$

则 $\varphi(T)$ 仍无偏，且方差不超过原来： $\text{Var}(\varphi(T)) \leq \text{Var}(\delta(\mathbf{X}))$ 。

为什么要这么做： $\delta(\mathbf{X})$ 可能只用了部分样本信息（如只看 X_1 ），条件期望把其余样本的信息也并入进来，使 $\varphi(T)$ 等价于充分统计量，关于 θ 的信息更完整，方差因此下降。

东邪的 tip 9.11

T 包含关于 θ 的全部信息，而 $\delta(\mathbf{X})$ (如 X_1) 可能只含部分信息。计算条件期望 $E[\delta | T]$ 时，被迫引入其他样本的所有可能情况及其概率，结果 $\varphi(T)$ 比原估计量含有更多关于 θ 的信息，方差因此下降。

一句话：Rao-Blackwell 不是“获得更多信息”，而是让估计量从“部分信息”升级到“充分统计量所含的全部信息”。

 **笔记** [Lehmann-Scheffé 定理 (勒曼-谢菲定理)] 若 T 是完备充分统计量， $\varphi(T)$ 是 $g(\theta)$ 的无偏估计，则 $\varphi(T)$ 是 $g(\theta)$ 的 UMVUE，且唯一。

为什么完备性保证了唯一最优：

假设有两个基于 T 的无偏估计 $\varphi_1(T)$ 和 $\varphi_2(T)$ ，则

$$E[\varphi_1(T) - \varphi_2(T)] = 0 \quad \forall \theta$$

完备性说：期望恒为零 $\Rightarrow$ 函数本身就是零，即 $\varphi_1(T) = \varphi_2(T)$ a.s.

基于完备充分统计量的无偏估计只有一个，唯一的那个自然是所有无偏估计里方差最小的。

9.3.3 指数族的优越性

 **笔记** [指数族的常见成员]

- 正态分布 $N(\mu, \sigma^2)$
- 泊松分布 $P(\lambda)$
- 二项分布 $B(n, p)$ ， n 已知
- 指数分布 $\text{Exp}(\lambda)$
- Gamma 分布 $\Gamma(\alpha, \beta)$
- 伯努利分布 $B(1, p)$

不是指数族：均匀分布 $U(0, \theta)$ (支撑集依赖 θ ，无法写成标准形式)。

 **笔记** [指数族标准形式：泊松与正态对比] 标准形式： $f(x; \theta) = h(x) \cdot \exp\{Q(\theta) \cdot t(x) - A(\theta)\}$

泊松 $P(\lambda)$:

$$f(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!} = \underbrace{\frac{1}{x!}}_{h(x)} \cdot \exp \left\{ \underbrace{\ln \lambda}_{Q(\lambda)} \cdot \underbrace{x}_{t(x)} - \underbrace{\lambda}_{A(\lambda)} \right\}$$

正态 $N(\mu, \sigma^2)$, σ^2 已知:

$$f(x; \mu) = \underbrace{\frac{1}{\sqrt{2\pi\sigma}}}_{h(x)} e^{-\frac{x^2}{2\sigma^2}} \cdot \exp \left\{ \underbrace{\frac{\mu}{\sigma^2}}_{Q(\mu)} \cdot \underbrace{x}_{t(x)} - \underbrace{\frac{\mu^2}{2\sigma^2}}_{A(\mu)} \right\}$$

 **笔记** [为什么指数族的充分统计量是完备的] 指数族密度含 $e^{Q(\theta) \cdot t(x)}$, 充分统计量 $T = \sum t(X_i)$ 的密度为

$$f_T(s; \theta) = \tilde{h}(s) \cdot e^{Q(\theta) \cdot s}$$

证完备性时, 假设 $E_\theta[\varphi(T)] = 0$, 展开得

$$\int \varphi(s) \cdot \tilde{h}(s) \cdot e^{Q(\theta) \cdot s} ds = 0 \quad \forall \theta$$

令 $\eta = Q(\theta)$, 这正是函数 $\varphi(s)\tilde{h}(s)$ 的拉普拉斯变换恒为零。

由拉普拉斯变换的唯一性: 变换恒为零 $\Rightarrow$ 原函数为零, 即 $\varphi(T) = 0$ a.s.

指数族的 $e^{Q(\theta) \cdot s}$ 结构天然就是拉普拉斯变换的形式, 完备性由此而来。

东邪的 tip 9.12

看见指数分布族只要无偏 + 完备统计量他就是 umvue

9.4 相和与渐进正态

9.4.1 相和

 **笔记** $g(\theta)$ 是为了写得更一般——它在估计 θ 的某个函数, 不一定是 θ 本身。

比如:

- 想估计 θ , 那 $g(\theta) = \theta$, $\hat{g}_n \rightarrow \theta$
- 想估计 θ^2 , 那 $g(\theta) = \theta^2$, $\hat{g}_n \rightarrow \theta^2$
- 想估计 e^θ , 那 $g(\theta) = e^\theta$, $\hat{g}_n \rightarrow e^\theta$

东邪的 tip 9.13

1. 简单来说, $g(\theta)$ 就是我们要估计的量, 写成这种形式就代表它是和未知参数 θ 相关的。
2. $\hat{g}_n(X_1, X_2, \dots, X_n)$ 是一个函数, 代入 n 个数据, 输出的结果就是我们对 $g(\theta)$ 的估计值。

 **笔记** 相合性定义的是一个宏观标准: 随着数据增多, 如果 $\hat{g}_n$ 这套公式的输出能收敛到真实值 $g(\theta)$, 我们就认为它是一个好的估计公式。

反过来, 如果数据堆再多结果也收敛不过去, 这套公式就不值得用。

东邪的 tip 9.14

强想和是几乎处处收敛, 就是不收敛的是一个固定的零测集, 弱收敛依概率收敛只要求每个固定 ε 下“超出误差”的概率趋于零, 但那个坏集合可以到处飘; 几乎处处收敛要求整条路径几乎必然最终落在真值上, 更强。

 **笔记** 强想和经过线形变化还是强想和, 也就强想和的公式经过线性变化还是好公式

 **笔记** [均方误差 (MSE)] MSE (Mean Squared Error, 均方误差) 度量估计量和真值之间的平均平方距离, 可以拆成两项:

$$E[(\hat{g}_n - g(\theta))^2] = \underbrace{[E\hat{g}_n - g(\theta)]^2}_{\text{偏差}^2} + \underbrace{\text{Var}(\hat{g}_n)}_{\text{方差}}$$

其中偏差 = $E[\hat{g}_n] - g(\theta)$, 衡量估计量的期望和真值之间的系统性差距。

两项的直觉:

- 偏差: 瞄准方向本身就歪了 (系统误差)
- 方差: 即使方向对, 每次结果也在抖动 (随机误差)

东邪的 tip 9.15

方差的定义是 $E[(\hat{g}_n - E\hat{g}_n)^2]$, 所以在括号里加减 $E\hat{g}_n$:

$$(\hat{g}_n - \theta^*) = \underbrace{(\hat{g}_n - E\hat{g}_n)}_{\text{方差来源}} + \underbrace{(E\hat{g}_n - \theta^*)}_{\text{偏差来源}}$$

平方展开后出现一次交叉项, 但由于 $E[\hat{g}_n - E\hat{g}_n] = 0$ 恒成立, 交叉项消掉, 只剩方差和偏差²两项。

 **笔记** 均方收敛 ($\text{MSE} \rightarrow 0$)

核心结论: 若 MSE 趋于 0, 则相合。

$$\text{MSE}(\hat{g}_n) = E[(\hat{g}_n - g(\theta))^2] \rightarrow 0 \implies \hat{g}_n \xrightarrow{P} g(\theta)$$

为什么? 切比雪夫不等式:

$$P(|\hat{g}_n - g(\theta)| > \varepsilon) \leq \frac{\text{MSE}(\hat{g}_n)}{\varepsilon^2} \rightarrow 0$$

MSE 拆开来是两项:

$$\text{MSE} = \text{偏差}^2 + \text{方差} = [E\hat{g}_n - g(\theta)]^2 + \text{Var}(\hat{g}_n)$$

所以要证 $\text{MSE} \rightarrow 0$, 只需证这两项都趋于 0:

- 偏差² $\rightarrow 0$ (估计量越来越不偏)
- 方差 $\rightarrow 0$ (估计量越来越集中)

实际用法: 无偏估计量偏差 = 0, 只需证方差 $\rightarrow 0$ 即可。这是最常用的情形。

 **笔记** 大数定律: 样本均值收敛到总体期望

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} E[X]$$

更一般地, 任何样本矩都收敛到对应的总体矩。

Slutsky 定理: 收敛可以穿过连续函数

$$T_n \xrightarrow{P} c \implies g(T_n) \xrightarrow{P} g(c) \quad (g \text{ 在 } c \text{ 处连续})$$

 **笔记** [验证相合性: Slutsky + 大数定律] 不算任何期望和方差, 只看结构——

这个估计量是不是样本矩的某个连续函数?

如果是, 大数定律直接给样本矩的收敛, Slutsky 直接传递过去, 一步到位。

矩估计量天生就是这个结构, 所以对矩估计量用这条路根本不需要展开 MSE。

两条路结论一样, 只是省不省计算而已。

东邪的 tip 9.16

第一步, 大数定律建立收敛:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} E[X]$$

即样本均值依概率收敛到总体期望，提供 $T_n \xrightarrow{P} c$ 这个条件。

第二步，连续映射定理传递收敛：

$$T_n \xrightarrow{P} c \implies g(T_n) \xrightarrow{P} g(c) \quad (g \text{ 在 } c \text{ 处连续})$$

对 k 阶样本矩同理： $\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} E[X^k]$ ，连续映射定理照常传递。

 **笔记** Slutsky 定理完整表述：

若 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{P} c$ (常数)，则：

1. $X_n + Y_n \xrightarrow{d} X + c$
2. $X_n \cdot Y_n \xrightarrow{d} c \cdot X$
3. $X_n / Y_n \xrightarrow{d} X / c \quad (c \neq 0)$

关键有两点是“连续不间断收敛”没说清楚的：

第一：必须一个依分布、一个依概率收敛到常数，两个都依分布不能用。

第二： Y_n 收敛的目标必须是常数，不能是随机变量。

这也是这道题先把 $Y_n \xrightarrow{a.s.} a$ 转成 $\frac{1}{Y_n} \xrightarrow{P} \frac{1}{a}$ 的原因——要凑出“依概率收敛到常数”这个形式，Slutsky 才能用。

东邪的 tip 9.17

要用 Slutsky 定理就得保证一个依分布收敛也就是 d-distribution 另一个第一必须是依概率收敛第二必须依概率收敛到常数

 **笔记**

- 依分布收敛 ($X_n \xrightarrow{d} X$)：保证了结果的极限分布形状是 X ，提供“收敛到谁”这个内容。
- 依概率收敛 ($Y_n \xrightarrow{P} c$)：保证了 Y_n 的取值高概率集中在 c 附近，误差 $|Y_n - c|$ 可以被控制住，使得 $X_n \cdot Y_n \approx X_n \cdot c$ 这个近似在极限下成立。
- 收敛到常数 (c 是常数而非随机变量)：消掉了联合分布的问题。常数没有随机性，不需要知道 X_n 和 Y_n 之间的相关结构，两个变量的联合行为自动退化成可操控的形式。

9.5 MLE 与渐近正态分布

 **笔记** [MLE 就是一种构造估计量的方式]

第一步：写似然函数

数据 $X_1, \dots, X_n$ 独立同分布，联合概率为：

$$L(\theta) = \prod_{i=1}^n f(X_i, \theta)$$

$L(\theta)$ 的含义：在参数为 θ 时，观测到这组数据的概率。

第二步：取对数

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(X_i, \theta)$$

取对数不改变最大值位置，但将连乘化为求和，便于求导。

第三步：求最大值

$$\ell'(\theta) = 0 \implies \hat{\theta}_{\text{MLE}}$$

核心思想：数据已经发生，反推使这组数据“最可能出现”的 θ ，即为 MLE。

东邪的 tip 9.18

Maximum Likelihood Estimation 理解

- **Max**: 要对似然函数求极大值，即求导令导数为零。
- **Likelihood**: 似然函数 $L(\theta) = \prod_{i=1}^n f(X_i, \theta)$ ，即在参数为 θ 时观测到这组数据的概率。
- **Estimation**: 解出 $\hat{\theta}$ 作为估计量。

为方便求导，先取对数：

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(X_i, \theta)$$

将连乘化为求和，不改变极值位置，再令 $\ell'(\theta) = 0$ 解出 $\hat{\theta}$ 。

数学意义：在现实已经发生情况 A 的条件下，是哪个 θ 导致 A 发生的可能性最大。

小补充： θ 是固定未知常数，非随机变量，不能说“ θ 是某个值的概率”。MLE 求的是 $L(\theta) = P(\text{数据} | \theta)$ 对 θ 的最大，而非贝叶斯的 $P(\theta | \text{数据})$ 。

 **笔记** MLE 解出来的 $\hat{\theta}$ 是一个数，但有两个问题：

- 问题 1：不知道它有没有偏（有限样本下 MLE 通常有偏）
- 问题 2：即使知道有偏，也不知道误差长什么形状

所以光有 $\hat{\theta}$ 这个数是不够的，还需要知道它的分布。渐近正态就是答案：

$$\hat{\theta} \approx N\left(\theta, \frac{1}{nI(\theta)}\right) \quad (n \text{ 很大时})$$

有了这个分布就知道了：

- 误差有多大（渐近方差 $\frac{1}{nI(\theta)}$ ）
- 误差是正态形状（可以做区间估计、假设检验）
- 渐近方差恰好等于 C-R 下界（MLE 在大样本下是最优的）

MLE 给你一个点 $\hat{\theta}$ ，渐近正态告诉你这个点周围的误差分布。

MLE 算出确定值但不知道好不好，渐近正态就是用来回答「好不好」这个问题的。

东邪的 tip 9.19

MLE 就是算得分函数什么时候是 0

9.5.1 渐近正态

定义 9.1 (渐近正态性与渐近方差)

设 $\hat{\theta}_n$ 是 θ 的估计量，若存在 $\sigma^2(\theta)$ 使得：

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, \sigma^2(\theta))$$

则称 $\hat{\theta}_n$ 是 θ 的渐近正态估计量， $\sigma^2(\theta)$ 称为渐近方差，等价地：

$$\hat{\theta}_n \xrightarrow{d} N\left(\theta, \frac{\sigma^2(\theta)}{n}\right)$$

对 MLE， $\sigma^2(\theta) = \frac{1}{I(\theta)}$ ，故：

$$\hat{\theta} \xrightarrow{d} N\left(\theta, \frac{1}{nI(\theta)}\right)$$



东邪的 tip 9.20

渐近存在的意义就是说 MLE 这种近似是好的，而且渐近正态不只说“好”，而是说好在哪里、好多少：

- 好在哪里：渐近无偏（中心落在真实 θ ）
- 好多少：渐近方差 $= \frac{1}{nI(\theta)} = \text{C-R 下界}$ （没有任何估计量能比它更好）

渐近正态证明的是：MLE 在大样本下是最优无偏估计量，这叫渐近有效。

 **笔记** MLE 渐近正态的证明核心是对 $\ell'(\hat{\theta}) = 0$ 在真实 θ 处 Taylor 展开：

$$0 = \ell'(\hat{\theta}) \approx \ell'(\theta) + (\hat{\theta} - \theta)\ell''(\theta)$$

整理得：

$$\sqrt{n}(\hat{\theta} - \theta) \approx \frac{\frac{1}{\sqrt{n}}\ell'(\theta)}{-\frac{1}{n}\ell''(\theta)}$$

- 分子：CLT $\Rightarrow N(0, I(\theta))$ ← Fisher 从这里进来
- 分母：LLN $\Rightarrow I(\theta)$ ← Fisher 又出现一次
- 结果：Slutsky $\Rightarrow N\left(0, \frac{1}{I(\theta)}\right)$

东邪的 tip 9.21

移项以后两边乘根号 n ，右侧上下同时除以 n ，得分函数期望是 0，所以上面有了 $1/\text{根号 } n$ 就能用中心极限定理凑出一个依分布收敛到正态分布，下面由于有 $1/n$ 还是独立同分布就可以说他依概率收敛到一个具体的数字也就是 fisher，然后一个依分布一个依概率就可以用 Slutsky 了。最后方差除以常数要把常数平方

东邪的 tip 9.22

Fisher 信息有两个等价定义：

$$I(\theta) = E\left[\left(\frac{\partial \ln f}{\partial \theta}\right)^2\right] = -E\left[\frac{\partial^2 \ln f}{\partial \theta^2}\right]$$

左边是得分函数的方差（均值为 0，故方差 = 二阶矩），右边是二阶导的负期望，两个定义相等。

 **笔记**

- CLT（中心极限定理）： n 个 iid 随机变量，均值 μ ，方差 σ^2 ，则

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu) \xrightarrow{d} N(0, \sigma^2)$$

不管原来什么分布，加起来除以 $\sqrt{n}$ ，极限就是正态。

- LLN（大数定律）： n 个 iid 随机变量，均值 μ ，则

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mu$$

样本均值收敛到总体期望。

定理 9.2 (Delta 方法)

设 $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, \sigma^2)$ ， g 在 θ 处可导且 $g'(\theta) \neq 0$ ，则：

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{d} N(0, [g'(\theta)]^2 \sigma^2)$$



 **笔记** [Delta 方法] 核心思路：用线性化“转移”分布。已知 $\sqrt{n}(\bar{X} - \lambda) \xrightarrow{d} N(0, \lambda)$ ，想知道 $\sqrt{n}(\bar{X}^2 - \lambda^2)$ 的极限

分布。直接算不行，但注意到 $g(x) = x^2$ 在 λ 附近是光滑的，可以 Taylor 展开：

$$g(\bar{X}) = g(\lambda) + g'(\lambda)(\bar{X} - \lambda) + \underbrace{O((\bar{X} - \lambda)^2)}_{\text{高阶项}}$$

所以 $g(\bar{X}) - g(\lambda) \approx g'(\lambda) \cdot (\bar{X} - \lambda)$ ，两边同乘 $\sqrt{n}$ ：

$$\sqrt{n}(g(\bar{X}) - g(\lambda)) \approx g'(\lambda) \cdot \sqrt{n}(\bar{X} - \lambda)$$

右边是已知分布乘以一个常数，这就能算了。

东邪的 tip 9.23

因为 $g'(\lambda)$ 是一个常数，所以乘进去方程的时候需要平方。

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \approx g'(\theta) \cdot \sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, [g'(\theta)]^2 \sigma^2)$$

 **笔记** [中心极限定理详解] Central Limit Theorem $\text{Var}(\sum X_i - n\mu) = \text{Var}(\sum X_i) = \sum_{i=1}^n \text{Var}(X_i) = n\sigma^2$

三种情况：

- 直接看和： $\sum X_i - n\mu$ ，方差 $= n\sigma^2 \rightarrow \infty$ (爆炸)
 - 除以 n (样本均值)： $\bar{X} - \mu$ ，方差 $= \frac{\sigma^2}{n} \rightarrow 0$ (塌缩成一个点，LLN)
 - 除以 $\sqrt{n}$ ： $\frac{1}{\sqrt{n}} \sum (X_i - \mu)$ ，方差 $= \sigma^2$ (稳定!)
- $\sqrt{n}$ 是让方差既不爆炸也不消失的唯一选择。

东邪的 tip 9.24

因为 n 个方差之和才是 $n\sigma^2$ ，有的直接拿的是 $\bar{X}$ ，相当于已经除以一个 n ，除多了，所以需要乘 $\sqrt{n}$ 恢复——相当于原来乘 $\frac{1}{\sqrt{n}}$ 。

$$\text{Var}(\sqrt{n}(\bar{X} - \mu)) = n \cdot \text{Var}(\bar{X}) = n \cdot \frac{\sigma^2}{n} = \sigma^2$$

9.5.2 渐近效率

定义 9.2 (渐近效率)

设 $\hat{\theta}_{1n}$ 、 $\hat{\theta}_{2n}$ 是 θ 的两个渐近正态估计量，渐近方差分别为 σ_1^2 、 σ_2^2 ，则称

$$e(\hat{\theta}_{2n}, \hat{\theta}_{1n}) = \frac{\sigma_1^2}{\sigma_2^2}$$

为 $\hat{\theta}_{2n}$ 相对于 $\hat{\theta}_{1n}$ 的渐近效率。

以 MLE (渐近方差 $= 1/I(\theta)$) 为基准： $e = 1/I(\theta)/\sigma_2^2$ ，当 $e = 1$ 时称 $\hat{\theta}_{2n}$ 渐近有效。



 **笔记** 含义： e 就是“换这个估计量等价于把样本量乘以 e ”。 $e < 1$ 说明它比 MLE 差，需要更多数据才能追上。

正态总体估计 μ ： $\bar{X}$ 渐近方差 σ^2 ，中位数渐近方差 $\pi\sigma^2/2$ ，故中位数的渐近效率 $= 2/\pi \approx 0.637$ ，需要多用约 57% 的样本。

第 10 章 能力三

能力三 区间估计

- 1. 概念层：置信区间是什么
 - 置信度 $1 - \alpha$ 的含义：重复抽样时区间覆盖 θ 的频率 $\geq 1 - \alpha$
 - 关键认知： θ 是固定常数，随机的是区间本身
 - 单侧/双侧：置信上限、置信下限、双侧区间
- 2. 方法层：枢轴量法（唯一方法，4 步走）
 - 步骤 1 找点估计量 T （比如 $\bar{X}$ 、 S^2 ）
 - 步骤 2 构造 $G(T, \theta)$ ，要求分布与 θ 无关（枢轴量）
 - 步骤 3 查表定范围，使 $P(G \in S) = 1 - \alpha$
 - 步骤 4 反解 θ ，得到 $[\theta_1(\mathbf{X}), \theta_2(\mathbf{X})]$
- 3. 应用层：正态总体选哪个枢轴量
 - 单个正态总体
 - 估 μ ， σ^2 已知 $\rightarrow Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$
 - 估 μ ， σ^2 未知 $\rightarrow T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$
 - 估 σ^2 ， μ 未知 $\rightarrow \chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$
 - 两个正态总体
 - 估 $\mu_1 - \mu_2$ ， σ_1^2, σ_2^2 已知 $\rightarrow Z$ 检验
 - 估 $\mu_1 - \mu_2$ ， $\sigma_1^2 = \sigma_2^2$ 未知 $\rightarrow$ 两样本 t
 - 估 $\sigma_1^2/\sigma_2^2 \rightarrow F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1)$

10.1 置信区间

东邪的 tip 10.1

具体一次含有 θ 就是含有，不含有就是不含有，就像一个具体的人身高是 180 就是一米八。只不过我们构造的置信区间是一个选择人群的方法，我们保证的是这个人群里面有 $1 - \alpha$ 的可能性抽出一个 180。

 **笔记** 置信区间是一套构造区间的公式，不是一个固定的区间。类比无偏估计量：

无偏估计量 $\bar{X} = \frac{1}{n} \sum X_i$ 公式，代入数据得一个点

置信区间 $\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$ 公式，代入数据得一个区间

两者都是实验前选好的公式，实验后代入具体样本才变成具体的数。唯一的区别是：

- 无偏估计量评价的是「这个公式平均不偏」
- 置信区间评价的是「这个公式长期套住 θ 的频率 $\geq 1 - \alpha$ 」

东邪的 tip 10.2

置信度 $1 - \alpha$ 是公式的性质，不是某次具体区间的性质——这就是为什么不能说「 μ 有 95% 的概率在这个区间里」，只能说「这套公式有 95% 的靠谱率」。

 **笔记** 置信区间的结构是：

$$\underbrace{\bar{X}}_{\text{中心}} \pm \underbrace{z_{\alpha/2} \frac{\sigma}{\sqrt{n}}}_{\text{误差限 (半宽)}}$$

其中 $z_{\alpha/2}$ 是标准正态分布 $N(0,1)$ 的上 $\alpha/2$ 分位数，满足 $P(Z > z_{\alpha/2}) = \alpha/2$ ，是一个查表得到的常数。

误差限拆开看：

- $z_{\alpha/2}$ ：由置信度决定，置信度越高， $z_{\alpha/2}$ 越大
- σ ：总体本身的波动，越散误差限越大
- $\sqrt{n}$ ：样本量越大误差限越小，区间越窄

东邪的 tip 10.3

想要更窄的区间，本质上就是在压缩误差限：要么降置信度（ $z_{\alpha/2}$ 变小），要么增大样本量（ $\sqrt{n}$ 变大）。

 **笔记** [正确理解] 想象你做了 100 次实验，每次抽一批样本，每次用同样的方法构造一个置信区间：

第 1 次样本	→	区间 [168.1, 172.5]	←	包含了真实 μ
第 2 次样本	→	区间 [169.0, 173.4]	←	包含了真实 μ
第 3 次样本	→	区间 [171.8, 176.2]	←	没包含（倒霉）
⋮		⋮		
第 100 次	→	⋯		

95% 置信度的意思是：这 100 个区间里，平均有 95 个会把真实的 μ 套住。

具体到某一次抽样得到的那个区间，你不知道它是不是那幸运的 95 个之一——但你知道这套方法长期来看靠谱率是 95%。

 **笔记** [可靠度和精度的取舍] 想要 99% 置信度？可以，但区间会更宽（更不精确）。

想要窄区间？只能降低置信度，或者增大样本量。

东邪的 tip 10.4

越可靠，区间越长；区间越长，精度越低。

 **笔记** [单侧与双侧置信区间] 双侧是在问： θ 在哪里？（两边都要套住）

单侧是在问： θ 有没有超过某个危险线？（只关心一边）

双侧区间——两边都套：

$$P(\theta_1(\mathbf{X}) \leq \theta \leq \theta_2(\mathbf{X})) \geq 1 - \alpha$$

置信上限——只关心「 θ 最多能有多大」：

$$P(\theta \leq \theta_2(\mathbf{X})) \geq 1 - \alpha$$

置信下限——只关心「 θ 至少有多大」：

$$P(\theta \geq \theta_1(\mathbf{X})) \geq 1 - \alpha$$

单侧的「网」是开口的：

双侧	[————— θ —————]	两边都围住，问「 θ 在哪」
置信上限	(————— θ)	只管右边，问「 θ 会不会太大」
置信下限	[θ —————)	只管左边，问「 θ 会不会太小」

单侧和双侧的分位数不同：置信度相同时，双侧两边各切 $\alpha/2$ ，查 $z_{\alpha/2}$ ；单侧只切一边，查 z_{α} 。因此单侧区间比双侧更窄——全部误差预算集中在一侧。

东邪的 tip 10.5

$$\underbrace{[\theta_1(\mathbf{X}), \theta_2(\mathbf{X})]}_{\text{抽象, 适用任何分布}} \xrightarrow{\text{正态总体}(\sigma^2 \text{已知}), \text{枢轴量法}} \underbrace{\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]}_{\theta_1 \text{ 和 } \theta_2 \text{ 的具体长相}}$$

- $\mathbf{X} = (X_1, X_2, \dots, X_n)$: 整批样本, 你抽到的所有数据
- $\theta_1(\mathbf{X})$: 区间左端点, 样本的函数, 代入数据得一个数
- $\theta_2(\mathbf{X})$: 区间右端点, 同上

10.2 枢轴量法 (Pivotal quantity method)

- 原来我们要求的是 $P(f(X) < \theta < p(X)) = 1 - \alpha$, 原来我们是想知道这个 $f(X)$ 和 $p(X)$ 这两个函数是什么, 但是我们压根不知道, 因为中间的 θ 我们也不知道。
- 于是呢, 我们需要对 θ 进行一点变换, 使得中心这个位置——这个位置其实就是核心, 是枢纽, 也就是 pivot——我们知道。于是我们就把原本的 θ 变成了 $\frac{\bar{X} - \theta}{\sigma/\sqrt{n}}$, 因为这样 pivot 这整个的分布我们就知道了。
- θ 从原来必须知道是多少, 现在它已经完成了将正态从以 θ 为中心移动到以 0 为核心的使命。
- 然后为了等式成立, 我们知道了两侧是 $z_{\alpha/2}$ 和 $-z_{\alpha/2}$, 但是我们要求的其实是 θ 两边的函数是什么, 所以把枢纽位置还原, 还原的过程两边函数也得跟着变, 这样两边的函数就知道是什么了。 θ 必须是单调的才能反转

东邪的 tip 10.6

- 其实就是保证中心的枢纽改变以后我们知道它的分布。比如 μ 未知, σ^2 也不知道, 就没法用 $N(0, 1)$ 了, 因为不知道 σ^2 , 所以没法把方差弄到 1, 只能用实际的方差, 然后弄成 t 分布了。
- 构造完了以后, 里面只能留要求的量是未知的, 其他的都得是已知的。

正态总体的标准情形:

1. 求 μ , σ^2 已知 $\rightarrow$ 用 Z 统计量

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

2. 求 μ , σ^2 未知 $\rightarrow$ 用 t 统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

3. 求 σ^2 , μ 已知 $\rightarrow$ 用 χ^2 统计量

$$\chi^2 = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$$

4. 求 σ^2 , μ 未知 $\rightarrow$ 用 χ^2 统计量

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

5. 两总体, 求 $\mu_1 - \mu_2$ ($\sigma_1^2 = \sigma_2^2$ 未知) $\rightarrow$ 用 t 统计量

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{1/m + 1/n}} \sim t(m+n-2)$$

6. 两总体, 求 σ_1^2/σ_2^2 , μ_1, μ_2 未知 $\rightarrow$ 用 F 统计量

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(m-1, n-1)$$

东邪的 tip 10.7

$\mu_1 - \mu_2$ 就是变相的 2, 5 就是变相的 3。

F 分布就是两个独立卡方分布之比。

定义: 若 $U \sim \chi^2(m)$, $V \sim \chi^2(n)$, 且相互独立, 则

$$F = \frac{U/m}{V/n} \sim F(m, n)$$

东邪的 tip 10.8

两样本 t 统计量不是两个 t 的叠加, 而是将差 $\bar{X} - \bar{Y}$ 整体作为分子, 用合并方差

$$S_p^2 = \frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2}$$

作为分母, 结构上与单样本 t 完全一致:

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{1/m + 1/n}} \sim t(m+n-2)$$

大样本置信区间**笔记**

使用场景: 总体分布未知, 但 n 足够大。

核心就是 CLT: 无论总体是什么分布, 只要 n 大,

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

σ 未知也没关系, 用样本标准差 S 替换, 近似仍成立:

$$Z = \frac{\bar{X} - \mu}{S/\sqrt{n}} \approx N(0, 1)$$

也就是说, 只要样本够大, σ^2 不知道也可以用 Z 而不是 T 。

1. 指数分布, 求 θ , $X_1 \sim \frac{1}{\theta}e^{-x/\theta}$

pivot: $G = \frac{2n\bar{X}}{\theta} \sim \chi^2(2n)$, 查表得

$$\frac{2n\bar{X}}{\chi_{\alpha/2}^2(2n)} \leq \theta \leq \frac{2n\bar{X}}{\chi_{1-\alpha/2}^2(2n)}$$

2. 均匀分布, 求 θ , $X_1 \sim U(\theta, \theta+1)$

pivot: $G = X_{(1)} - \theta \sim \text{Beta}(1, n)$, 手算分位数:

$$a = 1 - \left(1 - \frac{\alpha}{2}\right)^{1/n}, \quad b = 1 - \left(\frac{\alpha}{2}\right)^{1/n}$$

$$X_{(1)} - b \leq \theta \leq X_{(1)} - a$$

第 11 章 能力 4

能力四 假设检验

- 1. 功效函数与两类错误 (4.1 节) 3 题
- 2. 正态总体检验 (4.2 节) 5 题
- 3. 大样本检验 (4.3 节) 2 题
- 4. NP 引理 $\rightarrow$ UMP (4.4 节) 6 题 $\leftarrow$ 全部 * 最薄弱
- 5. 拟合优度 (12 周) 4 题 $\leftarrow$ 3 题 *

11.1 功效函数与两类错误

假设检验框架

- 两种现实 $\times$ 两种决定
 - H_0 为真, 拒绝 $H_0 \rightarrow$ 第一类错误 (弃真), 概率 $= \alpha$
 - H_1 为真, 接受 $H_0 \rightarrow$ 第二类错误 (取伪), 概率 $= \beta$
 - $\alpha \downarrow \Rightarrow \beta \uparrow$, 样本量固定时此消彼长
- 功效函数 $\beta(\theta) = P_\theta(\text{拒绝 } H_0)$ 统一两者
 - $\theta \in \Theta_0: \beta(\theta) = \alpha$ (第一类错误)
 - $\theta \in \Theta_1: 1 - \beta(\theta) = \beta$ (第二类错误)
- p 值: H_0 成立时, 观测到当前统计量或更极端结果的概率
 - $p < \alpha \rightarrow$ 拒绝 H_0 ; p 越小拒绝越强硬
 - p 值衡量拒绝的强度, α 是事先划定的门槛

东邪的 tip 11.1 (构造检验统计量)

我明白了其实整个逻辑是这样的先要 $-\mu_0$ 因为最终我们是 $N(0, 1)$ 正态分布, $\bar{X}$ 现在是相当于原点的横坐标并不是以 μ_0 为原点的横坐标, 减去以后我们就知道 $\bar{X}$ 如果以 μ_0 为原点他的坐标是多少, 然后他们两都要除以 $\sigma/\sqrt{n}$ 。也就是要同时缩放 x 轴坐标为了让整个分布变成方差为一的标准分布

东邪的 tip 11.2

求检验函数, 首先我们要知道分布和 σ 标准差是不是已知。分布决定统计量在 H_0 下服从什么分布, σ 是否已知决定统计量的具体形式 (用 σ 还是用 S), 这两件事合在一起决定我们查哪张表 ($N(0, 1)$ 的表、 t 分布的表)

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}, \quad T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

将 $\bar{X}$ 变成 Z 的动作叫, 构造枢轴量:

笔记

也就是现在 $\bar{X}$ 经过标准化以后现在就是他在 $N(0, 1)$ 标准正态分布的函数中 x 坐标, y 就是概率密度, H_1 和 α 共同决定了 $\bar{X}$ 操作后在 x 轴不能在的区域范围。其中 H_1 决定拒绝域在哪边 (左、右、还是两边), α 决定拒绝域多大 (切掉多少面积) 检验函数是把上面整个流程形式化成一个函数:

$$\varphi(X) = \begin{cases} 1 & T \in W \\ 0 & T \notin W \end{cases}$$

其中 W 是拒绝域, $\varphi = 1$ 表示拒绝 H_0 , $\varphi = 0$ 表示不拒绝。它不是一个新步骤, 只是把“看落没落在拒绝域里”这件事用数学语言写出来。

东邪的 tip 11.3 (关于 p 值-比观察更极端的概率)

p 值计算的概率是假设 H_0 成立时, 统计量比你观测值还极端的概率。比如经过标准化以后 $\bar{X}$ 落在了 8, 然后 $[1, +\infty)$ 都是拒绝域, 出现比 8 更极端的概率就是从 8 积分到正无穷。从直觉上理解, 如果落在 1.1 可能就是小失误拒绝的很勉强, 但是落在 8 很有可能就是 H_0 错误了。

所以 p 越小越强硬拒绝的逻辑是: 这么小概率的事情被我碰上, 那可能就不是小概率事件, 所以 H_0 很可能不成立, 对吗?

 **笔记** 拒绝域的大小限制了 p 值的上限。如果拒绝域很大 (α 大, 左边界 c 小), p 离拒绝域左边界很近时, 由于 α 本身就不小, 这次拒绝有可能是错误拒绝; 反之, 当拒绝域已经很小 (α 小, 左边界 c 大), p 离左边界再近也依然是强烈的拒绝。

东邪的 tip 11.4

(1) 整个标准化统计量然后看他落在 H_0 还是 H_1 , 接受域还是拒绝域的时候, 我们是想看他到底是拒绝了还是接受了, 如果拒绝了 p 值会告诉我们拒绝的强烈还是不强烈, 如果强烈拒绝我们就会怀疑 H_0 不是对的。

1. H_0 成立其实就不应该落在拒绝域, 这个就是第一类错误
2. H_1 成立就不该落在接受域。这个就是第二类 c 错误。第一类错误是 H_0 的曲线算右尾, 第二类错误是 H_1 的曲线算左尾。

 **笔记** 功效函数是

$$\beta(\theta) = P_{\theta}(\text{统计量落在拒绝域})$$

它是关于 θ 的函数, 对所有的 θ 都算一遍落在拒绝域的概率。

$$\text{第一类错误} = \int_c^{+\infty} f_{H_0}(x) dx = \alpha$$

$$\text{第二类错误} = \int_{-\infty}^c f_{H_1}(x) dx = \beta$$

东邪的 tip 11.5

就是第一类错误是以 H_0 为中心向右积分, 第二类错误是以 H_1 为中心像左积分, 那个 f 的下标是不一样的。

11.2 正态总体检验

定理 11.1 (假设检验统计量选择)

一、均值检验 (单总体)

设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 。

方差已知 $\rightarrow Z$ 检验:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

方差未知 $\rightarrow t$ 检验:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$$

分母用 S 替代 σ , 引入额外随机性, 分布变胖; n 越大 t 越接近正态。

二、方差检验 (单总体)

检验 $H_0: \sigma^2 = \sigma_0^2$:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$$

三、两总体方差比检验

检验 $H_0: \sigma_1^2 = \sigma_2^2$:

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1)$$



检验统计量与 CI 的 pivot 虽然长得相似但是却不—样，代入的是具体 μ 在代入的一刻就知道他在 0, 1 正态分布 x 轴落在了哪里了

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}, \quad T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}, \quad \chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$$

东邪的 tip 11.6

- 第一：置信区间是要找一个区间；假设检验那个区间是拒绝域，那个区间是接受域，都是确定的。
- 第二：置信区间 θ 是不知道的；假设检验 θ_0 是给我们具体的，需要代入然后观察落在哪里。
- 第三：他们两构造的目的其实不一样——一个是更换轴，我们才能求出两边的方程；一个就是为了标准正态化，方便查表计算。

单侧双侧拒绝域就是总积分为 α 的面积是都放左边、都放右边、还是两边各一半。

- 双侧：两边各放 $\frac{\alpha}{2}$ ，查 $z_{\alpha/2}$
- 单侧右：全放右边，查 z_α
- 单侧左：全放左边，查 $-z_\alpha$

H_1 指哪边就往哪边放。

 **笔记** 我们现在不知道 θ_0 是什么分布，但是样本很大，CLT 保证

$$\frac{\sqrt{n}(\hat{\theta} - \theta_0)}{\sqrt{V(\theta_0)}} \approx N(0, 1)$$

然后问题就变成：这个值落在 $N(0, 1)$ 的 x 轴哪里，有没有超过临界值 z_α 或 $z_{\alpha/2}$ ？超过了就拒绝 H_0 ，没超过就不拒绝。

θ 是谁：

- $\hat{\theta}$ ：估计量（比如 $\hat{p} = \bar{X}$ ，或 $\bar{X}$ ）
- θ_0 ： H_0 给定的具体值（比如 $p_0 = 0.1$ ）
- $V(\theta_0)$ ：估计量在 H_0 下的渐近方差

为什么和 CLT 长得—样：

你记的 CLT 基础形式是只乘 $\sqrt{n}$ ：

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N(0, \sigma^2)$$

但得到的是 $N(0, \sigma^2)$ ，方差不是 1，没法直接查表。为了查表，还要再除以 σ ：

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} N(0, 1)$$

大样本检验公式里的 $\sqrt{V(\theta_0)}$ 就是这个 σ ——多了这一步除法，才能落到标准正态的 x 轴上查表。对应关系：

- $\hat{\theta} = \bar{X}$
- $V(\theta_0) = \sigma^2$ （渐近方差，不带 $1/n$ ）

分母的 $\sqrt{n}$ 已经提到分子上去了，所以 $\sqrt{V(\theta_0)}$ 对应的是 σ ，不是 $\sigma/\sqrt{n}$ 。本质完全—样。

- 用 θ_0 ： H_0 明确给了 θ_0 的值，直接代入算方差。理论上更严格，因为检验本身就是假设 H_0 成立。

- 用 $\hat{\theta}$: θ_0 对应的方差形式复杂, 或题目直接用样本估计。大样本下 $\hat{\theta} \xrightarrow{P} \theta_0$, 两者等价。

11.3 NP-UMP

NP 引理的核心思想总结

 **笔记** [奈曼皮尔逊] 在简单假设 $H_0: \theta = \theta_0$ vs $H_1: \theta = \theta_1$ 下, 让 power 势最优——即拒绝域大小 (第一类错误概率) 确定的情况下, 使第二类错误概率最小:

$$\text{约束: } P_{\theta_0}(X \in W) = \alpha, \quad \text{目标: } \min P_{\theta_1}(X \notin W) \iff \max P_{\theta_1}(X \in W)$$

即“冤枉好人”概率不超过 α 的前提下, 使“抓住坏人”的概率最大。

第二类错误的几何形式取决于方向: 右侧检验为 H_1 下 c 左侧面积, 左侧检验为右侧面积。统一表述: H_1 下落在拒绝域之外的概率最小, 不绑定方向。

东邪的 tip 11.7

在 H_0 分布下, 以下三个 W 都能让积分 $= \alpha$:

$$W_1 = \{X \geq c_1\} \quad \text{右尾, } P_{\theta_0}(X \in W_1) = \alpha$$

$$W_2 = \{X \leq c_2\} \quad \text{左尾, } P_{\theta_0}(X \in W_2) = \alpha$$

$$W_3 = \{\text{某个中间奇怪区域}\} \quad P_{\theta_0}(X \in W_3) = \alpha$$

三个 W 在 H_0 下积分面积相同, 但对应的 x 取值范围完全不同。放到 H_1 分布下积分, 结果各异:

$$P_{\theta_1}(X \in W_1) \neq P_{\theta_1}(X \in W_2) \neq P_{\theta_1}(X \in W_3)$$

因为 H_1 的分布中心不同, 同一个 x 范围在 H_1 下积出的面积也不同, 三个 W 对应三个不同的势, 即三个不同的第二类错误。

约束的是 H_0 下的面积, 优化的是 H_1 下的面积, 二者独立。NP 引理保证: 用似然比 $\Lambda(x) \geq k$ 定出的 W , 在 H_1 下的面积最大 (势最大, 第二类错误最小)。

 **笔记** 似然比是一个性价比指标, 帮你决定每个 x 值值不值得放进 W 。

放一个 x 进 W 的代价和收益:

- 代价: 消耗掉一点 α 的预算 $\rightarrow f(x; \theta_0)$ 越大, 代价越高; 其中 $f(x; \theta_0)$ 就是以 θ_0 为中心的正态曲线在 x 处的纵坐标
- 收益: 增加一点势 $\rightarrow f(x; \theta_1)$ 越大, 收益越高; 其中 $f(x; \theta_1)$ 就是以 θ_1 为中心的正态曲线在 x 处的纵坐标

所以每个 x 的性价比就是:

$$\Lambda(x) = \frac{f(x; \theta_1)}{f(x; \theta_0)} = \frac{\text{收益}}{\text{代价}} = \frac{H_1 \text{ 曲线纵坐标}}{H_0 \text{ 曲线纵坐标}}$$

最优策略: 按性价比从高到低把 x 塞进 W , 直到 α 用完, 等价于:

$$W = \{\Lambda(x) \geq k\}$$

NP 引理证明的就是: 这个贪心策略给出全局最优——势最大, 第二类错误最小。

东邪的 tip 11.8

$\Lambda(x) \geq k$ 越大越好, 等价于:

- $f(x; \theta_0)$ (x 在 H_0 曲线的纵坐标) 越小越好 $\rightarrow$ 放进 W 消耗的 α 预算少, 代价小
- $f(x; \theta_1)$ (x 在 H_1 曲线的纵坐标) 越大越好 $\rightarrow$ 在 H_1 下对 W 积分越大, 势 $P_{\theta_1}(X \in W)$ 越大从而第二类错误 $= 1 - P_{\theta_1}(X \in W)$ 越小。

 **笔记** [一致最优势检验 UMP] **UMP = Uniformly Most Powerful Test**, 一致最优势检验。

NP 解决的是简单 vs 简单 (H_1 只有一个点), 但实际问题里 H_1 往往是一个范围:

$$H_1: \theta > \theta_0 \quad (H_1 \text{ 有无穷多个点})$$

这时对每个具体的 θ_1 用 NP 都能找到一个最优检验, 但不同的 θ_1 可能给出不同的拒绝域。

UMP 问的是: 有没有一个拒绝域 W , 对 H_1 范围内所有的 θ_1 同时最优?

$$\beta_W(\theta_1) \geq \beta_{W'}(\theta_1) \quad \text{对一切 } \theta_1 \in H_1 \text{ 成立}$$

如果存在, 就叫 **UMP** 检验。

- NP $\rightarrow$ 简单 vs 简单, 最优
- UMP $\rightarrow$ 简单 vs 复合, 对所有 θ_1 一致最优

UMP 不是总存在的, 单调似然比族 (如指数族) 里单侧检验一般有 UMP, 双侧一般没有。

 **笔记** [UMP 的构造] 构造 UMP 的核心工具是单调似然比。

思路: NP 告诉我们, 对每个固定的 θ_1 , 最优拒绝域是 $\{\Lambda(x) \geq k\}$ 。若 $\Lambda(x) = \frac{f(x; \theta_1)}{f(x; \theta_0)}$ 是某个统计量 $T(X)$ 的单调递增函数, 则:

$$\Lambda(x) \geq k \iff T(X) \geq c$$

右边的形式 $\{T(X) \geq c\}$ 与 θ_1 的具体取值无关, 对所有 $\theta_1 > \theta_0$ 给出同一个拒绝域。

东邪的 tip 11.9

选取比值大于等于 k 的 x 构成拒绝域 $W = \{\Lambda(x) \geq k\}$, 在 H_0 曲线下积分恰好等于 α :

$$P_{\theta_0}(X \in W) = \int_W f(x; \theta_0) dx = \alpha$$

k 即为让该积分恰好等于 α 的门槛值。也就是这些 x 坐标对应的 y 坐标乘 dx 再求和

 **笔记** [单调性的证明] 取对数后:

$$\ln \Lambda(x) = \frac{\mu_1 - \mu_0}{\sigma^2} \cdot \bar{X} - \text{常数}$$

这是关于 $\bar{X}$ 的线性函数, 系数为 $\frac{\mu_1 - \mu_0}{\sigma^2}$, 证单调只需看系数符号——正的单增, 负的单减。

虽然每个 θ_1 取值不同, 但只要 $H_1: \theta > \theta_0$, $\theta_1 - \theta_0 > 0$ 是确定的, 故上式形如 $k\bar{X} - b$ ($k > 0$), $\bar{X}$ 越大 $\Lambda(x)$ 越大, 单增方向锁死, 不随 θ_1 变。

故拒绝域 $\{\bar{X} \geq c\}$ 对所有 $\theta_1 > \theta_0$ 一致成立 $\Rightarrow$ **UMP**。

 **笔记** [似然比化简为拒绝域]

$$\Lambda(x) = \exp\left\{\frac{\mu_1 - \mu_0}{\sigma^2} \sum x_i - \text{常数}\right\} \geq k$$

两边取 $\ln$, 常数移右, 设右端为 c' :

$$\frac{\mu_1 - \mu_0}{\sigma^2} \sum x_i \geq c'$$

因 $\mu_1 > \mu_0$, 系数 > 0 , 两边除之不等号方向不变, 设右端为 c :

$$\Lambda(x) \geq k \iff \bar{X} \geq c$$

θ_1 虽出现在 c 的表达式中, 但 c 是一个具体的数, 最终由 $P_{\theta_0}(\bar{X} \geq c) = \alpha$ 定出, θ_1 被绕开。

东邪的 tip 11.10 (NP 到 UMP 的完整逻辑)

我们想知道这次实验拒绝域应该取在哪里。

由 NP 引理, 理论上最优拒绝域是让拒绝域内的 x 满足似然比大于等于 k :

$$W = \{\Lambda(x) \geq k\}$$

k 再小一点, 满足条件的 x 更多, 拒绝域变大, H_0 下的积分面积就超过 α 。

但此时仍不知道具体拒绝域范围在哪, 因为 $\Lambda(x)$ 含有未知的 θ_1 。

引入 $T(X)$, 利用单调性:

$$\Lambda(x) \geq k \iff T(X) \geq c, \quad c \text{ 由 } P_{\theta_0}(T(X) \geq c) = \alpha \text{ 定出}$$

$T(X)$ 只含数据, 代入样本即可算出具体拒绝域。

 **笔记** [从似然比到可用拒绝域] 最初只知道最优拒绝域是 $\{\Lambda(x) \geq k\}$, 但由于 $\Lambda(x) = \frac{f(x; \theta_1)}{f(x; \theta_0)}$ 含有未知的 θ_1 , 不知道 x 具体取哪些值, 拒绝域落在哪里。

因此需要找统计量 $T(X)$, 利用单调性将最优条件翻译成可计算的形式:

$$\Lambda(x) \geq k \iff T(X) \geq c$$

其中 c 由 $P_{\theta_0}(T(X) \geq c) = \alpha$ 定出, θ_1 被绕开, k 也无需单独计算。

完整逻辑链:

- 最优性: 由 NP 引理保证, $\{\Lambda(x) \geq k\}$ 是最优拒绝域
- 可计算: $T(X)$ 只含数据, 拿到样本即可算出
- 实际判断: 计算 $T(X)$, 与 c 比较, 判断样本是否落入拒绝域

11.4 卡方拟合优度检验

 **笔记** 为什么拟合优度检验要引入 F_0 、 F_n 这套新符号? 核心原因只有一个: 检验的对象变了。

之前检验的是一个数, 例如 $H_0: \mu = \mu_0$, 统计量是拿样本统计量和这个数比。现在要检验的是一整个分布, 分布是函数, 所以假设必须写成:

$$H_0: F = F_0, \quad H_1: F \neq F_0$$

其中 F_0 是假设的理论分布, F_n 是经验分布函数 (用手头数据估计出来的分布)。逻辑链升了一个层次: 原来比一个数 ($\bar{X}$ vs μ_0), 现在比两条曲线 (F_n vs F_0)。

三种方法度量 F_n 与 F_0 的差距, 方式不同:

- 卡方检验: 将曲线切成 k 段逐段比频数差, 有拒绝域, 结论客观
- K-S 检验: 取 $\sup_x |F_n(x) - F_0(x)|$ 最大垂直距离, 对尾部更敏感
- Q-Q 图: 比分位数是否对齐画图看直线, 直观但主观

这不是新体系, 逻辑框架和参数检验完全一样: 构造在 H_0 下分布已知的统计量, 超过临界值就拒绝。

东邪的 tip 11.11 (P-P 图的直观理解)

我们要比较的是: 样本自己说的概率和理论分布说的概率是不是一回事。

对于同一个数值 $x_{(i)}$:

- 横轴 x : 经验概率 $F_n(x_{(i)}) = i/n$, 这个是确定的, 只和排名有关。比如 10 个人最后一名 55 分, 他就告诉了我们后百分之 10 对应的分位数是 10%。
- 纵轴 y : 理论概率 $F(x_{(i)})$, 查表得 55 分的分位数应该是 0.045。

配对描点为 $\left(\frac{i}{n}, F(x_{(i)})\right)$, 如果两者相等就能画出一条 $y = x$ 的图像。

 **笔记** [$F_n(x_{(i)}) = i/n$ 的含义]

- n : 样本总数, 比如一共 10 个人, $n = 10$
 - i : 排序后第 i 个数, 比如 55 分排第 1, $i = 1$; 70 分排第 5, $i = 5$
- 所以 $F_n(x_{(i)}) = i/n$ 就是「第 i 个数在 n 个数里的排名百分比」。

笔记 [正态分布理论分位数公式推导]

正态分布的 CDF 定义为：

$$F(x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

已知概率 p ，反过来问：对应的 x 是多少？这就是求反函数 $F^{-1}(p)$ ，解得：

$$F^{-1}\left(\frac{i}{n}\right) = \hat{\mu} + \hat{\sigma} \cdot \Phi^{-1}\left(\frac{i}{n}\right)$$

其中各部分含义如下：

- $\Phi^{-1}(p)$ ：标准正态分布的分位数，即标准正态分布里有 p 的概率低于这个值。比如 $\Phi^{-1}(0.1) = -1.28$ ，意思是标准正态里有 10% 的概率低于 -1.28 。
- $\hat{\sigma} \cdot \Phi^{-1}(p)$ ：标准正态是均值 0 方差 1 的，乘以 $\hat{\sigma}$ 是把尺度还原到原始数据的尺度。
- $\hat{\mu} + \hat{\sigma} \cdot \Phi^{-1}(p)$ ：再加上 $\hat{\mu}$ 是把中心平移回原始数据的均值。

笔记 [Q-Q 图 (Quantile-Quantile Plot, 分位数-分位数图) 的横纵坐标]

- 横轴 x ：理论分位数 $F^{-1}(i/n)$ ，即理论分布说排名第 i/n 的人应该是多少。
- 纵轴 y ：样本分位数 $x_{(i)}$ ，即样本里实际排名第 i 的人是多少。

若样本来自该分布，两者相等，点落在对角线 $y = x$ 上。

定义 11.1 (Kolmogorov-Smirnov 检验)

设 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} F(x)$ ，经验分布函数为 $F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i \leq x)$ 。对假设 $H_0: F(x) = F_0(x)$ (F_0 完全已知且连续)，定义统计量

$$D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F_0(x)|$$

在 H_0 下, $\sqrt{n} D_n \xrightarrow{d} K(\lambda)$, 其中 $K(\lambda) = \sum_{k=-\infty}^{+\infty} (-1)^k e^{-2k^2 \lambda^2}$ 。给定显著性水平 α , 拒绝域为 $\sqrt{n} D_n > \lambda_\alpha$ 。

第 12 章 能力五综合应用

12.1 最小二乘与检验

 **笔记** 模型在说什么

你观测到一堆点 (x_i, Y_i) ，假设它们之间有线性关系，但不是完美的直线，每个点都有误差：

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

ε 是随机噪声，假设服从 $N(0, \sigma^2)$ 。 x 是你控制的（比如广告投入）， Y 是结果（比如销量），随机性全来自 ε 。

最终要检验的是什么

核心假设是 $H_0: \beta_1 = 0$ ，翻译成人话： x 对 Y 根本没有线性影响，你以为有关系，其实是噪声造成的。

- 拒绝 H_0 ： x 和 Y 之间的线性关系是显著的，这条直线是有意义的
- 不能拒绝 H_0 ：你拟合的直线可能就是在拟合噪声， $\hat{\beta}_1$ 虽然不等于零但完全可能是随机波动

所以整个流程是：先假设线性 $\rightarrow$ 用 OLS 估出直线 $\rightarrow$ 检验这条直线是否真的有意义 ($\beta_1 \neq 0$) $\rightarrow$ 如果有意义再去做预测和区间估计。

东邪的 tip 12.1

回归模型就是 $y=kx+b$ ， k 也就是 x 对 y 对影响程度 b 也就是为了让某些是 0 的时刻有初始条件

 **笔记** 记忆： $\hat{\beta}_1 = S_{xy}/S_{xx} = \widehat{\text{Cov}}(x, Y)/\widehat{\text{Var}}(x)$ ，即斜率 = 协方差 $\div$ 方差，与相关系数公式同根，仅少除 σ_Y 。
截距由回归直线过中心点 $(\bar{x}, \bar{Y})$ 反推： $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$ 。

东邪的 tip 12.2

最小二乘就是为了残差平方和最小，也就是 $(Y - kx - b)^2$ 再求和，由于这里面有两个变量，最小值就是先对两个变量分别求偏导都是 0。

 **笔记** 最小二乘的目的就是算出 x 前面的系数 $\hat{\beta}_1$ ， H_0 默认是 0，也就是不相关。但 $\hat{\beta}_1 \neq 0$ 不够——万一只是随机波动碰巧算出来的呢？

核心问题是： $\hat{\beta}_1$ 离零有多远，远到不像噪声造成的？

光看 $\hat{\beta}_1$ 本身没意义，单位不同你不知道大还是小，所以标准化：

$$T = \frac{\hat{\beta}_1}{\hat{\sigma}/\sqrt{S_{xx}}} \sim t(n-2) \quad (H_0 \text{ 下})$$

T 超过临界值就拒绝 H_0 ，本质在问：估出来的斜率，相对于数据的噪声水平，够不够大？

- $S_{xx} = \sum (x_i - \bar{x})^2$ 是 x 的离散程度。直觉： x 取值越分散，斜率估计越准——如果所有 x 都挤在一起，根本看不出斜率是多少。
- $\hat{\sigma} = \sqrt{SS_e/(n-2)}$ 是噪声的估计，即残差的标准差——数据点离拟合直线平均有多远，越大说明数据越乱。
- T 的直觉：分子 $\hat{\beta}_1$ 是斜率有多大，分母 $\hat{\sigma}/\sqrt{S_{xx}}$ 是考虑到数据有多乱、 x 有多散之后斜率估计的不确定性。 T 大 = 斜率相对于噪声够显著 $\Rightarrow$ 拒绝 H_0 。

$$T = \frac{\hat{\beta}_1}{\hat{\sigma}/\sqrt{S_{xx}}} \sim t(n-2) \quad (H_0 \text{ 下})$$

东邪的 tip 12.3

检验统计量 $T = \hat{\beta}_1 / (\hat{\sigma} / \sqrt{S_{xx}})$ 里需要 σ , 但 σ 未知, 要从数据估计。用残差来估:

$$\hat{\sigma}^2 = \frac{SS_e}{n-2}, \quad SS_e = \sum (Y_i - \hat{Y}_i)^2 = S_{yy} - \frac{S_{xy}^2}{S_{xx}}$$

直觉: S_{yy} 是 Y 的总变动, S_{xy}^2/S_{xx} 是被直线解释掉的部分, 剩下的就是残差。

所以流程是: $SS_e \rightarrow \hat{\sigma} \rightarrow T \rightarrow$ 查 $t(n-2)$ 表 $\rightarrow$ 拒绝或不拒绝 H_0 。

● 背景: 已有 $\hat{Y} = 43.5 + 7.5x$, 新来 $x^* = 3$, 有两个不同的问题:

1. $x = 3$ 时, 所有学生的平均成绩是多少? (均值置信区间)
2. $x = 3$ 时, 新来一个具体学生会考多少分? (个体预测区间)

● 均值置信区间: 估的是直线上那个点 $E(Y|x^*) = \beta_0 + \beta_1 x^*$, 不确定性只来自 $\hat{\beta}_0, \hat{\beta}_1$ 的估计误差:

$$\hat{Y}^* \pm t_{\alpha/2}(n-2) \cdot \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

● 个体预测区间: 估的是新个体 $Y^* = \beta_0 + \beta_1 x^* + \varepsilon^*$, 不确定性来自两处: 参数估计误差 + 新个体自己的随机噪声 ε^* :

$$\hat{Y}^* \pm t_{\alpha/2}(n-2) \cdot \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

多出来的“1”就是 ε^* 贡献的方差, 所以预测区间永远比置信区间宽。

 笔记 两种区间形式完全一样:

$$\hat{Y}^* \pm t_{\alpha/2}(n-2) \cdot SE$$

查的是同一张 $t(n-2)$ 表, 区别只在 SE 公式不同。

12.2 方差分析

 笔记 为什么不直接两两 t 检验?

有 k 个组, 两两检验需要做 $\binom{k}{2}$ 次。每次 $\alpha = 0.05$, 但整体至少犯一次错的概率:

$$1 - (1 - 0.05)^{\binom{k}{2}}$$

组数越多错误率膨胀越离谱, $k = 4$ 时已经达到 26%。

ANOVA (Analysis of Variance, 方差分析) 的思路是一次检验解决问题:

$$H_0: \mu_1 = \mu_2 = \cdots = \mu_k$$

用一个统计量 F 判断, 整体错误率就是设定的 α , 不会膨胀。

名字叫“方差分析”而不叫“均值分析”, 是因为它的做法是把数据总变动拆成两部分来比较, 用的是方差的语言 ($SS_T = SS_A + SS_E$)。

定义 12.1 (单因子方差分析模型)

$$y_{ij} = \mu + \mu_i + e_{ij}, \quad e_{ij} \sim N(0, \sigma^2) \text{ iid}$$

k 个组, 第 i 组有 n_i 个观测, $N = \sum n_i$, 约束 $\sum \mu_i = 0$ 。

- μ : 所有组共同的总体均值, “基准线”
- μ_i : 第 i 组相对于基准线的偏移, “这组特别在哪”
- e_{ij} : 个体随机噪声
- 约束 $\sum \mu_i = 0$ 是为了让分解唯一——否则 μ 加大、 μ_i 减小, 无数种组合都能表示同一个值

- $H_0: \mu_1 = \dots = \mu_k = 0$, 即所有组偏移为零, 没有组间差异

 **笔记** 平方和分解 $SS_T = SS_A + SS_E$, 数据的总波动拆成组间和组内两部分:

- $SS_T = \sum_i \sum_j (y_{ij} - \bar{y})^2$: 所有观测值离总均值的距离, 衡量数据整体有多散
- $SS_A = \sum_i n_i (\bar{y}_i - \bar{y})^2$: 每组均值离总均值的距离, 衡量各组之间差异有多大, 各组均值差不多则 SS_A 小
- $SS_E = \sum_i \sum_j (y_{ij} - \bar{y}_i)^2$: 每个观测值离自己组均值的距离, 衡量组内随机噪声, 纯粹是误差

核心逻辑: 用 F 统计量比较组间和组内:

$$F = \frac{MS_A}{MS_E} = \frac{SS_A/(k-1)}{SS_E/(N-k)}$$

- H_0 下: MS_A 和 MS_E 都是 σ^2 的无偏估计, 比值应该接近 1
- H_1 下: 组间差异让 MS_A 偏大, $F \gg 1$ 说明不像随机波动

$F > F_\alpha(k-1, N-k)$ 则拒绝 H_0 。

东邪的 tip 12.4

平方和分解类比柯赫伦定理: SS_T 自由度 $N-1$ 被正交拆成两块:

$$\underbrace{SS_T}_{N-1} = \underbrace{SS_A}_{k-1} + \underbrace{SS_E}_{N-k}$$

柯赫伦定理保证 H_0 下 SS_A 与 SS_E 相互独立, 且:

$$\frac{SS_A}{\sigma^2} \sim \chi^2(k-1), \quad \frac{SS_E}{\sigma^2} \sim \chi^2(N-k)$$

于是 F 统计量服从 F 分布直接来自 F 分布的定义——两个独立卡方除以各自自由度之比:

$$F = \frac{MS_A}{MS_E} = \frac{SS_A/(k-1)}{SS_E/(N-k)} \sim F(k-1, N-k)$$

不是凭空规定的, 是柯赫伦定理的直接推论。

第 13 章 一些思考

13.1 posong 与二项

- $E[X] = \lambda$
- $E[X^2] = E[X(X-1)] + E[X] = \lambda^2 + \lambda$
- $E[X^3] = E[X(X-1)(X-2)] + 3E[X(X-1)] + E[X] = \lambda^3 + 3\lambda^2 + \lambda$
- $E[X^4] = E[X(X-1)(X-2)(X-3)] + 6E[X(X-1)(X-2)] + 7E[X(X-1)] + E[X] = \lambda^4 + 6\lambda^3 + 7\lambda^2 + \lambda$

东邪的 tip 13.1

泊松分布和二项分布中都出现阶乘，自然想问：背后是否对应某个函数？

$$\frac{x^k}{k!} \Rightarrow e^x, \quad C_n^k x^k \Rightarrow (1+x)^n.$$

阶乘来自对 $f(x)$ 反复微分：Taylor 展开系数 $a_n = \frac{f^{(n)}(0)}{n!}$ ，故看见阶乘求和，天然对应微分结构。

笔记

- 泊松分布： $P(X=k) = e^{-\lambda} \frac{\lambda^k}{k!}$ ，归一化来自 $e^{-\lambda} \cdot e^{\lambda} = 1$ ，背后函数为 e^x 。
- 二项分布： $P(X=k) = C_n^k p^k (1-p)^{n-k}$ ，归一化来自 $(p+1-p)^n = 1$ ，背后函数为 $(1+x)^n$ 。
- 极限关系： $\text{Bin}(n, p) \rightarrow \text{Poisson}(\lambda)$ ，函数层面对应 $(1+\frac{x}{n})^n \rightarrow e^x$ 。
- 推广： $n! \Rightarrow \Gamma(n+1)$ ，带阶乘的分布背后往往与 Gamma 函数有关。

东邪的 tip 13.2

- e 最先发现是为了构造一个函数让他的导数等于本身，然后他才和 $\frac{1}{n!}$ 的阶乘求和扯上关系。
- 或者说，看见底下的阶乘的求和我们天然要想到微分。
- 所以级数的发明是为了描述函数吗？其实级数研究的就是函数项级数的系数问题
- 因为 a_n 其实就是相当于微分的系数，而 x^n 是固定的。

东邪的 tip 13.3

然后从哲学上讲他们的核心思想就是把系数和本体拆开来看

13.2 ump 与 umvue

	UMVUE	UMP
目标	找用哪个统计量估计 θ	找拒绝域放在哪里
所在领域	点估计	假设检验
核心条件	指数族 + 完备充分统计量	似然比关于 $T(X)$ 单调 (MLR)
最优标准	无偏中方差最小	α 约束下功效最大
构造方法	Rao-Blackwell + Lehmann-Scheffé	N-P 引理 / MLR 定理

东邪的 tip 13.4

相同点：两者都依赖完备充分统计量 $T(X)$ ，且都在指数族中最容易找到——指数族同时保证了完备充分统计量的存在（为 UMVUE 服务）和 MLR 的成立（为 UMP 服务）。”一致” (uniform) 的含义也相同：对参数空间中所有 θ 成立，而非只在某个点最优。

不同点：UMVUE 的约束是无偏性，优化目标是方差；UMP 的约束是第一类错误 $\leq \alpha$ ，优化目标是功效

$\beta(\theta)$ 。当 UMP 不存在时（如双侧检验），加上无偏约束得到 UMPU，此时 UMVUE 与 UMPU 完全对称：前者是“无偏估计中方差最小”，后者是“无偏检验中功效最大”。