




回归分析

前三章学习笔记

作者：东邪

时间：2026 年 10 月 6 日

版本：1.0

内容：定义、定理与必要公式



不要以为抹消过去，重新来过，即可发生什么改变。——比企谷八幡

目录

第1章 什么是回归	1
回归分析的功能结构	1
1.1 回归对象与条件均值	2
1.2 相关性	2
1.3 构建回归模型的步骤	3
1.4 有向无环图与路径	3
第2章 条件期望函数	4
2.1 条件期望、重期望与最优预测	4
2.2 条件方差与 CEF 误差	5
2.3 线性 CEF 与最优线性预测	5
2.4 条件均值模型的正确设定	6
2.5 拾遗：矩阵求导	7
第3章 古典线性回归模型	8
3.1 经典模型的假设	8
3.2 普通最小二乘估计	9
3.3 投影几何与拟合优度	9
3.4 OLS 的统计性质	10
3.5 正态模型的精确分布	11
3.6 线性限制的假设检验	12
3.7 拾遗：随机矩阵的矩	13
3.8 拾遗：多元正态与二次型	13
3.9 拾遗：约束最小二乘回归	14
第二章作业：条件期望函数	16
1 第一次作业	16
2 第二次作业	19
第三章作业：古典线性回归模型	23
1 第三次作业	23

第 1 章 什么是回归

回归分析的功能结构

回归分析：用解释变量研究响应变量的条件分布

- 研究对象：随机向量 $(Y, X')'$ 与观测样本
 - 条件均值回答平均怎样变化；条件方差回答波动怎样变化
- 描述关系：哪些变量共同变化，怎样组织模型？
 - 工具：协方差、相关系数、领域理论、DAG（第 1 章）
 - 区分相关、预测与因果；因果解释还需识别假设
- 预测响应：给定 X ，怎样预测 Y ？
 - 全部平方可积函数中选 CEF，最小化 MSE（第 2 章）
 - 限制为仿射函数，得到最优线性投影（第 2 章）
 - 用样本矩替代总体矩，得到 OLS（第 3 章）
- 量化不确定性：系数可靠吗，限制成立吗？
 - 工具：外生性、球形方差、Gauss--Markov（第 3 章）
 - 正态假设给出精确分布、 t/F 检验与区间（第 3 章）
 - 已知线性限制可用 CLS，提高估计效率（第 3 章）
 - 大样本理论与高维方法（第 4、5 章，本次正文未展开）
- 检查模型：所拟合的对象是否回答原问题？
 - 正确设定：CEF 与线性投影何时一致（第 2 章）
 - 检查秩、外生性、同方差、正态性各自支持什么结论
 - 拟合优度描述样本解释率；预测需关注样本外表现
- 连接各部分的工具链
 - 条件期望与矩：把预测问题写成正交条件
 - 线性代数与矩阵求导：从正交条件到投影和 OLS
 - 正态向量与二次型：从投影到抽样分布和检验

这棵树是按功能重组的个人学习框架。划分参考 CMU 的 [Cosma Shalizi: Modern Regression \(2015\)](#) 中预测、估计、推断、假设检查与模型选择的安排，以及 [Larry Wasserman: Modern Regression \(2017\)](#) 的课程进路；上树的中文分组和本讲义章次映射由东邪整理。

前三章把“研究关系”连到“选择总体预测器”，再连到“样本估计及推断”。预测损失、模型设定与因果识别是不同问题，不能仅凭显著系数或较高 R^2 替代后两者的论证。

本章的作用

- 用相关系数度量线性共同变动。
- 用 DAG 检查路径与控制变量的作用。
- 用条件分布与领域知识提出模型。

1.1 回归对象与条件均值

定义 1.1 (回归分析与 CEF)

响应变量 Y 为标量, 解释变量 X 为向量。回归分析研究 Y 随 X 的取值而变化的规律, 尤其是条件分布及条件均值。若 $\mathbb{E}|Y| < \infty$, 记

$$\mu(x) = \mathbb{E}[Y | X = x], \quad Y = \mu(X) + e, \quad \mathbb{E}[e | X] = 0.$$

在连续情形且 $f_X(x) > 0$ 时, $f_{Y|X}(y | x) = f_{X,Y}(x, y) / f_X(x)$,

$$\mu(x) = \int_{\mathbb{R}} y f_{Y|X}(y | x) dy.$$

可用于描述关系和预测; 把关系解释为因果效应, 需要额外识别条件。



命题 1.1 (二元正态的回归关系)

设 (X, Y) 联合正态, 均值为 μ_X, μ_Y , 方差为 $\sigma_X^2, \sigma_Y^2 > 0$, 相关参数 $|\rho| < 1$ 。令 $z_X = (x - \mu_X) / \sigma_X$, $z_Y = (y - \mu_Y) / \sigma_Y$, 其联合密度为

$$f(x, y) = \frac{\exp\left[-\frac{z_X^2 - 2\rho z_X z_Y + z_Y^2}{2(1-\rho^2)}\right]}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}}.$$

边缘分布分别为 $N(\mu_X, \sigma_X^2)$ 、 $N(\mu_Y, \sigma_Y^2)$, 并且

$$Y | X \sim N\left(\mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (X - \mu_X), \sigma_Y^2 (1 - \rho^2)\right),$$

$$X | Y \sim N\left(\mu_X + \rho \frac{\sigma_X}{\sigma_Y} (Y - \mu_Y), \sigma_X^2 (1 - \rho^2)\right).$$

两个方向的斜率为 $\beta_{Y|X} = \rho\sigma_Y/\sigma_X$ 与 $\beta_{X|Y} = \rho\sigma_X/\sigma_Y$; 乘积为 ρ^2 , 当两方差相等时两斜率相同。



1.2 相关性

定义 1.2 (相关系数)

若 X, Y 的二阶矩有限且方差均正, 定义

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} = \frac{\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]}{\sqrt{\text{Var}(X) \text{Var}(Y)}}.$$

其中 $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$ 。



定理 1.1 (相关系数与 Cauchy-Schwarz)

设 X, Y 二阶矩有限。

1. 若 X, Y 独立, 则协方差为零; 方差正时 $\rho_{XY} = 0$ 。一般逆命题不成立。
2. $\mathbb{E}|XY| \leq \sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}$ 。
3. 若两方差均正, 则 $|\rho_{XY}| \leq 1$ 。

联合正态时, 零相关等价于独立。



定义 1.3 (样本相关系数)

对于配对样本 $(X_i, Y_i)_{i=1}^n$, 令 $\bar{X} = n^{-1} \sum_i X_i$, $\bar{Y} = n^{-1} \sum_i Y_i$, $s_X^2 = n^{-1} \sum_i (X_i - \bar{X})^2$, $s_Y^2 = n^{-1} \sum_i (Y_i - \bar{Y})^2$. 若 $s_X s_Y > 0$, 定义

$$R = \frac{n^{-1} \sum_i X_i Y_i - \bar{X} \bar{Y}}{s_X s_Y} = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_i (X_i - \bar{X})^2 \sum_i (Y_i - \bar{Y})^2}}.$$

**定理 1.2 (样本相关系数的一致性)**

若配对样本独立同分布, $\mathbb{E}X^2, \mathbb{E}Y^2 < \infty$ 且总体两方差均正, 则在样本相关系数定义的事件上, $R \xrightarrow{P} \rho_{XY}$; 该事件的概率趋于 1。

**命题 1.2 (相关性与因果关系)**

相关系数只衡量线性关联。零相关不能排除非线性依赖; 相关不等于因果, 共同原因、选择机制等都可能产生关联。用回归系数解释因果效应时, 必须另行说明研究设计和识别假设。



1.3 构建回归模型的步骤

命题 1.3 (四步建模及两类假设)

1. 收集数据并作描述性分析, 寻找需要解释的模式。
2. 结合领域知识建立理论模型, 确定对象、变量和作用机制。
3. 选择函数形式、未知参数及误差条件, 进行估计和检验。
4. 用模型解释或预测, 并检查结论是否适用于原问题。

要分清函数形式及变量选择等模型设定假设, 与估计和推断所需的统计假设; 估计量表现良好并不能证明函数形式正确。



1.4 有向无环图与路径

定义 1.4 (DAG)

有向无环图 (directed acyclic graph) 以节点表示变量, 以有向边表示假定的因果方向, 且不存在有向循环。讲义用实心节点表示可观测变量、空心节点表示不可观测变量。箭头编码的是模型假设, 不能仅从相关系数推出。

**命题 1.4 (三种基本路径的功能)**

链 $X \rightarrow M \rightarrow Y$ 表示中介路径; 分叉 $X \leftarrow C \rightarrow Y$ 表示共同原因路径; 碰撞结构 $X \rightarrow C \leftarrow Y$ 的中间节点称为碰撞点。按 DAG 的路径阻断规则, 前两条路径在未控制中间节点时开放, 控制中间节点则阻断; 碰撞路径默认阻断, 控制碰撞点或其后代可能使它开放。在采用图的 Markov 条件时, 所有路径被阻断 (d-separation) 才给出相应条件独立; 一条路径开放只表示图不强制独立, 不保证实际相关系数非零。控制混杂变量可阻断相应后门路径, 但能否识别因果效应须检查全部相关路径和识别条件。



第2章 条件期望函数

本章的作用

- 条件期望是平方损失下的最优预测。
- 正确设定连接投影系数与真实条件均值参数。
- 线性投影把全部函数的优化限制为仿射函数。

本章 $Y \in \mathbb{R}$, 总体解释向量 $X \in \mathbb{R}^K$; 含截距时统一写成 $X = (1, X_1, \dots, X_k)'$, $K = k + 1$ 。

2.1 条件期望、重期望与最优预测

定义 2.1 (条件期望函数)

若 $\mathbb{E}|Y| < \infty$, 定义 $\mu(x) = \mathbb{E}[Y | X = x]$, 称为条件期望函数 (CEF); 作为随机变量写成 $\mu(X) = \mathbb{E}[Y | X]$ 。连续情形可用条件密度积分, 离散情形用条件分布求和。等式按几乎处处意义理解。

命题 2.1 (条件期望的基本性质)

在所涉及随机变量可积的条件下, 对于常数 a, b 和可测函数 g ,

$$\mathbb{E}[aY + b | X] = a\mathbb{E}[Y | X] + b, \quad \mathbb{E}[g(X)Y | X] = g(X)\mathbb{E}[Y | X].$$

若 X, Y 独立, 则 $\mathbb{E}[Y | X] = \mathbb{E}Y$, 以及 $\mathbb{E}[g(X)Y | X] = g(X)\mathbb{E}Y$ 。乘积公式要求 $g(X)Y$ 可积。

定义 2.2 (均值独立)

若 $\mathbb{E}[Y | X] = \mathbb{E}Y$, 称 Y 均值独立于 X 。此性质通常不对称。相互独立推出两个方向的均值独立; 若 X, Y 二阶矩有限, 任一方向的均值独立均推出 $\text{Cov}(X, Y) = 0$ 。这些逆命题一般不成立。

定理 2.1 (重期望公式 I)

若 $\mathbb{E}|Y| < \infty$, 则对任意随机向量 X ,

$$\mathbb{E}_X [\mathbb{E}_Y [Y | X]] = \mathbb{E}_Y [Y].$$

定理 2.2 (重期望公式 II)

对任意可测函数 $G(X, Y)$, 若 $\mathbb{E}|G(X, Y)| < \infty$, 则

$$\mathbb{E}_X [\mathbb{E}_Y [G(X, Y) | X]] = \mathbb{E}_{X, Y} [G(X, Y)].$$

定义 2.3 (均方误差)

用可测函数 $g(X)$ 预测 Y , 定义均方误差

$$\text{MSE}(g) = \mathbb{E}[(Y - g(X))^2].$$

以下最优预测结论要求 Y 及候选预测函数平方可积。

定理 2.3 (最优预测)

设 $\mathbb{E}Y^2 < \infty$, $\mathbb{F} = \{g : \mathbb{R}^K \rightarrow \mathbb{R} : g \text{ 可测}, \mathbb{E}[g(X)^2] < \infty\}$ 。则

$$\mu(X) = \mathbb{E}[Y | X] = \arg \min_{g \in \mathbb{F}} \text{MSE}(g).$$

更准确地, 最优预测在几乎处处意义下唯一, 且

$$\text{MSE}(g) = \mathbb{E}[(Y - \mu(X))^2] + \mathbb{E}[(\mu(X) - g(X))^2].$$



2.2 条件方差与 CEF 误差

定义 2.4 (条件方差)

若 $\mathbb{E}Y^2 < \infty$, 定义

$$\begin{aligned}\sigma^2(X) &= \text{Var}(Y | X) = \mathbb{E}[(Y - \mathbb{E}[Y | X])^2 | X] \\ &= \mathbb{E}[Y^2 | X] - (\mathbb{E}[Y | X])^2.\end{aligned}$$

在 $X = x$ 时记为 $\sigma^2(x)$.



定理 2.4 (条件方差分解)

若 $\mathbb{E}Y^2 < \infty$, 则

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y | X)] + \text{Var}(\mathbb{E}[Y | X]).$$



定义 2.5 (CEF 误差)

定义 $e = Y - \mu(X)$, 其中 $\mu(X) = \mathbb{E}[Y | X]$ 。由此得 $Y = \mu(X) + e$ 。反过来, 若 $Y = \mu(X) + e$, Y, e 可积、 μ 可测且 $\mathbb{E}[e | X] = 0$, 则 $\mu(X) = \mathbb{E}[Y | X]$ 。



定理 2.5 (CEF 误差的正交性)

若 $\mathbb{E}|Y| < \infty$, $e = Y - \mathbb{E}[Y | X]$, 则

$$\mathbb{E}[e | X] = 0, \quad \mathbb{E}e = 0.$$

对任意可测函数 h , 若 $\mathbb{E}|h(X)e| < \infty$, 还有 $\mathbb{E}[h(X)e] = 0$ 。乘积可积条件不可省略。



定义 2.6 (同方差与异方差)

对于平方可积的 CEF 误差, $\text{Var}(e | X) = \sigma^2(X)$ 。若 $\sigma^2(x) = \sigma^2$ 不依赖 x (几乎处处), 称误差同方差; 若依赖于 x , 称异方差。零条件均值并不推出同方差或统计独立。



2.3 线性 CEF 与最优线性预测

定义 2.7 (仿射函数)

令 $X = (1, X_1, \dots, X_k)' \in \mathbb{R}^K$, $K = k + 1$, $\beta = (\beta_0, \dots, \beta_k)'$ 。仿射函数类为

$$\mathbb{A} = \left\{ g(X) = X'\beta = \beta_0 + \sum_{j=1}^k \beta_j X_j : \beta \in \mathbb{R}^K \right\}.$$

把常数 1 放入解释向量后, 可统一称为对扩充向量 X 的线性函数。



定义 2.8 (线性模型与线性 CEF)

当 $g \in \mathbb{A}$ 时, $Y = g(X) + e = X'\beta + e$ 称为 Y 对 X 的线性模型。若另有 $\mathbb{E}[e | X] = 0$, 则 $\mathbb{E}[Y | X] = X'\beta$, 称为线性 CEF 模型。仅有代数分解并不保证条件均值线性。



命题 2.2 (线性预测的矩与识别条件 (假设 2.2.1))

设 $X \in \mathbb{R}^K$ 、 $Y \in \mathbb{R}$ ，满足

$$\mathbb{E}Y^2 < \infty, \quad \mathbb{E}\|X\|^2 < \infty, \quad Q_{XX} := \mathbb{E}[XX'] \succ 0.$$

前两条保证二阶矩和混合矩有限；正定性保证 Q_{XX} 可逆，排除总体上的精确线性依赖。

定义 2.9 (最优线性预测与投影系数)

在上述矩条件下，最优线性预测（线性投影）定义为

$$L(Y | X) = X'\beta^*, \quad \beta^* = \arg \min_{\beta \in \mathbb{R}^K} \mathbb{E}[(Y - X'\beta)^2].$$

称 β^* 为线性投影系数。目标函数为

$$S(\beta) = \mathbb{E}Y^2 - 2\beta'\mathbb{E}[XY] + \beta'Q_{XX}\beta.$$

定理 2.6 (投影系数的存在唯一性)

在假设 2.2.1 的有限二阶矩与正定性条件下， β^* 存在且唯一，

$$\beta^* = Q_{XX}^{-1}\mathbb{E}[XY].$$

正规方程为 $Q_{XX}\beta^* = \mathbb{E}[XY]$ ，Hessian 为 $2Q_{XX} \succ 0$ 。

定理 2.7 (投影误差的刻画)

在假设 2.2.1 的条件下，令 $Y = X'\beta + e_L$ ，则

$$\beta = \beta^* \iff \mathbb{E}[Xe_L] = 0.$$

若 X 含常数项，则 $\mathbb{E}e_L = 0$ 。一般 $\mathbb{E}[e_L | X]$ 未必为零；CEF 误差与投影误差只在线性 CEF 的情形一致。

命题 2.3 (CEF 与线性投影的损失比较)

设上述条件成立，并令 $e_L = Y - X'\beta^*$ 。则

$$\mathbb{E}[(Y - X'\beta^*)^2] = \mathbb{E}[(Y - \mu(X))^2] + \mathbb{E}[(\mu(X) - X'\beta^*)^2].$$

因此最优线性预测的 MSE 不小于 CEF 的 MSE；等号当且仅当 $\mu(X) = X'\beta^*$ 几乎处处。不能把两个预测器本身写成大小不等式。

2.4 条件均值模型的正确设定

定义 2.10 (正确设定与错误设定)

对 $Y \in \mathbb{R}$ 、 $X \in \mathbb{R}^K$ ，若存在 $\beta^o \in \mathbb{R}^K$ 使

$$\mathbb{E}[Y | X] = X'\beta^o \quad \text{几乎处处},$$

称线性模型对条件均值正确设定；若不存在这样的参数，称错误设定。正确设定等价于存在 β^o 使误差 $Y - X'\beta^o$ 的条件均值为零。

定理 2.8 (正确设定连接 CEF 与投影)

在假设 2.2.1 的矩条件下，若线性模型对 $\mathbb{E}[Y | X]$ 正确设定，则：

1. 存在 β^o 和 $e = Y - X'\beta^o$ ，使 $Y = X'\beta^o + e$ 且 $\mathbb{E}[e | X] = 0$ 。
2. 线性投影系数满足 $\beta^* = \beta^o$ 。

对于连续解释变量 X_j ，线性 CEF 给出偏导 $\partial E[Y | X] / \partial X_j = \beta_j^o$ ；截距不属于这一偏导，因果解释仍需额外条件。



2.5 拾遗：矩阵求导

定义 2.11 (梯度与导数排列)

对可微标量函数 $g: \mathbb{R}^K \rightarrow \mathbb{R}$ ，采用列梯度

$$\frac{\partial g(x)}{\partial x} = (\partial g / \partial x_1, \dots, \partial g / \partial x_K)'.$$

对列向量函数 F ，Jacobian 的 (i, j) 元为 $\partial F_i / \partial x_j$ 。行向量函数的按列梯度堆叠与此互为转置。



定理 2.9 (线性与二次型求导)

设 $A \in \mathbb{R}^{K \times K}$ 、 $x, w \in \mathbb{R}^K$ ， A, w 不依赖 x 。按上述排列约定，

$$\begin{aligned} \frac{\partial(w'x)}{\partial x} &= \frac{\partial(x'w)}{\partial x} = w, \\ \frac{\partial(x'A)}{\partial x} &= A, \quad \frac{\partial(Ax)}{\partial x'} = A, \\ \frac{\partial(x'Ax)}{\partial x} &= (A + A')x, \\ \frac{\partial^2(x'Ax)}{\partial x \partial x'} &= A + A'. \end{aligned}$$

若 A 对称，后两式化为 $2Ax$ 和 $2A$ 。



第3章 古典线性回归模型

本章的作用

- OLS 用样本矩估计总体线性投影系数。
- 外生性和球形方差支持无偏性与 BLUE；条件正态性支持精确推断。
- 投影几何解释拟合值、残差与自由度。

总体单个观测的解释向量写为 $X_i \in \mathbb{R}^K$ ；样本设计矩阵写为 $\mathbf{X} \in \mathbb{R}^{n \times K}$ ，第 i 行为 X_i' 。本章的分布与独立性均明确以 $\mathbf{X}$ 为条件。

3.1 经典模型的假设

命题 3.1 (线性 (假设 3.1.1))

设 $(Y_i, X_i')_{i=1}^n$ 为可观测随机样本，

$$Y_i = X_i' \beta + u_i, \quad i = 1, \dots, n, \quad \beta \in \mathbb{R}^K.$$

u_i 是不可观测扰动， $Y = (Y_1, \dots, Y_n)'$ 、 $u = (u_1, \dots, u_n)'$ ，于是

$$Y = \mathbf{X} \beta + u, \quad \mathbf{X} = (X_1, \dots, X_n)', \quad \mathbf{X}' \mathbf{X} = \sum_i X_i X_i'.$$

含截距时 $X_i = (1, X_{i1}, \dots, X_{ik})'$ ， $K = k + 1$ 。

命题 3.2 (严格外生性 (假设 3.1.2))

对于上述样本模型，假设

$$\mathbb{E}[u_i | \mathbf{X}] = \mathbb{E}[u_i | X_1, \dots, X_n] = 0, \quad i = 1, \dots, n.$$

即 $\mathbb{E}[u | \mathbf{X}] = 0$ 。从而 $\mathbb{E}u_i = 0$ ，且在相应乘积可积时 $\mathbb{E}[X_i u_j] = 0$ 、 $\text{Cov}(X_i, u_j) = 0$ 对所有 i, j 成立。严格外生性一般强于逐观测 $\mathbb{E}[u_i | X_i] = 0$ ；当观测对 (X_i, u_i) 独立同分布时，两条件等价。

命题 3.3 (秩条件 (假设 3.1.3))

假设 $\text{rank}(\mathbf{X}) = K < n$ (随机设计时几乎必然)。则列线性无关， $\text{rank}(\mathbf{X}' \mathbf{X}) = K$ ， $\mathbf{X}' \mathbf{X}$ 非奇异、可逆且正定。这排除严格多重共线性，确保 OLS 参数解唯一并留下正残差自由度。

命题 3.4 (球形误差方差 (假设 3.1.4))

假设 $\sigma^2 > 0$ 且

$$\mathbb{E}[u_i^2 | \mathbf{X}] = \sigma^2, \quad \mathbb{E}[u_i u_j | \mathbf{X}] = 0 \quad (i \neq j).$$

结合严格外生性，等价于

$$\text{Var}(u | \mathbf{X}) = \mathbb{E}[u u' | \mathbf{X}] = \sigma^2 I_n.$$

这同时要求条件同方差与跨观测条件不相关；不相关本身不等于独立。

3.2 普通最小二乘估计

定义 3.1 (OLS)

线性模型的普通最小二乘估计定义为

$$\hat{\beta} = \arg \min_{b \in \mathbb{R}^K} \text{SSE}(b), \quad \text{SSE}(b) = \sum_i (Y_i - X_i' b)^2 = (Y - \mathbf{X}b)'(Y - \mathbf{X}b).$$

它用样本平方损失替代总体平方损失。



定理 3.1 (OLS 的显式解)

在线性模型与秩条件下，OLS 解存在且唯一，

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'Y = \left(\frac{1}{n} \sum_i X_i X_i' \right)^{-1} \frac{1}{n} \sum_i X_i Y_i.$$

正规方程为 $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'Y$ ，目标函数的 Hessian 为 $2\mathbf{X}'\mathbf{X} \succ 0$ 。



定义 3.2 (拟合值、残差与方差估计)

定义 $\hat{Y} = \mathbf{X}\hat{\beta}$ 和 $\hat{u} = Y - \hat{Y}$ 。则

$$\hat{u} = u + \mathbf{X}(\beta - \hat{\beta}).$$

扰动 u 是模型中不可观测的真实误差，残差 $\hat{u}$ 由估计参数计算，两者不可混同。定义

$$\hat{\sigma}^2 = \frac{\hat{u}'\hat{u}}{n}, \quad s^2 = \frac{\hat{u}'\hat{u}}{n-K}.$$

后者在经典假设下修正自由度，并非任意模型下都无偏。



定理 3.2 (残差的样本正交性)

在线性模型与秩条件下，

$$\mathbf{X}'\hat{u} = 0, \quad \hat{Y}'\hat{u} = 0.$$

若解释变量含常数项，则 $\sum_i \hat{u}_i = 0$ ，进而 $\bar{\hat{Y}} = \bar{Y}$ 。这是 OLS 的代数性质，不要求正态性、外生性或同方差。



3.3 投影几何与拟合优度

定义 3.3 (投影矩阵与消灭矩阵)

若 $\mathbf{X}$ 满列秩，定义

$$P = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}', \quad M = I_n - P.$$

P 是到 $\mathcal{C}(\mathbf{X})$ 的正交投影， M 是到该列空间正交补的投影。于是

$$\hat{Y} = PY, \quad \hat{u} = MY = Mu, \quad P\mathbf{X} = \mathbf{X}, \quad M\mathbf{X} = 0, \quad PM = MP = 0.$$



定理 3.3 (投影矩阵的性质)

对任意满列秩 $\mathbf{X} \in \mathbb{R}^{n \times K}$ ， $n \geq K$ ，投影矩阵 P 满足

$$P' = P, \quad P'P = P^2 = P, \quad \text{tr}(P) = K, \quad \text{rank}(P) = K.$$

P 的特征值为 K 个 1 和 $n - K$ 个 0。



定理 3.4 (消灭矩阵的性质)

对任意满秩 $\mathbf{X} \in \mathbb{R}^{n \times K}$, $n \geq K$, $M = I_n - P$ 满足

$$M' = M, \quad M'M = M^2 = M, \quad \text{tr}(M) = n - K, \quad \text{rank}(M) = n - K.$$

同时 $M\mathbf{X} = 0$.

**命题 3.5 (正交分解与平方和)**

满秩时 $Y = \hat{Y} + \hat{u}$ 且 $\hat{Y}'\hat{u} = 0$, 所以 $Y'Y = \hat{Y}'\hat{Y} + \hat{u}'\hat{u}$. 若含截距, 中心化后有

$$\text{TSS} = \sum_i (Y_i - \bar{Y})^2, \quad \text{ESS} = \sum_i (\hat{Y}_i - \bar{Y})^2,$$

$$\text{RSS} = \hat{u}'\hat{u}, \quad \text{TSS} = \text{ESS} + \text{RSS}.$$

对应于空间维数 (自由度) 为 $n - 1 = (K - 1) + (n - K)$. 含截距条件不能省略。

**定义 3.4 (决定系数)**

含截距且 $\text{TSS} > 0$ 时, 决定系数定义为

$$\mathcal{R}^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}, \quad 0 \leq \mathcal{R}^2 \leq 1.$$

它度量样本中被线性拟合解释的中心化平方和比例。无截距时这两个表达式一般不等价。

**定理 3.5 (加入变量后的决定系数)**

在同一响应向量、同一样本、含截距且 $\text{TSS} > 0$ 的两个嵌套 OLS 模型中, 较大模型在原 k 个解释变量外增加 $q \geq 1$ 个变量; 两设计矩阵满足相应秩条件。则

$$\text{RSS}_2 \leq \text{RSS}_1, \quad \mathcal{R}_2^2 \geq \mathcal{R}_1^2.$$

这只说明训练样本拟合不会变差, 不保证预测性能提高。

**定义 3.5 (调整决定系数)**

含截距、 $n > K$ 且 $\text{TSS} > 0$ 时, 定义

$$\bar{\mathcal{R}}^2 = 1 - \frac{\text{RSS}/(n - K)}{\text{TSS}/(n - 1)} = 1 - \frac{n - 1}{n - K}(1 - \mathcal{R}^2).$$

它通过自由度惩罚解释变量数量, 增加变量不保证其上升; 可为负。



3.4 OLS 的统计性质

定理 3.6 (无偏性)

在线性模型、严格外生性和秩条件下,

$$\mathbb{E}[\hat{\beta} | \mathbf{X}] = \beta.$$

若无条件期望存在, 则 $\mathbb{E}\hat{\beta} = \beta$. 所有无条件矩结论均需相应可积性; 随机矩阵逆的可积性并非仅由逐样本满秩保证。

**定理 3.7 (OLS 条件协方差)**

在线性模型、严格外生性、秩条件和球形误差方差条件下,

$$V_{\hat{\beta}} := \text{Var}(\hat{\beta} | \mathbf{X}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}.$$



定义 3.6 (线性无偏估计量)

若估计量 $\tilde{\beta} = LY$, 其中 $L \in \mathbb{R}^{K \times n}$ 可依赖于 $\mathbf{X}$, 但给定 $\mathbf{X}$ 后不依赖于 Y , 称其对 Y 为线性估计。若对所有 β , $\mathbb{E}[\tilde{\beta} | \mathbf{X}] = \beta$, 称线性无偏估计。在外生模型下, 这等价于 $L\mathbf{X} = I_K$ 。

**定理 3.8 (Gauss–Markov)**

在线性模型、严格外生性、秩条件及球形误差方差条件下, OLS 是最优线性无偏估计 (BLUE)。对于任意线性无偏估计量 $\tilde{\beta}$,

$$\text{Var}(\tilde{\beta} | \mathbf{X}) - \text{Var}(\hat{\beta} | \mathbf{X}) \succeq 0.$$

“最小”指协方差矩阵的半正定顺序; 不声称在全部非线性或有偏估计量中最优, 也不要求正态误差。

**定理 3.9 (残差的矩性质)**

在线性模型、严格外生性、秩条件及球形误差方差条件下,

$$\mathbb{E}[\hat{u} | \mathbf{X}] = 0, \quad \text{Var}(\hat{u} | \mathbf{X}) = \sigma^2 M, \quad \text{Cov}(\hat{\beta}, \hat{u} | \mathbf{X}) = 0.$$

条件不相关尚不能推出条件独立。

**定理 3.10 (方差估计的无偏性)**

在线性模型、严格外生性、秩条件及球形误差方差条件下,

$$\mathbb{E}[\hat{u}'\hat{u} | \mathbf{X}] = (n - K)\sigma^2, \quad \mathbb{E}[s^2 | \mathbf{X}] = \sigma^2.$$

所以 $\mathbb{E}[\hat{\sigma}^2 | \mathbf{X}] = (n - K)\sigma^2/n$; OLS 协方差的无偏估计为

$$\hat{V}_{\hat{\beta}} = s^2(\mathbf{X}'\mathbf{X})^{-1}, \quad \mathbb{E}[\hat{V}_{\hat{\beta}} | \mathbf{X}] = V_{\hat{\beta}}.$$



3.5 正态模型的精确分布

命题 3.6 (条件正态性 (假设 3.5.1))

假设 $u | \mathbf{X} \sim N(0, \sigma^2 I_n)$, $\sigma^2 > 0$ 。该条件推出严格外生性和球形方差, 且给定 $\mathbf{X}$ 时各扰动独立。其条件密度和似然为

$$f(u | \mathbf{X}) = (2\pi\sigma^2)^{-n/2} \exp[-u'u/(2\sigma^2)],$$

$$\ell(b, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{(Y - \mathbf{X}b)'(Y - \mathbf{X}b)}{2\sigma^2}.$$

在满列秩且 RSS 正的情形, 极大似然解为 $\hat{b}_{\text{MLE}} = \hat{\beta}$, $\hat{\sigma}_{\text{MLE}}^2 = \text{RSS}/n$ 。

**定理 3.11 (OLS 的条件正态分布)**

在线性模型、秩条件和条件正态性下, $n > K$,

$$\hat{\beta} | \mathbf{X} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}).$$

**定理 3.12 (残差分布及条件独立性)**

在线性模型、秩条件和条件正态性下, $n > K$,

$$\hat{u} | \mathbf{X} \sim N(0, \sigma^2 M).$$

给定 $\mathbf{X}$ 时, $\hat{u}$ 与 $\hat{\beta}$ 独立。因为 M 秩为 $n - K < n$, 这个残差正态分布是退化的。



定理 3.13 (误差方差估计的分布)

在线性模型、秩条件和条件正态性下, $n > K$,

$$\frac{(n-K)s^2}{\sigma^2} \mid \mathbf{X} \sim \chi_{n-K}^2.$$

给定 $\mathbf{X}$ 时, s^2 与 $\hat{\beta}$ 独立。这里的条件独立不能一概改成无条件独立。



3.6 线性限制的假设检验

定义 3.7 (线性限制与拒绝域)

令 $R \in \mathbb{R}^{J \times K}$ 满行秩, $r \in \mathbb{R}^J$, $1 \leq J \leq K$, 检验

$$H_0: R\beta = r, \quad H_1: R\beta \neq r.$$

检验用原假设下的统计量分布确定显著性水平 α 的拒绝域。落在拒绝域时拒绝 H_0 ; 没有拒绝不能当作证明 H_0 为真。令 $Q = (\mathbf{X}'\mathbf{X})^{-1}$, 则 $RQR' \succ 0$ 。

**定理 3.14 (限制估计量的正态分布)**

在线性模型、秩条件和条件正态性下, 若 $H_0: R\beta = r$ 成立, 且 R 满行秩,

$$R\hat{\beta} - r \mid \mathbf{X} \sim N(0, \sigma^2 RQR').$$

**定理 3.15 (单个限制的 t 检验)**

在线性模型、秩条件、条件正态性和 $H_0: R\beta = r$ 下, $n > K$, $J = 1$ 且 $R \neq 0$,

$$T = \frac{R\hat{\beta} - r}{\sqrt{s^2 RQR'}} \mid \mathbf{X} \sim t_{n-K}.$$

双侧水平 α 检验在 $|T| > t_{n-K, 1-\alpha/2}$ 时拒绝。对单个系数的置信区间为

$$\hat{\beta}_j \pm t_{n-K, 1-\alpha/2} \sqrt{s^2 Q_{jj}}.$$

**命题 3.7 (联合限制的 F 统计量)**

在相同正态模型条件下, R 满行秩, 且 H_0 成立, 则

$$F = \frac{(R\hat{\beta} - r)'(RQR')^{-1}(R\hat{\beta} - r)}{Js^2} \mid \mathbf{X} \sim F_{J, n-K}.$$

水平 α 检验在 $F > F_{J, n-K, 1-\alpha}$ 时拒绝。 $J = 1$ 时 $F = T^2$ 。

**定理 3.16 (约束回归形式的 F 检验)**

在线性模型、秩条件、条件正态性及 $H_0: R\beta = r$ 下, $n > K$, R 有 J 个独立限制。令 $\tilde{u}$ 为约束最小二乘残差, $\hat{u}$ 为无约束 OLS 残差, 则

$$F_1 = \frac{(\tilde{u}'\tilde{u} - \hat{u}'\hat{u})/J}{\hat{u}'\hat{u}/(n-K)} \mid \mathbf{X} \sim F_{J, n-K}.$$

它与上面的二次型形式相等。

**命题 3.8 (所有斜率的联合检验)**

含截距模型有 $K - 1 \geq 1$ 个斜率。检验所有斜率为零时, 约束拟合为 $\bar{Y}$, 故约束 RSS 等于 TSS。若 TSS

正，则

$$F = \frac{\mathcal{R}^2/(K-1)}{(1-\mathcal{R}^2)/(n-K)}.$$

在上述正态模型与原假设下， $F | \mathbf{X} \sim F_{K-1, n-K}$ 。



3.7 拾遗：随机矩阵的矩

定义 3.8 (随机向量协方差)

随机矩阵期望逐元素定义，要求每个元素可积。对于二阶矩有限的向量 X, Y ,

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)'], \quad \text{Var}(X) = \text{Cov}(X, X).$$

固定矩阵 A, B 满足维度相容时， $\text{Cov}(AX, BY) = A \text{Cov}(X, Y) B'$ 。



定理 3.17 (期望的线性性质)

若随机矩阵或向量 X, Y 的元素可积， A, B 为维度相容的常数矩阵，则

$$\mathbb{E}[AX + BY] = A\mathbb{E}[X] + B\mathbb{E}[Y].$$

对于可积方阵， $\text{tr}(\mathbb{E}X) = \mathbb{E}(\text{tr} X)$ 。



定理 3.18 (协方差矩阵的性质)

若 $X \in \mathbb{R}^K$ 且 $\mathbb{E}[X'X] < \infty$ ，记 $\mu = \mathbb{E}X$ ， A 为常数矩阵、 b 为常数向量，则

$$\text{Var}(X) \succeq 0, \quad \text{Var}(X) = \mathbb{E}[XX'] - \mu\mu', \quad \text{Var}(AX + b) = A \text{Var}(X) A'.$$



命题 3.9 (二次型期望的必要公式)

设 X 二阶矩有限， $\mu = \mathbb{E}X$ 、 $\Sigma = \text{Var}(X)$ ， A 为常数方阵，则

$$\mathbb{E}[X'AX] = \text{tr}(A\Sigma) + \mu' A \mu.$$

此式把 RSS 的期望转化为投影矩阵的迹，是自由度修正的工具。



3.8 拾遗：多元正态与二次型

定义 3.9 (多元正态分布)

若 $Z \sim N(0, I_m)$ ， $Y = \mu + BZ \in \mathbb{R}^d$ ，则称 Y 多元正态，记 $Y \sim N(\mu, \Sigma)$ ，其中 $\Sigma = BB'$ ， $\mathbb{E}Y = \mu$ 、 $\text{Var}(Y) = \Sigma$ 。若 $\Sigma \succ 0$ ，其密度为

$$f(y) = (2\pi)^{-d/2} |\Sigma|^{-1/2} \exp[-(y - \mu)' \Sigma^{-1} (y - \mu)/2].$$

若 Σ 奇异，分布仍可由仿射表示定义，但不能使用这条相对于 $\mathbb{R}^d$ Lebesgue 测度的密度公式。



定理 3.19 (正态向量的仿射变换)

若 $Y \sim N(\mu, \Sigma)$ ， a, C 为维度相容的常数向量和矩阵，则

$$a + CY \sim N(a + C\mu, C\Sigma C').$$



定理 3.20 (分块正态分布)

设 $Y = (Y_1', Y_2')'$ 联合正态，均值分块为 $(\mu_1', \mu_2')'$ ，协方差分块为 $(\Sigma_{ij})_{i,j=1,2}$ 。则

1. $Y_1 \sim N(\mu_1, \Sigma_{11})$ 。

2. 若 Σ_{22} 可逆，则

$$Y_1 | Y_2 \sim N(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(Y_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}).$$

3. 若 $\Sigma_{12} = 0$ ，则 Y_1, Y_2 独立；联合正态下此条件也必要。

**定理 3.21 (正态平方和与卡方分布)**

1. 若 $Y \sim N(0, I_n)$ ，则 $Y'Y \sim \chi_n^2$ 。

2. 若 $Y \sim N(0, \Sigma)$ 且 $\Sigma \succ 0$ ，则 $Y'\Sigma^{-1}Y \sim \chi_n^2$ 。

3. 若 $Y \sim N(\mu, I_n)$ ，则 $Y'Y \sim \chi_n^2(\lambda)$ ， $\lambda = \mu'\mu$ 。

4. 若 $Y \sim N(\mu, \Sigma)$ 且 $\Sigma \succ 0$ ，则 $Y'\Sigma^{-1}Y \sim \chi_n^2(\lambda)$ ， $\lambda = \mu'\Sigma^{-1}\mu$ 。

非中心参数统一采用平方范数惯例，不带 1/2 因子。

**定理 3.22 (正态投影二次型)**

设 Q 是非随机 $n \times n$ 对称幂等矩阵， $\text{rank } Q = r \leq n$ 。若 $Y \sim N(0, I_n)$ ，则

$$Y'QY \sim \chi_r^2.$$

更一般地，若 $Z \sim N(\mu, I_n)$ ，则 $Z'QZ \sim \chi_r^2(\lambda)$ ， $\lambda = \mu'Q\mu$ 。 $r = 0$ 时按恒为零的退化分布理解。

**定理 3.23 (线性形式与二次型的独立性)**

若 $Y \sim N(0, I_n)$ ， $A \in \mathbb{R}^{m \times n}$ ， $B \in \mathbb{R}^{n \times n}$ 为对称常数矩阵，且 $AB = 0$ ，则 AY 与 $Y'BY$ 独立。

**定理 3.24 (两个投影二次型的独立性)**

若 $Y \sim N(0, I_n)$ ， A, B 为 $n \times n$ 对称幂等常数矩阵，则

$$Y'AY \text{ 与 } Y'BY \text{ 独立} \iff AB = 0.$$



3.9 拾遗：约束最小二乘回归

定义 3.10 (CLS 及其显式解)

令 $Q = (\mathbf{X}'\mathbf{X})^{-1}$ ， $R \in \mathbb{R}^{J \times K}$ 满行秩， $1 \leq J \leq K$ ， $r \in \mathbb{R}^J$ 。在满列秩条件下定义

$$\tilde{\beta} = \arg \min_{Rb=r} (Y - \mathbf{X}b)'(Y - \mathbf{X}b).$$

解及相关矩阵为

$$\tilde{\beta} = \hat{\beta} - QR'(RQR')^{-1}(R\hat{\beta} - r),$$

$$A = QR'(RQR')^{-1}RQ, \quad D = (Q - A)\mathbf{X}'.$$

$RQR' \succ 0$ ；只有真实参数满足 $R\beta = r$ 时，才有 $\tilde{\beta} = \beta + Du$ 。

**定理 3.25 (CLS 的无偏性)**

在线性模型、严格外生性、秩条件及真实限制 $R\beta = r$ 下， R 满行秩，则

$$\mathbb{E}[\tilde{\beta} | \mathbf{X}] = \beta.$$

错误限制通常导致有偏，不能省去真实限制条件。



定理 3.26 (CLS 的条件协方差)

在线性模型、严格外生性、秩条件、球形误差方差及真实限制 $R\beta = r$ 下， R 满行秩，则

$$V_{\tilde{\beta}} := \text{Var}(\tilde{\beta} | \mathbf{X}) = \sigma^2 DD' = \sigma^2(Q - A).$$

**定理 3.27 (真实限制带来的方差改进)**

在线性模型、严格外生性、秩条件、球形误差方差及真实限制 $R\beta = r$ 下， R 满行秩，则

$$V_{\hat{\beta}} - V_{\tilde{\beta}} = \sigma^2 A \succeq 0.$$

限制利用额外的真实信息降低方差，与 Gauss–Markov 在无约束参数空间上的最优性并不冲突。

**定义 3.11 (CLS 残差与方差估计)**

令 $\tilde{u} = Y - \mathbf{X}\tilde{\beta}$ 。在真实限制 $R\beta = r$ 下，

$$\tilde{u} = Cu, \quad C = M + \mathbf{X}A\mathbf{X}'.$$

C 对称幂等， $\text{tr } C = \text{rank } C = n - K + J$ 。定义

$$s_{\text{cls}}^2 = \frac{\tilde{u}'\tilde{u}}{n - K + J}, \quad \hat{V}_{\tilde{\beta}} = s_{\text{cls}}^2(Q - A).$$

**定理 3.28 (CLS 方差估计的无偏性)**

在线性模型、严格外生性、秩条件、球形误差方差及真实限制 $R\beta = r$ 下， R 满行秩，则

$$\mathbb{E}[s_{\text{cls}}^2 | \mathbf{X}] = \sigma^2, \quad \mathbb{E}[\hat{V}_{\tilde{\beta}} | \mathbf{X}] = V_{\tilde{\beta}}.$$

**定理 3.29 (CLS 的条件抽样分布)**

在线性模型、秩条件、条件正态性及真实限制 $R\beta = r$ 下， R 满行秩，则

$$\tilde{\beta} | \mathbf{X} \sim N(\beta, \sigma^2(Q - A)), \quad \frac{(n - K + J)s_{\text{cls}}^2}{\sigma^2} \Big| \mathbf{X} \sim \chi_{n-K+J}^2.$$

参数分布一般退化，反映 J 个确定限制。



第二章作业：条件期望函数

1 第一次作业

阅读至第 2.1.2 节前；整理相关系数、重期望公式与最优预测的证明，完成练习 1-6。相关系数需正方差；最优平方损失预测需 $\mathbb{E}Y^2 < \infty$ 。

课程笔记

命题 2.10 (阅读笔记：协方差与相关系数)

若 X, Y 二阶矩有限，协方差定义为

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \mathbb{E}Y.$$

它刻画两个变量的线性共同变动，具有

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y), \quad |\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}.$$

当 $\text{Var}(X), \text{Var}(Y) > 0$ 时，相关系数为

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \in [-1, 1].$$

$|\rho| = 1$ 当且仅当 $Y - \mathbb{E}Y = c(X - \mathbb{E}X)$ 几乎处处成立。独立必然推出零相关，但零相关通常不能推出独立；若 (X, Y) 联合正态，则零相关与独立等价。

样本相关系数是

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{[\sum_{i=1}^n (X_i - \bar{X})^2] [\sum_{i=1}^n (Y_i - \bar{Y})^2]}},$$

它对平移与正比例缩放不变。相关性只表示线性关系强弱，不自动表示因果关系。

命题 2.11 (阅读笔记：重期望公式及证明)

若 $\mathbb{E}|Y| < \infty$ ，则

$$\mathbb{E}\{\mathbb{E}(Y | X)\} = \mathbb{E}Y.$$

连续情形中，设联合密度为 $f(x, y)$ ，边缘密度为 $f_X(x)$ ，条件密度为 $f(y | x)$ ，则

$$\begin{aligned} \mathbb{E}\{\mathbb{E}(Y | X)\} &= \int \left[\int y f(y | x) dy \right] f_X(x) dx \\ &= \iint y f(x, y) dy dx \\ &= \int y f_Y(y) dy = \mathbb{E}Y. \end{aligned}$$

更一般地，只要 $\mathbb{E}|G(X, Y)| < \infty$ ，

$$\mathbb{E}\{\mathbb{E}[G(X, Y) | X]\} = \mathbb{E}G(X, Y).$$

证明的本质是：先在每个给定 $X = x$ 的子总体内平均，再按 X 的分布加权，恰好恢复总体平均。

命题 2.12 (阅读笔记：最优预测及证明)

用平方损失预测 Y ，对任意可测且平方可积的函数 $g(X)$ ，定义

$$\text{MSE}(g) = \mathbb{E}[(Y - g(X))^2].$$

令 $\mu(X) = \mathbb{E}(Y | X)$ 。把误差分解为

$$Y - g(X) = \{Y - \mu(X)\} + \{\mu(X) - g(X)\}.$$

平方并取期望。交叉项等于

$$\mathbb{E}[\{\mu(X) - g(X)\}\mathbb{E}\{Y - \mu(X) | X\}] = 0.$$

因此

$$\text{MSE}(g) = \mathbb{E}[(Y - \mu(X))^2] + \mathbb{E}[(\mu(X) - g(X))^2].$$

第一项与 g 无关，第二项非负，所以 $g(X) = \mu(X)$ 时均方误差最小。故条件期望是平方损失下的最优预测。



练习 1: 二元正态与独立性

 **作业练习 1** 来源:《回归分析 60 题》已有原题第 2 页文件。

设 (X, Y) 服从二元正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 其中 $\sigma_1, \sigma_2 > 0, |\rho| < 1$. 证明 X, Y 的相关系数为 $\rho_{XY} = \rho$; 在二元正态条件下, $\rho = 0$ 是 X, Y 相互独立的充要条件。

解 二元正态的协方差矩阵为

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}.$$

所以 $\text{Cov}(X, Y) = \rho\sigma_1\sigma_2$, 从而 $\rho_{XY} = \rho$. 独立必然推出协方差为零; 反过来, 在联合正态条件下, $\rho = 0$ 使联合密度分解为两个边缘密度之积, 因此 X, Y 独立。

东邪的 tip 2.1 (二元正态与独立性)

零协方差推出独立必须使用联合正态条件; 一般随机变量只有独立推出零协方差。

练习 2: Cauchy-Schwarz 及等号条件

 **作业练习 2** 来源:《回归分析 60 题》已有原题第 2 页文件。

设 X, Y 二阶矩有限。证明柯西-施瓦茨不等式, 讨论等号成立的条件。需区分 $|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}X^2\mathbb{E}Y^2}$ 和 $\mathbb{E}|XY| \leq \sqrt{\mathbb{E}X^2\mathbb{E}Y^2}$ 两种形式。

解 若 $\mathbb{E}(Y^2) > 0$, 对任意 t ,

$$0 \leq \mathbb{E}(X - tY)^2 = \mathbb{E}X^2 - 2t\mathbb{E}(XY) + t^2\mathbb{E}Y^2.$$

取 $t = \mathbb{E}(XY)/\mathbb{E}(Y^2)$ 即得不等式。当 $\mathbb{E}Y^2 > 0$ 时, 等号成立当且仅当 $X = tY$ 几乎处处。若 $\mathbb{E}Y^2 = 0$, 则 $Y = 0$ 几乎处处, 不等式恒取等号, 无须 $X = 0$ 。统一条件是存在不全为零的常数 a, b 使 $aX + bY = 0$ 几乎处处。对绝对乘积形式, 把同一证明用于 $|X|, |Y|$, 得到 $\mathbb{E}|XY| \leq \sqrt{\mathbb{E}X^2\mathbb{E}Y^2}$; 非退化时其等号条件为 $|X| = c|Y|$ 几乎处处。

东邪的 tip 2.2 (Cauchy-Schwarz 及等号条件)

二阶矩为零的变量几乎处处为零。非退化时对 $\mathbb{E}(X - tY)^2$ 最小化; 绝对乘积形式则把 X, Y 换成 $|X|, |Y|$ 。

练习 3: 期望的绝对值

 **作业练习 3** 来源:《回归分析 60 题》已有原题第 2 页文件。

证明期望不等式: 对可积随机变量 X , 有 $|\mathbb{E}X| \leq \mathbb{E}|X|$ 。原题提示: 利用詹森不等式。

解 $\phi(x) = |x|$ 为凸函数, 由 Jensen 不等式

$$|\mathbb{E}X| = \phi(\mathbb{E}X) \leq \mathbb{E}\phi(X) = \mathbb{E}|X|.$$

东邪的 tip 2.3 (期望的绝对值)

先检查可积性; 绝对值是凸函数, 直接应用 Jensen。

练习 4: 线性条件均值下的混合矩

 **作业练习 4** 来源:《回归分析 60 题》已有原题第 2 页文件。

若 $\mathbb{E}[Y | X] = a + bX$, 请证明 $\mathbb{E}[YX]$ 是 X 的矩的函数。假定相关期望存在, 例如 X, Y 二阶矩有限。

解

$$\mathbb{E}(YX) = \mathbb{E}\{X\mathbb{E}(Y | X)\} = a\mathbb{E}X + b\mathbb{E}(X^2).$$

东邪的 tip 2.4 (线性条件均值下的混合矩)

先对 X 条件化, 再把可测的 X 提出。

练习 5: 条件混合矩与重期望

 **作业练习 5** 来源:《回归分析 60 题》已有原题第 2 页文件。

如果 $\mathbb{E}[Y | X] = a + bX$, 请证明 $\mathbb{E}[YX]$ 是 X 的矩的函数。假定相关期望存在, 例如 X, Y 二阶矩有限。此题与第 4 题重复, 沿用原题编号分别保留。

解 因为 X 对 $\sigma(X)$ 可测,

$$\mathbb{E}(YX | X) = X\mathbb{E}(Y | X) = aX + bX^2.$$

两边取无条件期望即得 $\mathbb{E}(YX) = a\mathbb{E}X + b\mathbb{E}(X^2)$ 。

东邪的 tip 2.5 (条件混合矩与重期望)

原题重复不意味着漏题: 此处从条件混合矩写起, 再用重期望, 保留另一种书写顺序。

练习 6: 广义重期望

 **作业练习 6** 来源:《回归分析 60 题》已有原题第 2 页文件。

对任意可测函数 $G(X, Y)$, 若 $\mathbb{E}|G(X, Y)| < \infty$, 证明

$$\mathbb{E}_X[\mathbb{E}_Y[G(X, Y) | X]] = \mathbb{E}_{X,Y}[G(X, Y)].$$

解 根据条件期望的定义, 对全集 $\Omega \in \sigma(X)$ 有

$$\int_{\Omega} \mathbb{E}(G | X) dP = \int_{\Omega} G dP.$$

左、右两边正是 $\mathbb{E}\{\mathbb{E}(G | X)\}$ 与 $\mathbb{E}G$, 所以结论成立。

东邪的 tip 2.6 (广义重期望)

条件期望的定义直接包含对全集积分的恒等式, 证明不限于存在密度的情形。

知识点定位

题号	核心方法
1	二元正态与独立性
2	Cauchy-Schwarz 及等号条件
3	期望的绝对值
4	线性条件均值下的混合矩
5	条件混合矩与重期望
6	广义重期望

2 第二次作业

阅读至第 2.3 节前；整理条件方差、CEF 误差和最优线性预测，完成练习 8、9、10、11、18。各二阶矩公式按相应平方可积条件使用。

课程笔记

命题 2.13 (阅读笔记：条件方差与全方差公式)

条件方差为

$$\text{Var}(Y | X) = \mathbb{E}(Y^2 | X) - \{\mathbb{E}(Y | X)\}^2.$$

令 $\mu(X) = \mathbb{E}(Y | X)$ ，则

$$Y - \mathbb{E}Y = \{Y - \mu(X)\} + \{\mu(X) - \mathbb{E}Y\}.$$

两部分正交，因为 $\mathbb{E}[Y - \mu(X) | X] = 0$ 。因此

$$\text{Var}(Y) = \mathbb{E}\{\text{Var}(Y | X)\} + \text{Var}\{\mathbb{E}(Y | X)\}.$$

第一项是无法由 X 解释的平均波动，第二项是不同 X 子总体条件均值之间的波动。

命题 2.14 (阅读笔记：CEF 误差与正交性)

把

$$Y = \mu(X) + e, \quad \mu(X) = \mathbb{E}(Y | X)$$

称为条件期望函数分解。由定义

$$\mathbb{E}(e | X) = 0.$$

于是对任意满足 $\mathbb{E}|h(X)e| < \infty$ 的可测函数 $h(X)$ ，

$$\mathbb{E}[h(X)e] = \mathbb{E}\{h(X)\mathbb{E}(e | X)\} = 0.$$

因此 CEF 误差不仅与 X 正交，也与 X 的任意可测变换正交。需要注意： $\mathbb{E}(Xe) = 0$ 只是一个无条件矩条件，通常不能反推出 $\mathbb{E}(e | X) = 0$ 。

命题 2.15 (阅读笔记：线性 CEF 与最优线性预测)

若 $\mathbb{E}(Y | X) = X'\beta$ ，则条件均值被正确设定为线性函数。即使真实 CEF 非线性，也可以在所有线性函数中寻找

$$\beta = \arg \min_b \mathbb{E}[(Y - X'b)^2].$$

一阶条件为

$$\mathbb{E}[X(Y - X'\beta)] = 0,$$

若 $\mathbb{E}(XX')$ 可逆, 则

$$\beta = \{\mathbb{E}(XX')\}^{-1}\mathbb{E}(XY).$$

该 $X'\beta$ 是最优线性预测。线性投影误差只保证 $\mathbb{E}(Xe) = 0$; 只有模型正确设定时, 才进一步有 $\mathbb{E}(e | X) = 0$ 。



练习 8: 回归误差的高阶矩

作业练习 8 来源:《回归分析 60 题》已有原题第 2 页文件。

在线性模型 $Y = X'\beta + e$ 下, 采用有限二阶矩及 $Q_{XX} = \mathbb{E}[XX'] \succ 0$ 的总体假设 (原习题称 “假设 2.1”, 讲义对应假设 2.2.1)。证明若

$$\mathbb{E}|Y|^r < \infty, \quad \mathbb{E}\|X\|^r < \infty, \quad r \geq 2,$$

则 $\mathbb{E}|e|^r < \infty$ 。原题提示: 使用 Minkowski 不等式, 对于 $p \geq 1$,

$$(\mathbb{E}|U + V|^p)^{1/p} \leq (\mathbb{E}|U|^p)^{1/p} + (\mathbb{E}|V|^p)^{1/p}.$$

解 由 $e = Y - X'\beta$ 、Minkowski 不等式和 $|X'\beta| \leq \|X\|\|\beta\|$,

$$(\mathbb{E}|e|^r)^{1/r} \leq (\mathbb{E}|Y|^r)^{1/r} + \|\beta\|(\mathbb{E}\|X\|^r)^{1/r} < \infty.$$

因此 $\mathbb{E}|e|^r < \infty$ 。

东邪的 tip 2.7 (回归误差的高阶矩)

先用向量 Cauchy-Schwarz 把 $|X'\beta|$ 控制为 $\|X\|\|\beta\|$, 再用 Minkowski。该矩界本身不依赖投影最优性。

练习 9: 乘法异方差模型

作业练习 9 来源:《回归分析 60 题》已有原题第 2 页文件。

假设 $Y = \beta_0 + \beta_1 X_1 + |X_1|e$, 其中 $\mathbb{E}X_1 = 0$ 、 $\text{Var}(X_1) = \sigma_{X_1}^2 > 0$, $\mathbb{E}e = 0$ 、 $\text{Var}(e) = \sigma_e^2 > 0$, e 与 X_1 相互独立, β_0, β_1 是未知参数。

1. 求 $\mathbb{E}[Y | X_1]$ 。
2. 求 $\text{Var}(Y | X_1)$ 。
3. 证明 $\beta_1 = 0$ 当且仅当 $\text{Cov}(X_1, Y) = 0$ 。

解

$$\mathbb{E}(Y | X_1) = \beta_0 + \beta_1 X_1, \quad \text{Var}(Y | X_1) = X_1^2 \sigma_e^2.$$

又因为 $\mathbb{E}[X_1 | X_1] e] = \mathbb{E}[X_1 | X_1] \mathbb{E}e = 0$,

$$\text{Cov}(X_1, Y) = \beta_1 \text{Var}(X_1) = \beta_1 \sigma_{X_1}^2.$$

$\sigma_{X_1}^2 > 0$, 所以 $\beta_1 = 0$ 当且仅当 $\text{Cov}(X_1, Y) = 0$ 。

东邪的 tip 2.8 (乘法异方差模型)

条件化后 $|X_1|$ 是常数, 所以方差会带 X_1^2 。斜率与协方差等价的关键是 $\text{Var}(X_1) > 0$ 。

练习 10: 遗漏交互项

 **作业练习 10** 来源:《回归分析 60 题》已有原题第 2 页文件。

总体模型为 $Y = 0.8X_1X_2 + e$, 其中 X_1, X_2, e 相互独立且均服从 $N(0, 1)$ 。令 $X = (1, X_1, X_2)'$ 。假设利用只含截距和两个主效应的线性回归模型 $Y = X'\beta + u$ 刻画 Y 与 X 的相关关系, 有什么问题? 原题沿用 e 表示该拟合误差; 这里改记 u , 以免与真实噪声混淆。

解 真实条件均值为

$$\mathbb{E}(Y | X_1, X_2) = 0.8X_1X_2,$$

它不是 $(1, X_1, X_2)$ 的线性函数。由于各变量独立标准正态,

$$\mathbb{E}Y = \mathbb{E}(X_1Y) = \mathbb{E}(X_2Y) = 0,$$

所以该线性投影的三个系数全为零。模型遗漏了关键交互项 X_1X_2 , 会把真实可预测结构误判为“没有关系”。

又 $\mathbb{E}[XX'] = I_3$, 故 $\beta^* = 0$ 。若加入交互项 X_1X_2 , 最优系数为 $(0, 0, 0, 0.8)'$, 可恢复真实 CEF。

东邪的 tip 2.9 (遗漏交互项)

交互作用可以存在而所有主效应投影系数都为零。加入 X_1X_2 后对参数仍是线性模型。原设定投影 MSE 为 1.64, 真实 CEF 的 MSE 为 1。

练习 11: 离散条件矩

 **作业练习 11** 来源:《回归分析 60 题》已有原题第 3 页文件。

随机变量 X, Y 只能取 0 或 1, 联合分布如下 (行标为 Y , 列标为 X):

	$X = 0$	$X = 1$
$Y = 0$	0.1	0.2
$Y = 1$	0.4	0.3

求 $X = 0$ 或 $X = 1$ 时 $\mathbb{E}[Y | X]$ 、 $\mathbb{E}[Y^2 | X]$ 和 $\text{Var}(Y | X)$ 。

解 $P(X = 0) = P(X = 1) = 0.5$, 且 $Y^2 = Y$ 。因此

	$\mathbb{E}(Y X)$	$\mathbb{E}(Y^2 X)$	$\text{Var}(Y X)$
$X = 0$	0.8	0.8	0.16
$X = 1$	0.6	0.6	0.24

东邪的 tip 2.10 (离散条件矩)

必须先确认表格方向, 再计算每列的边际概率。 Y 为 Bernoulli 型取值, 故 $Y^2 = Y$ 、条件方差为 $p(1-p)$ 。

练习 18: 线性预测与 CEF

 **作业练习 18** 来源:《回归分析 60 题》已有原题第 3 页文件。

设 X, Y 的联合概率密度为 $f(x, y) = \frac{3}{2}(x^2 + y^2)$, 其中 $0 \leq x, y \leq 1$ (其余处为零)。求最优线性预测 $\alpha + \beta X$ 的系数, 算出 $\mu(x) = \mathbb{E}[Y | X = x]$; 最优线性预测与条件期望是否相同?

解 积分得到

$$\mathbb{E}X = \mathbb{E}Y = \frac{5}{8}, \quad \mathbb{E}X^2 = \frac{7}{15}, \quad \mathbb{E}(XY) = \frac{3}{8}.$$

故

$$\begin{aligned} \text{Var}(X) &= \frac{73}{960}, & \text{Cov}(X, Y) &= -\frac{1}{64}, \\ \beta &= \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = -\frac{15}{73}, & \alpha &= \mathbb{E}Y - \beta\mathbb{E}X = \frac{55}{73}. \end{aligned}$$

最优线性预测为

$$\hat{Y}_L = \frac{55}{73} - \frac{15}{73}X.$$

又

$$f_X(x) = \frac{3}{2} \left(x^2 + \frac{1}{3} \right),$$

所以

$$\mu(x) = \mathbb{E}(Y | X = x) = \frac{x^2/2 + 1/4}{x^2 + 1/3} = \frac{3(2x^2 + 1)}{4(3x^2 + 1)}.$$

$\mu(x)$ 非线性，故条件期望与最优线性预测不同。

东邪的 tip 2.11 (线性预测与 CEF)

先用总体矩求仿射预测，再用条件密度求 CEF；两者优化的候选函数类不同。

知识点定位

题号	核心方法
8	回归误差的高阶矩
9	乘法异方差模型
10	遗漏交互项
11	离散条件矩
18	线性预测与 CEF

第三章作业：古典线性回归模型

1 第三次作业

整理第二章剩余内容和第 3.2、3.3 节的全部已有阅读笔记。此次数学作业没有另列习题。总体矩公式要求有限二阶矩；总体 R^2 要求 $\text{Var}(Y) > 0$ ；样本 R^2 要求 TSS 正，OLS 与方差修正要求满列秩及 $n > K$ 。

第二章：条件期望函数的剩余内容

命题 3.16 (阅读笔记：条件方差、CEF 误差与全方差分解)

设 $\mu(X) = \mathbb{E}(Y | X)$ ，定义 CEF 误差

$$e = Y - \mu(X).$$

则

$$\mathbb{E}(e | X) = 0, \quad \mathbb{E}[h(X)e] = 0$$

对任意适当的可测函数 h 都成立。条件方差为

$$\sigma^2(X) = \text{Var}(Y | X) = \mathbb{E}(e^2 | X) = \mathbb{E}(Y^2 | X) - \mu(X)^2.$$

总体波动可分解为

$$\text{Var}(Y) = \mathbb{E}\{\text{Var}(Y | X)\} + \text{Var}\{\mathbb{E}(Y | X)\}.$$

前者是平均条件噪声，后者是由解释变量引起的条件均值变动。

命题 3.17 (阅读笔记：最优线性预测)

当只允许使用线性函数 $X'b$ 预测 Y 时，定义

$$\beta = \arg \min_b \mathbb{E}[(Y - X'b)^2].$$

目标函数对 b 的一阶条件为

$$\mathbb{E}[X(Y - X'\beta)] = 0.$$

若 $Q = \mathbb{E}(XX')$ 正定，则

$$\beta = Q^{-1}\mathbb{E}(XY).$$

记投影误差 $e_L = Y - X'\beta$ ，则

$$\mathbb{E}(Xe_L) = 0.$$

这是一组无条件正交条件。若真实条件均值恰为线性函数，

$$\mathbb{E}(Y | X) = X'\beta,$$

则投影误差还满足更强的 $\mathbb{E}(e_L | X) = 0$ 。

命题 3.18 (阅读笔记：投影误差与拟合优度的总体形式)

若 X 含常数项，线性投影误差均值为零。由正交性，

$$\mathbb{E}(Y^2) = \mathbb{E}[(X'\beta)^2] + \mathbb{E}(e_L^2).$$

中心化后可写为

$$\text{Var}(Y) = \text{Var}(X'\beta) + \text{Var}(e_L).$$

总体线性拟合优度可定义为

$$R^2 = \frac{\text{Var}(X'\beta)}{\text{Var}(Y)} = 1 - \frac{\text{Var}(e_L)}{\text{Var}(Y)}.$$

R^2 描述线性投影解释的方差比例，但不能单独证明因果关系，也不能保证模型设定正确。

命题 3.19 (阅读笔记：条件均值模型的正确设定)

模型 $m(X, \theta)$ 正确设定，表示存在真值 θ_0 使

$$\mathbb{E}(Y | X) = m(X, \theta_0).$$

若错误地把非线性 CEF 设为线性函数，OLS 仍可估计最优线性近似，但系数只解释线性投影，不再等同于真实 CEF 的结构参数。判断模型设定时应：

1. 根据理论选择解释变量和函数形式；
2. 检查残差是否仍与 X 的非线性变换相关；
3. 比较不同设定的样本外预测与稳健性；
4. 区分预测关系、相关关系和因果关系。

第 3.2 节：普通最小二乘估计

命题 3.20 (阅读笔记：OLS 的矩阵推导)

样本模型为

$$Y = X\beta + u,$$

其中 Y 是 $n \times 1$ 向量， X 是满列秩的 $n \times K$ 矩阵。OLS 最小化残差平方和

$$S(b) = (Y - Xb)'(Y - Xb).$$

展开并求导：

$$\frac{\partial S(b)}{\partial b} = -2X'Y + 2X'Xb.$$

一阶条件给出正规方程

$$X'X\hat{\beta} = X'Y,$$

因此

$$\hat{\beta} = (X'X)^{-1}X'Y.$$

残差满足

$$\hat{u} = Y - X\hat{\beta}, \quad X'\hat{u} = 0.$$

最后一个等式说明残差与每一列解释变量样本正交。

命题 3.21 (阅读笔记：拟合值、残差和误差方差估计)

定义

$$P = X(X'X)^{-1}X', \quad M = I - P.$$

则

$$\hat{Y} = PY, \quad \hat{u} = MY.$$

若经典同方差假设

$$\mathbb{E}(u | X) = 0, \quad \text{Var}(u | X) = \sigma^2 I_n$$

成立，则

$$\hat{\sigma}^2 = \frac{\hat{u}'\hat{u}}{n-K}$$

是 σ^2 的无偏估计，因为

$$\mathbb{E}(\hat{u}'\hat{u} | X) = \mathbb{E}(u'Mu | X) = \sigma^2 \text{tr}(M) = \sigma^2(n-K).$$



第 3.3 节：几何解释与拟合优度

命题 3.22 (阅读笔记：投影矩阵 P)

P 把任意 $Y \in \mathbb{R}^n$ 正交投影到 X 的列空间：

$$\hat{Y} = PY \in \mathcal{C}(X).$$

它具有

$$P' = P, \quad P^2 = P, \quad PX = X,$$

且

$$\text{rank}(P) = \text{tr}(P) = K.$$

对称性表示正交投影，幂等性表示投影一次后再次投影不会改变结果。



命题 3.23 (阅读笔记：消灭矩阵 M)

$M = I - P$ 把 Y 投影到 $\mathcal{C}(X)$ 的正交补：

$$\hat{u} = MY.$$

它具有

$$M' = M, \quad M^2 = M, \quad MX = 0,$$

以及

$$\text{rank}(M) = \text{tr}(M) = n - K.$$

名称“消灭矩阵”来自 $MX = 0$ ：它消去所有位于解释变量列空间中的分量。



命题 3.24 (阅读笔记：几何分解与样本 R^2)

OLS 给出正交分解

$$Y = \hat{Y} + \hat{u}, \quad \hat{Y}'\hat{u} = 0.$$

若模型含截距，则 $\bar{\hat{Y}} = \bar{Y}$ 、 $\sum_i \hat{u}_i = 0$ ，并有

$$\underbrace{\sum_i (Y_i - \bar{Y})^2}_{TSS} = \underbrace{\sum_i (\hat{Y}_i - \bar{Y})^2}_{ESS} + \underbrace{\sum_i \hat{u}_i^2}_{RSS}.$$

因此

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}.$$

加入解释变量不会增加 RSS，所以普通 R^2 不会下降；比较不同维度模型时还应结合调整 R^2 、理论合理性和样本外表现。

命题 3.25 (阅读笔记：本次笔记的结构)

条件期望 $\rightarrow$ 最优线性投影 $\rightarrow$ 样本 OLS $\rightarrow$ 投影矩阵与 R^2 .

第二章给出总体层面的最优预测与正交条件；第 3.2 节把总体问题变成样本最小二乘；第 3.3 节用投影几何解释拟合值、残差和拟合优度。